

KSTAR 희소 전하교환분광(CES) 신호의

멀티모달 나우캐스팅

고속 진단은 미래를 보는 보간을 넘어 이온온도를 복원하지만
토로이달 회전은 복원하지 못한다

이승상 (Seungsang Lee)

서울대학교 원자핵공학과

lss010330@snu.ac.kr

국문 원고 — 2026년 9월 6일

초록

배경 전하교환분광(CES)은 토카막에서 이온온도(T_i)와 토로이달 회전(V_{rot})을 측정하는 핵심 진단이지만, 광자 수집 제약 때문에 느리고 간헐적으로 결측된다. 본 연구의 KSTAR 10 ms 격자에서 T_i 의 8.2%, V_{rot} 의 23.9%가 서로 독립적으로 결측되고, V_{rot} 은 여기에 더해 41.1%가 계측기 유지값(held)이어서 격자의 65.0%가 독립적인 V_{rot} 정보를 갖지 않는다 (§3, §3.4).

질문 CES가 결측된 시점에서, 항상 측정되는 고속 진단—빔방출분광(BES), 전자사이클로트론방출 영상(ECEI), Mirnov 코일—과 불규칙한 과거 CES 이력만으로, CES 자체의 시간 보간으로는 복원할 수 없는 $T_i \cdot V_{\text{rot}}$ 정보를 회복할 수 있는가 (§1).

설계 고속 진단은 10 ms 격자 위에서 조밀하므로 문제를 인과적 전체격자 시퀀스 추정으로 프레임팅한다. 소형(0.36M 파라미터) 2분기 순환 나우캐스터가 격자의 모든 행을 맥락으로 소비하고, 희소한 타겟은 행을 버리는 대신 타겟별 마스킹 손실로 처리하며, V_{rot} 분기는 구조적으로 고속 진단에서 차단된다—이 라우팅은 두 보존식에서 나온 것이지 튜닝의 산물이 아니다. 관측 마스킹 풀링을 갖춘 원도 기반 GRU-어텐션 모델이 짝지은 대조군이다 (§4).

기준선 평가는 의도적으로 불리하게 설계했다. 오프라인 보간(선형, 단조 3차 PCHIP, 국소 AR, 가우시안 과정)은 타겟 시점 양쪽의 과거와 미래 CES 이웃을 볼 수 있는 반면 모델은 엄격히 인과적이며, 배치 가능한 가장 강한 기준선은 인과 GP가 대표한다 (§5).

프로토콜 사전등록: plateau 최소 이력($W=2$), 유지값 제거 학습·채점, 파일 단위 분할, 모델 선택이 전혀 건드리지 않는 test 셋, shot 군집 paired bootstrap(10,000회 재표본), 그리고 T_i 스펙트럼 피팅 실패(>3 keV, 0.53%)를 결측으로 처리하거나 그대로 두는 두 개의 공동 1차 모집단—무조건적 주장은 둘 다에서 성립해야 한다 (§5, §7).

주 결과 나우캐스터는 T_i 에 대해 미래를 쓰는 PCHIP을 $\text{skill}_{\text{PCHIP}} = +0.17 \sim +0.26$ (스파이크 컷)과 $+0.23 \sim +0.32$ (스파이크 포함)로 이기며, 두 모집단 각각의 독립적인 4개 held-out 분할 모두에서 95% 신뢰구간이 0을 제외하고, 8개 셀 전부에서 인과 GP도 이긴다. 가장 강한 미래 사용 평활기인 오프라인 GP와는 동률이다 (§6).

부정 결과 V_{rot} 은 같은 관문을 4개 중 1개와 2개 분할에서만 통과하므로 동률로 보고한다. 고속 진단을 0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하고 이력을 0으로 만들면 붕괴하므로, 회전은 10 ms에서 이력 자기상관의 한계에 머문다(미관측 NBI 토크, 100 Hz로 샘플된 Mirnov 신호의 kHz 모드 회전 앨리어싱). 이를 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭이라 부른다 (§6.7).

스트레스 두 개의 테스트가 오프라인 주장과 배치 주장을 분리한다. 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중해도 모든 인과 방법 대비 우위는 전 분할에서 유지되고 PCHIP 대비 우위는 2/4(컷)와 4/4(포함)에서 유지된다. 캠페인을 가로질러 시간으로 엄격히 재분할하면—이는 원도 대조군의 보간 대비 우위를 제거한다—시퀀스 나우캐스터는 두 모집단 모두에서 4/4 초기화에 대해 PCHIP과 인과 GP를 앞선다 (§6.5, §6.6).

우위의 소재 우위는 고변동 국소 구간에 집중되며(peak 계층 T_i skill $+0.45 \sim +0.72$, 8/8 PASS), 보정된 conformal 구간은 32개 모집단-타겟-변형-분할 셀 전부에서 두 기준선의 구간을 이긴다(§6.10, §8).

한계의 축 persistence+보정의 정확한 분해를 갖는 21k 파라미터 잠재 병목 모델은 스파이크 컷에서 백본의 T_i skill과 대등하고, 백본을 34k에서 879k 파라미터로 넓혀도 그 값은 ± 0.01 미만으로 변한다—총합 손실의 한계는 추정기가 아니라 정보다(제공오차의 46.6%가 상위 1%의 한 스텝 변화에 몰려 있어 이 진술은 꼬리 통계에 관한 것이다, §6.9).

문맥과 구조 둘을 따로 움직이면 역할이 갈린다. 연속 인과 문맥을 20에서 630 ms로 늘리면 skill이 $+0.055$ 에서 $+0.138$ 로 오르고 인과 GP를 이기는 방전의 비율이 0.52에서 0.66으로 오르는 반면, 같은 도달 범위에서 순환·확장 합성곱·attention은 0.023 이내로 동물이다—아키텍처는 skill이 아니라 비용을 정한다(§6.12).

공개 전체 파이프라인, 사전등록 문서, 평가 산출물을 공개한다.

한 값은 한 자리에서만 정의된다. 같은 수치를 여러 절에서 되풀이하면 그 자체가 절 불일치의 자리가 되므로, 이 원고는 값마다 정의 절을 하나만 두고 다른 절에서는 그 절을 가리킨다. 위 초록의 괄호가 그 자리다. 값이 어긋나 보이면 정의 절이 옳다. 인용된 모든 수치는 동결된 평가 산출물에서 단일 수집 스크립트 (collect_paper_numbers.py)가 읽어 온다.

목차

심사자용 한 쪽 요약 — 이 논문이 답하는 것 전부	4
1 서론	6
2 관련 연구	7
3 데이터와 문제 설정	8
3.1 데이터셋	8
3.2 학습 예제의 두 가지 프레이밍	10
3.3 설계 원칙	10
3.4 데이터 품질 감사 1: 유지(forward-fill)된 V_{rot} 값	10
3.5 데이터 품질 감사 2: T_i 스펙트럼 피팅 실패와 두 모집단	10
4 모델	11
4.1 추정 대상, 손실, 그리고 환원 불가능한 하한	11
4.2 두 보존식이 입력 라우팅을 정한다	11
4.3 모델이 놓인 시간 척도	12
4.4 전체격자 인과 시퀀스 백본	13
4.5 원도 대조군: 관측 마스킹 어텐션 풀링	13
4.6 해석 가능한 사다리 칸	13
4.7 최적화 설정, 그리고 그 근거의 현황	13
5 평가 방법론	14
6 결과	15
6.1 나우캐스터는 모든 인과 기준선을 압도한다	15
6.2 헤드라인: T_i 는 두 모집단 모두에서 4개 독립 분할에 걸쳐 미래를 쓰는 보간을 이긴다	16
6.3 전체격자 프레이밍 대 원도 대조군: 백본 관문	17
6.4 skill이 사는 곳: 간극 영역	17
6.5 실제로 결측인 지점에서는 이 중 얼마가 살아남는가?	18
6.6 캠페인 이동을 견디는가?	18
6.7 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭	20
6.8 이력은 얼마나 필요한가? 관측 하나	20
6.9 복잡도는 무엇을 사고, 크기는 도움이 되는가? 사다리와 폭 스윙	21
6.10 우위는 고변동 국소 구간에 집중된다	22
6.11 컷 임계값 민감도	23
6.12 문맥·구조·비용: 무엇이 skill을 정하고 무엇이 값을 정하는가	23
7 모델 선택 프로토콜	25
8 배치 가능한가?	26
9 남은 개선 여지는 어디인가	27
10 한계	27
11 결론	29

심사자용 한 쪽 요약 — 이 논문이 답하는 것 전부

이 쪽에만 있는 값은 없다. 아래 모든 수치는 본문의 정의 절에서 왔고, 괄호 안이 그 자리다.

문제. KSTAR의 10 ms 격자에서 CES는 T_i 의 8.2%, V_{rot} 의 23.9%를 비운다. 두 타겟은 서로 독립적으로 빠지고(§3), V_{rot} 은 41.1%가 계측기 유지값이어서 실제로 독립적인 회전 측정을 담은 행은 35.0%뿐이다 (§3.4). 그리고 결측은 아무 데나 있지 않다—저신호 구간, ELM, 천이 같은 물리적으로 흥미로운 순간에 몰린다. 즉 무작위적이지 않은 결측(MNAR)이다. 같은 플라즈마를 BES·ECEI·Mirnov는 결측 없이 본다. 셋 중 어느 것도 T_i 나 V_{rot} 을 직접 측정하지는 않는다.

지금 하는 일과 이 논문이 하는 일. 결측 채움의 현직 방법은 CES 채널 자체의 시간 보간이고, 그것은 타겟 시점 양쪽의 이웃을 쓴다—즉 미래를 읽으므로 온라인에서는 쓸 수 없다. 이 논문은 미래를 읽지 않는 모델이 미래를 읽는 그 방법을 이기는지를 묻는다. 이겼다면 고속 진단이 CES의 시간 구조에 없는 CES 정보를 운반한다는 뜻이고, 그 뜻은 CES 단독으로는 도달할 수 없다.

판정은 착수 전에 고정되었다. 이력 길이 $W=2$ 는 24-run 스윙의 plateau 최소 규칙으로, 계측기 유지값 제거는 학습과 채점 양쪽에, 분할은 파일 단위로, 유의성은 shot 군집 paired bootstrap 10,000회로, 그리고 T_i 스펙트럼 피팅 실패 0.53%는 두 개의 공동 1차 모집단으로—모든 팔에서 결측 처리하거나, 모든 곳에서 유지하거나—정해졌다. 무조건적 주장은 두 모집단 모두에서 성립해야 한다. test 셋은 모델 선택이 한 번도 읽지 않았다 (§5, §7).

답 셋. *하나*, T_i 는 이긴다—미래를 쓰는 PCHIP 대비 skill $+0.17 \sim +0.32$, 두 모집단의 4개 분할 여덟 셀 전부에서 신뢰구간이 0을 제외하고, 배치 가능한 가장 강한 기준선인 인과 GP도 8/8로 이긴다 (§6). *둘*, V_{rot} 은 이기지 못한다—같은 관문을 1/4·2/4만 통과하므로 동물로 적는다. 이것은 튜닝 부족이 아니다. 고속 진단 입력을 전부 0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하다 (§6.7). *셋*, 남은 손실은 추정기 문제가 아니다—21k 파라미터 모델이 백본과 대등하고 폭을 $26\times$ 넓혀도 skill은 ± 0.01 안에서 움직인다 (§6.9).

그리고 이 논문은 스스로 멈춘다. 반증 지점 여섯을 착수 전에 적어 두었고 (표 1), 그중 둘은 실제로 걸렸다—회전은 관문을 통과하지 못해 동물로 강등되었고, 오프라인 GP와의 동물 때문에 “미래를 쓰는 보간을 이긴다”는 “모든 오프라인 방법을 이긴다”로 넓혀 적지 않는다. 걸린 것을 걸렸다고 적은 자리가 이 원고에서 가장 정보가 많은 자리다.




그림 1. 논증 사슬 — 어느 마디가 무엇으로 지탱되는가. 굵은 테두리는 이 논문이 직접 판정하는 두 마디다.

표 1. 사전등록된 반증 지점 여섯. 각 행은 착수 전에 문서로 고정되었고, 마지막 열이 실제로 관측된 것이다. 둘은 걸렸다.

주장	틀렸다면 관측되는 것	그때 하는 일	미리 적힌 곳	실제로 관측된 것
T_i 나우캐스팅이 미래를 쓰는 보간을 이긴다	8개 모집단-분할 셀 중 하나라도 95% CI가 0을 포함	무조건적 주장을 철회하고 모집단 조건부로 강등한다	§5	8/8 통과. skill _{PCHIP} = +0.17 ~ +0.32
V_{rot} 도 같은 관문을 통과한다	4개 분할 중 통과가 3개 미만	동물로 보고하고 원인을 절제 실험으로 지목한다	§5	걸렸다. 1/4·2/4 → 동물. 고속 진단 0에도 출력 비트 동일
우위가 진짜 결측 지점에서도 남는다	결측 공변량으로 재가중하면 CI가 0을 포함	우위를 관측 지점 조건부로 한정한다	§6.5	인과 대비 8/8 유지, PCHIP 대비 2/4(컷)·4/4(포함)
캠페인 경계를 넘어도 남는다	시간 분할에서 보간 대비 우위 소멸	우위를 캠페인 내부로 한정한다	§6.6	원도 대조군은 실제로 소멸 (2/4·0/4), 시퀀스 백본은 4/4 유지
모든 오프라인 방법을 이긴다	어떤 오프라인 평활기와 동물이거나 진다	주장을 “사전등록된 보간들”로 좁힌다	§10	걸렸다. 오프라인 GP와 동물(8셀 중 1개 유의) → 주장 축소
남은 손실이 추정기 용량 때문이다	폭을 넓히면 skill이 오른다	크기 축을 열린 레버로 남긴다	§6.9	34k→879k 에서 ±0.01 미만 → 크기 축은 닫혔다

1 서론

플라즈마 경계부의 이온온도 T_i 와 토로이달 회전 V_{rot} 은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근 등 토카막 성능과 안정성의 핵심 요소를 지배한다. 두 물리량의 표준 측정법은 전하교환분광(CES) [1]으로, 전하교환 선방출의 도플러 확장에서 T_i 를, 도플러 이동에서 V_{rot} 을 추정한다. CES는 충분한 신호대잡음비를 위해 광자를 적분해야 하므로 본질적으로 느리고, 개별 시점 측정은 노출·신호품질 문제로 자주 소실된다. 본 연구의 KSTAR 데이터에서는 균일한 10 ms 격자 위에서도 T_i 의 8.2%, V_{rot} 의 23.9%가 —서로 독립적으로— 결측된다. 나아가 V_{rot} 은 41.1%가 직전 관측값을 그대로 반복하는 유지값이어서 (§3.4), 격자의 35.0%만이 독립적인 V_{rot} 측정값을 담고 있다. 우리 데이터셋에서 경험적으로 결측은 물리적으로 흥미로운 순간(저신호 구간, ELM, 천이)에 집중된다. 즉 Little and Rubin [2]의 의미에서 무작위적이지 않은 결측(MNAR)이다.

한편 여러 고속 진단은 같은 플라즈마를 결측 없이 관측한다: BES는 밀도요동 구조를, ECEI는 전자온도를, Mirnov 코일은 자기요동을 측정한다. 이들 중 어느 것도 T_i 나 V_{rot} 을 직접 측정하지 않는다. 본 논문의 질문은 다음과 같다.

CES가 결측된 10 ms 시점에서, 동시각 고속 진단과 불규칙한 과거 CES 이력만으로, CES 단독의 시간 보간이 복원할 수 없는 T_i , V_{rot} 정보를 회복할 수 있는가?

긍정적 답은 데이터 기반 가상 센서(virtual sensor)를 정당화한다: 강한 역산 가정 없이 CES 결측을 온라인으로 채워, 끊임 없는 페데스탈 분석과 궁극적으로 실시간 활용을 가능하게 하는 모델이다.

의도적으로 어려운 기준선. 결측 채움의 자명한 기준선은 CES 채널 자체의 보간이다. 우리는 비교를 모델에 의도적으로 불리하게 설계했다: 보간 기준선(선형, 단조 3차 PCHIP [3], 국소 AR 참조, 그리고 가우시안 과정)은 오프라인으로, 타겟 시점 양쪽의—미래를 포함한—CES 이웃을 사용할 수 있다. 반면 모델은 엄격히 인과적이며, 타겟 시점까지의 고속 진단과 과거 CES 이력만 본다. 인과 모델이 미래를 쓰는 보간을 이긴다면, 고속 진단이 CES의 시간 구조만으로는 답을 수 없는 CES 관련 정보를 운반한다는 뜻이다. 그리고 미래를 쓰는 보간을 이기는 모델은 당연히 모든 인과 기준선을 이긴다. 배치 가능한 가장 강한 경쟁자는 persistence가 아니라 과거만 쓰는 평활기이므로, 인과 GP 팔을 추가하고 그에 대한 모델의 성능을 따로 보고한다.

기여.

1. **희소 타겟 나우캐스팅을 위한 인과적 전체적자 프레이밍 (§4).** 고속 진단은 격자 위에서 조밀하므로, 샘플별 원도를 조립하고 라벨 없는 행을 버리는 대신 입력이 완전한 모든 행을 시퀀스 맥락으로 유지하고 희소성을 손실로 옮긴다: 2분기 인과 LSTM이 타겟별 이월값·경과시간(staleness)·관측 플래그 채널과 함께 한 방전 세그먼트의 과거 전체를 읽으며, V_{rot} 분기는 구조적으로 고속 진단에서 차단된다. 관측 마스킹 풀링을 갖춘 짝지은 원도 GRU-어텐션 대조군을 상대로 이 재프레이밍은 통합 T_i skill +0.081의 가치를 지니며 (16회 실행, 실행 군집 CI [+0.067, +0.096], 16/16 양수) 학습 비용은 오히려 일부에 불과하다. 그리고 이것이 사들이는 도달 범위가 인과 GP를 넘어서게 만든다.
2. **사전등록된 두-모집단 shot 군집 평가 프로토콜 (§5).** 이력 길이는 24-run 스윙에서 plateau 최소 규칙으로 정한다($W=2$). 계측기 유지값은 학습과 채점에서 제거한다. T_i 스펙트럼 피팅 실패 0.53%(>3 keV)가 두 개의 공동 1차 모집단—모든 팔에서 결측 처리하거나, 모든 곳에서 유지하거나—을 정의하며 무조건적 주장은 두 모집단 모두에서 성립해야 한다. test 셋은 모델 선택이 결코 읽지 않고, 유의성은 shot 군집 paired bootstrap이며, 모든 모델 결정은 해당 TEST 채점 이전에 문서로 고정되었다.
3. **T_i 에 대한 강건한 긍정 결과 (§6):** 인과 나우캐스터가 미래를 쓰는 PCHIP을 $\text{skill}_{\text{PCHIP}} = +0.17 \sim +0.26$ (컷)과 $+0.23 \sim +0.32$ (포함)로 이기며, 두 모집단의 4개 held-out 분할 전부에서 CI가 0을 제외하고, 8개 분할-모집단 셀 전부에서 인과 GP도 이긴다. 가장 강한 미래 사용 평활기인 오프라인 GP와는 동물이다.
4. **V_{rot} 에 대한 물리 기반 부정 결과:** 실패가 아니라 발견으로 보고한다. V_{rot} 은 미래를 쓰는 보간과 동물이고 (1/4, 2/4 유의 — 잡음 만으로도 나올 수준) 대부분의 분할에서 persistence는 이긴다. 고속 진단을 0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하고 이력을 0으로 만들면 붕괴하므로, 회전은 10 ms에서 여전히 이력 자기상관의 한계에 머문다(미관측 NBI 토크, Mirnov 앨리어싱). 이를 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭이라 부른다.

5. 보통 뭉개지는 두 주장을 분리하는 두 개의 스트레스 테스트 (§6.5, §6.6). 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중해도 T_i 우위는 두 모집단 모두에서 모든 인과 방법 대비 4/4 분할, PCHIP 대비 2/4(컷)와 4/4(포함)로 유지된다. 캠페인을 가로질러 시간으로 엄격히 재분할하면 원도 대조군의 보간 대비 우위는 사라지지만(2/4, 0/4)—고속 진단은 기간 사이에 1.22σ (BES) 이동하는 반면 타겟은 0.115σ 다—각 방전의 입력을 그 방전 자신의 통계로 표준화하는 시퀀스 나우캐스터는 두 모집단 모두에서 4/4 초기화에 대해 PCHIP과 인과 GP를 앞선다.
6. **우위가 사는 곳**: 고변동 국소 구간(peak 계층 T_i skill $+0.45 \sim +0.72$, 8/8 모집단-분할 셀 PASS; V_{rot} 은 점추정 $+0.54 \sim +0.79$ 이고 bulk에서는 0)과 비인접 영역($\Delta t > 15$ ms 통합, 두 모집단 모두 PASS)이다.
7. **복잡도 사다리**와 크기 축, 둘 다 측정 (§6.9): 탐침 가능한 잠재 8개에서 선형으로 읽어낸 유계 보정을 *persistence*에 더해 예측하는 21,498 파라미터 모델이 스파이크 컷에서 백본의 T_i skill과 대등하고(찍지는 평균 $+0.002$)—컷이 없으면 -0.19 를 잃는데, 유계 보정으로는 스파이크가 낀 앵커를 복구할 수 없기 때문이다—백본을 34k에서 879k 파라미터로 넓혀도 T_i skill은 ± 0.01 미만으로 움직인다. 총합 손실의 한계는 추정기가 아니라 입력 집합이며, 남은 레버는 이름이 지목되어 있다 (§9).
8. **문맥과 구조의 분리** (§6.12): 연속 인과 문맥을 20에서 630 ms로 늘리면 T_i skill이 $+0.055$ 에서 $+0.138$ 로 오르고 인과 GP를 이기는 방전의 비율이 0.52에서 0.66으로 오르는 반면, 도달 범위를 맞추면 순환·확장 합성곱·attention의 $110\times$ 파라미터 범위가 0.023 이내로 동물이다. 문맥은 승리를 전형적으로 만들고, 계열은 값을 정하며, 그 값은 디스패치되는 연산자 수이다.
9. **측정된 배치 가능성** (§8): 예측기를 전혀 건드리지 않고 32개 모집단-타겟-변형-분할 셀 전부에서 두 기준선의 구간을 이기는 분포 무가정 conformal 구간, 그리고 CPU에서 10 ms 주기 안에 들어가는 순환 나우캐스터의 상태 유지형 1-스텝 추론.

2 관련 연구

핵융합 진단의 프로파일 피팅과 결측 보간. 가우시안 과정 회귀 [4]는 핵융합 프로파일 데이터의 피팅과 불확실성 정량화의 커뮤니티 표준 도구로서 KSTAR CES T_i 프로파일에도 SVM 기반 이상치 제거와 결합되어 적용돼 있으며 [5–7], PCHIP 같은 단조 보간 [3, 8]은 자연 3차 스플라인 [9]이 ELM·툽니파형 계단에서 Gibbs형 진동을 보이기 때문에 [10] 과도 현상 근방에서 선호된다. 불규칙 표본 시계열에는 정확한 AR형 영모형(IAR/CIAR)이 존재한다 [11, 12]. 우리는 이 사다리—*persistence*, 선형 보간 [13], PCHIP, 국소 AR—를 사전등록된 기준선으로 사용하며, PCHIP을 헤드라인 비교 대상으로, Murphy의 MSE skill 점수 [14]를 지표로 삼는다. 본 연구의 기여는 이 문헌과 직교한다: 더 나은 CES 단독 보간이 아니라, 다른 진단들이 어떤 CES 단독 방법도 넘어서는 정보를 더하는지를, 인과 멀티모달 모델을 미래를 쓰는 보간과 맞세워 검정한다.

핵융합에서의 신경망 진단 추론. 신경망 진단 추론에는 세 갈래가 있으며, 각각에 대해 *타겟 측정이 없을 때 어떻게 되는가?*를 묻는 것이 유익하다. 가장 오래된 갈래는 스펙트럼 피팅 가속이다—JET 전하교환 스펙트럼의 신경망 분석 [15, 16]과 EAST CXRS 스펙트럼의 고속 T_i 추정 [17], 그리고 *우리와* 같은 진단에서 나온 가장 최근 구성원인 NN-CES—물리 제약 신경망이 KSTAR CES 스펙트럼에서 T_i 와 회전을 빔 변조 없이 직접 추출한다 [18]. 이들은 최소자승 피팅 대비 수십 배의 속도를 얻지만, 구조상 해당 시점에 측정된 스펙트럼을 요구한다: CES 노출이 결측되면 입력 자체가 없다. NN-CES는 본 연구에 가장 가까운 선행 연구이므로 구분을 한 문장으로 적는다—*NN-CES는 측정이 있는 시각을 더 잘 읽고, 본 연구는 측정이 없는 시각을 채운다*. 입력이 CES 자신의 스펙트럼인 이상 노출이 결측된 시각에는 정의되지 않으며, 그 시각이 우리 문제의 전부다. 그리고 둘의 관계는 경쟁이 아니라 보완이다: 빔 변조를 요구하지 않는 분석은 결측 자체를 줄이고, 그것이 산출하는 적합 품질 메타데이터는 §9의 첫 번째 레버가 요구하는 바로 그 값이다. 두 번째 갈래는 한 진단의 추론 파이프라인을 다른 진단으로 대체한다: W7-X의 베이지안 모형 에뮬레이션 [19], NSTX-U의 스칼라 파라미터 기반 프로파일 형상 예측 [20], 그리고—우리 타겟에 가장 가까운—EAST의 X선 결정 분광기로부터의 T_i ·회전 프로파일 추론 [21]. Lin 등은 정확히 우리의 두 물리량을 예측하지만 입력이 또 다른 도플러 분광기, 즉 동일한 물리 정보 채널이고 같은 광자 통계 한계를 가지며, 매핑은 순간적이고 소스 진단의 가용성을 그대로 상속한다. 세 번째 갈래는 느린 재구성 코드의 종단간 대리모형이다: 볼로미터 단층촬영 [22], 선적분 진단 [23], 안전인자 프로파일 [24], 실시간 평형 [25], 그리고 KSTAR 자체의 신경망

Grad-Shafranov 솔버 [26, 27]와 고속 EPED 파라미터화 프로파일 재구성 [28] — 후자는 CES를 입력으로 쓰며 회전 확장을 명시된 향후 과제로 남긴다. 이들은 분석 *지연시간*을 다루지, 측정 *가용성*을 다루지 않는다: 존재하는 데이터의 역산을 가속할 뿐이다. 가용성 문제에 더 가까운 두 연구가 있다. DIII-D의 액추에이터 조건부 프로파일 예보 [29]는 우리 모델처럼 인과적이고 이력 기반이지만, 제어를 위해 *조밀하게* 측정된 프로파일로부터 미래를 예보하며, 희소 채널의 복원이 아니다. RTCAKINN [30]은 실시간으로 운동학 프로파일(불순물 온도·회전 포함)을 재구성하고 dropout 학습으로 Thomson/CER 입력 소실을 견디지만, 거기서 결측은 입력을 0으로 만드는 강건성 조건인 반면, 우리 설정에서는 타겟 자신의 희소성이 문제 그 자체이며 타겟별 관측 플래그와 불규칙 시간 특징으로 명시적으로 추적된다. 세 갈래 모두의 공통 가정은 모델이 실행될 때 정보 소스가 존재한다는 것이다. *자기 자신의* 측정이 없는 시점에서, 다른 채널들과 자신의 과거로부터 진단값을 복원하는 일은 이들의 범위 밖이다.

교차 진단 재구성과 시간 조밀화 (가장 가까운 선행 연구). 최근 한 계열은 다른 진단들로부터 특정 진단을 재구성한다. GP 기반 대체는 KSTAR에서 고장난 자기 센서를 밀리초 이하로 복원하고 [31], ML은 손상 센서를 탐지·보상하며 [32], 오토인코더는 중복 밀도 진단을 융합해 복원력을 얻고 [33], 시계열 외생 회귀는 EAST의 결측 전자온도를 채우며 [34], FusionMAE는 HL-3의 88개 채널에서 마스킹 채널 “가상 백업 진단”을 수행한다 [35]. 우리 프레이밍에 가장 가까운 것으로, Diag2Diag는 DIII-D에서 다른 동시각 진단들로부터 Thomson 산란 T_e/n_e 를 요동 진단 속도로 합성하고 [36], COMPASS에서는 고속 복사 진단으로부터 Thomson 프로파일의 시간 초해상이 시연되었으며 [37], PanoMHD는 제어를 위해 인과 트랜스포머로 멀티모달 신호 동역학을 모델링한다 [38]. 본 연구는 이 계열과 네 가지 축에서 다르며, 각 축은 인용 논문들의 명시된 범위에서 확인 가능하다: (i) *타겟 채널*—이 계열의 모든 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성하고(36과 37의 Thomson T_e/n_e , 34의 ECE형 T_e , 35의 임의의 마스킹 채널), CER/CES가 등장하는 경우에도 어디까지나 입력이며 [36] 희소 타겟이 아니다; (ii) *인과성*—Diag2Diag와 COMPASS 연구는 기억 없는 동시각 매핑이고 FusionMAE는 원도 내 재구성인 반면, 우리 모델은 타겟 자신의 불규칙한 과거에 조건화되며 미래를 절대 읽지 않는다; (iii) *평가 기준*—어느 것도, 결측 채움에서 현직 방법인 타겟 채널의 *미래* 사용 보간을, 사전등록된 shot 군집 프로토콜로 이어야 할 기준선으로 세우지 않는다; (iv) *정보 분석*—재구성 가능성이 타겟별로 검정되지 않고 가정되는 반면, $T_i \leftrightarrow V_{\text{rot}}$ 비대칭은 우리의 중심 발견이다. 요컨대 본 연구는 이 활발한 계열이 확립한 프로그램—항상 있는 진단으로 없는 측정을 재구성한다—을 이어받아 세 방향으로 확장한다: 전자 채널에서 *희소 이온 채널*로, 동시각의 기억 없는 매핑에서 *타겟 자신의 불규칙 과거에 조건화된 인과 추정*으로, 그리고 가정된 재구성 가능성에서 *사전등록 기준선에 대한 타겟별 검정*으로. 우리가 아는 한 이 세 확장의 결합—희소 CXRS 이온 측정의 인과적 시간 결측 채움—은 아직 다뤄지지 않았으며, 우리는 이를 계열로부터의 이탈이 아니라 그 자연스러운 다음 단계로 제시한다.

차별점을 실명으로 대조한다. 위 세 단락의 대비를 표 2에 한자리로 모은다. 각 행은 인접 연구를 실명으로 적고, 그 차이가 구조(설계가 다른 것을 한다)인지 *배치*(같은 재료를 다르게 놓은 것)인지를 구분하며, 마지막 열에 그 판단을 확정하는 근거—해당 논문이 명시한 범위—를 적는다. “최초”라는 낱말은 이 원고 어디에서도 주장으로 쓰지 않는다. 범위를 좁히는 것은 남는 주장을 약하게 만들기 위해서가 아니라 반증 가능하게 만들기 위해서다.

불규칙 시간·마스킹 멀티태스크 학습. 본 설계는 불규칙 시계열 문헌의 표준 재료—관측 마스크와 감식 인지 순환 (GRU-D [39]), 연속시간 임베딩 위 어텐션 (mTAN [40]), 잠재 ODE 동역학 [41]—과 부분 라벨 멀티태스크 학습 [42], 후기 융합 멀티모달 구조 [43, 44], pre-LayerNorm 트랜스포머 [45], 어텐션 풀링 [46]을 차용한다. “나우캐스팅” 프레이밍은 기계학습 기상 예보에서의 용법을 따른다 [47, 48]. 새로움은 개별 재료가 아니라, 물리적으로 불리한 평가 프로토콜 아래에서의 누수 방지 조합에 있다.

3 데이터와 문제 설정

3.1 데이터셋

데이터 제공 측이 하드웨어 일관성과 H-mode ELM 억제(RMP) 구간을 기준으로 선정한 641개 KSTAR 방전(shot) 파일(shot 30801–32751)을 공통 10 ms 격자에 정렬해 사용한다: 총 247,207행(파일당 중앙값 339

표 2. 실명 대조. 구조 = 대상·조건화·검정 대상 자체가 다름. 배치 = 같은 재료를 다른 평가 규칙 아래 놓음.

#	차별점	실명 인접자	구조/배치	확정 근거
1	측정이 없는 시각을 채운다(측정이 있는 시각을 더 잘 읽는 것이 아니라)	NN-CES [18](KSTAR CES 스펙트럼에서 T_i 회전을 빔 변조 없이 추출), JET·EAST 스펙트럼 신경망 분석 [15–17]	구조	이 갈래의 입력은 CES 자신의 스펙트럼이므로 노출이 결측된 시각에는 정의되지 않는다. 우리 입력은 다른 진단과 타겟 자신의 과거다. 둘은 경쟁이 아니라 보완이며, NN-CES가 내는 적합 품질 메타데이터는 §9의 1번 레버다
2	교차 진단 재구성 계열에서 재구성 대상이 <i>희소 이온</i> 채널이다(CES $T_i \cdot V_{\text{rot}}$)	Diag2Diag [36], COMPASS 시간 초해상 [37], FusionMAE [35], EAST 결측 T_e [34]	구조	이 계열의 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성한다. CER/CES가 등장하는 경우에도 어디까지나 입력이며 [36] 희소 타겟이 아니다
3	타겟 자신의 불규칙한 과거에 조건화된 인과 추정이고, 미래를 절대 읽지 않는다	Diag2Diag·COMPASS(동 시각 무기억 매핑), FusionMAE(윈도 내 재구성), PanoMHD [38](인과이지만 결측 채움이 아님)	구조	우리 입력은 타겟별 관측 플래그와 경과시간(staleness)을 명시 채널로 나르고, 타겟 시점은 전부 마스킹되어 누수가 구조적으로 불가능하다(§3.2)
4	이겨야 할 기준선을 타겟 채널의 미래 사용 보간으로 세우고 그것을 착수 전에 등록한다	위 전부, 그리고 프로파일 GP·스플라인 문헌 [3, 5, 6]	배치	어느 구성원도 결측 채움의 현직 방법(타겟 채널 자체의 양쪽 이웃 보간)을 넘여야 할 관문으로 두지 않는다. 이 배치가 “고속 진단이 CES 밖 정보를 나르는가”를 답이 갈리는 물음으로 만든다(§5)
5	재구성 가능성을 가정하지 않고 타겟별로 검정한다	RTCAKINN [30](결측은 입력 강건성 조건), DIH-D 액추에이터 조건부 예보 [29](조밀 프로파일에서 미래 예보)	구조	같은 모델·같은 손실에서 T_i 는 통과하고 V_{rot} 은 통과하지 못한다. 고속 진단 절제에서 V_{rot} 출력이 비트 단위로 동일하다는 것이 그 검정의 결과다(§6.7)
6	계측기 유지값을 채점에서 제거하고, 스펙트럼 피팅 실패를 두 공동 1차 모집단으로 괄호 친다	우리가 아는 범위에서 이 계열에 대조 사례 없음	배치	V_{rot} 은 41.1%가 직전 값의 반복이므로, 제거하지 않으면 채점이 모델의 예측이 아니라 계측기의 반복을 채점한다(§3.4). 피팅 실패 0.53%는 컷의 선택만으로 결론을 뒤집을 수 있어 두 모집단 모두에서 성립할 것을 요구한다(§3.5)

CES is sparse and the targets go missing independently; counting instrument holds, 65.0% of the grid carries no independent V_{rot} information




그림 2. 10 ms 격자에서의 CES 결측 구조. T_i 와 V_{rot} 은 독립적으로 결측되며(8.2% / 23.9%), 행 필터링이 아닌 타겟별 마스킹을 요구한다. 계측기 유지값까지 세면 격자의 65.0%가 독립적인 V_{rot} 정보를 갖지 않는다.

행). 각 행은 BES [49] 9채널, ECEI [50] 4채널, Mirnov 코일 2채널, 시간, 그리고 두 CES 타겟 T_i , V_{rot} [1]을 제공한다. 이 격자에서 T_i 는 8.2%, V_{rot} 은 23.9%의 행에서 서로 독립적으로 결측된다(그림 2). 행은 ≥ 0.5 s의 시간 간극에서 연속 세그먼트로 묶이며(이 임계값은 이봉(bimodal) delta 분포의 골에 놓인다: ~ 247 k개의 행간 delta 중 (0.1, 0.5)s 구간은 82개뿐이고, 세그먼트 안에서는 스텝의 99.4%가 10 ms다), 전형적인 파일은 주 세그먼트 하나(중앙값 301행 ≈ 3.0 s; 10–90분위 1.3–7.0s; 두 개인 파일 28개, 10행보다 긴 것이 없는 파일 20개)와 그로부터 중앙값 6.3s 간극으로 떨어진 고립 단일행 몇 개(전체 1,279개, 대개 $t = 0$ 의 첫 행)로 이루어진다. 어떤 arm도—보간이든 모델 입력이든—간극을 넘지 않는다.

3.2 학습 예제의 두 가지 프레이밍

원도 프레이밍(우리의 대조군, §4)은 타겟 인덱스 t 의 샘플을 직전 W 개 격자 행으로 구성한다: `bes` ($W, 9$), `ecei` ($W, 4$), `mc` ($W, 2$), `time_features` ($W, 4$), `ces_history` ($W, 4$), 정규화 타겟 $[T_i, V_{\text{rot}}] \in \mathbb{R}^2$, 그리고 타겟별 관측 마스크 $m \in \{0, 1\}^2$. 네 개의 시간 특징—lookback 초, 행간 delta 초, 그리고 각각의 $\log(1+x)$ 변환—은 불규칙 관측 패턴을 명시적으로 노출한다(과거 CES 값의 신뢰도는 그것이 10 ms 전 값인지 200 ms 전 값인지에 강하게 의존한다). CES 이력의 네 채널은 직전 정규화 T_i , 직전 정규화 V_{rot} , 그리고 타겟마다 하나씩의 관측 플래그다. 본문 전체에서 $W=2$ 이다 (§6.8).

전체격자 시퀀스 프레이밍(우리의 주 모델)은 고속 진단에 결측이 없다는 점을 이용해, 연속 세그먼트의 입력이 완전한 모든 행을—라벨 유무와 무관하게—맥락으로 유지한다. 각 스텝은 엄격히 인과적인 22개 채널을 담는다: z-score된 15개 고속 채널, $\log(1+\Delta t_{\text{prev}})$, 그리고 타겟별로 t 이전 행에서 이월된 마지막 관측값, $\log(1+\text{경과시간})$, 과거 관측 존재 여부 플래그. 타겟은 병렬 관측 마스크와 함께 z-score되며, 희소성은 전적으로 손실에서 처리된다. 두 프레이밍 어느 쪽도 모델이 타겟 행 자신의 값을 읽게 하지 않는다.

3.3 설계 원칙

가짜 라벨 금지. 학습 행을 만들기 위해 타겟을 대체(impute)하지 않는다. 원도 프레이밍에서 행은 진단 입력이 완전하고 CES 타겟 중 적어도 하나가 실제로 관측된 경우에만 유지되며, 시퀀스 프레이밍에서 라벨 없는 행은 맥락으로만 기여한다.

타겟별 마스킹 손실. 손실은 타겟별로 마스킹된다: $\mathcal{L} = \sum_{k \in \{T_i, V_{\text{rot}}\}} m_k (\hat{y}_k - y_k)^2 / \sum_k m_k$. 한 타겟만 관측된 행도 그 타겟은 학습에 기여한다. 두-타겟-필수 필터는 라벨 행의 $\approx 28\%$ 를 조용히 버렸을 것이며, 이를 제거한 것은 순수한 데이터 이득이다.

누수 방지. (i) *파일 단위 분할*: 한 shot 내 인접 행은 강하게 자기상관되므로 분할은 shot 파일 단위로 이루어지고 디스크에 고정된다; (ii) *학습 파일 전용 정규화*: 모든 z-score 통계(희소 타겟은 NaN-인지)는 학습 파일에서만 추정되며, 시퀀스 모델은 여기에 더해 각 방전의 고속 진단을 그 방전 자신의 평균·분산으로 표준화한다—다른 방전도 타겟도 사용하지 않는다(왜 중요한지는 §6.6); (iii) *타겟 시점 마스킹*: 타겟 행 자신의 값과 관측 플래그는 입력에 결코 들어가지 않는다.

3.4 데이터 품질 감사 1: 유지(forward-fill)된 V_{rot} 값

관측된 V_{rot} 값의 54%가 계측기 유지값이다: 같은 연속 시간 블록 안에서 직전 관측과 비트 단위로 동일한 반복(최대 1,214행 연속; 641개 중 499개 파일 영향)이다. V_{rot} 의 고유 측정 주기가 행 주기보다 느려 생기는 현상으로, 독립적인 측정이 아니다. V_{rot} 은 소수점 다섯 자리까지 기록되고 서로 다른 값 사이의 최소 간격이 4×10^{-5} 이므로 “연속 동일”에는 측정 가능한 위양성 통로가 없으며, T_i 는 영향이 없다(226,991행 중 1행). 확정된 프로토콜에서 유지값은 모든 곳에서 제거된다—지도 타겟, 이력·이월 입력과 그 관측 플래그, 정규화 통계, 그리고 모든 기준선의 보간 앵커에서—따라서 어떤 팔도 forward-fill로 공짜 점수를 받을 수 없다. 본 논문의 모든 수치는 진짜 측정만을 사용한다. 프로젝트 기록에는 이전의 유지값 포함 규약과, 유지값이 학습도 오염시킴을 보인 짝지는 재학습(forward-fill 계단은 이력을 복사하는 것이 거의 최적이라고 모델에 가르친다)이 남아 있으며, 이것이 유지값 제거를 민감도 한 줄이 아니라 프로토콜로 삼은 이유다.

3.5 데이터 품질 감사 2: T_i 스펙트럼 피팅 실패와 두 모집단

관측된 T_i 의 p99는 2,089 eV, p99.9는 9,601 eV이고 최댓값은 14,984 eV다. 이 먼 꼬리는 플라스마 물리가 아니라 실패한 스펙트럼 피팅이다. **1,197행(0.53%)이 3 keV를 초과하며** 274개 방전에서 951개의 런을 이룬다. 런의 85%는 단일 행이고 5행 이상 지속하는 것은 2%뿐이며, 런 정점의 중앙값은 관측된 이웃 평균의 $13\times$ (IQR 6–26 $\times$). 이런 행은 어떤 방법으로도 예측 불가능하며, 공정한 비교에는 더 나쁘게도 보간 앵커로 쓰인 스파이크가 그 이웃에서 보간을 오염시킨다. 두 가지 대응이 모두 방어 가능하고 각각 비판의 여지가 있다: $>3\text{ keV}$ 를 모든 팔에서 결측으로 처리하면 어떤 방법도 예측할 수 없는 행을 제거하지만 “어려운 행을 없앴다”는 비판을 부르고, 그대로 두면 스파이크 앵커를 먹인 채 오프라인 기준선에 핸디캡을 준다. 그래서 우리는 **두 개의 공동 1차 모집단을** 사전등록했다: 컷($>3\text{ keV}$ 값을 적재 시점에 결측으로 처리하며, 지도·이력 입력·정규화 통계·모든 기준선의 앵커에 동일하게 적용)과 포함(컷 없음). **어떤 주장은 두 모집단 모두에서 성립할 때만 조건 없이 진술한다.** 한쪽에서만 성립하는 결과는 모집단을 명시해 보고한다. 임계값은

2.5–4 keV 범위에서 무의미하다 (§6.11). 값 기준 컷은 CES 피팅 품질 메타데이터가 확보되기 전까지 쓰는, 물리적으로 동기가 있는 대리 지표(“3 keV 초과는 KSTAR 이온온도가 아니다”)이며 한쪽 방향뿐이다 —같은 감사는 어떤 값 컷도 건드리지 못하는 단일 표본 *하향* 급락(양쪽 이웃의 $\frac{1}{2}$ 이하인 4,965행)을 함께 찾아내고, 컷이 제거하는 것은 $\geq 2\times$ 상향 이상치의 19%뿐이다. V_{rot} 에도 피팅 실패 스파이크가 있으나(16개 shot에서 1,000 km/s를 넘는 119행, 그중 101행은 한 방전의 한 블록), 프로토콜은 V_{rot} 을 컷하지 않고 persistence 기반 V_{rot} 비교마다 그 행들이 담은 제공오차 비중을 보고한다.

4 모델

주 모델 `seq_v2`는 **357,570** 파라미터의 인과 시퀀스 나우캐스터이며, 그것이 대체한 원도 모델은 201,258 파라미터의 후기 융합 네트워크로 짚지은 대조군으로 유지된다. 이 절은 그 두 모델을 기술하기 전에 무엇을 추정하는가, 왜 그 입력이 그 타겟에 배선되는가, 어떤 시간 척도 위에서 동작하는가를 먼저 정한다. 셋 다 뒤의 결과 절이 측정할 양이 아니라 그 측정을 해석 가능하게 만드는 전제이며, 라우팅에 관해서는 설계 선택이 아니라 보존식의 결과다.

4.1 추정 대상, 손실, 그리고 환원 불가능한 하한

모델은 각 격자 시간 t 에서 정규화된 타겟 $y_t = [T_i, V_{\text{rot}}]_t$ 를 그 시각까지의 관측 이력 $x_{\leq t}$ 로부터 추정한다. 손실은 타겟별 관측 마스크 $m_{t,c} \in \{0, 1\}$ 위의 마스킹 평균제곱오차이며, 여기에 정규화 영점 z_0 아래의 T_i 예측을 억제하는 물리 페널티가 더해진다:

$$\mathcal{L} = \frac{\sum_t \sum_{c \in \{T_i, V_{\text{rot}}\}} m_{t,c} (\hat{y}_{t,c} - y_{t,c})^2}{\sum_t \sum_c m_{t,c}} + \lambda \overline{\text{ReLU}(z_0 - \hat{y}_{t,T_i})}, \quad \lambda = 0.1. \quad (1)$$

식 (1)의 첫 항을 최소화하는 추정량은 조건부 기댓값 $\mathbb{E}[y_t \mid x_{\leq t}]$ 이므로, 본 연구가 보고하는 것은 조건부 분포의 평균이지 그 분포 전체가 아니다. 불확실성은 별도로, 모델을 건드리지 않는 분포 무가정 구간으로 다룬다 (§8).

이 목표에는 추정기가 제거할 수 없는 하한이 있다. 타겟은 광자 적분 스펙트럼 피팅의 산물이므로 스스로 측정 잡음 σ_{meas} 를 지니며, 참 물리량을 완벽히 맞히는 예측자라도

$$\text{RMSE}^2 = \sigma_{\text{meas}}^2 + b^2 \quad (2)$$

를 기록한다(b 는 물리적 오차). 관측 계열 자체에서 차분 기반 추정기로 낸 σ_{meas} 는 컷 모집단 T_i 에서 **46.4–129.9 eV**이다(4차 차분 상한 129.9, 상위 5% 절사 68.7, 강건 MAD 46.4). 백본의 RMSE 157.8 eV는 이 범위와 같은 자릿수이며, 두 끝값이 3배 가까이 벌어지는 이유가 손실의 성격을 결정한다: **4차 차분 제공질량의 46.6%(V_{rot} 은 65.6%)가 상위 1%의 한 스텝 변화에 몰려 있다**. 따라서 식 (1)의 총합은 *꼬리 통계*이고, 폭과 계열이 평평하다는 뒤의 결과 (§6.9)는 정보의 고갈이 아니라 이 사실의 귀결로 읽어야 한다. 본류에서는 모델이 여전히 타겟 자체 산포의 2.3–3.4배 위에 있다.

$\lambda = 0.1$ 은 본 연구가 유도한 값이 아니라 원도 파이프라인에서 물려받은 설정이며, 이를 유도로 바꾸는 방법은 위반율 목표를 정하고 승수를 제약 최적화로 푸는 것이다. 현재 판본은 그 대신 페널티가 결과를 만들지 않는다는 사실만 보고한다: 사다리의 모든 팔이 동일한 λ 로 학습되며, 해석 가능한 칸 **b3k8**는 persistence에서 출발하는 구성상 페널티가 거의 활성화되지 않는에도 백본과 동급이다 (§6.9).

4.2 두 보존식이 입력 라우팅을 정한다

`seq_v2`의 V_{rot} 분기는 고속 진단을 보지 않는다. 이는 모델링 취향이 아니라 두 전송 방정식을 항별로 읽은 결과다. 이온 에너지와 토로이달 각운동량은

$$\frac{\partial}{\partial t} \left(\frac{3}{2} n_i T_i \right) + \nabla \cdot \mathbf{q}_i = Q_{ei} (T_e - T_i) + S_i, \quad (3)$$

$$\frac{\partial}{\partial t} (n_i m_i \langle R^2 \rangle \omega_\varphi) + \nabla \cdot \Pi_\varphi = T_{\text{NBI}} + T_{\text{NTV}} + T_{\text{int}} + \dots \quad (4)$$

표 3. 식 (4)의 항별 감사. 641개 방전 전수, 확정 데이터 처리(스파이크 컷 후 유지값 제거), 624개 연속 블록. r 은 모달리티 표준화 평균과 타겟(또는 그 한 스텝 증분) 사이의 lag 0 통합 Pearson 상관이다.

항	물리	우리 데이터에 있는가	판정
$\partial L/\partial t$	회전 변화율	연속 관측쌍의 차분	측정됨
T_{NBI}	빔 토크	0-D 채널이 존재하지 않음	부재 (§6.7)
$T_{\text{NTV}} \sim \delta B^2$	비축대칭 제동	Mirnov, 100 Hz 데시메이트	음성 종결
$\nabla \cdot \Pi_\varphi$	난류 운동량 유속	BES가 밀도요동을 봄	측정 → 널
T_{int}	잔여응력	∇T_i 필요, 스칼라만 보유	도달 불가

를 따르며, 두 식 모두 값이 아니라 *변화율*을 구속한다. 그러므로 회전에 대해 물어야 할 것은 고속 진단이 V_{rot} 과 상관되는가가 아니라 dV_{rot}/dt 와 상관되는가이다. 식 (4)의 각 항을 우리가 보유한 채널에 대조하면 표 3가 된다.

T_{NTV} 는 이미 달힌 항이다: Mirnov는 100 Hz로 데시메이트되어 |MC|와 이동 RMS 같은 진폭 대리 지표가 모두 도움이 되지 않았다 (§6.7). 남아 있던 유일한 항은 난류 운동량 유속이며, BES가 그것이 올라타는 밀도요동을 보므로 원리상 도달 가능하다. 측정 결과는 널이다:

$$\underbrace{r(\text{BES}, dV_{\text{rot}}/dt) = -0.006, \quad r(\text{ECEI}, dV_{\text{rot}}/dt) = -0.003}_{\text{운동량식}} \quad \text{대} \quad \underbrace{+0.070, \quad +0.078}_{\text{에너지식}(dT_i/dt)}$$

값 수준에서도 같은 비대칭이 나타난다($\text{BES} \rightarrow T_i + 0.341$, $\text{ECEI} \rightarrow T_i + 0.311$ 대 $V_{\text{rot}} + 0.027$, $+0.005$). 같은 측정이 에너지식에서는 신호를 잡으므로 회전의 널은 방법의 한계가 아니다. T_{NBI} 가 데이터셋에 없고 T_{NTV} 가 달렸으며 T_{int} 가 도달 불가인 상태에서 마지막 항까지 널이므로, 우리 입력이 식 (4)을 통해 V_{rot} 에 닿을 경로는 남아 있지 않다. 인코더에서 분기를 나누는 설계는 이 감사의 구현이며, 그 결과 15개 고속 채널을 전부 교란해도 V_{rot} 출력이 비트 단위로 동일하다 (§6.7). 남은 레버는 모델이 아니라 취득이다 (§9).

4.3 모델이 놓인 시간 척도

세 개의 시간이 이 문제를 규정한다. 첫째, 격자 간격 $\Delta t = 10 \text{ ms}$ 이므로 Nyquist 주파수는

$$f_{\text{Nyq}} = \frac{1}{2\Delta t} = 50 \text{ Hz} \quad (5)$$

이다. Mirnov가 답아야 할 모드 회전은 kHz 대역이고(본 데이터셋의 방전들에서 보고된 EHO 조화파는 약 4와 8 kHz이다), 반앨리어싱 필터 없이 100 Hz로 데시메이트된 dB/dt 는 표본화 정리상 그것을 표현할 수 없다. §6.7의 lag-1 자기상관 -0.009 (BES $+0.568$ 대비)는 이 사실의 확인이지 그 근거가 아니다.

둘째, 전자와 이온을 결합시키는 시간이다. Braginskii 전자 충돌시간 $\tau_e = 3.44 \times 10^5 T_e^{3/2} / (Z n_e \ln \Lambda)$ (초, T_e 는 eV, n_e 는 cm^{-3})로부터 온도 평형화 시간은

$$\tau_{\text{eq}} \simeq \frac{m_i}{2m_e} \tau_e \quad (6)$$

이다. 중수소, $\ln \Lambda = 17$, $Z = 1$ 에서 τ_{eq} 는 $T_e = 0.5\text{--}3 \text{ keV}$ 와 $n_e = 2\text{--}5 \times 10^{19} \text{ m}^{-3}$ 범위에서 8.3–305 ms이고, 관측된 T_i 중앙값 593 eV에 대응하는 구석에서는 **8–59 ms**이다. 본 연구가 측정한 연속 인과 문맥의 포화점은 약 50 ms이며, 두 수는 같은 자릿수다. 이는 자릿수 수준의 정합성 진술이고 그 이상이 아니다: 식 (6)의 플라스마 파라미터는 인용값이며(BES와 ECEI는 계측기 단위이므로 본 연구는 n_e 와 T_e 를 물리 단위로 갖지 않는다) 앞의 상수에는 order-unity 관례가 있다.

셋째, 신호가 스스로를 닮아 있는 시간이다. 641개 파일에서 켄 자기상관의 $1/e$ 시간은 T_i 159 ms, BES 161 ms, ECEI 147 ms로 서로 10% 이내에서 일치한다. V_{rot} 은 그렇지 않다: 관측의 54%가 계측기 유지값이므로 유지값을 제거하면 16 ms, 유지하면 300 ms를 넘어 19배 이상 벌어진다. V_{rot} 의 **완화 시간은 이 데이터셋에서 측정 불가능하다**. T_i 는 641개 파일에서 유지값이 1행뿐이라 이 문제를 겪지 않는다. 유지값 병리는 값의 54%뿐 아니라 그 물리량의 동역학을 특징지을 능력까지 앗아간 것이며, 이는 NBI 토크와 원본 kHz Mirnov에 이은 세 번째 취득 과제다 (§9). 이 자기상관들은 추세를 제거하지 않고 계산되어 방전 포락선이 지배하므로 수송 시간 τ_E 나 τ_φ 로 인용하지 않는다.

4.4 전체격자 인과 시퀀스 백본

`seq_v2`는 세그먼트의 22채널 격자 시퀀스(§3.2) 위에서 서로 독립인 두 개의 인과 LSTM을 돌린다. T_i 분기(2층, 160 유닛)는 전체 상태—고속 진단, 두 타겟의 이월값, 경과시간 플래그, Δt —를 읽고, V_{rot} 분기(1층, 64 유닛)는 *고속이 아닌 7개 채널만* 읽는다: Δt 와 타겟별 이월값, 경과시간, 관측 플래그. 이 배선이 §4.2의 항별 감사를 그대로 구현한 것이다. 각 분기는 LayerNorm과 작은 GELU 헤드로 끝나며, 출력은 항별 정규화 $[T_i, V_{\text{rot}}]$ 이고 손실은 식 (1)를 세그먼트의 모든 라벨 행에 대해 적용한 것이다. 이 프레임에서 두 가지가 따라 나온다. 첫째, 모델이 과거로 뻗는 도달 범위가 고정 윈도우가 아니라 세그먼트 전체다—§6.3에서 이 모델을 모든 윈도우 변형과 가르는 바로 그 양이다. 둘째, 라우팅이 *인코더* 수준에서 성립한다: 순환 상태를 공유하면 헤드를 어떻게 배선하든 고속 진단 정보가 V_{rot} 헤드로 흘러들지만, 여기서는 15개 고속 채널을 전부 교란해도 V_{rot} 출력이 비트 단위로 동일하다(§6.7).

4.5 윈도우 대조군: 관측 마스킹 어텐션 풀링

대조군은 각 모달리티(BES, ECEI, MC)를 $W=2$ 윈도우 위의 전용 시간 인지 1-D CNN으로 인코딩하고, CES 이력을 양방향 GRU(은닉 64)로 읽은 뒤 시점별 출력을 타겟마다 하나씩 두 개의 독립적인 멀티헤드 가산 어텐션 readout으로 풀링하되, *하드 마스킹*하여 어텐션 질량이 그 타겟이 실제로 측정된 행에만 놓이도록 한다—보간 자신의 귀납 편향(관측된 표본만 사용)을 파라미터 비용 0으로 어텐션에 써 넣은 것이다. T_i 헤드는 고속 진단·시간·이력을 융합하고, V_{rot} 헤드는 이력과 시간만 융합한다. 두 모델이 공유하는 모든 것—데이터 제약, 유지값 제거 처리, 타겟별 마스킹, 분할, 채점 모집단—은 동일하게 고정되므로 두 모델의 비교는 행 단위로 짝지어진다.

4.6 해석 가능한 사다리 칸

`b3k8`(§6.9)는 `seq_v2`의 프레임과 라우팅을 유지하되 각 헤드를 *정확한* 분해로 대체한다: $\hat{y} = \text{이월값} + \sum_k w_k z_k + b$, 여기서 $z \in [-1, 1]^K$ 는 작은 인과 GRU(64/32 유닛, T_i 는 $K=8$, V_{rot} 은 4)의 tanh 잠재이고 readout은 0으로 초기화되어 학습이 정확히 persistence에서 시작한다. 파라미터는 21,498개로 백본의 6%다.

4.7 최적화 설정, 그리고 그 근거의 현황

학습은 AdamW($\eta = 10^{-3}$, weight decay 10^{-4}), 배치 16 세그먼트, gradient norm clipping 1.0, 검증 마스킹 MSE에 대한 ReduceLROnPlateau (patience 2, factor 0.5)와 조기 종료(patience 6, 최대 30 epoch; 확정 실행은 14–25 epoch에서 멈췄다)를 사용한다.

이 값들은 *유도된 것이 아니라* 윈도우 파이프라인에서 물려받은 것이며, 본 연구는 그 사실을 감추지 않는다. 데이터와 구조의 축은 전부 통제 실험으로 달렸지만 (윈도우 크기 §6.8, 유지값 처리 §3.4, 두 모집단 §3.5, 복잡도와 폭 §6.9), 최적화 축은 그런 축정을 거치지 않았다. 현재 이 설정을 방어하는 증거는 하나뿐이며 그것은 간접적이다: 백본 관문의 *예산 균등화* 조건은 두 모델을 고정 10 epoch로 학습시키고 검증 기반 체크포인트 선택을 금지하는데, 그 조건에서도 백본의 짝지은 T_i 이득은 4개 분할 전부 양수였다(+0.063, +0.033, +0.045, +0.030; §7). 즉 결론은 학습 일정의 인공물이 아니다.

“왜 배치 16인가”는 이제 측정된 답을 갖는다. 경사 잡음 척도 $B_{\text{simple}} = \text{tr } \Sigma / \|G\|^2$ 는 그래디언트의 신호와 잡음이 맞먹는 배치 크기이며, 표본 단위를 학습 루프가 실제로 뽑는 단위인 블록으로 두면 학습셋 위에서 정확히 계산된다. 즉 g_i 를 블록 i 의 마스킹 손실 그래디언트라 할 때

$$G = \frac{1}{N} \sum_i g_i, \quad \text{tr } \Sigma = \frac{1}{N} \sum_i \|g_i\|^2 - \|G\|^2, \quad B_{\text{simple}} = \frac{\text{tr } \Sigma}{\|G\|^2} \quad (7)$$

이다. 학습 중 일곱 시점에서 452개 학습 블록 전부에 대해 계산한 결과 초기값 이후 B_{simple} 의 중앙값은 **33.6** 블록(기하평균 28.4, 범위 6.0–61.4)이다. **배치 16은 측정된 잡음 척도의 절반쯤에 있다.** B_{simple} 아래에서는 배치 크기와 스텝 수가 대체로 선형으로 교환되므로, 16은 낭비도 아니고 명백히 열등하지도 않으며, 32로 늘리면 같은 데이터 효율에서 스텝 수가 대략 절반이 되고 60을 크게 넘으면 예제를 낭비하기 시작한다.

이는 자릿수 진술이다. $\frac{1}{N} \sum_i \|g_i\|^2$ 와 $\text{tr } \Sigma$ 는 첫 epoch 이후 단조롭게 감소하지만(10.5 $\rightarrow$ 7.5, 10.3 $\rightarrow$ 7.3) $\|G\|^2$ 가 0.15에서 1.74 사이를 오가며, 이 값은 452개 블록 전부에서 정확히 계산되므로 그 진동은 측정 오차가 아니라 Adam 궤적이 epoch 경계에서 어디에 있는지에 대한 실제 성질이다. 반면 안정적인 것은 잡음

비중이다: 첫 epoch 이후 블록 하나의 그래디언트 에너지 가운데 **86–98%가 잡음**이고 신호는 2–14%에 그친다. 측정은 dropout을 끈 상태에서 수행하였으므로(표본추출 잡음만 재기 위험이다) 실제 학습 루프의 유효 잡음 척도는 위 값 *이상*이며, 이 수는 계산 비용과 스텝 수의 교환에 관한 것이지 최종 skill에 관한 것이 아니다.

두 번째 측정인 μP —폭에 따라 최적 학습률이 이동하지 않는 파라미터화—는 아직 수행하지 않았다. 그것을 쓰면 §6.9의 폭 스윙이 평평한 이유가 “용량이 도움이 되지 않는다”인지 “학습률이 그 폭에 맞지 않았다”인지의 구분이 구성상 불필요해진다.

탐색이 가르쳐 준 것. 윈도 계열에 대한 두 라운드의 통제된 아키텍처 반복에서(선택은 깨끗한 검증 skill만으로), 살아남은 메커니즘은 어텐션 풀링 하나뿐이었고 용량 확장·스킵 위상·추가 추출기는 한 번도 도움이 되지 않았다. 확정된 프로토콜 아래에서 같은 교환이 두 번 더 반복된다: seq_v2에 관측 마스크 인과 어텐션을 더한 것은 작고 일관되게 양수이지만 유의하지 않은 이득이었고(§7), seq_v2의 5점 폭 스윙은 평평하다(§6.9). 이 문제의 병목은 용량이 아니라 정보이며, 식 (2)와 표 3가 그 병목이 각각 어디에 있는지를 타겟별로 말해 준다.

5 평가 방법론

지표. 모든 오차는 물리 CES 단위로 역정규화되어 타겟별로 계산된다. 1차 점수는 사전등록된 헤드라인 기준선에 대한 Murphy skill [14], $\text{skill}_{\text{PCHIP}} = 1 - \text{MSE}_{\text{model}} / \text{MSE}_{\text{PCHIP}}$ (양수 = 모델 우위; 0 = 동률)이다. 모든 팔(모델과 모든 기준선)은 동일한 (파일, 행) 샘플 집합에서 동일한 타겟별 유지 마스크로 채점되며, 어떤 짝지은 비교 이전에도 모집단 키가 비트 단위로 동일함을 검증한다. 보간은 타겟 자신의 값을 제외한다(누수 없음). 보간도 모델 입력도 세그먼트 경계를 넘지 않으며, 경계 너머의 이웃이 필요한 지점에서는 보간이 persistence 값을 대신 예측한다(모집단 축소 없음, PR2).

기준선 사다리. persistence와 국소 과거 전용 AR은 최초 사전등록의 인과 기준이고, 선형·PCHIP·가우시안 과정(정확한 Matérn-3/2 + 백색잡음, 최근점 16+16 국소 적합, 표본별 주변우도 격자 선택, PR2 fallback을 그대로 상속)은 미래를 읽는다. 인과 쪽에는 **인과 GP**를 추가한다: 같은 GP를 과거 이웃 16개로 제한하고 NaN 조건을 동일하게 두어 채점 모집단이 움직이지 않게 한 것이다. 이것이 배치 가능한 가장 강한 기준선임은 분명하며(시드 42 T_i RMSE 164.3 대 persistence 197.2, 컷 모집단), “배치 가능한 모든 인과 방법을 이긴다”는 persistence가 아니라 이 기준선에 대해 판정한다.

3분할; 선택은 TEST를 보지 않는다. 파일들은 train/val/test로 분할된다. 모든 분할의 test 파일은 어떤 아키텍처 탐색 *이전에* 예약되었고 모델 선택 과정에서 절대 읽지 않는다. 표준(시드 42) test 셋은 컷 모집단에서 96개 shot에 걸친 관측 T_i $n = 32,589$ 행과 60개 shot에 걸친 진짜 V_{rot} $n = 10,463$ 행을 담는다(포함 모집단은 32,721 / 10,461). 4개 분할(시드 42, 1, 7, 123)은 각각 96개 shot에 걸쳐 T_i 32.6–35.9k행, 60–66개 shot에 걸쳐 V_{rot} 10.5–14.5k행을 담는다. 본 논문의 모든 수치는 단일 수집 스크립트가 동결된 실행 디렉터리에서 읽어오므로, 본문·표·그림이 서로 어긋날 수 없다.

사전등록. 해당 test 수치를 보기 전에 문서로 고정한 규칙들은 다음과 같다. **PR1** 헤드라인 비교 대상은 PCHIP(과도 현상에서의 단조성·무진동을 근거로 사전 선택; 사다리 전체도 함께 보고); **PR2** 보간은 모델이 채점되는 모든 곳에서 예측하며, 미래 이웃이 없으면 persistence로 후퇴하고 그 후퇴 비율을 보고한다(채점된 T_i 행의 0.3–0.4%, 그러나 **채점된 V_{rot} 행의 40–44%**이므로 V_{rot} 의 “PCHIP 대비”는 5분의 2가 “persistence 대비”다); **PR3** test 셋 최소 규모(≥ 15 shot, $\geq 3,000$ 관측 T_i 샘플; 전부 충족); **PR4** 유의성은 skill에 대한 shot 군집 bootstrap 95% CI가 0을 제외하는 것으로 정의. 확정된 프로토콜은 여기에 다음을 더한다: 유지값 제거 학습·채점; 24-run 스윙의 plateau 최소 규칙에 따른 $W=2$ (§6.8); 윈도 계열의 파일당 샘플 상한 500; §3.5의 두 공동 1차 모집단; 그리고 백본 관문, 단 하나의 어텐션 후보, 해석 가능한 사다리 칸, 폭 스윙에 대해 **TEST 채점 이전에** **확정한 모델 결정 규칙**(§7). 임계값 민감도(2.5/3/4 keV)도 보고한다.

표 4. 물리 단위 RMSE 사다리. 표준 held-out test 분할(시드 42), 컷 모집단, 진짜 측정만($n = 32,589 T_i$, 10,463 V_{rot}). 낮을수록 좋다. 아래쪽 세 행은 미래를 읽는다. 포함 모집단에서는 seq_v2 363.0 / 23.7, PCHIP 412.4 / 30.2, 인과 GP 394.6 / 28.8, persistence 478.0 / 33.4(T_i / V_{rot})로, 피팅 실패 스파이크가 모든 T_i RMSE를 두 배 이상으로 키우지만 순서는 바꾸지 않는다.

팔	정보 접근	T_i RMSE (eV)	V_{rot} RMSE (km/s)
seq_v2 (나우캐스터)	고속 진단 + 과거 CES, 세그먼트 전체	157.8	23.6
윈도 대조군 ($W=2$)	고속 진단 + 과거 CES 2행	169.2	26.1
인과 GP	과거 CES 이웃 16개	164.3	28.8
Persistence	마지막 관측 CES	197.2	33.4
AR (국소, 인과)	과거 CES만	472.2	51.0
GP (오프라인)	과거 + 미래 CES	153.8	24.7
선형 보간	과거 + 미래 CES	169.8	29.0
PCHIP 보간	과거 + 미래 CES	173.6	30.2

Physical-unit RMSE ladder on the canonical test split (seed 42, cut population, genuine measurements only). Grey = causal; light = reads the future; the backbone is lowest for both targets.




그림 3. 시드 42 test 분할의 RMSE 사다리(컷 모집단, 진짜 측정): 인과 나우캐스터가 두 타겟 모두에서 배치 가능한 방법 중 최저 RMSE를 달성하고 미래를 쓰는 보간도 앞선다. 표 4와 같은 수치이며, 둘 다 같은 동결 산출물에서 생성된다.

Shot 군집 paired bootstrap. 한 방전 내 인접 CES 행은 강하게 상관된다. 샘플을 독립으로 취급하면 불확실성이 크게 과소평가된다. 샘플별 짝지는 오차 $SE_{\text{model}} - SE_{\text{PCHIP}}$ 를 shot 단위로 집계하고, shot 전체를 복원추출로 재표본한다(10,000회, 고정 시드). 얻어진 CI는 진짜 shot 간 일반화를 반영한다. 대가는 유효 표본 크기가 shot 수(T_i 는 ≈ 96 , V_{rot} 은 60–66)가 된다는 것이며, 이것이 전체 검정력을 제한한다. 모델 대 모델 비교(백본 대 대조군, 사다리 칸 대 백본)도 같은 행 위에서 같은 paired bootstrap을 사용한다.

MNAR 문제와 그에 대한 우리의 대응. 진짜 결측 시점에는 참값이 없으므로 skill은 관측된 시점을 가려 측정한다. CES 결측은 MNAR이므로(저신호, ELM, 천이에서 탈락) 관측 시점 skill은 진짜 결측 시점 성능의 낙관적 추정이다. §6.5에서 채점된 지점들을 실제로 결측인 지점들의 공변량 분포 위로 재가중하여 skill이 얼마나 살아남는지를 보고하고, 아울러 결측 모집단 중 애초에 이 분석의 도메인 안에 있는 비율도 함께 보고한다.

6 결과

6.1 나우캐스터는 모든 인과 기준선을 압도한다

표 4는 표준 test 분할에서의 물리 단위 RMSE 사다리를 보여준다. seq_v2는 미래를 읽지 않는 모든 방법 가운데 두 타겟 모두에서 최저 RMSE를 가지며, 배치 가능한 가장 강한 팔인 인과 GP를 RMSE 기준 4%(T_i)와 18%(V_{rot}) 차로 이기고, 미래를 쓰는 보간들도 앞선다. 유일하게 동물인 팔은 잡음 앵커를 통과하는 대신 평균해 내는 오프라인 GP다(T_i 153.8 대 157.8). 이는 본 논문에서 가장 강건한 결과다: 미래 CES가 정의상 없는 모든 온라인 환경에서 시퀀스 나우캐스터는 명백한 승자다.

표 5. seq_v2의 held-out test skill_{PCHIP}와 shot 군집 95% CI(10,000회 재표본), 두 모집단. 마지막 열은 같은 행 위에서 인과 GP에 대해 짝지은 skill이다. 굵은 글씨 = PASS(CI가 0을 제외).

타겟	분할	컷: skill _{PCHIP} (95% CI)	포함: skill _{PCHIP} (95% CI)	인과 GP 대비 (컷 / 포함)
T_i	42	+0.174 [+0.097, +0.236]	+0.225 [+0.109, +0.293]	+0.078 / +0.154
	1	+0.248 [+0.188, +0.295]	+0.238 [+0.153, +0.302]	+0.133 / +0.169
	7	+0.257 [+0.199, +0.302]	+0.292 [+0.232, +0.344]	+0.138 / +0.123
	123	+0.264 [+0.188, +0.320]	+0.316 [+0.186, +0.392]	+0.105 / +0.149
V_{rot}	42	+0.390 [+0.077, +0.591]	+0.384 [+0.066, +0.586]	+0.331 / +0.324
	1	+0.183 [-0.028, +0.280]	+0.195 [+0.000, +0.286]	+0.130 / +0.143
	7	+0.135 [-0.358, +0.269]	+0.132 [-0.362, +0.266]	+0.020 / +0.018
	123	+0.305 [-0.049, +0.437]	+0.304 [-0.065, +0.433]	+0.134 / +0.132

seq_v2 backbone vs. future-using PCHIP on four independent test splits, both populations (shot-clustered 95% CI, B = 10,000; W = 2, held-free)




그림 4. 두 모집단, 4개 독립 held-out 분할에 걸친 seq_v2의 skill_{PCHIP}와 shot 군집 95% CI의 forest plot. T_i 는 8개 셀 전부에서, V_{rot} 은 3개 셀에서 0을 제외한다.

6.2 헤드라인: T_i 는 두 모집단 모두에서 4개 독립 분할에 걸쳐 미래를 쓰는 보간을 이긴다

표 5은 두 공동 1차 모집단에서 4개 독립 held-out 분할(시드 42, 1, 7, 123 — 뒤의 셋은 어떤 선택 단계에도 쓰이지 않았다)에 대한 백본의 성능을 PCHIP 대비와 인과 GP 대비로 보고한다. 그림 4는 PCHIP 대비 신뢰구간을 보여준다.

- T_i : 두 모집단 모두에서 4개 분할 전부 PASS. skill_{PCHIP}는 컷에서 +0.17 ~ +0.26, 포함에서 +0.23 ~ +0.32이며 모든 shot 군집 CI가 0을 제외한다. 8개 모집단-분할 셀 전부가 인과 GP(+0.08 ~ +0.17)와 persistence(+0.36 ~ +0.46)도 이긴다. 이것이 본 논문의 무조건적 주장이다. 오프라인 GP를 상대로는 백본이 동물이므로(점추정 -0.05 ~ +0.11, 8개 중 1개 셀에서 유의), 관측 모집단에 대한 주장은 “사전등록된 보간들과 배치 가능한 모든 인과 방법을 이기고, 미래를 쓰며 표본별로 튜닝된 평활기와는 대등하다”로 읽힌다.
- V_{rot} : 승리가 아니라 동률. 두 모집단 모두에서 점추정은 모든 분할에서 양수지만, PR4를 통과하는 것은 1/4(컷)과 2/4(포함)이다—둘 다 시드 42, 그리고 포함 모집단의 시드 1이 [+0.000, +0.286]이다. persistence 대비로는 두 모집단 모두 3/4 분할에서 통과하고(+0.30 ~ +0.50; 시드 7의 CI는 0에 닿는다) 인과 GP 대비로는 2/4다. 4개 중 1-2개 유의는 잡음이 만들어낼 수 있는 수준이므로 회전 채널의 승리는 주장하지 않는다.
- 왜 포함 모집단의 수치가 더 높은가. 컷이 없으면 모든 팔이 PCHIP을 상대로 더 좋은 점수를 받는다(백본 평균 +0.268 대 +0.236, 대조군 +0.238 대 +0.173). 스파이크가 보간 앵커를 오염시키기 때문이다: 학습된 모델은 스파이크가 낀 이월값을 할인할 수 있지만 보간은 그럴 수 없다. §6.7이 이 성분을 정량화하며, 이것이 어느 한 모집단만 인용하지 않는 이유다.

표 6. 간극 계층별 skill. 4개 test 분할 통합, shot 군집 95% CI, seq_v2. 굵은 글씨 = CI가 0을 제외. 샘플이 50개 미만인 행은 채점하지 않는다.

Δt	n (컷 / 포함)	shot 수	컷: PCHIP 대비	포함: PCHIP 대비
T_i				
≤ 15 ms	134,546 / 135,317	301	+0.239 [+0.197, +0.274]	+0.299 [+0.244, +0.347]
> 15 ms	3,422 / 3,334	265 / 263	+0.268 [+0.187, +0.337]	+0.206 [+0.108, +0.290]
> 45 ms	460 / 429	104 / 101	+0.267 [+0.092, +0.414]	-0.004 [-0.304, +0.246]
V_{rot}				
≤ 15 ms	51,689	197	+0.233 [+0.020, +0.318]	+0.233 [+0.020, +0.317]
> 15 ms	466 / 456	130	+0.418 [+0.104, +0.680]	+0.432 [+0.128, +0.696]
> 45 ms	14	7	—	—

6.3 전체격자 프레이밍 대 윈도 대조군: 백본 관문

시퀀스 프레이밍을 채택할 만했는가? 이 결정은 네 개의 조건을 갖춘 관문으로 사전등록되었고 한 번만 채점되었다(컷 모집단 — 내부 모델 선택이 수행되는 모집단이다): 분할 시드 $\times$ 초기화 시드의 4×4 격자를 돌리고, 각 실행을 해당 분할의 $W=2$ 윈도 대조군과 행 단위로 짝지었다. 짝지은 T_i skill은 **16/16 실행에서 양수였고 13/16에서 개별적으로 유의했다**. 분할별 초기화 평균은 +0.129, +0.059, +0.078, +0.058이고(초기화 산포가 분할 산포보다 훨씬 작다), 통합 평균은 실행 군집 95% CI [+0.067, +0.096]과 함께 **+0.081**이다. 예산을 균등화한 팔(고정 10 epoch, 최종 가중치, 검증 선택 없음)도 4/4 분할에서 부호를 유지하므로(+0.063, +0.033, +0.045, +0.030) 이 이득은 학습 예산 효과가 아니라 아키텍처에서 온다. 그리고 어떤 실행도 유의한 V_{rot} 손실을 보이지 않았다(8/16은 유의한 승리). 네 조건이 모두 성립했다. 본 논문의 나머지 전부에서 보고 되는 4개 확정 분할에서 같은 비교는 컷에서 +0.130, +0.058, +0.062, +0.044, 포함에서 +0.053, +0.024, +0.047, +0.029로 8/8 양수이고 각 모집단에서 2/4 유의다.

이 관문은 프레이밍이 무엇을 사는지도 확정한다. 윈도 대조군은 인과 GP와 동물인 반면(컷 기준 1/4 분할 유의) 시퀀스 백본은 두 모집단 모두에서 4/4로 이긴다: 세그먼트의 과거 전체로 뺀 도달 범위가 배치 가능한 가장 강한 기준선을 넘어서게 하는 요소다. 그 비용은 음수다—샘플별 윈도 조립도 조합적 증강도 없기 때문에 백본은 윈도 계열의 학습 시간 중 일부만으로 학습된다.

6.4 skill이 사는 곳: 간극 영역

마지막 관측 CES로부터의 경과시간 Δt 로 계층화하면, 채점 타겟의 $\geq 96\%$ 가 인접 영역($\Delta t \leq 15$ ms)에 있다. 분할별로는 넓은 구간에 수백 개 샘플밖에 없으므로 4개 test 분할을 통합하고 bootstrap을 물리적 방전 단위로 군집한다(표 6). Δt 가 커질수록 PCHIP의 과제는 쉬워지고(간극을 사이에 둔 두 실제 관측을 보간한다) 우리 과제는 어려워지므로, 이 영역은 인과 방법이 이길 것으로 기대하기 가장 어려운 곳이다.

T_i 의 승리는 인접 이력에 국한되지 않는다. 15 ms를 넘어서도 백본은 두 모집단 모두에서 미래를 쓰는 PCHIP을 이기고(+0.268과 +0.206, 두 CI 모두 0 위), 거기서 persistence는 +0.40과 +0.43으로 이긴다. 45 ms를 넘어서면 컷에서는 여전히 이기지만(+0.267) 포함 모집단에서는 동물이다(-0.004, CI [-0.30, +0.25]): 101개 shot의 429행은 소수의 스파이크 앵커 행이 한 계층을 지배할 수 있는 바로 그 지점이며, 우리는 이를 동물로 보고한다.

V_{rot} 은 보간에 가장 어려운 그 한 곳에서 보간을 이긴다. 전역 V_{rot} 동물은 인접 영역에서의 동물이다. $\Delta t > 15$ ms에서는 백본이 두 모집단 모두에서 PCHIP을 이기며(+0.418과 +0.432, 130개 shot) — 본 논문에서 유일한 무조건적 V_{rot} 긍정 판정이다 — ≤ 15 ms에서는 persistence를 이긴다(+0.39). 가장 넓은 구간은 14행뿐이라 채점하지 않는다.

표 7. 관측 모집단에서 진짜 결측이면서 도메인 안인 모집단으로 재가중한 `seq_v2`의 T_i skill(계층 가중치를 고정한 shot 군집 95% CI). 굵은 글씨 = CI가 0을 제외. 무가중은 표 5의 헤드라인이다.

모집단	분할	PCHIP 대비		persistence 대비	
		무가중	결측 정합 (95% CI)	무가중	결측 정합 (95% CI)
컷	42	+0.174	+0.140 [-0.071, +0.290]	+0.360	+0.398 [+0.278, +0.518]
	1	+0.248	+0.164 [+0.062, +0.250]	+0.406	+0.366 [+0.299, +0.448]
	7	+0.257	+0.203 [-0.024, +0.346]	+0.403	+0.310 [+0.227, +0.398]
	123	+0.264	+0.283 [+0.069, +0.392]	+0.415	+0.381 [+0.246, +0.464]
포함	42	+0.225	+0.140 [+0.033, +0.250]	+0.423	+0.443 [+0.141, +0.623]
	1	+0.238	+0.217 [+0.086, +0.319]	+0.436	+0.383 [+0.273, +0.536]
	7	+0.292	+0.167 [+0.067, +0.265]	+0.406	+0.283 [+0.172, +0.380]
	123	+0.316	+0.221 [+0.050, +0.320]	+0.459	+0.337 [+0.164, +0.455]

6.5 실제로 결측인 지점에서는 이 중 얼마가 살아남는가?

지금까지의 모든 것은 마침 관측된 CES 지점에서 측정된 것이다. 참값이 없는 곳에서 오차를 측정할 수는 없다. 그러나 관측 행과 결측 행 모두에서 계산 가능한 공변량 위에서 skill이 어떻게 변하는지는 측정할 수 있고, 재가중할 수 있다. 기전을 담는 공변량은 둘이다: 마지막 진짜 관측으로부터의 Δt (15/25/45 ms로 구간화)와 §6.10의 입력 전용 국소 활동 플래그다. 후자는 자기 행을 제외한 이웃 집합으로 계산되므로 결측 행에서도 정의된다. $\Delta t \times$ 활동으로 사후 계층화하고, 채점 샘플이 30개 미만인 계층은 버리며, 모든 추정치 옆에 살아남은 커버리지를 함께 보고한다. 가중 격자는 모집단과 일관되게 만든다(컷은 여기에도 적용한다). 한 계층 안에서 결측 행과 관측 행이 교환 가능하다는 가정은 없앤 적하지 않고 명시한다.

먼저, 적용 범위에 관한 결과. 이 분석의 도메인은 “해당 타겟의 진짜 관측이 두 행 이내에 있음”이라는 $W=2$ 기준이다. 진짜 결측인 T_i 행 가운데 분할별로 **54–68%가 도메인 안**이고, 진짜 결측인 V_{rot} 행 가운데는 **4–6%뿐**이다. V_{rot} 간극이 긴 블록이기 때문이다(살아남은 계층의 커버리지는 T_i 0.99, V_{rot} 0.73–0.76). 따라서 재가중된 V_{rot} 행은 결측 질량의 20분의 1에 대한 질문에 답하는 것이며, 우리는 거기서 아무것도 끌어내지 않는다.

둘째, 두 비교가 갈라지며 — 그 갈라짐 자체가 쓸모 있는 것이다. **persistence** — 온라인 시스템이 실제로 돌리는 기준선 — 를 상대로는 T_i 우위가 두 모집단 모두에서 4개 분할 전부 재가중을 견딘다(+0.28 ~ +0.44, 모든 CI가 0을 제외). MNAR 보정이 앓아가는 skill은 많아야 0.12이고 어떤 분할에서는 전혀 없다. **미래를 쓰는 PCHIP**을 상대로는 재가중된 점추정이 +0.14 ~ +0.28에 머물지만, 고정 가중치의 넓은 CI가 컷 모집단 2개 분할에서 0을 지난다(2/4 유의; 포함 모집단은 4/4). 결측 지점은 더 큰 Δt 에 놓이는데, 그곳이 바로 양쪽 앵커가 가장 크게 도움이 되고 재가중 bootstrap이 가장 얇은 곳이다. 따라서 정말 중요한 지점들에서 증거가 지지하는 주장은 다음과 같다: **진짜 결측이면서 도메인 안인 시점에서 나우캐스터는 두 모집단 모두에서 CES 단독의 어떤 인과 방법보다 유의하게 낮고, 오프라인 보간보다는 모집단 조건부 유의성(컷 2/4, 포함 4/4)으로 낮다.** 윈도 대조군도 같은 방식으로 거동한다 (PCHIP 대비 2/4와 4/4, persistence 대비 4/4).

6.6 캠페인 이동을 견디는가?

무작위 분할이 하지 않지만 실제 배치가 하는 두 번째 일은 시간상 앞으로 나아가는 것이다. 641개 방전 전부를 shot 번호(30801–32751)로 정렬하고 시간으로 엄격히 잘랐다: **train 416 shot [30801, 31991], val 128 [32002, 32310], test 97 [32312, 32751]**이며 어떤 test shot도 어떤 train shot보다 앞서지 않는다. 나머지는 전부 헤드라인 프로토콜에 고정되어 바뀐 변수는 분할 규칙 하나뿐이다. 분할이 고정되어 있으므로 네 번의 실행은 초기화 시드만 달리하며, 이를 4개 분할인 것처럼 제시하지 않고 그대로 밝힌다. 모집단마다 세 개의 팔을 둔다: 헤드라인에서 학습된 그대로의 윈도 대조군(학습 파일 전용 정규화), 고속 진단을 shot별로 표준화한 같은 대조군(컷 모집단), 그리고 `seq_v2`이다(표 8, 그림 5).

표 8. 시간(캠페인) 분할, 4개 초기화, 뒤쪽 방전 97개로 이루어진 TEST 블록. 항목은 $\text{skill}_{\text{PCHIP}}$ 이며 **굵은 글씨** = PR4 PASS. 마지막 열은 같은 행 위에서 원도 대조군에 대한 seq_v2 의 짝지은 T_i skill이다.

모집단	팔	T_i PCHIP 대비 (초기화 42 / 1 / 7 / 123)	PASS	T_i 인과 GP 대비	seq_v2 - 대조군
컷	원도 대조군 (OFF)	+0.027 / +0.091 / -0.001 / +0.061	2/4	0/4	—
	대조군, shot별 표준화 (ON)	+0.103 / +0.107 / +0.094 / +0.107	4/4	—	—
	seq_v2	+0.187 / +0.174 / +0.181 / +0.177	4/4	4/4 (+0.11 ~ +0.12)	+0.164 / +0.091 / +0.182 / +0.124
포함	원도 대조군 (OFF)	+0.014 / +0.047 / +0.055 / +0.089	0/4	0/4	—
	seq_v2	+0.173 / +0.202 / +0.198 / +0.184	4/4	4/4 (+0.13 ~ +0.16)	+0.161 / +0.163 / +0.151 / +0.104

Campaign (temporal) split — train shots 30801-31991, test 32312-32751: the window model's offline advantage collapses, the backbone's survives (labels = mean, PR4 PASS count)




그림 5. 캠페인(시간) 분할: 원도 대조군의 보간 대비 우위는 붕괴하고, shot별 표준화가 이를 복구하며, 시퀀스 나우캐스터는 두 모집단 모두에서 우위를 유지한다. 막대는 4개 초기화의 평균이며 초기화별 점과 PR4 카운트를 함께 표시한다.

이 표에서 명시할 만한 것이 셋 있다. 첫째, 원도 모델의 오프라인 보간 대비 우위는 이동을 견디지 못한다: 2/4(컷)와 0/4(포함) 초기화이며, 인과 GP 대비로는 0/4다. 둘째, 이름이 지목되었던 그 수리가 작동한다: 각 방전의 고속 진단을 그 방전 자신의 평균·분산으로 적재 시점에 표준화하면(타겟은 손대지 않는다) 컷 모집단의 관문이 2/4에서 4/4로 올라가고 짝지은 값은 +0.078, +0.018, +0.095, +0.049(3/4 유의)이며 V_{rot} 은 변하지 않는다(-0.003 ~ +0.008) — V_{rot} 헤드가 고속 진단을 애초에 보지 않으므로 기대되는 음성 대조다. 셋째, 그리고 이것이 이 절의 결과다: **시퀀스 나우캐스터는 붕괴하지 않는다**. 두 모집단 모두에서 4/4 초기화에 대해 PCHIP을 이기고(+0.17 ~ +0.20), 두 모집단 모두에서 4/4로 인과 GP를 이기며(+0.11 ~ +0.16), 8/8에서 원도 대조군을 이긴다. V_{rot} 은 원도 대조군이 0/4인 자리에서 두 모집단 모두 4/4로 persistence를 이기고(+0.31 ~ +0.34), 대조군 대비 V_{rot} 마진은 8/8에서 유의하다(+0.06 ~ +0.18).

대조군이 왜 나빠지는가 — 단언이 아니라 측정. 전이에 실패해야 하는 것은 고속 진단 경로다. CES 단독 보간 대비 우위를 사는 것이 바로 그 경로인 반면, CES 이력 경로는 두 기간 모두에서 같은 물리량을 같은 단위로 보기 때문이다. 대조군이 정규화된 그 단위에서 채널별 train→test 드리프트를 측정하면 이것이 확인 된다: 위치 이동의 중앙값은 **BES가 1.22 σ , ECEI가 0.53 σ** 이고 척도 비는 각각 0.75와 0.62인 반면, **CES 타겟 자신은 0.115 σ 에 척도 비 1.06**이다. 고속 진단은 예측 대상보다 5–11× 더 이동한다. 학습 파일 전용 정규화(§3)는 무작위 분할에서는 올바른 누수 방지 선택이지만 캠페인 이동에서 바로 그것이 깨진다. shot별 표준화는 그 방전 자신의 데이터만 쓰므로 누수가 없다. seq_v2 는 정의상 shot별로 표준화하며—이것이 전이가 되는 두 이유 중 하나이고, 다른 하나는 도달 범위다(§6.3).

두 개의 스트레스 테스트, 하나의 독법. 표 9는 채택된 모델에 대해 둘을 나란히 놓는다. 실시간 시스템이 실제로 돌릴 수 있는 기준선들에 대한 우위는 두 모집단 모두에서 두 스트레스 테스트를 모두 견딘다. 미래를 쓰는 보간에 대한 우위는 두 모집단 모두에서 시간 이동을 견디고, MNAR 재가중은 모집단 조건부 유의성으로 견딘다. 이 표의 원도 모델 판본—본 연구의 이전 초안이 보고했던 것—에서는 오프라인 우위가 두 테스트 모두 견디지 못했다. 그것을 바꾼 것이 시퀀스 프레이밍이며, 새 열이 원래부터 거기 있었던 것처럼 제시하지 않고 그대로 밝힌다.

남는 단서. 네 번의 캠페인 통과는 하나의 시간 test 블록 위의 초기화들이므로 이는 4개 분할의 증거가 아니라 하나의 시간 분할의 증거이며, 컷 모집단 seq_v2 캠페인 실행 4개 중 2개는 30-epoch 상한에서 멈췄다.

표 9. 스트레스 하의 두 주장, seq_v2 , T_i . 항목은 PR4 통과 수(컷 / 포함)와 점 추정 범위다.

평가	PCHIP 대비 (오프라인, 미래 사용)	인과 기준선 대비
무작위 분할, 관측 지점	4/4 / 4/4, +0.17 ~ +0.32	인과 GP 대비 4/4 / 4/4, +0.08 ~ +0.17
결측 지점으로 재가중 (§6.5)	2/4 / 4/4, +0.14 ~ +0.28	persistence 대비 4/4 / 4/4, +0.28 ~ +0.44
시간 캠페인 분할 (§6.6)	4/4 / 4/4, +0.17 ~ +0.20	인과 GP 대비 4/4 / 4/4, +0.11 ~ +0.16

표 10. $W=2$ 원도 대조군의 평가 시점 모달리티 절제, TEST, 두 모집단: $\text{skill}_{\text{PCHIP}}$ (4개 분할 평균)와 절제하지 않은 실행에 대한 짝지은 변화 (분할 42 / 1 / 7 / 123; * = 유의하게 악화).

입력	타겟	컷	포함
전체 (이력 + 고속 + 시간)	T_i	+0.173	+0.238
이력 + 시간만 (고속 없음)	T_i	-0.125; 짝지은 -0.25* / -0.38* / -0.42* / -0.43*	+0.201; 짝지은 -0.03* / -0.04 / -0.03 / -0.09*
고속 + 시간만 (이력 없음)	T_i	-2.11; 짝지은 -4.6* / -1.8* / -2.3* / -1.9*	-1.16; 짝지은 -1.5* / -3.4* / -1.2* / -1.1*
전체	V_{rot}	+0.213	+0.206
이력 + 시간만 (고속 없음)	V_{rot}	+0.213; 짝지은 +0.000 × 4 (비트 동일)	+0.206; 짝지은 +0.000 × 4 (비트 동일)
고속 + 시간만 (이력 없음)	V_{rot}	-2.89; 짝지은 -5.4* / -6.3* / -1.8* / -2.3*	-3.51; 짝지은 -6.9* / -7.8* / -1.9* / -2.2*

6.7 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭

원도 대조군에 대한 통제된 입력 모달리티 절제—한 모달리티 그룹을 평가 시점에 0으로 만들고, 재학습은 하지 않으며, persistence와 보간은 실제 이력에서 계산—는 두 타겟이 왜 다르게 거동하는지를 설명하고 §4의 라우팅을 확정된 프로토콜 아래에서 다시 근거 짓는다(표 10, 그림 6).

- 이력은 두 타겟 모두에 필수불가결하다. CES 이력이 없으면 원도 모델은 두 모집단의 두 타겟 모두에서 PCHIP 대비 -1에서 -4까지 떨어진다: 자기 앵커 없이 100 Hz 진단만으로 예측 가능한 타겟은 없다.
- T_i : 보간 대비 마진은 고속 진단 정보다 — 컷 모집단에서. BES/ECEI/MC를 0으로 만들면 대조군은 보간기 아래로 떨어진다(-0.10 ~ -0.18; 짝지은 변화 -0.25 ~ -0.43, 4/4 유의). 물리 채널은 충돌성 전자-이온 결합이며($t_{ei} \propto T_e^{3/2}/n_e$), ECEI가 T_e 를, BES가 n_e 구조를 공급한다.
- 포함 모집단에서는 같은 이력 전용 모델이 여전히 PCHIP을 +0.15 ~ +0.23로 이기며, 고속 채널이 더하는 것은 0.03-0.09뿐이다 (2/4 유의). 보간기의 앵커에 스파이크가 끼어 있고, 학습된 모델은 보간이 할 수 없는 방식으로 그것을 할인하기 때문이다. 따라서 스파이크 포함 마진에는 고속 진단 정보가 아닌 스파이크 강건성 성분이 들어 있으며, 이것이 본 논문이 더 좋아 보이는 한쪽이 아니라 두 모집단을 보고하는 측정된 이유다. 고속 진단의 기여를 분리해 내는 쪽은 컷 모집단이다.
- V_{rot} : 정보는 전적으로 CES 이력이며, 구조적으로도 측정으로도 그렇다. 고속 진단을 0으로 만들어도 V_{rot} 출력은 8/8 모집단-분할 셀에서 비트 단위로 동일하고(라우팅이 구조적이다), seq_v2 와 b3k8 의 V_{rot} 분기도 같은 교란 시험을 통과한다. 토로이달 회전은 우리 입력 중 어느 것도 관측하지 않는 운동량 원천—외부 NBI 토크와 고유 회전 구동 [51]—이 지배하며, Mirnov 신호는 100 Hz로 샘플되어 회전의 대리가 될 수 있었을 kHz 모드 회전 주파수를 앨리어싱으로 잃는다 (§9).

이 비대칭은 절제 실험 이전에 물리로부터 예측되었고 절제로 확인되었다. V_{rot} 의 비승리는 모델의 실패가 아니라 진단 정보량에 관한 발견이며, §4의 타겟별 라우팅을 정당화한다.

6.8 이력은 얼마나 필요한가? 관측 하나

원도 계열의 이력 원도는 원래 검토되지 않은 기본값이었다($W=4$). 우리는 그 단언을 곡선과 명시된 선택 규칙으로 대체했다: **24회의 독립 실행**, $W \in \{2, 3, 4, 6, 8\} \times$ 시드 {42, 1, 7, 123}에 더해 *history-0* 지점 × 4시드이며, 각각 헤드라인과 동일한 프로토콜(유지값 제거, 파일당 상한 500, 스파이크 컷 없음—이 스윙은 컷보다 앞서며, 동결된 $W=2$ 실행이 §6.2의 포함 모집단 대조군이다)로 자기 held-out test 분할에서 채점된다. 세 가지 통제가 지점들을 비교 가능하게 만든다: 파일 단위 분할이 원도에 불변이고(모든 실행이 시드별로 같은 96개 test shot을 평가한다), 파일당 상한이 시간 부분집합 증강— $W=2$ 의 240k 샘플에서 $W=8$ 의 30.1M으로 폭발한다—이 소수의 긴 블록 방전에 지배되는 것을 막으며, 채점 모집단은 $W=2$ 에서 $W=8$ 까지 1.8%만 줄어든다.




그림 6. 원도 대조군의 평가 시점 모달리티 절제, 두 모집단. 고속 진단을 0으로 만들면 V_{rot} 은 비트 단위로 동일하고 컷에서는 T_i 마진이 사라진다. 이력을 0으로 만들면 두 타겟 모두 붕괴한다.

표 11. Window 스윙, 4시드에 걸친 held-out test skill_{PCHIP} 평균(PASS = shot 군집 95% CI가 0을 제외하는 시드 수). History-0은 $W=4$ 에서의 no_history 절제이며, $W=1$ 은 구성할 수 없다.

이력 관측 수	W	T_i skill	PASS	V_{rot} skill	PASS
0	4	-0.026	0/4	-0.783	0/4
1	2	+0.238	4/4	+0.206	0/4
2	3	+0.246	4/4	+0.203	1/4
3	4 (구 기본값)	+0.221	3/4	+0.190	1/4
5	6	+0.190	3/4	+0.205	1/4
7	8	+0.216	4/4	+0.204	2/4

이력은 필수적이며, 그 첫 관측 하나가 사실상 전부를 담는다. 이전 CES를 완전히 제거하면 T_i 는 PCHIP 아래로 내려가고(-0.026, 0/4) V_{rot} 은 -0.78이 된다. 단 하나의 과거 관측이 두 타겟을 곧바로 plateau로 끌어 올리고 곡선은 거기서부터 평평하다: T_i 는 0.190-0.246, V_{rot} 은 0.190-0.206 범위인데, 한 지점 안에서의 시드 산포가 0.07-0.16으로 곡선 전체보다 넓다. “plateau에 도달하는 가장 작은 W ”를 적용하면 $W = 2$ 가 나온다. 기존의 $W=4$ 는 두 타겟 모두에서 $W=2/W=3$ 값보다 아래이므로, 정확도를 근거로 더 긴 원도의 비용을 치를 이유는 데이터 안에 없다. 더 넓게 가야 할 방어 가능한 이유는 **커버리지** 하나다: 원도 샘플은 원도 안에 관측값이 있을 때만 채점되므로 $W=2$ 에서 $W=8$ 로 가면 $\Delta t > 15$ ms 채점 행이 456 $\rightarrow$ 1,958개, $\Delta t > 45$ ms가 14 $\rightarrow$ 135개가 된다. 이는 더 긴 원도의 근거가 아니라, 도달 범위가 세그먼트 전체이고 W 가 하이퍼파라미터가 아닌 시퀀스 프레임의 근거다.

6.9 복잡도는 무엇을 사고, 크기는 도움이 되는가? 사다리와 폭 스윙

학습된 나우캐스터에 대한 정당한 비판 하나는 그 파라미터를 설명할 수 없다는 것이다. 유용한 답변은 같은 프로토콜 아래에서, TEST 채점 이전에 고정된 결정 규칙으로 복잡도가 무엇을 벌어들이는지 측정하는 것이다.

해석 가능한 사다리 칸. b3k8(§4)는 작은 인과 GRU가 낸 $z \in [-1, 1]^K$ 와 0으로 초기화된 readout으로 $\hat{y} = \text{이월값} + \sum_{k=1}^K w_k z_k + b$ 를 예측하므로, (i) $K+1$ 개 명명된 항으로의 분해가 귀속 근사가 아니라 정확하고, (ii) readout이 볼 수 있는 모든 수는 K 개의 탐침 가능한 잠재 중 하나이며, (iii) 보정은 타겟 σ 단위로 $\sum_k |w_k| + |b|$ 에 의해 유계다. K 는 탐색된 유일한 변수였고(검증만, 두 분할; $K=8$ 선택), 두 팔 모두 구속력 없는 상한과 같은 patience 규칙으로 멈춘다. 사전등록된 조건은 둘이다: 재학습된 명명된 항 앵커+ Δ 모델(1,258 파라미터)을 V_{rot} 손실 없이 4/4 분할에서 이길 것, 그리고 백본의 T_i skill 대비 평균 -0.05 이내에 머물 것.

표 12. 복잡도 사다리, T_i 에 대한 held-out TEST skill_{PCHIP}(4개 분할 평균)와 사전등록 규칙의 짝지은 판정, 두 모 집단. 앵커+ Δ 모델은 $W=2$ 에서 persistence로 붕괴한다(기울기 향이 관측된 이력 행 두 개를 필요로 하는데 결코 발화하지 않는다).

팔	파라미터	컷	포함	b3k8 - 앵커 (T_i , 컷 / 포함)	b3k8 - seq_v2 (T_i , 컷 / 포함)
Persistence	0	-0.264	-0.288		
앵커+ Δ (명명된 항)	1,258	-0.261	-0.287	+0.35 ~ +0.42, 4/4* / +0.29 ~ +0.34, 4/4*	평균 +0.002 (모든 CI가 0 포함) / 평균 -0.194 (4/4*)
b3k8	21,498	+0.237	+0.126		
윈도 대조군	201,258	+0.173	+0.238		
seq_v2 백본	357,570	+0.236	+0.268		




그림 7. 복잡도 사다리와 폭 스위칭을 한 축에 놓은 그림(TEST T_i skill 대 학습 가능 파라미터 수, 4개 분할 평균). 컷에서는 21k 잠재 병목 모델이 백본의 곡선 위에 놓이고 곡선은 34k에서 879k 파라미터까지 평평하다. 포함 모 집단에서는 유계 보정 사다리 칸이 +0.126으로 떨어진다.

- 컷에서는 백본의 T_i skill 전부가 유계 수 여덟 개와 persistence로의 압축을 견딘다. b3k8은 V_{rot} 손실 없이 4/4 분할에서 재학습된 앵커를 이기고, 백본에 대한 짝지은 T_i skill은 -0.009 , -0.005 , $+0.026$, -0.004 이다(평균 +0.002, 모든 CI가 0을 포함). PCHIP 대비 PR4를 4/4로 통과하고 인과 GP도 4/4로 이긴다. TEST 입력에 대한 선형 probe(타겟은 건드리지 않음)는 T_i 잠재가 마지막 관측 T_i (R^2 0.47–0.75)와 ECEI T_e 대리 지표(0.31–0.48)를 여러 차원에 분산해 부호화하며, 국소 BES 활동(0.09–0.13)이나 경과시간(0.01–0.07)은 거의 부호화하지 않음을 보인다. 학습된 보정은 예측 분산의 25–39%를 설명한다. 이 과제에 필요한 것은 전체격자 인과 상태이며, 그 상태는 작다.
- 컷이 없으면 이 사다리 칸은 백본 대비 $-0.16 \sim -0.21$ 을 치르고(4/4 유의) 3/4 분할에서 윈도 대조군 아래에 놓인다 — 잠재 여덟 개가 너무 적어서가 아니라, 유계 보정으로는 스파이크가 낀 이월값을 복구할 수 없기 때문이다: persistence 오차가 2 keV를 넘는 행은 포함 모 집단 test 행의 0.6–1.3%인데 b3k8의 T_i 제공오차의 73–83%를 담는다(PCHIP을 포함한 다른 모든 팔에서도 70–83%). 사다리 칸 조건은 거기서도 성립하지만(앵커 대비 4/4) 백본 허용 조건은 컷 조건부이며, 우리는 그렇게 진술한다.
- 용량을 더 사도 얻는 것이 없다. seq_v2의 T_i 인코더를 24에서 260 유닛으로 넓히면(34k / 49k / 114k / 358k / 879k 파라미터, 다른 설정은 전부 고정, 지점마다 TEST 1회) T_i skill 평균은 $+0.230$ / $+0.236$ / $+0.235$ / $+0.236$ / $+0.230$ (컷)이고, 358k 백본에 대해 짝지은 평균은 ± 0.008 이내이며, 가장 넓은 지점이 유의하게 나은 것은 1/4 분할, 24 유닛까지 내려가도 $\geq 3/4$ 에서 유의하게 나쁜 폭은 없다. V_{rot} 은 (분기가 고정되어) 움직이지 않는다($+0.250 \sim +0.254$). 사다리 칸과 함께 이것은 모델 크기 축을 달는다: {100 Hz BES/ECEI/MC + CES 이력 + 시간}에 든 T_i 정보는 $\sim 50k$ 파라미터의 인과 순환 상태로 소진되며, 분할 간에 남는 분산(시드 42의 $+0.14 \sim +0.17$ 대 시드 123의 $+0.23 \sim +0.28$)은 용량이 아니라 분할 분산이다.

6.10 우위는 고변동 국소 구간에 집중된다

타겟과 무관한 입력 측 국소 활동 대리 지표(이웃 괄호 기울기가 크거나 국소 CES 이웃 분산이 높음, 타겟 행을 제외하고 계산)를 사용해 각 TEST 분할을 “peak”(고활동; 분할당 T_i 4.1–4.6k행, V_{rot} 2.4–2.9k행)와 bulk 행으로 나누고, 각각에서 shot 군집 bootstrap으로 seq_v2를 채점한다(그림 8).

The backbone's edge concentrates where interpolation is weakest: peak-stratified TEST skill, both populations




그림 8. seq_v2의 peak 계층별 TEST skill, 두 모집단(4개 분할 평균, 분할별 점, PR4 카운트). 보간 대비 우위는 보간이 가장 약한 곳에 집중되며, V_{rot} skill은 전적으로 peak 계층에 산다.

- T_i : peak 계층 skill_{PCHIP}는 컷에서 +0.45 ~ +0.61, 포함에서 +0.62 ~ +0.72이며, 미래 이웃을 가진 보간기를 상대로 8/8 PASS다. bulk는 컷에서 +0.09 ~ +0.20(PASS 4/4), 포함에서 +0.06 ~ +0.19(PASS 2/4)를 담는다. 매끄러운 bulk에서는 보간이 거의 최적이며, 모델의 가치는 활동 구간에 있다 — 그리고 이 진술은 무조건적이다.
- V_{rot} : peak 계층 skill은 +0.54 ~ +0.79(8/8에서 점추정 양수, 각 모집단에서 PASS 2/4, persistence 대비로는 +0.75 ~ +0.86에 8/8 PASS)이고 bulk에서는 ≈ 0 이다(-0.07 ~ +0.15, PASS 0/8). 따라서 비대칭은 지역적이다: 전역적으로 V_{rot} 은 보간과 동물이지만, 매끄러운 과거+미래 보간이 가장 나쁜 고활동 국소 구간에서는 이력 기반 V_{rot} 예측기조차 가치를 더한다. 이를 전역 영가설의 뒤집힘이 아니라 유의성 기반이 얇은 지역적 강점으로 보고한다.

6.11 컷 임계값 민감도

스파이크 임계값을 2.5와 4 keV로 두고 백본을 재학습하면(각각 4개 분할, 자기 모집단에서 채점) T_i skill 평균이 +0.230과 +0.232로 3 keV의 +0.236에 대응하고, 모든 임계값에서 PCHIP 대비 PR4 4/4, 인과 GP 대비 4/4이며, V_{rot} 은 +0.252 / +0.253 / +0.257이다. 물리학자가 방어할 만한 범위 안에서 임계값은 무의미하다. 중요한 것은 꼬리 안의 어디에서 자르느냐가 아니라 두 모집단이다.

6.12 문맥·구조·비용: 무엇이 skill을 정하고 무엇이 값을 정하는가

앞의 결과들은 하나의 아키텍처를 하나의 문맥 길이 위에서 채점한다. 이 절은 그 둘을 따로 움직여 어느 쪽이 결과를 만드는지를 가른다. 두 축은 서로 크게 다른 답을 준다: 문맥을 20 ms에서 630 ms로 늘리면 T_i skill이 +0.055에서 +0.138로 오르지만, 같은 문맥에서 계열을 순환에서 확장 합성곱이나 attention으로 바꾸면 어디에서도 0.023을 넘지 못한다. 그러므로 아키텍처는 skill이 아니라 비용으로 정해야 하며, 그 비용은 파라미터 수가 아니라 디스패치되는 연산자 수에서 나온다.

도달 범위는 절단이 아니라 학습으로 재야 한다. 학습된 백본의 순환 상태를 사후에 r 스텝으로 자르면 T_i 는 500 ms까지 손해를 보는 것처럼 보이지만, 이는 정보 부족이 아니라 학습되지 않은 상태 재구축을 정보로 잘못 읽은 것이다. 각 r 에서 잘라 낸 비중첩 세그먼트로 다시 학습하면 그 결손의 최소 84%가 회복된다. 이하의 모든 도달 범위 수치는 절단이 아니라 각 문맥에서 학습된 모델의 것이다.

약 50 ms에서 포화하며, 문맥이 사는 것은 평균이 아니라 전형성이다. 사전등록된 규칙(전체 문맥 대비 결손이 0.02 미만이고 유의한 결손이 4개 분할 중 1개 이하인 가장 작은 r)을 한 스텝 간격으로 밀집시킨 사다리에 적용하면 5스텝 = 50 ms가 반환된다. 그러나 이를 “이겨야 할 문맥”으로 읽으면 안 된다. 4개 분할을 방전 단위로 통합해 301개 방전 위에서 재채점하면 표 13가 되고, 모델은 20 ms에서도 인과 GP를 이긴다 (+0.057, 95 % CI [+0.027, +0.085]).

표 13. 순환 계열, 301개 방전 통합 재채점. “승률”은 인과 GP를 이긴 방전의 비율, “-상위10”은 기여가 큰 방전 10개를 지운 뒤의 통합 skill이다. 문맥 10배당 추세는 +0.0497 [+0.0363, +0.0638]로 상승한다.

문맥	T_i skill vs 인과 GP [95 % CI]	승률	-상위10
20 ms	+0.057 [+0.027, +0.085]	0.52	+0.028
30 ms	+0.087 [+0.061, +0.111]	0.60	+0.060
50 ms	+0.104 [+0.079, +0.128]	0.64	+0.077
70 ms	+0.119 [+0.095, +0.142]	0.66	+0.092
150 ms	+0.123 [+0.096, +0.148]	0.66	+0.096
630 ms	+0.143 [+0.118, +0.168]	0.67	+0.116

표 14. 계열별 도달 범위 사다리(T_i skill vs 인과 GP, 4개 분할 평균 · CI가 0을 제외한 분할 수). 본 연구의 승격 기준 $\geq 3/4$ 위에서 세 계열 모두 단조이다. 합성곱 팔의 30 ms는 구조적 최소(1층, 수용영역 3)이므로 그 교차점은 상한이다.

문맥	순환(LSTM)	확장 합성곱(TCN)	띠 attention
20 ms	+0.055 · 2/4	—	—
30 ms	+0.083 · 3/4	+0.079 · 3/4	—
50 ms	+0.098 · 3/4	+0.103 · 3/4	+0.090 · 2/4
70 ms	+0.115 · 4/4	+0.111 · 4/4	+0.094 · 3/4
150 ms	+0.117 · 4/4	+0.130 · 4/4	+0.119 · 4/4
630 ms	+0.138 · 4/4	+0.124 · 4/4	+0.122 · 4/4

승률 열이 이 절의 결론이다: $0.52 \rightarrow 0.60 \rightarrow 0.64 \rightarrow 0.66$ 으로 오른 뒤 약 70 ms부터 평평하다. 20 ms에서 모델은 평균으로는 이기지만 방전의 절반에서만 이기고, 70 ms에서는 3분의 2에서 이긴다. **문맥은 평균을 올린다기보다 승리를 전형적인 것으로 만든다.** 이것이 배치를 판단하는 쪽이 필요로 하는 진술이며, 문맥을 “유용해지기 위해 필요한 문맥”으로 기술해서는 안 된다: 20 ms에서도 모델은 배치된 시스템이 실제로 대체 하는 persistence를 +0.356으로 앞선다.

한 가지 방법론적 주의를 이 사다리가 강제한다. 분할별 4/4 계수는 한 스텝 간격에서 도달 범위의 단조 함수가 아니다(20–630 ms에서 $2/4 \rightarrow 3/4 \rightarrow 4/4 \rightarrow 3/4 \rightarrow 4/4 \rightarrow 4/4 \rightarrow 3/4 \rightarrow 4/4 \rightarrow 4/4 \rightarrow 4/4$). 그 아래의 점추정은 매끄럽게 오르므로, 이는 4개 표본에 대한 5단계 투표의 성질이지 실행의 문제가 아니다. 계수는 보고하되 판정은 결손으로 한다.

같은 문맥에서 계열은 skill을 정하지 않는다. 도달 범위를 맞춘 채 순환 LSTM(357,570 파라미터), 확장 인과 합성곱(3,238), 띠 attention(295,746)을 비교하면 셋 다 인과 GP를 4/4로 이기고 그 값은 +0.113 / +0.119 / +0.119이다. 110배의 파라미터 범위와 서로 가장 다른 세 시퀀스 연산자가 구별되지 않는 결과를 낸다. 사다리로 보면 표 14이며, 같은 도달 범위에서 짝지어 비교하면 차이는 더 조용하다: tcn3/5/7은 같은 도달 범위의 LSTM과 동률이고(−0.004, +0.005, −0.004; 어느 쪽으로도 유의한 분할 없음), attention만 70 ms 간에서 −0.023(3/4 유의)으로 사전등록 규칙이 “차이”를 반환한다. 어디에서든 계열이 T_i 를 움직이는 폭은 최대 0.023이고, 도달 범위를 20에서 70 ms로 옮기는 효과는 +0.060이다.

네 번째 계열인 대각 상태공간 모형(SSM)은 같은 사다리 위에서 다르게 행동한다. 문맥을 skill로 바꾸기는 하지만(+0.0235 / 문맥 10배 [+0.0102, +0.0372]) 약 70 ms에서 멈추고 더 낮은 천장에 머문다: 630 ms에서 +0.105로 순환의 +0.143에 못 미치고 승률도 0.58–0.60에서 0.66에 이르지 못한다. 다만 20 ms 통합 점수에서는 어느 계열보다 좋다(+0.065 대 순환 +0.057) — 같은 칸의 통합 비교이지 짝지는 검정이 아니므로 보고만 하고 승격하지 않는다. V_{rot} 은 네 계열 모두에서 문맥이 길어질수록 나빠진다.

그러므로 아키텍처는 비용으로 정하며, 비용은 연산자 수이다. 온라인 1스텝의 지연은 파라미터 수나 부동소수점 연산량이 아니라 디스패치되는 연산자 개수를 따라간다(약 $2\text{--}3\ \mu\text{s}$ /연산자). 그 개수는 기계와 무관하게 정확하며, 이 기계의 절댓값은 5개 세션 사이에서 21.84배로 흔들렸으므로 인용하지 않는다.

표 15. 계열별 온라인 1스텝 비용. R 은 도달 범위, “ops”는 스텝당 디스패치되는 `aten::` 연산자 수이다. attention도 KV 캐시 덕분에 R 에 대해 $O(1)$ 이지만 상수가 3.5–4.3배 나쁘다.

계열	R 에 대한 비용	$R = 15$	$R = 63$
순환(LSTM)	$O(1)$ — 상태가 나른다	111	111
확장 인과 합성곱	$O(\log R)$, 층당 +48	209	305
따 attention	$O(1)$, 상수 4.3배	473	473

이 문제에서 attention은 *엄밀히 지배당한다*: `tcn3k(3,238` 파라미터)가 같은 `skill(+0.119, 4/4)`을 91배 적은 파라미터와 2.3–2.7배 적은 연산자로 낸다. 이름 붙일 만한 운용점은 셋이다 — `tcn3k`는 357,570 파라미터 백본과 T_i 에서 동급이고 인과 GP를 4/4로 이기며, `v2m4k(3,898)`는 4/4를 유지하는 가장 짤 순환 팔, `tcn2k(1,808)`는 계열을 통틀어 가장 짤 팔이다. 이들은 “모델의 축소판”이 아니라 이 문제가 실제로 요구하는 것의 답이다. 10 ms 예산은 어느 팔에도 구속 조건이 아니며, 1 ms 판정은 위의 세션 간 산포 때문에 사전등록 규칙에 따라 보류되었다.

윈도 계열이 이 측에 닿을 수 없었던 이유. §6.8는 과거 관측 하나면 충분하다고 보고했고 이 절은 약 50 ms의 연속 문맥이 필요하다고 보고한다. 둘은 다른 자원을 세트로 충돌하지 않는다. 윈도 계열은 첫 번째를 만족했지만 두 번째에는 어떤 W 에서도 도달할 수 없었다: 윈도를 평균 풀링하면 순서가 버려지고, 시간적 부분집합 증강은 각 윈도를 과거 행의 임의의 비연속 부분집합으로 만들며, 타겟이 관측되지 않은 행은 모델이 보기 전에 버려진다. 수치가 정확히 그 설명이 예측하는 자리에 놓인다: $W=2$ 의 윈도 모델은 인과 GP 대비 +0.041(1/4)이고, 같은 2스텝으로 자른 `seq_v2`는 +0.055(2/4)이다. 서로 다른 아키텍처, 같은 결핍, 같은 결과다. 전체격자 재프레이밍은 모델링 취향이 아니라 문제가 요구하는 자원에 도달하는 유일한 방법이었다.

모델은 타겟이 움직이는 방전에서 이긴다. 통합 재채점은 V_{rot} 에 대해 홀로 읽으면 오독될 결과를 낸다: 모든 간의 통합 CI가 0을 제외한다(예: 70 ms에서 +0.123 [+0.036, +0.248]). 그러나 방전 단위 승률은 0.48이고 중앙 방전의 skill은 약 0이며, 약 62개 방전 중 상위 5개를 제거하면 네 분할 모두에서 통합 순위가 0 이하로 내려간다. **좁은 구간은 일반적 효과와 같지 않다.** T_i 는 반대다: 방전의 70%에서 이기고 상위 1개 방전의 기여 비중이 9–16%에 그친다.

승패를 예측하는 공변량을 11개 검사한 결과 살아남은 것은 하나뿐이며, 그것은 *방전 안에서 타겟이 얼마나 움직이는가*이다. 그 산포의 3분위로 나누면 T_i 의 승률은 42% / 83% / 85%, V_{rot} 은 34% / 48% / 55%이다. 메커니즘은 통계적이 아니라 물리적이다: 방전이 평평한 곳에서는 인과 GP가 이미 최적에 가깝고 직선을 보간하는 일에 모델이 더할 것이 없다. 그리고 V_{rot} 이 가장 변동이 큰 3분위에서조차 55%에 그친다는 사실은 §4.2의 항별 감사를 반대편에서 다시 말한 것이다 — 회전의 구동 변수가 관측되지 않으므로, 모델은 입력이 없는 운동을 따라갈 수 없다. 계열의 선호도 같은 방향을 가리킨다: V_{rot} 에 가장 좋은 팔은 작은 순환 팔이고 T_i 에 가장 좋은 팔은 작은 합성곱 팔인데, 이는 V_{rot} 이 강하게 자기상관된 이월값을 따므로 순환이면 족하고 T_i 는 고속 진단 이력을 적분하므로 시간에 걸친 가중치 공유가 값을 한다는 라우팅의 예측 그대로다.

7 모델 선택 프로토콜

본 논문의 모든 모델 결정은 검증 데이터 위에서, 또는 해당 TEST 채점 이전에 문서로 확정된 결정 규칙 아래에서 이루어졌고, TEST는 결정마다 한 번만 채점되었다.

윈도 계열. 그 아키텍처는 통제된 실험의 연속으로 도달했다. 각 실험은 데이터 계약을 보존해야 하는 *하나의* 변경이었고, *깨끗한 비증강* 검증 `skillPCHIP`로 채점되었으며—증강된 검증 손실은 보간이 이미 강한 바로 그곳에서 평활화를 보상하므로 결코 쓰지 않았다—지금까지의 최고 점수를 개선할 때만 유지되었다. 이후 이력 길이는 §6.8의 스윕으로 정해졌고, 유지값은 §3.4의 감사에 따라 학습에서 제거되었다.

백본 관문. 시퀀스 프레이밍은 §6.3의 네 조건 관문(4/4 분할에서 부호 유지, 통합 실행 군집 CI가 0을 제외, 예산 균등화에서도 부호 유지, V_{rot} 손실 없음)이 먼저 고정되고 그 다음 충족된 뒤에야 채택되었다. 같은

규칙 아래에서 이후 탐색된 단 하나의 아키텍처 후보—각 타겟 자신의 과거 관측 스텝에 대한 관측 마스킹 인과 어텐션을 0으로 초기화된 사영과 함께 `seq_v2`에 추가한 것—은 4/4 분할에서 양수였으나(백본 대비 $+0.009, +0.013, +0.033, +0.020$) $\geq 3/4$ 라는 사전 확정 기준에 대해 1/4에서만 유의했으므로 승격되지 않았고, 백본은 `seq_v2`로 남았다. 이 후보의 검증 이득은 탐색 분할에서 2/2 유의했는데, 이는 선택 분할 결과의 통상적 낙관이며 승격 기준을 TEST에 두는 이유다.

사다리 칸과 폭 스윙 (§6.9)은 두 갈래 판정과 서술적 독법(천장 / 무릎)을 어떤 TEST 채점 이전에 적어 두었고, 구성상 이 스윙 위에서 백본을 재선택하는 것은 허용되지 않았다. 전체 사전등록 문서와 배치별 실행 기록, 러너 스크립트는 공개 저장소에 있다.

8 배치 가능한가?

skill 점수와 쓸 만한 계측기 사이에는 두 가지가 놓여 있다. 측정 주기 안에서 돌아야 하고, 얼마나 믿어도 되는지를 말할 수 있어야 한다.

자연시간: 상태 유지형 1-스텝 추론은 여유를 두고 CPU에 들어간다. CES는 10ms 격자 위에 있으므로 온라인 결측 채움기는 한 스텝당 10ms에서 획득과 제어가 이미 쓰는 몫을 뺀 시간을 갖는다. 순환 나우캐스터는 온라인에서 상태를 유지한 채 실행된다: 은닉 상태가 격자를 따라 이월되고 새 행마다 배치 1의 순환 스텝 하나가 드는데, 이것이 실제로 중요한 수치다. 유희 상태의 노트북급 머신에서 워밍업 후 1,000회 호출을 계측해 네트워크 순전파만(특징 조립은 모델 밖이다) 잔 값으로, `seq_v2` 스텝은 CPU에서 중앙값 1.05 ms, p99 1.61 ms(격자 주기의 16%; p95 1.35 ms), GPU에서 1.21 / 2.31 ms이다—이 크기에서 GPU는 배치 1에서 아무것도 사주지 않는다. 오프라인 채점이 쓰는 세그먼트 전체 재실행은 CPU에서 100행(1s) 블록당 중앙값 2.9ms / p99 5.6ms, 300행당 6.4 / 8.9ms, 즉 대량 재처리 기준 35–47k 행/s(GPU 47–63k 행/s)이다. 배치 1의 원도 대조군은 더 느리고 이 머신에서는 꼬리가 무겁다: $W=2$ 는 CPU 중앙값 3.8ms이지만 p99 18.9ms(GPU 7.2 / 11.6ms), $W=4$ 는 4.0 / 8.1ms. 같은 벤치마크를 유희 상태에서 두 번 돌린 결과는 절대값에서 최대 $2\times$ 차이가 났고(다른 실행에서 `seq_v2` 스텝은 중앙값 / p99 0.51 / 0.99ms), 노트북의 전원 상태가 이 수치를 움직이기 때문이지만 순서—시퀀스 스텝 $\ll$ 원도 순전파, CPU로 충분—는 바뀌지 않았다. 따라서 실무 지침은 상태 유지형 나우캐스터를 제어 계산기의 CPU에서 돌리라는 것이며, 10ms 예산의 80% 이상이 획득과 제어에 남는다.

불확실성: 모델을 건드리지 않는 분포 무가정 구간. 핵융합 프로파일 데이터의 커뮤니티 표준은 사후분포를 돌려주는 가우시안 과정 회귀이고, 우리 모델은 점추정을 돌려준다. 분산 헤드나 분위 헤드를 붙이면 재학습이 필요하고 위의 모든 수치가 움직이므로, 대신 *split conformal prediction*을 쓴다: 해당 실행 자신의 검증 분할에서 보정하고, 예측기는 아무것도 바꾸지 않으며, 분포 무가정 유한표본 주변 커버리지를 얻는다. 변형은 둘이다: 단일 분위(global)와 Δt 구간별 분위(Mondrian). 동일한 절차를 PCHIP과 persistence에도 적용하므로 비교되는 것은 보정 기법이 아니라 구간의 품질이다. $\alpha = 0.10$, TEST, 두 모집단에서:

- **모델의 구간이 모든 셀에서 두 기준선의 구간을 이긴다**(32/32 모집단 $\times$ 타겟 $\times$ 변형 $\times$ 분할). 폭과 빛나감을 함께 벌하는 Winkler 구간 점수 기준으로 컷 모집단의 T_i 는 1,272 대 1,554(PCHIP) 대 1,727(persistence), 포함 모집단은 2,290 대 2,851 대 3,120이며, V_{rot} 은 150 대 164 대 179이다(global 변형, 4개 분할 평균). 이는 더 나은 점추정에서 따라 나오는 것이 아니라 별개의 성질이다.
- **포함 모집단에서 모델의 T_i 구간은 실제로 PCHIP의 것보다 넓은데**(반폭 224–255 대 211–241 eV) 그 럼에도 점수는 더 좋다: 스파이크가 빛나감 별점을 부풀리는데 모델이 덜 빛나가기 때문이다. Mondrian 보정은 모든 T_i 팔을 $\approx 4\text{--}5\%$ 좁히고 V_{rot} 은 그대로 두며 어떤 판정도 바꾸지 않는다.
- **정직한 실패: 커버리지는 주변적이지 조건부가 아니다.** T_i 커버리지는 목표 0.90에 대해 0.87–0.92이고(모든 팔에서 한 분할이 미달) V_{rot} 은 0.91–0.94이며, shot별 커버리지는 여전히 넓게 흩어진다. Conformal은 교환가능성 아래에서 커버리지를 보장하는데, 보정과 test는 서로소인 방편이다. shot 수준의 이동이 그 가정을 깬다. 배치된 계측기에는 통합 수치보다 이것이 더 중요하며, 이를 고치려면 현재 shot 수로는 지탱할 수 없는 shot 조건부 보정이 필요하다.

9 남은 개선 여지는 어디인가

본 논문의 부정 결과들은 이례적으로 구체적이며, 그 구체성이 그것들을 쓸모 있게 만든다: “이 문제는 어렵다”가 아니라 *어떤 변경이 이를 움직일지*를 말한다. 용량은 배제되었고 (§6.9), 더 긴 원도도 배제되었으며 (§6.8), 도달 범위를 사는 프레이밍은 채택되었다 (§6.3). 남은 것은 데이터이고, 각 레버는 이미 이 데이터셋 안에 있는 증거로 지목된다.

1. CES 피팅 품질 메타데이터는 대리 지표를 측정으로 대체할 것이다. 두 모집단 보고가 존재하는 이유는 값 기준 컷이 “피팅이 실패했다”의 대리 지표이기 때문이다: 어떤 방법도 예측할 수 없는 단일 표본 상향 사건을 제거하지만 한쪽 방향뿐이고(하향 급락은 손대지 않는다) $\geq 2\times$ 상향 이상치의 19%만 잡는다 (§3.5). 표본별 피팅 χ^2 이나 신호 수준이 있다면 품질 컷이 모든 팔에서 한꺼번에 값 컷을 대체하거나 동반할 수 있고, 두 모집단은 하나로 합쳐질 것이다. 그 값을 얻는 경로는 이미 같은 장치 위에 있다: NN-CES는 빔 변조 없이 CES 스펙트럼을 분석하므로 노출마다 적합 진단값을 내놓으며 [18], 같은 이유로 변조 구간에서 오던 결측 자체를 줄인다. 이 레버는 우리 쪽 코드 변경이 아니라 CES 재분석 산출물의 확보다. V_{rot} 자신의 스파이크(1,000 km/s를 넘는 119행)도 같은 규칙으로 처리될 것이다. 그때까지 persistence 기반 V_{rot} 비교는 §6.9처럼 그 행들이 담는 제공오차 비중을 보고한다.

2. Mirnov 정보는 플라스마에 없었던 것이 아니라 전처리에서 파괴되었다. §6.7에서 자기 진단이 회전 정보를 운반하지 않는다고 결론짓는 것은 틀렸다. 동일한 10 ms 격자에서 연속 블록 내 lag-1 자기상관은 BES가 +0.568, ECEI가 +0.572인 반면 Mirnov 코일은 -0.009이고 블록의 82%가 $|r| = 0.1$ 아래다: 이 격자 위에서 자기 채널은 백색잡음이다. 이는 dB/dt 가 kHz 모드 주파수로 진동하는 것을 앤티앨리어싱 필터 없이 100 Hz로 데시메이션한 결과의 특징으로, 연속한 표본들의 상대 위상이 무작위가 된다. 우리 진단 집합에서 토로이달 회전의 대리가 될 수 있었던 유일한 물리량인 모드 회전 주파수가 모델보다 상류에서 버려진 것이며, 우리가 시도한 모든 파생 MC 특징(적분, PCHIP 적분, $|MC|$, 이동 RMS)이 실패한 이유이기도 하다: 이미 잃은 정보는 하류에서 복구할 수 없다. 해결책은 모델 변경이 아니라 전처리 변경이다: 원시 kHz Mirnov 시계열에서 계산한 원도별 RMS, 대역 파워, 모드 수, 모드 회전 주파수를 사전등록된 pilot-then-expand 규칙 아래 V_{rot} 분기로 라우팅하는 것. 이것이 V_{rot} 에 대해 우리가 지목할 수 있는 가장 가치 높은 실험이며, 아카이브된 데이터로 검정 가능하다.

3. 액추에이터 채널이 아예 없다. 토로이달 회전은 주입된 토크로 결정되는데, 이 데이터셋에는 토크 신호가 존재하지 않는다. 데이터가 그 단절을 정확히 보여준다: shot 사이에서 ECE 유래 T_e 대리 지표는 T_i 와 $r = +0.353(p = 3 \times 10^{-17})$ 으로 상관되지만 V_{rot} 과는 $r = +0.024(p = 0.58)$ 이고, shot 내부에서 T_i 상관은 일관된 부호를 유지하는 반면 V_{rot} 상관은 부호가 무작위다. 즉 T_e 는 가열 수준을 추적하지만 가열 수준은 회전에 닿지 않는다—파워는 토크가 아니며, 토크는 빔 에너지, 접선 반경, 주입 기하에 의존한다. NBI 토크(또는 그것을 계산하는 빔별 파워와 기하)를 더하는 일은 모델링 과제가 아니라 데이터 획득 과제이고, 회전의 자기상관이 아니라 원인을 다루는, 우리가 지목할 수 있는 유일한 레버다. 문헌에 이미 양성 대조가 있다: 빔 액추에이터를 입력으로 받는 DIII-D의 순환 전방전 시뮬레이터는 회전의 시간 변화를 예측한다 [52]. 따라서 없는 채널은 측정되기만 하면 학습 가능하다.

이들 중 어느 것도 현재 결과가 천장에 있다는 진술이 아니다. 이들은 다음의 측정 가능한 이득이 있는 자리를 값싸게 시도할 수 있는 순서로 늘어놓은 것이며, 셋 모두 아카이브된 KSTAR 데이터에서 실행 가능하다.

10 한계

이 장의 결론. 다른 장에 흩어 둔 한계를 한자리에 모아 열 항목으로 적는다. 항목마다 이 논문이 그것을 어떻게 다루는지를 함께 적고, *다루지 못하는 것은 다루지 못한다고 적는다*. 그리고 마지막 열은 그 한계를 뒤집으려면 무엇을 재야 하는지다—“정보가 부족하다”로 끝나는 줄은 이 표에 없다.

표 16. 한계 열 항목. 마지막 열의 측정이 수행되고 그 결과가 반대로 나오면 해당 행의 진술은 철회된다.

#	한계	크기	이 논문이 하는 일	이것을 뒤집을 측정
1	V_{rot} 에 대한 부정 결과는 방법의 한계가 아니라 입력의 한계다	크다	실패가 아니라 발견으로 보고한다. 고속 진단을 0으로 만들어도 출력이 비트 단위로 동일함을 보여 원인을 입력 쪽으로 확정한다 (§6.7)	데이터셋에 없는 NBI 토크 채널, 그리고 100 Hz 데시메이션이 모델이 보기도 전에 파괴한 kHz 모드 회전을 담은 원시 Mirnov 스트림에서 다시 계산한 특징 (§9)
2	통계적 검정력. 재현의 단위는 shot이고 분할당 test shot이 96개(T_i)·60–66개(V_{rot})다. shot별 제공오차 차이는 꼬리가 두껍다(포함 모집단에서 행의 $\approx 1\%$ 가 모든 팔의 T_i 제공오차의 70–83%를 담는다)	크다	유의성 판정을 shot 군집 paired bootstrap으로 하고, 하나의 분할이 아니라 두 모집단 $\times$ 4개 독립 분할의 8개 셀 전부를 관문으로 둔다	같은 프로토콜을 더 많은 shot—다음 캠페인—에서 반복. 표본이 커져도 8/8이 유지되는지가 이 주장의 재현 시험이다
3	MNAR 낙관. skill은 관측 지점에서만 측정된다	중간	§6.5의 재가중이 두 모집단 모두에서 인과 비교에 대한 낙관의 상한을, 오프라인 비교에 대해서는 모집단 조건부 유의성으로 그 상한을 정한다	재가중은 결측 T_i 행의 54–68%에 달지만 결측 V_{rot} 행의 4–6%에만 달는다. 나머지에 닿으려면 V_{rot} 결측을 예측하는 공변량이 더 있어야 한다
4	오프라인 주장의 상한은 GP 동물이다. 오프라인 GP는 PCHIP을 이기고 모델은 그것과 동물이 뿐이다(8개 셀 중 1개 유의)	중간	“미래를 쓰는 보간을 이긴다”를 “사전등록된 보간들을 이긴다”로 좁혀 적는다. 배치 가능한 최강인 인과 GP로는 확장된다	오프라인 GP를 넘으려면 CES의 시간 구조 밖에서 오는 정보가 더 필요하다—1행과 같은 두 레버가 그 후보다
5	값 기준 컷은 대리 지표다. 두 공동 1차 모집단이 피팅 실패 문제를 팔호로 묶지만 V_{rot} 의 스파이크는 컷되지 않은 채 남는다	중간	무조건적 주장을 두 모집단 모두에서 요구해, 컷의 선택이 결론을 정하지 못하게 한다 (§6.11의 임계값 민감도 포함)	CES 피팅 품질 메타데이터($\chi^2 \cdot \text{신호세기}$)를 받아 값 기준 컷을 품질 기준 컷으로 바꾸는 것 (§9). NN-CES 재분석 [18]이 그 값을 내는 경로다. 이것이 이 문제를 결말짓는다
6	캠페인 전이는 하나의 시간 블록에 기대다	중간	4개 분할이 아니라 4개 초기화로 보고하고 그렇게 적는다. 컷 모집단 실행 4개 중 2개는 epoch 상한에서 멈췄다 (§6.6)	원도 대조군을 전이시키는 수리인 shot별 표준화는 오프라인 형태다. 실제로 출하될 인과적 러닝(확장 원도·EWMA) 추정기는 여기서 측정되지 않았다
7	지표의 비대칭. 보간은 shot 전체의 이웃을, 원도 대조군은 두 행을, 백본은 세그먼트의 과거를 본다	중간	인과 모델에 의도적으로 불리한 설계이므로 우위 방향의 해석은 안전하다	도달 범위를 맞춘 계열 대조 (§6.12)가 이 비대칭을 부분적으로만 건너낸다. 완전히 건너내려면 모든 팔의 문맥 길이를 동일하게 고정한 스왑이 필요하다
8	단일 장치, 단일 모델 계열. 하나의 장치, 하나의 진단 집합, 밀접하게 관련된 두 순환 계열	크다	전이에 대해 아무것도 주장하지 않는다	다른 토크막의 CXRS 측정에 같은 프로토콜을 그대로 옮겨 재는 것. 그 전까지 이 결과의 범위는 KSTAR 2022 캠페인이다
9	불확실성은 주변적으로 보정된다. 방전별 조건부가 아니다	작다	분포 무가정 conformal 구간이 32개 셀 전부에서 두 기준선의 구간을 이긴다는 사실만 주장한다 (§8)	방전별 조건부 보정(Mondrian conformal)을 같은 셀에서 재는 것
10	지연시간과 범위. 지연시간은 노트북급 머신 한 대에서 네트워크만 켜 있고 전원 상태에 따라 실행 간 최대 $2 \times$ 변동한다. 페데스탈 상단 프레임은 데이터 선정에서 물려받은 것이다	작다	특징 조립·획득 오버헤드가 빠졌음을 명시한다. §6.10의 고변동 분석은 사건에 무관한 대리 지표라고 적는다	실제 제어 계산기에서 획득→특징→추론 전 구간을 재는 것. 그리고 반경 스캔과 사건 위상(ELM 주기·L–H 천이) 정렬 분석

11 결론

우리는 최소한 KSTAR CES 타겟을 위한 인과적·누수 방지 멀티모달 나우캐스터— V_{rot} 분기가 고속 진단을 결코 보지 않는 전체격자 2분기 순환 모델—를 만들고, 사전등록된 shot 군집 두-모집단 프로토콜 아래에서 의도적으로 불리한 기준 — 미래를 보는 보간, 그리고 미래를 보지 않는 방법 중 가장 강한 인과 GP — 에 대해 평가했다. 관측 모집단에서 모델은 이온온도에 대해 미래를 쓰는 PCHIP을 유의하고 재현 가능한 skill로 이기고(4개 독립 분할과 두 모집단에 걸쳐 $+0.17 \sim +0.32$), 가장 강한 오프라인 평활기와 동률이며, 두 타겟 모두에서 모든 인과 기준선을 — 8개 셀 전부의 인과 GP와 비인접 영역($\Delta t > 15$ ms)을 포함해 — 이긴다.

배치에 대한 우리의 주장은 이제 두 스트레스 테스트 모두의 지지를 받는다. 진짜 결측이면서 도메인 안인 시점에서 모든 인과 방법 대비 우위는 8/8 모집단-분할 셀에서 재가중을 견딘다. 캠페인 경계를 가로질러서는 시퀀스 나우캐스터가 두 모집단 모두에서 4/4 초기화에 대해 PCHIP과 인과 GP를 앞서는데, 그것이 대체한 원도 대조군은 오프라인 우위를 완전히 잃었던 자리다. 그리고 그 차이는 단언이 아니라 측정이다: 고속 진단은 캠페인 사이에 타겟보다 5–11× 더 이동하고, shot별 표준화가 대조군을 수리하며, 시퀀스 프레이밍은 구성상 shot별로 표준화하고 과거 전체에 닿는다. 온라인 가상 센서는 미래를 읽는 보간이 아니라 persistence와 인과 평활기와 경쟁하며, 그 비교로 보면 나우캐스터는 중요한 지점에서 작동한다. 또한 모든 셀에서 적합한 채점 규칙으로 두 기준선의 구간을 이기는 보정된 구간을 내놓는다.

작동하지 않는 곳과 그 이유도 함께 보고한다. 회전은 전역적으로 보간과 동률이고 그 skill은 과도 구간에 산다. 두 모집단 중 하나를 정의하는 값 기준 컷은 피팅 품질에 대한 한쪽 방향 대리 지표다. 재가중은 결측 T_i 행의 54–68%와 결측 V_{rot} 행의 20분의 1에 닿는다. 예측 구간은 방전별이 아니라 주변적으로 보정된다. 그리고 45 ms를 넘어서면 포함 모집단은 동률이다. 이 중 어느 것도 천장 논변이 아니며, 어느 것도 어깨를 으쓱하는 것으로 남겨두지 않았다. 각각은 구체적이고 검정 가능한 변경을 가리킨다—CES 피팅 품질 메타 데이터, 100 Hz 데시메이션이 모델이 보기도 전에 파괴한 정보를 담고 있는 원시 kHz Mirnov 스트림에서 다시 계산한 원도별 특징, 그리고 데이터셋에 없지만 회전의 물리적 원인인 NBI 토크 채널. 그리고 모델 크기 측은 달렸다: 21k 파라미터의 persistence+유계 보정 모델이 컷에서 백본과 대등하고, 26× 폭 스윙은 평평하다. 이와 함께 본 연구는 교정된 V_{rot} 평가(54%의 예측기 유지값, 전 구간 제거), 어느 한 모집단만으로는 왜 충분하지 않은지를 보이는 측정을 동반한 스펙트럼 피팅 실패의 두-모집단 처리, 배치 가능한 가장 강한 기준선을 넘어서게 하는 도달 범위를 지닌 전체격자 인과 프레이밍, 그리고 모든 결정 규칙이 그것이 결정할 수치보다 먼저 적힌 test 동결 선택 프로토콜을 기여한다.

재현성

분할은 디스크에 고정되고 재적재 시 검증된다. 정규화 통계는 학습 파일 전용이다(시퀀스 계열은 여기에 shot별 입력 표준화가 더해진다). 모델 선택은 test 데이터를 결코 읽지 않는다. bootstrap은 고정 시드와 10,000회 재표본을 쓴다. 인용된 모든 수치는 단일 수집 스크립트가 동결된 평가 산출물에서 읽어온다.

코드 가용성

전체 파이프라인, 배치별 실행 기록을 담은 사전등록 문서, 여기 보고된 모든 결과 뒤의 통제 실험 러너, 고정된 train/validation/test 분할, 그리고 동결된 평가 산출물에서 인용된 모든 수치를 재생성하는 수집기는 <https://github.com/iseungsang01/ml-intern-revision>에서 공개되어 있다. 백본은 `ces_prediction/experiments/seq/model_seq_v2.py`, 해석 가능한 사다리 칸은 `model_seq_b3.py`, 원도 대조군은 `ces_prediction/model_iter009.py`(테스트 스위트에서 내용 해시로 보호)이므로, 이 수치를 만든 코드가 공개된 코드와 어긋날 수 없다.

데이터 가용성

본 연구의 바탕이 되는 KSTAR 진단 데이터—641개 방전, shot 30801–32751—는 코드와 함께 재배포되지 않는다. 이는 KSTAR 장치의 실험 데이터로 운영 기관의 데이터 정책을 따르며, 접근 요청은 그쪽으로 보내야 한다. 저장소에는 shot 파일이 갖춰진 뒤 분석을 재현하는 데 필요한 모든 것이 들어 있다: 정확한 파일 단위 분할 manifest, 보고된 모든 실행의 환경 설정, 그리고 bootstrap 통계를 계산하는 표본별 제공오차 아카이브.

참고문헌

- [1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81: 10D740, 2010. doi: 10.1063/1.3496991.
- [2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.
- [3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2):238–246, 1980. doi: 10.1137/0717021.
- [4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.
- [5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.
- [6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.
- [7] Minseok Kim, W.H. Ko, Sehyun Kwak, Semin Joung, Wonjun Lee, B. Kim, D. Kim, J.H. Lee, Choongki Sung, Yong-Su Na, and Y.-C. Ghim. Kinetic profile inference with outlier detection using support vector machine regression and Gaussian process regression. *Nuclear Fusion*, 64: 106052, 2024. doi: 10.1088/1741-4326/ad7304.
- [8] R. L. Dougherty, A. S. Edelman, and J. M. Hyman. Nonnegativity-, monotonicity-, or convexity-preserving cubic and quintic Hermite interpolation. *Mathematics of Computation*, 52(186):471–494, 1989. doi: 10.1090/S0025-5718-1989-0962209-1.
- [9] C. H. Reinsch. Smoothing by spline functions. *Numerische Mathematik*, 10(3):177–183, 1967. doi: 10.1007/BF02162161.
- [10] G. Kvernadze. Convergence and Gibbs’ phenomenon in cubic spline interpolation of discontinuous functions. *Journal of Computational and Applied Mathematics*, 92(2):173–188, 1998. doi: 10.1016/S0377-0427(97)00199-4.
- [11] S. Eyheramendy, F. Elorrieta, and W. Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481(4):4311–4322, 2018. doi: 10.1093/mnras/sty2487.
- [12] F. Elorrieta, S. Eyheramendy, and W. Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, 2019. doi: 10.1051/0004-6361/201935560.
- [13] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, 3rd edition, 2007.
- [14] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.

- [15] Chris Bishop, C.M. Roach, and M. G. von Hellermann. Automatic analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 35:765–773, 1993. doi: 10.1088/0741-3335/35/6/010.
- [16] J. Svensson, M. von Hellermann, and R. König. Analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 41:315–338, 1999. doi: 10.1088/0741-3335/41/2/016.
- [17] Baoyue Chai, Yingying Li, Ze Chen, Wei Tao, Yixuan Zhou, Shifeng Mao, Zhengping Luo, Yi Yu, Bo Lyu, and Minyou Ye. Fast estimation of ion temperature from EAST charge exchange recombination spectroscopy using neural network. *Plasma Science and Technology*, 21:105103, 2019. doi: 10.1088/2058-6272/ab2674.
- [18] J.K. Lee, W.H. Ko, H.H. Lee, B. Kim, Y.H. Lee, G.W. Shin, J. Kim, and J.M. Lee. Neural network-based analysis of charge exchange spectra in KSTAR. *Fusion Engineering and Design*, 222:115518, 2026. doi: 10.1016/j.fusengdes.2025.115518.
- [19] A. Pavone, J. Svensson, A. Langenberg, U. Höfel, S. Kwak, N. Pablant, and R. C. Wolf. Neural network approximation of Bayesian models for the inference of ion and electron temperature profiles at W7-X. *Plasma Physics and Controlled Fusion*, 61:075012, 2019. doi: 10.1088/1361-6587/ab1d26.
- [20] Mark D. Boyer and Jason D. Chadwick. Prediction of electron density and pressure profile shapes on NSTX-U using neural networks. *Nuclear Fusion*, 61:046024, 2021. doi: 10.1088/1741-4326/abe08b.
- [21] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64:106061, 2024. doi: 10.1088/1741-4326/ad73e8.
- [22] Francisco A. Matos, Diogo R. Ferreira, and P. Carvalho. Deep learning for plasma tomography using the bolometer system at JET. *Fusion Engineering and Design*, 114:18–25, 2016. doi: 10.1016/j.fusengdes.2016.11.006.
- [23] Cong Wang, Weizhe Yang, Haiping Wang, Renjie Yang, Jing Li, Zhijun Wang, Yixiong Wei, Xianli Huang, Chenshu Hu, Zhaoyang Liu, Xinyao Yu, Changqing Zou, and Zhifeng Zhao. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 65:076022, 2025. doi: 10.1088/1741-4326/ade0ce.
- [24] Xishuo Wei, Shuying Sun, W. M. Tang, Zhihong Lin, Hongfei Du, and Ge Dong. Reconstruction of tokamak plasma safety factor profile using deep learning. *Nuclear Fusion*, 63:086020, 2023. doi: 10.1088/1741-4326/acdf00.
- [25] G.H. Zheng, Zongyu Yang, Songfen Liu, Rui Ma, Xinwen Gong, Ao Wang, Shuo Wang, and W.L. Zhong. Real-time equilibrium reconstruction by multi-task learning neural network based on HL-3 tokamak. *Nuclear Fusion*, 64:126041, 2024. doi: 10.1088/1741-4326/ad8014.
- [26] S. Joung, J. Kim, S. Kwak, J. Bak, S. Lee, H. Han, H. Kim, G. Lee, D. Kwon, and Y. Ghim. Deep neural network Grad-Shafranov solver constrained with measured magnetic signals. *Nuclear Fusion*, 2020.
- [27] Semin Joung, Young chul Ghim, Jaewook Kim, S. Kwak, Daeho Kwon, Chih-Jen Sung, Dong Ju Kim, Hyun-Seok Kim, J.G. Bak, and S.W. Yoon. GS-DeepNet: mastering tokamak plasma equilibria with deep neural networks and the Grad-Shafranov equation. *Scientific Reports*, 13:15799, 2023. doi: 10.1038/s41598-023-42991-5.

- [28] L. Jung, Jaewook Kim, and Jisung Kang. Machine learning-based plasma profile reconstruction in KSTAR. *Journal of the Korean Physical Society*, 88:1079 – 1087, 2026. doi: 10.1007/s40042-026-01580-1.
- [29] Joseph Abbate, Rory Conlin, and Egemen Kolemen. Data-driven profile prediction for DIII-D. *Nuclear Fusion*, 61:046027, 2021. doi: 10.1088/1741-4326/abe08d.
- [30] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2024. doi: 10.1088/1741-4326/ad142f.
- [31] Semin Joung, Jaewook Kim, S. Kwak, Kyeo reh Park, S.H. Hahn, Hyunsun Han, Hyun-Seok Kim, J.G. Bak, S. G. Lee, and Young chul Ghim. Imputation of faulty magnetic sensors with coupled Bayesian and Gaussian processes to reconstruct the magnetic equilibrium in real time. *Review of Scientific Instruments*, 89:10K106, 2018. doi: 10.1063/1.5038938.
- [32] Debashish Mohapatra, Bidyadhar Subudhi, and Raju Daniel. Real-time sensor fault detection in Tokamak using different machine learning algorithms. *Fusion Engineering and Design*, 151:111401, 2019. doi: 10.1016/j.fusengdes.2019.111401.
- [33] S. Kaldas, R. Rossi, I. Wyss, M. Gelfusa, and P. Gaudio. Developing autoencoder models for multi-diagnostic electron density processing in tokamaks within a scientific machine learning framework. *Journal of Fusion Energy*, 45, 2026. doi: 10.1007/s10894-026-00568-w.
- [34] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.
- [35] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Niannian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.
- [36] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.
- [37] M. Imříšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiland, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.
- [38] HyeonJun Noh, Chweeho Heo, Xiaotian Gao, and Yong-Su Na. PanoMHD: Multimodal modelling of plasma dynamics towards Tokamak control. 2026.
- [39] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.
- [40] Satya Narayan Shukla and Benjamin M. Marlin. Multi-time attention networks for irregularly sampled time series. 2021:14897–14911, 2021. doi: 10.48550/arxiv.2101.10318.

- [41] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. 32:5320–5330, 2019.
- [42] Rich Caruana. Multitask learning. *Machine Learning*, 28:41–75, 1997. doi: 10.1023/a:1007379606734.
- [43] Jiquan Ngiam, Aditya Khosla, Mingyu Kim, Juhan Nam, Honglak Lee, and Andrew Y. Ng. Multimodal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 2011.
- [44] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:423–443, 2018. doi: 10.1109/tpami.2018.2798607.
- [45] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Xing Chen, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [46] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. 2018. doi: 10.48550/arxiv.1802.04712.
- [47] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. 2015. doi: 10.48550/arxiv.1506.04214.
- [48] Suman Ravuri, Karel Lenc, Matthew Willson, Dmitry Kangin, Rémi Lam, Piotr Mirowski, M. A. Fitzsimons, Maria Athanassiadou, Sheleem Kashem, Sam Madge, Rachel Prudden, Amol Mandhane, Aidan Clark, Andrew Brock, Karen Simonyan, Raia Hadsell, N. Robinson, Ellen Clancy, Alberto Arribas, and Shakir Mohamed. Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597:672–677, 2021. doi: 10.1038/s41586-021-03854-z.
- [49] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.
- [50] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.
- [51] J. E. Rice, A. Ince-Cushman, J.S. deGrassie, L.-G. Eriksson, Y. Sakamoto, A. Scarabosio, A. Bortolon, K.H. Burrell, B.P. Duval, C. Fenzi-Bonizec, M. Greenwald, R. J. Groebner, G. T. Hoang, Y. Koide, E. S. Marmor, A. Pochelon, and Y. Podpaly. Inter-machine comparison of intrinsic toroidal rotation in tokamaks. *Nuclear Fusion*, 47:1618–1624, 2007. doi: 10.1088/0029-5515/47/11/025.
- [52] Ian Char, Youngseog Chung, Joseph Abbate, Egemen Kolemen, and Jeff Schneider. Full shot predictions for the DIII-D tokamak via deep recurrent networks. arXiv:2404.12416, 2024.