

KSTAR 희소 전하교환분광 (CES) 신호의 멀티모달 나우캐스팅: 고속 진단은 미래를 보는 보간을 넘어 이온온도를 복원하지만 토로이달 회전은 복원하지 못한다

이승상 (Seungsang Lee)
서울대학교 원자핵공학과
lss010330@snu.ac.kr

국문 초안 — 2026 년 8 월 16 일

초록

전하교환분광 (CES) 은 토카막에서 이온온도 (T_i) 와 토로이달 회전 (V_{rot}) 을 측정하는 핵심 진단이지만, 광자 수집 제약 때문에 느리고 간헐적으로 결측된다. 본 연구가 다루는 KSTAR 10 ms 격자에서는 T_i 의 8.2%, V_{rot} 의 23.9% 가 결측되고 두 타겟은 서로 독립적으로 빠지며, V_{rot} 은 여기에 더해 41.1% 가 계측기 유지값 (held) 이어서 격자의 65.0% 가 독립적인 V_{rot} 정보를 갖지 않는다. 본 논문은 항상 측정되는 고속 진단—빔방출분광 (BES), 전자사이클로트론방출영상 (ECEI), Mirnov 코일—과 불규칙한 과거 CES 이력을 결합하면, CES 가 결측된 시점에서 CES 자체의 시간 보간으로는 복원할 수 없는 정보를 회복할 수 있는지를 묻는다. 고속 진단은 10 ms 격자 위에서 조밀하므로 우리는 문제를 인과적 전체격자 시퀀스 추정으로 프레임링한다: 소형 (0.36M 파라미터) 2 분기 순환 나우캐스터가 격자의 모든 행을 맥락으로 소비하고, 희소한 타겟은 행을 버리는 대신 타겟별 마스크 손실로 처리하며, V_{rot} 분기는 구조적으로 고속 진단에서 차단된다. 관측 마스크 풀링을 갖춘 원도 GRU-어텐션 모델이 짝지는 대조군이다. 평가는 의도적으로 불리하게 설계했다: 오프라인 보간 (선형, 단조 3 차 PCHIP, 국소 AR, 가우시안 과정) 은 타겟 시점 양쪽의 과거와 미래 CES 이웃을 볼 수 있는 반면 모델은 엄격히 인과적이며, 인과 GP 가 배치 가능한 가장 강한 기준선을 대표한다. 사전등록된 프로토콜—plateau 최소 이력 ($W=2$), 유지값 제거 학습-채점, 파일 단위 분할, 모델 선택이 전혀 건드리지 않는 test 셋, shot 군집 paired bootstrap(10,000 회 재표본), 그리고 T_i 스펙트럼 피팅 실패 ($>3\text{ keV}$, 0.53%) 를 결측으로 처리하거나 그대로 두는 두 개의 공동 1 차 모집단 (무조건적 주장은 둘 다에서 성립해야 한다)—하에서 나우캐스터는 T_i 에 대해 미래를 쓰는 PCHIP 을 skill $+0.17 \sim +0.26$ (스파이크 컷) 과 $+0.23 \sim +0.32$ (스파이크 포함) 로 이기며, 두 모집단 각각의 독립적인 4 개 held-out 분할 모두에서 95% 신뢰구간이 0 을 제외하고, 8 개 셀 전부에서 인과 GP 도 이긴다. V_{rot} 은 같은 관문을 4 개 중 1 개와 2 개 분할에서만 통과하므로 동물로 보고한다. 두 개의 스트레스 테스트가 오프라인 주장과 배치 주장을 분리한다: 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중해도 모든 인과 방법 대비 우위는 전 분할에서 유지되고 PCHIP 대비 우위는 2/4(컷) 와 4/4(포함) 에서 유지된다. 캠페인을 가로질러 시간으로 엄격히 재분할하면 —이는 원도 대조군의 보간 대비 우위를 제거한다—시퀀스 나우캐스터는 두 모집단 모두에서 4/4 초기화에 대해 PCHIP 과 인과 GP 를 앞선다. 우위는 고변동 국소 구간에 집중되며 (peak 계층 T_i skill $+0.45 \sim +0.72$, 8/8 PASS), 보정된 conformal 구간은 모든 셀에서 두 기준선의 구간을 이긴다. persistence+ 보정의 정확한 분해를 갖는 21k 파라미터 잠재 병목 모델은 스파이크 컷에서 백본의 T_i skill 과 대등하고, 백본을 34k 에서 879k 파라미터로 넓혀도 그 값은 ± 0.01 미만으로 변한다—한계는 추정기가 아니라 정보다. 입력 절제 (ablation) 실험은 $T_i \leftrightarrow V_{\text{rot}}$ 비대칭이 물리적임을 보인다: 컷 모집단에서 이력만 쓰는 모델은 T_i 에 대해 보간 아래로 떨어지는 반면, 고속 진단을 0 으로 만들어도 V_{rot} 은 비트 단위로 동일하다 (미관측 NBI 토크, 100 Hz 로 샘플된 Mirnov 신호가 kHz 모드 회전을 엘리어싱으로 소실). 전체 파이프라인, 사전등록 문서, 평가 산출물을 공개한다.

1 서론

플라즈마 경계부의 이온온도 T_i 와 토로이달 회전 V_{rot} 은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근 등 토카막 성능과 안정성의 핵심 요소를 지배한다. 두 물리량의 표준 측정법은 전하교환분광 (CES) [1] 으로, 전하교환 선방출의 도플러 확장에서 T_i 를, 도플러 이동에서 V_{rot} 을 추정한다. CES 는 충분한 신호대

잡음비를 위해 광자를 적분해야 하므로 본질적으로 느리고, 개별 시점 측정은 노출·신호품질 문제로 자주 소실된다. 본 연구의 KSTAR 데이터에서는 균일한 10 ms 격자 위에서도 T_i 의 8.2%, V_{rot} 의 23.9% 가 —서로 독립적으로—결측된다. 나아가 V_{rot} 은 41.1% 가 직전 관측값을 그대로 반복하는 유지값이어서 (§3.4), 격자의 35.0% 만이 독립적인 V_{rot} 측정값을 담고 있다. 우리 데이터셋에서 경험적으로 결측은 물리적으로 흥미로운 순간 (저신호 구간, ELM, 천이) 에 집중된다. 즉 Little and Rubin [2] 의 의미에서 무작위적이지 않은 결측 (MNAR) 이다.

한편 여러 고속 진단은 같은 플라스마를 결측 없이 관측한다: BES 는 밀도요동 구조를, ECEI 는 전자 온도를, Mirnov 코일은 자기요동을 측정한다. 이들 중 어느 것도 T_i 나 V_{rot} 을 직접 측정하지 않는다. 본 논문의 질문은 다음과 같다.

CES 가 결측된 10 ms 시점에서, 동시각 고속 진단과 불규칙한 과거 *CES* 이력만으로, *CES* 단독의 시간 보간이 복원할 수 없는 T_i , V_{rot} 정보를 회복할 수 있는가?

긍정적 답은 데이터 기반 가상 센서 (*virtual sensor*) 를 정당화한다: 강한 역산 가정 없이 *CES* 결측을 온라인으로 채워, 끊임 없는 페데스탈 분석과 궁극적으로 실시간 활용을 가능하게 하는 모델이다.

의도적으로 어려운 기준선. 결측 채움의 자명한 기준선은 *CES* 채널 자체의 보간이다. 우리는 비교를 모델에 의도적으로 불리하게 설계했다: 보간 기준선 (선형, 단조 3 차 PCHIP [3], 국소 AR 참조, 그리고 가우시안 과정) 은 오프라인으로, 타겟 시점 양쪽의—미래를 포함한—*CES* 이웃을 사용할 수 있다. 반면 모델은 엄격히 인과적이며, 타겟 시점까지의 고속 진단과 과거 *CES* 이력만 본다. 인과 모델이 미래를 쓰는 보간을 이긴다면, 고속 진단이 *CES* 의 시간 구조만으로는 답을 수 없는 *CES* 관련 정보를 운반한다는 뜻이다. 그리고 미래를 쓰는 보간을 이기는 모델은 당연히 모든 인과 기준선을 이긴다. 배치 가능한 가장 강한 경쟁자는 persistence 가 아니라 과거만 쓰는 평활기이므로, 인과 GP 팔을 추가하고 그에 대한 모델의 성능을 따로 보고한다.

기여.

1. **희소 타겟 나우캐스팅을 위한 인과적 전체격자 프레이밍 (§4).** 고속 진단은 격자 위에서 조밀하므로, 샘플별 원도를 조립하고 라벨 없는 행을 버리는 대신 입력이 완전한 모든 행을 시퀀스 맥락으로 유지하고 희소성을 손실로 옮긴다: 2 분기 인과 LSTM 이 타겟별 이월값·경과시간 (staleness)·관측 플래그 채널과 함께 한 방전 세그먼트의 과거 전체를 읽으며, V_{rot} 분기는 구조적으로 고속 진단에서 차단된다. 관측 마스킹 풀링을 갖춘 짝지은 원도 GRU-어텐션 대조군을 상대로 이 재프레이밍은 통합 T_i skill +0.081 의 가치를 지니며 (16 회 실행, 실행 군집 CI [+0.067, +0.096], 16/16 양수) 학습 비용은 오히려 일부에 불과하다. 그리고 이것이 사들이는 도달 범위가 인과 GP 를 넘어서게 만든다.
2. **사전등록된 두-모집단 shot 군집 평가 프로토콜 (§5).** 이력 길이는 24-run 스윙에서 plateau 최소 규칙으로 정한다 ($W=2$). 예측기 유지값은 학습과 채점에서 제거한다. T_i 스펙트럼 피팅 실패 0.53%(>3 keV) 가 두 개의 공동 1 차 모집단—모든 팔에서 결측 처리하거나, 모든 곳에서 유지하거나—을 정의하며 무조건적 주장은 두 모집단 모두에서 성립해야 한다. test 셋은 모델 선택이 결코 쉽지 않고, 유의성은 shot 군집 paired bootstrap 이며, 모든 모델 결정은 해당 TEST 채점 이전에 문서로 고정되었다.
3. **T_i 에 대한 강건한 긍정 결과 (§6):** 인과 나우캐스터가 미래를 쓰는 PCHIP 을 skill_{PCHIP} = +0.17 ~ +0.26(컷) 과 +0.23 ~ +0.32(포함) 로 이기며, 두 모집단의 4 개 held-out 분할 전부에서 CI 가 0 을 제외하고, 8 개 분할-모집단 셀 전부에서 인과 GP 도 이긴다. 가장 강한 미래 사용 평활기인 오프라인 GP 와는 동률이다.
4. **V_{rot} 에 대한 물리 기반 부정 결과:** 실패가 아니라 발견으로 보고한다. V_{rot} 은 미래를 쓰는 보간과 동률이고 (1/4, 2/4 유의 — 잡음 만으로도 나올 수준) 대부분의 분할에서 persistence 는 이긴다. 고속 진단을 0 으로 만들어도 V_{rot} 출력은 비트 단위로 동일하고 이력을 0 으로 만들면 붕괴하므로, 회전은 10 ms 에서 여전히 이력 자기상관의 한계에 머문다 (미관측 NBI 토크, Mirnov אלייריש). 이를 $T_i \leftrightarrow V_{rot}$ 정보 비대칭이라 부른다.
5. **보통 공개되는 두 주장을 분리하는 두 개의 스트레스 테스트 (§6.5, §6.6).** 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중해도 T_i 우위는 두 모집단 모두에서 모든 인과 방법 대비 4/4 분할, PCHIP 대비 2/4(컷) 와 4/4(포함) 로 유지된다. 캠페인을 가로질러 시간으로 엄격히 재분할하면 원도 대조

군의 보간 대비 우위는 사라지지만 (2/4, 0/4)—고속 진단은 기간 사이에 1.22σ (BES) 이동하는 반면 타겟은 0.115σ 다—각 방전의 입력을 그 방전 자신의 통계로 표준화하는 시퀀스 나우캐스터는 두 모집단 모두에서 4/4 초기화에 대해 PCHIP 과 인과 GP 를 앞선다.

6. **우위가 사는 곳:** 고변동 국소 구간 (peak 계층 T_i skill $+0.45 \sim +0.72$, 8/8 모집단-분할 셀 PASS; V_{rot} 은 점추정 $+0.54 \sim +0.79$ 이고 bulk 에서는 0) 과 비인접 영역 ($\Delta t > 15$ ms 통합, 두 모집단 모두 PASS) 이다.
7. **복잡도 사다리와 크기 축, 둘 다 측정 (§6.9):** 탐침 가능한 잠재 8 개에서 선형으로 읽어낸 유계 보정을 *persistence* 에 더해 예측하는 21,498 파라미터 모델이 스파이크 컷에서 백본의 T_i skill 과 대등하고 (짜지은 평균 $+0.002$)—컷이 없으면 -0.19 를 잃는데, 유계 보정으로는 스파이크가 긴 앵커를 복구할 수 없기 때문이다—백본을 34k 에서 879k 파라미터로 넓혀도 T_i skill 은 ± 0.01 미만으로 움직인다. 한계는 추정기가 아니라 입력 집합이며, 남은 레버는 이름이 지목되어 있다 (§9).
8. **측정된 배치 가능성 (§8):** 예측기를 전혀 건드리지 않고 32 개 모집단-타겟-변형-분할 셀 전부에서 두 기준선의 구간을 이기는 분포 무가정 conformal 구간, 그리고 CPU 에서 10 ms 주기 안에 들어가는 순환 나우캐스터의 상태 유지형 1-스텝 추론.

2 관련 연구

핵융합 진단의 프로파일 피팅과 결측 보간. 가우시안 과정 회귀 [4] 는 핵융합 프로파일 데이터의 피팅과 불확실성 정량화의 커뮤니티 표준 도구로서 KSTAR CES T_i 프로파일에도 SVM 기반 이상치 제거와 결합되어 적용돼 있으며 [5–7], PCHIP 같은 단조 보간 [3, 8] 은 자연 3 차 스플라인 [9] 이 ELM-툰니파형 계단에서 Gibbs 형 진동을 보이기 때문에 [10] 과도 현상 근방에서 선호된다. 불규칙 표본 시계열에는 정확한 AR 형 영모형 (IAR/CIAR) 이 존재한다 [11, 12]. 우리는 이 사다리—persistence, 선형 보간 [13], PCHIP, 국소 AR—를 사전등록된 기준선으로 사용하며, PCHIP 을 헤드라인 비교 대상으로, Murphy 의 MSE skill 점수 [14] 를 지표로 삼는다. 본 연구의 기여는 이 문헌과 직교한다: 더 나은 CES 단독 보간이 아니라, 다른 진단들이 어떤 CES 단독 방법도 넘어서는 정보를 더하는지를, 인과 멀티모달 모델을 미래를 쓰는 보간과 맞세워 검증한다.

핵융합에서의 신경망 진단 추론. 신경망 진단 추론에는 세 갈래가 있으며, 각각에 대해 타겟 측정이 없을 때 어떻게 되는가? 를 묻는 것이 유익하다. 가장 오래된 갈래는 스펙트럼 피팅 가속이다—JET 전하교환 스펙트럼의 신경망 분석 [15, 16] 과 EAST CXRS 스펙트럼의 고속 T_i 추정 [17]. 이들은 최소자승 피팅 대비 수십 배의 속도를 얻지만, 구조상 해당 시점에 측정된 스펙트럼을 요구한다: CES 노출이 결측되면 입력 자체가 없다. 두 번째 갈래는 한 진단의 추론 파이프라인을 다른 진단으로 대체한다: W7-X 의 베이지안 모형 에뮬레이션 [18], NSTX-U 의 스칼라 파라미터 기반 프로파일 형상 예측 [19], 그리고—우리 타겟에 가장 가까운—EAST 의 X 선 결정 분광기로부터의 T_i 회전 프로파일 추론 [20]. Lin 등은 정확히 우리의 두 물리량을 예측하지만 입력이 또 다른 도플러 분광기, 즉 동일한 물리 정보 채널이고 같은 광자 통계 한계를 가지며, 매핑은 순간적이고 소스 진단의 가용성을 그대로 상속한다. 세 번째 갈래는 느린 재구성 코드의 종단간 대리모형이다: 볼로미터 단층촬영 [21], 선적분 진단 [22], 안전인자 프로파일 [23], 실시간 평형 [24], 그리고 KSTAR 자체의 신경망 Grad-Shafranov 솔버 [25, 26] 와 고속 EPED 파라미터화 프로파일 재구성 [27] — 후자는 CES 를 입력으로 쓰며 회전 확장을 명시된 향후 과제로 남긴다. 이들은 분석 지연 시간을 다루지, 측정 가용성을 다루지 않는다: 존재하는 데이터의 역산을 가속할 뿐이다. 가용성 문제에 더 가까운 두 연구가 있다. DIII-D 의 액추에이터 조건부 프로파일 예보 [28] 는 우리 모델처럼 인과적이고 이력 기반이지만, 제어를 위해 조밀하게 측정된 프로파일로부터 미래를 예보하며, 희소 채널의 복원이 아니다. RTCAKENN [29] 은 실시간으로 운동학 프로파일 (불순물 온도·회전 포함) 을 재구성하고 dropout 학습으로 Thomson/CER 입력 소실을 견디지만, 거기서 결측은 입력을 0 으로 만드는 강건성 조건인 반면, 우리 설정에서는 타겟 자신의 희소성이 문제 그 자체이며 타겟별 관측 플래그와 불규칙 시간 특징으로 명시적으로 추적된다. 세 갈래 모두의 공통 가정은 모델이 실행될 때 정보 소스가 존재한다는 것이다. 자기 자신의 측정이 없는 시점에서, 다른 채널들과 자신의 과거로부터 진단값을 복원하는 일은 이들의 범위 밖이다.

교차 진단 재구성과 시간 조밀화 (가장 가까운 선행 연구). 최근 한 계열은 다른 진단들로부터 특정 진단을 재구성한다. GP 기반 대체는 KSTAR 에서 고장난 자기 센서를 밀리초 이하로 복원하고 [30], ML 은

CES is sparse and the targets go missing independently; counting instrument holds, 65.0% of the grid carries no independent V_{rot} information




그림 1: 10 ms 격자에서의 CES 결측 구조. T_i 와 V_{rot} 은 독립적으로 결측되며 (8.2% / 23.9%), 행 필터링이 아닌 타겟별 마스킹을 요구한다. 계측기 유지값까지 세면 격자의 65.0% 가 독립적인 V_{rot} 정보를 갖지 않는다.

손상 센서를 탐지·보상하며 [31], 오토인코더는 중복 밀도 진단을 융합해 복원력을 얻고 [32], 시계열 외생 회귀는 EAST의 결측 전자온도를 채우며 [33], FusionMAE는 HL-3의 88개 채널에서 마스킹 채널 “가상 백업 진단”을 수행한다 [34]. 우리 프레임에 가장 가까운 것으로, Diag2Diag는 DIII-D에서 다른 동시각 진단들로부터 Thomson 산란 T_e/n_e 를 요동 진단 속도로 합성하고 [35], COMPASS에서는 고속 복사 진단으로부터 Thomson 프로파일의 시간 초해상이 시연되었으며 [36], PanoMHD는 제어를 위해 인과 트랜스포머로 멀티모달 신호 동역학을 모델링한다 [37]. 본 연구는 이 계열과 네 가지 축에서 다르며, 각 축은 인용 논문들의 명시된 범위에서 확인 가능하다: (i) 타겟 채널—이 계열의 모든 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성하고 (35과 36의 Thomson T_e/n_e , 33의 ECE형 T_e , 34의 임의 마스킹 채널), CER/CES가 등장하는 경우에도 어디까지나 입력이며 [35] 희소 타겟이 아니다; (ii) 인과성—Diag2Diag와 COMPASS 연구는 기억 없는 동시각 매핑이고 FusionMAE는 원도 내 재구성인 반면, 우리 모델은 타겟 자신의 불규칙한 과거에 조건화되며 미래를 절대 읽지 않는다; (iii) 평가 기준—어느 것도, 결측 채움에서 현직 방법인 타겟 채널의 미래 사용 보간을, 사전등록된 shot 군집 프로토콜로 이겨야 할 기준선으로 세우지 않는다; (iv) 정보 분석—재구성 가능성이 타겟별로 검정되지 않고 가정되는 반면, $T_i \leftrightarrow V_{\text{rot}}$ 비대칭은 우리의 중심 발견이다. 요컨대 본 연구는 이 활발한 계열이 확립한 프로그램—항상 있는 진단으로 없는 측정을 재구성한다—을 이어받아 세 방향으로 확장한다: 전자 채널에서 희소 이온 채널로, 동시각의 기억 없는 매핑에서 타겟 자신의 불규칙 과거에 조건화된 인과 추정으로, 그리고 가정된 재구성 가능성에서 사전등록 기준선에 대한 타겟별 검정으로. 우리가 아는 한 이 세 확장의 결합—희소 CXRS 이온 측정의 인과적 시간 결측 채움—은 아직 다뤄지지 않았으며, 우리는 이를 계열로부터의 이탈이 아니라 그 자연스러운 다음 단계로 제시한다.

불규칙 시간·마스킹 멀티태스크 학습. 본 설계는 불규칙 시계열 문헌의 표준 재료—관측 마스크와 감쇠 인지 순환 (GRU-D [38]), 연속시간 임베딩 위 어텐션 (mTAN [39]), 잠재 ODE 동역학 [40]—과 부분 라벨 멀티태스크 학습 [41], 후기 융합 멀티모달 구조 [42, 43], pre-LayerNorm 트랜스포머 [44], 어텐션 풀링 [45]을 차용한다. “나우캐스팅” 프레임은 기계학습 기상 예보에서의 용법을 따른다 [46, 47]. 새로움은 개별 재료가 아니라, 물리적으로 불리한 평가 프로토콜 아래에서의 누수 방지 조합에 있다.

3 데이터와 문제 설정

3.1 데이터셋

하드웨어 일관성을 위해 캠페인 #24000–#33000에서 우선 선정한 641개 KSTAR 방전 (shot) 파일을 사용하며, H-mode ELM 억제 (RMP) 구간을 타겟으로 D_α 활동 구간 주변 ~ 100 ms 세그먼트를 절단한다. 모든 신호는 공통 10 ms 격자에 정렬된다. 각 행은 BES [48] 9 채널, ECEI [49] 4 채널, Mirnov 코일 2 채널, 시간, 그리고 두 CES 타겟 T_i , V_{rot} [1]을 제공한다. 이 격자에서 T_i 는 8.2%, V_{rot} 은 23.9%의 행에서 서로 독립적으로 결측된다 (그림 1). 247,207개 행은 ≥ 0.5 s의 시간 간극에서 연속 세그먼트로 나뉘며, 이 임계값은 이봉 (bimodal) delta 분포의 골에 놓인다 (~ 247 k개의 행간 delta 중 (0.1, 0.5) s 구간에 드는 것은 82개 뿐이다).

3.2 학습 예제의 두 가지 프레이밍

원도 프레이밍 (우리의 대조군, §4) 은 타겟 인덱스 t 의 샘플을 직전 W 개 격자 행으로 구성한다: `bes` ($W, 9$), `ecei` ($W, 4$), `mc` ($W, 2$), `time_features` ($W, 4$), `ces_history` ($W, 4$), 정규화 타겟 $[T_i, V_{\text{rot}}] \in \mathbb{R}^2$, 그리고 타겟별 관측 마스크 $m \in \{0, 1\}^2$. 네 개의 시간 특징—lookback 초, 행간 delta 초, 그리고 각각의 $\log(1+x)$ 변환—은 불규칙 관측 패턴을 명시적으로 노출한다 (과거 CES 값의 신뢰도는 그것이 10ms 전 값인지 200ms 전 값인지에 강하게 의존한다). CES 이력의 네 채널은 직전 정규화 T_i , 직전 정규화 V_{rot} , 그리고 타겟마다 하나씩의 관측 플래그다. 본문 전체에서 $W=2$ 이다 (§6.8).

전체격자 시퀀스 프레이밍 (우리의 주 모델) 은 고속 진단에 결측이 없다는 점을 이용해, 연속 세그먼트의 입력이 완전한 모든 행을—라벨 유무와 무관하게—맥락으로 유지한다. 각 스텝은 엄격히 인과적인 22 개 채널을 담는다: z-score 된 15 개 고속 채널, $\log(1+\Delta t_{\text{prev}})$, 그리고 타겟별로 t 이전 행에서 이월된 마지막 관측값, $\log(1+\text{경과시간})$, 과거 관측 존재 여부 플래그. 타겟은 병렬 관측 마스크와 함께 z-score 되며, 희소성은 전적으로 손실에서 처리된다. 두 프레이밍 어느 쪽도 모델이 타겟 행 자신의 값을 읽게 하지 않는다.

3.3 설계 원칙

가짜 라벨 금지. 학습 행을 만들기 위해 타겟을 대체 (impute) 하지 않는다. 원도 프레이밍에서 행은 진단 입력이 완전하고 CES 타겟 중 적어도 하나가 실제로 관측된 경우에만 유지되며, 시퀀스 프레이밍에서 라벨 없는 행은 맥락으로만 기여한다.

타겟별 마스크 손실. 손실은 타겟별로 마스크된다: $\mathcal{L} = \sum_{k \in \{T_i, V_{\text{rot}}\}} m_k (\hat{y}_k - y_k)^2 / \sum_k m_k$. 한 타겟만 관측된 행도 그 타겟은 학습에 기여한다. 두-타겟-필수 필터는 라벨 행의 $\sim 28\%$ 를 조용히 버렸을 것이며, 이를 제거한 것은 순수한 데이터 이득이다.

누수 방지. (i) 파일 단위 분할: 한 shot 내 인접 행은 강하게 자기상관되므로 분할은 shot 파일 단위로 이루어지고 디스크에 고정된다; (ii) 학습 파일 전용 정규화: 모든 z-score 통계 (희소 타겟은 NaN-인지) 는 학습 파일에서만 추정되며, 시퀀스 모델은 여기에 더해 각 방전의 고속 진단을 그 방전 자신의 평균-분산으로 표준화한다—다른 방전도 타겟도 사용하지 않는다 (왜 중요한지는 §6.6); (iii) 타겟 시점 마스크: 타겟 행 자신의 값과 관측 플래그는 입력에 결코 들어가지 않는다.

3.4 데이터 품질 감사 1: 유지 (forward-fill) 된 V_{rot} 값

관측된 V_{rot} 값의 54% 가 계속기 유지값이다: 같은 연속 시간 블록 안에서 직전 관측과 비트 단위로 동일한 반복 (최대 1,214 행 연속; 641 개 중 499 개 파일 영향) 이다. V_{rot} 의 고유 측정 주기가 행 주기보다 느려 생기는 현상으로, 독립적인 측정이 아니다. V_{rot} 은 소수점 다섯 자리까지 기록되고 서로 다른 값 사이의 최소 간격이 4×10^{-5} 이므로 “연속 동일”에는 측정 가능한 위양성 통로가 없으며, T_i 는 영향이 없다 (226,991 행 중 1 행). 확정된 프로토콜에서 유지값은 모든 곳에서 제거된다—지도 타겟, 이력-이월 입력과 그 관측 플래그, 정규화 통계, 그리고 모든 기준선의 보간 앵커에서—따라서 어떤 팔도 forward-fill 로 공짜 점수를 받을 수 없다. 본 논문의 모든 수치는 진짜 측정만을 사용한다. 프로젝트 기록에는 이전의 유지값 포함 규약과, 유지값이 학습도 오염시킴을 보인 짝지는 재학습 (forward-fill 계단은 이력을 복사하는 것이 거의 최적이라고 모델에 가르친다) 이 남아 있으며, 이것이 유지값 제거를 민감도 한 줄이 아니라 프로토콜로 삼은 이유다.

3.5 데이터 품질 감사 2: T_i 스펙트럼 피팅 실패와 두 모집단

관측된 T_i 의 p99 는 2,089 eV, p99.9 는 9,601 eV 이고 최댓값은 14,984 eV 다. 이 먼 꼬리는 플라스마 물리가 아니라 실패한 스펙트럼 피팅이다. **1,197 행 (0.53%) 이 3 keV 를 초과하며** 274 개 방전에서 951 개의 런을 이룬다. 런의 85% 는 단일 행이고 5 행 이상 지속하는 것은 2% 뿐이며, 런 정점의 중앙값은 관측된 이웃 평균의 $13\times$ 다 (IQR 6–26 $\times$). 이런 행은 어떤 방법으로도 예측 불가능하며, 공정한 비교에는 더 나쁘게도 보간 앵커로 쓰인 스파이크가 그 이웃에서 보간을 오염시킨다. 두 가지 대응이 모두 방어 가능하고 각각 비판의 여지가 있다: $>3\text{keV}$ 를 모든 팔에서 결측으로 처리하면 어떤 방법도 예측할 수 없는 행을 제거하지만 “어려운 행을 없앴다” 는 비판을 부르고, 그대로 두면 스파이크 앵커를 먹인 채 오프라인 기준선에 핸드캡을 준다. 그래서 우리는 **두 개의 공동 1 차 모집단을** 사전등록했다: 컷 ($>3\text{keV}$ 값을 적재 시점에 결측으로 처리하며, 지도-이력 입력-정규화 통계-모든 기준선의 앵커에 동일하게 적용) 과 포함 (컷 없음). 어떤

주장은 두 모집단 모두에서 성립할 때만 조건 없이 진술한다. 한쪽에서만 성립하는 결과는 모집단을 명시해 보고한다. 임계값은 2.5–4 keV 범위에서 무의미하다 (§6.11). 값 기준 컷은 CES 피팅 품질 메타데이터가 확보되기 전까지 쓰는, 물리적으로 동기가 있는 대리 지표 (“3 keV 초과는 KSTAR 이온온도가 아니다”)이며 한쪽 방향뿐이다 —같은 감사는 어떤 값 컷도 건드리지 못하는 단일 표본 하향 급락 (양쪽 이웃의 $\frac{1}{2}$ 이하인 4,965 행) 을 함께 찾아내고, 컷이 제거하는 것은 $\geq 2\times$ 상향 이상치의 19% 뿐이다. V_{rot} 에도 피팅 실패 스파이크가 있으나 (16 개 shot 에서 1,000 km/s 를 넘는 119 행, 그중 101 행은 한 방전의 한 블록), 프로토콜은 V_{rot} 을 컷하지 않고 persistence 기반 V_{rot} 비교마다 그 행들이 담는 제곱오차 비중을 보고한다.

4 모델

주 모델 seq_v2 는 357,570 파라미터의 인과 시퀀스 나우캐스터이며, 그것이 대체한 원도 모델은 201,258 파라미터의 후기 융합 네트워크로 짚지는 대조군으로 유지된다. 이 문제의 병목은 용량이 아니라 정보이며 (§6.9), 두 모델 모두 test 를 동결한 선택 프로토콜 (§7) 아래에서 도달했다.

전체격자 인과 시퀀스 백본. seq_v2 는 세그먼트의 22 채널 격자 시퀀스 (§3.2) 위에서 서로 독립인 두 개의 인과 LSTM 을 돌린다. T_i 분기 (2 층, 160 유닛) 는 전체 상태—고속 진단, 두 타겟의 이월값, 경과시간 플래그, Δt —를 읽고, V_{rot} 분기 (1 층, 64 유닛) 는 고속이 아닌 7 개 채널만 읽는다: Δt 와 타겟별 이월값, 경과시간, 관측 플래그. 각 분기는 LayerNorm 과 작은 GELU 헤드로 끝나며, 출력은 행별 정규화 $[T_i, V_{\text{rot}}]$ 이고 손실은 세그먼트의 모든 라벨 행에 대한 타겟별 마스킹 MSE 다. 이 프레임에서 두 가지가 따라 나온다. 첫째, 모델이 과거로 뻗는 도달 범위가 고정 원도가 아니라 세그먼트 전체다—§6.3 에서 이 모델을 모든 원도 변형과 가르치는 바로 그 양이다. 둘째, 라우팅이 인코더 수준에서 성립한다: 순환 상태를 공유하면 헤드를 어떻게 배선하든 고속 진단 정보가 V_{rot} 헤드로 흘러들지만, 여기서는 15 개 고속 채널을 전부 교란해도 V_{rot} 출력이 비트 단위로 동일하다 (§6.7). 학습은 AdamW(10^{-3}), 배치 16 세그먼트, 검증 마스킹 MSE 기준 조기 종료 (patience 6, 최대 30 epoch; 확정 실행은 14–25 epoch 에서 멈췄다) 를 사용한다.

원도 대조군: 관측 마스킹 어텐션 풀링. 대조군은 각 모달리티 (BES, ECEI, MC) 를 $W=2$ 원도 위의 전용 시간 인지 1-D CNN 으로 인코딩하고, CES 이력을 양방향 GRU(은닉 64) 로 읽은 뒤 시점별 출력을 타겟마다 하나씩 두 개의 독립적인 멀티헤드 가산 어텐션 readout 으로 풀링하되, 하드 마스킹하여 어텐션 질량이 그 타겟이 실제로 측정된 행에만 놓이도록 한다—보간 자신의 귀납 편향 (관측된 표본만 사용) 을 파라미터 비용 0 으로 어텐션에 써 넣은 것이다. T_i 헤드는 고속 진단·시간·이력을 융합하고, V_{rot} 헤드는 이력과 시간만 융합한다. 두 모델이 공유하는 모든 것—데이터 계약, 유지값 제거 처리, 타겟별 마스킹, 분할, 채점 모집단—은 동일하게 고정되므로 두 모델의 비교는 행 단위로 짝지어진다.

해석 가능한 사다리 칸. b3k8 (§6.9) 는 seq_v2 의 프레임링과 라우팅을 유지하되 각 헤드를 정확한 분해로 대체한다: $\hat{y} = \text{이월값} + \sum_k w_k z_k + b$, 여기서 $z \in [-1, 1]^K$ 는 작은 인과 GRU(64/32 유닛, T_i 는 $K=8$, V_{rot} 은 4) 의 tanh 잠재이고 readout 은 0 으로 초기화되어 학습이 정확히 persistence 에서 시작한다. 파라미터는 21,498 개로 백본의 6% 다.

탐색이 가르쳐 준 것. 원도 계열에 대한 두 라운드의 통제된 아키텍처 반복에서 (선택은 깨끗한 검증 skill 만으로), 살아남은 메커니즘은 어텐션 풀링 하나뿐이었고 용량 확장·스킵 위상·추가 추출기는 한 번도 도움이 되지 않았다. 확정된 프로토콜 아래에서 같은 교훈이 두 번 더 반복된다: seq_v2 에 관측 마스킹 인과 어텐션을 더한 것은 작고 일관되게 양수이지만 유의하지 않은 이득이었고 (§7), seq_v2 의 5 점 폭 스윙은 평평하다 (§6.9). 모델 절이 짧고 평가 절이 그렇지 않은 이유다.

5 평가 방법론

지표. 모든 오차는 물리 CES 단위로 역정규화되어 타겟별로 계산된다. 1 차 점수는 사전등록된 헤드라인 기준선에 대한 Murphy skill [14], $\text{skill}_{\text{PCHIP}} = 1 - \text{MSE}_{\text{model}}/\text{MSE}_{\text{PCHIP}}$ (양수 = 모델 우위; 0 = 동률) 이다. 모든 팔 (모델과 모든 기준선) 은 동일한 (파일, 행) 샘플 집합에서 동일한 타겟별 유지 마스크로 채점되며, 어떤 짝지는 비교 이전에도 모집단 키가 비트 단위로 동일함을 검증한다. 보간은 타겟 자신의 값을 제외한다 (누수 없음). 보간도 모델 입력도 세그먼트 경계를 넘지 않으며, 경계 너머의 이웃이 필요한 지점에서는 보간이 persistence 값을 대신 예측한다 (모집단 축소 없음, PR2).

기준선 사다리. persistence 와 국소 과거 전용 AR 은 최초 사전등록의 인과 기준이고, 선형-PCHIP-가우시안 과정 (정확한 Matérn-3/2 + 백색잡음, 최근접 16+16 국소 적합, 표본별 주변우도 격자 선택, PR2 fallback 을 그대로 상속) 은 미래를 읽는다. 인과 쪽에는 **인과 GP** 를 추가한다: 같은 GP 를 과거 이웃 16 개로 제한하고 NaN 조건을 동일하게 두어 채점 모집단이 움직이지 않게 한 것이다. 이것이 배치 가능한 가장 강한 기준선임은 분명하며 (시드 42 T_i RMSE 164.3 대 persistence 197.2, 컷 모집단), “배치 가능한 모든 인과 방법을 이긴다” 는 persistence 가 아니라 이 기준선에 대해 판정한다.

3 분할; 선택은 TEST 를 보지 않는다. 파일들은 train/val/test 로 분할된다. 모든 분할의 test 파일은 어떤 아키텍처 탐색 이전에 예약되었고 모델 선택 과정에서 절대 읽지 않는다. 표준 (시드 42) test 셋은 컷 모집단에서 96 개 shot 에 걸친 관측 T_i $n = 32,589$ 행과 60 개 shot 에 걸친 진짜 V_{rot} $n = 10,463$ 행을 담는다 (포함 모집단은 32,721 / 10,461). 4 개 분할 (시드 42, 1, 7, 123) 은 각각 96 개 shot 에 걸쳐 T_i 32.6–35.9k 행, 60–66 개 shot 에 걸쳐 V_{rot} 10.5–14.5k 행을 담는다. 본 논문의 모든 수치는 단일 수집 스크립트가 동결된 실행 디렉터리에서 읽어오므로, 본문-표-그림이 서로 어긋날 수 없다.

사전등록. 해당 test 수치를 보기 전에 문서로 고정한 규칙들은 다음과 같다. **PR1** 헤드라인 비교 대상은 PCHIP(과도 현상에서의 단조성-무진동을 근거로 사전 선택; 사다리 전체도 함께 보고); **PR2** 보간은 모델이 채점되는 모든 곳에서 예측하며, 미래 이웃이 없으면 persistence 로 후퇴하고 그 후퇴 비율을 보고한다 (채점된 T_i 행의 0.3–0.4%, 그러나 **채점된 V_{rot} 행의 40–44%** 이므로 V_{rot} 의 “PCHIP 대비” 는 5 분의 2 가 “persistence 대비” 다); **PR3** test 셋 최소 규모 (≥ 15 shot, $\geq 3,000$ 관측 T_i 샘플; 전부 충족); **PR4** 유의성은 skill 에 대한 shot 군집 bootstrap 95% CI 가 0 을 제외하는 것으로 정의. 확정된 프로토콜은 여기에 다음을 더한다: 유지값 제거 학습-채점; 24-run 스왑의 plateau 최소 규칙에 따른 $W=2$ (§6.8); 윈도 계열의 파일당 샘플 상한 500; §3.5 의 두 공동 1 차 모집단; 그리고 백본 관문, 단 하나의 어텐션 후보, 해석 가능한 사다리 칸, 폭 스왑에 대해 **TEST** 채점 이전에 확정된 모델 결정 규칙 (§7). 임계값 민감도 (2.5/3/4 keV) 도 보고한다.

Shot 군집 paired bootstrap. 한 방전 내 인접 CES 행은 강하게 상관된다. 샘플을 독립으로 취급하면 불확실성이 크게 과소평가된다. 샘플별 짝지는 오차 $SE_{\text{model}} - SE_{\text{PCHIP}}$ 를 shot 단위로 집계하고, shot 전체를 복원추출로 재표본한다 (10,000 회, 고정 시드). 얻어진 CI 는 진짜 shot 간 일반화를 반영한다. 대가는 유효 표본 크기가 shot 수 (T_i 는 ≈ 96 , V_{rot} 은 60–66) 가 된다는 것이며, 이것이 전체 검정력을 제한한다. 모델 대 모델 비교 (백본 대 대조군, 사다리 칸 대 백본) 도 같은 행 위에서 같은 paired bootstrap 을 사용한다.

MNAR 문제와 그에 대한 우리의 대응. 진짜 결측 시점에는 참값이 없으므로 skill 은 관측된 시점을 가려 측정한다. CES 결측은 MNAR 이므로 (저신호, ELM, 천이에서 탈락) 관측 시점 skill 은 진짜 결측 시점 성능의 낙관적 추정이다. §6.5 에서 채점된 지점들을 실제로 결측인 지점들의 공변량 분포 위로 재가중하여 skill 이 얼마나 살아남는지를 보고하고, 아울러 결측 모집단 중 애초에 이 분석의 도메인 안에 있는 비율도 함께 보고한다.

6 결과

6.1 나우캐스터는 모든 인과 기준선을 압도한다

표 1 는 표준 test 분할에서의 물리 단위 RMSE 사다리를 보여준다. seq_v2 는 미래를 읽지 않는 모든 방법 가운데 두 타겟 모두에서 최저 RMSE 를 가지며, 배치 가능한 가장 강한 팔인 인과 GP 를 RMSE 기준 4%(T_i) 와 18%(V_{rot}) 차로 이기고, 미래를 쓰는 보간들도 앞선다. 유일하게 동률인 팔은 잡음 앵커를 통과하는 대신 평균해 내는 오프라인 GP 다 (T_i 153.8 대 157.8). 이는 본 논문에서 가장 강력한 결과다: 미래 CES 가 정의상 없는 모든 온라인 환경에서 시퀀스 나우캐스터는 명백한 승자다.

6.2 헤드라인: T_i 는 두 모집단 모두에서 4 개 독립 분할에 걸쳐 미래를 쓰는 보간을 이긴다

표 2 은 두 공동 1 차 모집단에서 4 개 독립 held-out 분할 (시드 42, 1, 7, 123 — 뒤의 셋은 어떤 선택 단계에도 쓰이지 않았다) 에 대한 백본의 성능을 PCHIP 대비와 인과 GP 대비로 보고한다. 그림 3 는 PCHIP

표 1: 물리 단위 RMSE 사다리. 표준 held-out test 분할 (시드 42), 컷 모집단, 진짜 측정만 ($n = 32,589$ T_i , $10,463$ V_{rot}). 낮을수록 좋다. 아래쪽 세 행은 미래를 읽는다. 포함 모집단에서는 seq_v2 363.0 / 23.7, PCHIP 412.4 / 30.2, 인과 GP 394.6 / 28.8, persistence 478.0 / 33.4(T_i / V_{rot}) 로, 피팅 실패 스파이크가 모든 T_i RMSE 를 두 배 이상으로 키우지만 순서는 바꾸지 않는다.

팔	정보 접근	T_i RMSE (eV)	V_{rot} RMSE (km/s)
seq_v2 (나우캐스터)	고속 진단 + 과거 CES, 세그먼트 전체	157.8	23.6
윈도 대조군 ($W=2$)	고속 진단 + 과거 CES 2 행	169.2	26.1
인과 GP	과거 CES 이웃 16 개	164.3	28.8
Persistence	마지막 관측 CES	197.2	33.4
AR (국소, 인과)	과거 CES 만	472.2	51.0
GP (오프라인)	과거 + 미래 CES	153.8	24.7
선형 보간	과거 + 미래 CES	169.8	29.0
PCHIP 보간	과거 + 미래 CES	173.6	30.2

Physical-unit RMSE ladder on the canonical test split (seed 42, cut population, genuine measurements only). Grey = causal; light = reads the future; the backbone is lowest for both targets.




그림 2: 시드 42 test 분할의 RMSE 사다리 (컷 모집단, 진짜 측정): 인과 나우캐스터가 두 타겟 모두에서 배치 가능한 방법 중 최저 RMSE 를 달성하고 미래를 쓰는 보간도 앞선다. 표 1 와 같은 수치이며, 둘 다 같은 동결 산출물에서 생성된다.

대비 신뢰구간을 보여준다.

- T_i : 두 모집단 모두에서 4 개 분할 전부 PASS. skill_{PCHIP} 는 컷에서 +0.17 ~ +0.26, 포함에서 +0.23 ~ +0.32 이며 모든 shot 군집 CI 가 0 을 제외한다. 8 개 모집단-분할 셀 전부가 인과 GP(+0.08 ~ +0.17) 와 persistence(+0.36 ~ +0.46) 도 이긴다. 이것이 본 논문의 무조건적 주장이다. 오프라인 GP 를 상대로는 백본이 동물이므로 (점추정 $-0.05 \sim +0.11$, 8 개 중 1 개 셀에서 유의), 관측 모집단에 대한 주장은 “사전등록된 보간들과 배치 가능한 모든 인과 방법을 이기고, 미래를 쓰며 표본별로 튜닝된 평활기와는 대등하다” 로 읽힌다.
- V_{rot} : 승리가 아니라 동물. 두 모집단 모두에서 점추정은 모든 분할에서 양수지만, PR4 를 통과하는 것은 1/4(컷) 과 2/4(포함) 이다—둘 다 시드 42, 그리고 포함 모집단의 시드 1 이 [+0.000, +0.286] 이다. persistence 대비로는 두 모집단 모두 3/4 분할에서 통과하고 (+0.30 ~ +0.50; 시드 7 의 CI 는 0 에 닿는다) 인과 GP 대비로는 2/4 다. 4 개 중 1-2 개 유의는 잡음이 만들어낼 수 있는 수준이므로 회전 채널의 승리는 주장하지 않는다.
- 왜 포함 모집단의 수치가 더 높은가. 컷이 없으면 모든 팔이 PCHIP 을 상대로 더 좋은 점수를 받는다 (백본 평균 +0.268 대 +0.236, 대조군 +0.238 대 +0.173). 스파이크가 보간 앵커를 오염시키기 때문이다: 학습된 모델은 스파이크가 낀 이월값을 할인할 수 있지만 보간은 그럴 수 없다. §6.7 이 이 성분을 정량화하며, 이것이 어느 한 모집단만 인용하지 않는 이유다.

6.3 전체격자 프레임링 대 윈도 대조군: 백본 관문

시퀀스 프레임링을 채택할 만했는가? 이 결정은 네 개의 조건을 갖춘 관문으로 사전등록되었고 한 번만 채점되었다 (컷 모집단 — 내부 모델 선택이 수행되는 모집단이다): 분할 시드 $\times$ 초기화 시드의 4×4 격자를

표 2: seq_v2 의 held-out test skill_{PCHIP} 와 shot 군집 95% CI(10,000 회 재표본), 두 모집단. 마지막 열은 같은 행 위에서 인과 GP 에 대해 짝지은 skill 이다. 굵은 글씨 = PASS(CI 가 0 을 제외).

타겟	분할	컷: skill _{PCHIP} (95% CI)	포함: skill _{PCHIP} (95% CI)	인과 GP 대비 (컷 / 포함)
T_i	42	+0.174 [+0.097, +0.236]	+0.225 [+0.109, +0.293]	+0.078 / +0.154
	1	+0.248 [+0.188, +0.295]	+0.238 [+0.153, +0.302]	+0.133 / +0.169
	7	+0.257 [+0.199, +0.302]	+0.292 [+0.232, +0.344]	+0.138 / +0.123
	123	+0.264 [+0.188, +0.320]	+0.316 [+0.186, +0.392]	+0.105 / +0.149
V_{rot}	42	+0.390 [+0.077, +0.591]	+0.384 [+0.066, +0.586]	+0.331 / +0.324
	1	+0.183 [-0.028, +0.280]	+0.195 [+0.000, +0.286]	+0.130 / +0.143
	7	+0.135 [-0.358, +0.269]	+0.132 [-0.362, +0.266]	+0.020 / +0.018
	123	+0.305 [-0.049, +0.437]	+0.304 [-0.065, +0.433]	+0.134 / +0.132

seq_v2 backbone vs. future-using PCHIP on four independent test splits, both populations (shot-clustered 95% CI, B = 10,000; W = 2, held-free)




그림 3: 두 모집단, 4 개 독립 held-out 분할에 걸친 seq_v2 의 skill_{PCHIP} 와 shot 군집 95% CI 의 forest plot. T_i 는 8 개 셀 전부에서, V_{rot} 은 3 개 셀에서 0 을 제외한다.

돌리고, 각 실행을 해당 분할의 $W=2$ 원도 대조군과 행 단위로 짝지었다. 짝지은 T_i skill 은 16/16 실행에서 양수였고 13/16 에서 개별적으로 유의했다. 분할별 초기화 평균은 +0.129, +0.059, +0.078, +0.058 이고 (초기화 산포가 분할 산포보다 훨씬 작다), 통합 평균은 실행 군집 95% CI [+0.067, +0.096] 과 함께 +0.081 이다. 예산을 균등화한 팔 (고정 10 epoch, 최종 가중치, 검증 선택 없음) 도 4/4 분할에서 부호를 유지하므로 (+0.063, +0.033, +0.045, +0.030) 이 이득은 학습 예산 효과가 아니라 아키텍처에서 온다. 그리고 어떤 실행도 유의한 V_{rot} 손실을 보이지 않았다 (8/16 은 유의한 승리). 네 조건이 모두 성립했다. 본 논문의 나머지 전부에서 보고되는 4 개 확정 분할에서 같은 비교는 컷에서 +0.130, +0.058, +0.062, +0.044, 포함에서 +0.053, +0.024, +0.047, +0.029 로 8/8 양수이고 각 모집단에서 2/4 유의다.

이 관문은 프레이밍이 무엇을 사는지도 확정한다. 원도 대조군은 인과 GP 와 동률인 반면 (컷 기준 1/4 분할 유의) 시퀀스 백본은 두 모집단 모두에서 4/4 로 이긴다: 세그먼트의 과거 전체로 뺀는 도달 범위가 배치 가능한 가장 강한 기준선을 넘어서게 하는 요소다. 그 비용은 음수다—샘플별 원도 조립도 조합적 증강도 없기 때문에 백본은 원도 계열의 학습 시간 중 일부만으로 학습된다.

6.4 skill 이 사는 곳: 간극 영역

마지막 관측 CES 로부터의 경과시간 Δt 로 계층화하면, 채점 타겟의 $\geq 96\%$ 가 인접 영역 ($\Delta t \leq 15$ ms) 에 있다. 분할별로는 넓은 구간에 수백 개 샘플밖에 없으므로 4 개 test 분할을 통합하고 bootstrap 을 물리적 방전 단위로 군집한다 (표 3). Δt 가 커질수록 PCHIP 의 과제는 쉬워지고 (간극을 사이에 둔 두 실제 관측을 보간한다) 우리 과제는 어려워지므로, 이 영역은 인과 방법이 이길 것으로 기대하기 가장 어려운 곳이다.

표 3: 간극 계층별 skill. 4 개 test 분할 통합, shot 군집 95% CI, seq_v2. 굵은 글씨 = CI 가 0 을 제외. 샘플이 50 개 미만인 행은 채점하지 않는다.

Δt	n (컷 / 포함)	shot 수	컷: PCHIP 대비	포함: PCHIP 대비
T_i				
≤ 15 ms	134,546 / 135,317	301	+0.239 [+0.197, +0.274]	+0.299 [+0.244, +0.347]
> 15 ms	3,422 / 3,334	265 / 263	+0.268 [+0.187, +0.337]	+0.206 [+0.108, +0.290]
> 45 ms	460 / 429	104 / 101	+0.267 [+0.092, +0.414]	-0.004 [-0.304, +0.246]
V_{rot}				
≤ 15 ms	51,689	197	+0.233 [+0.020, +0.318]	+0.233 [+0.020, +0.317]
> 15 ms	466 / 456	130	+0.418 [+0.104, +0.680]	+0.432 [+0.128, +0.696]
> 45 ms	14	7	—	—

T_i 의 승리는 인접 이력에 국한되지 않는다. 15 ms 를 넘어서도 백본은 두 모집단 모두에서 미래를 쓰는 PCHIP 을 이기고 (+0.268 과 +0.206, 두 CI 모두 0 위), 거기서 persistence 는 +0.40 과 +0.43 으로 이긴다. 45 ms 를 넘어서면 컷에서는 여전히 이기지만 (+0.267) 포함 모집단에서는 동물이다 (-0.004, CI [-0.30, +0.25]): 101 개 shot 의 429 행은 소수의 스파이크 앵커 행이 한 계층을 지배할 수 있는 바로 그 지점이며, 우리는 이를 동물로 보고한다.

V_{rot} 은 보간에게 가장 어려운 그 한 곳에서 보간을 이긴다. 전역 V_{rot} 동물은 인접 영역에서의 동물이다. $\Delta t > 15$ ms 에서는 백본이 두 모집단 모두에서 PCHIP 을 이기며 (+0.418 과 +0.432, 130 개 shot) — 본 논문에서 유일한 무조건적 V_{rot} 긍정 판정이다 — ≤ 15 ms 에서는 persistence 를 이긴다 (+0.39). 가장 넓은 구간은 14 행뿐이라 채점하지 않는다.

6.5 실제로 결측인 지점에서는 이 중 얼마나 살아남는가?

지금까지의 모든 것은 마침 관측된 CES 지점에서 측정된 것이다. 참값이 없는 곳에서 오차를 측정할 수는 없다. 그러나 관측 행과 결측 행 모두에서 계산 가능한 공변량 위에서 skill 이 어떻게 변하는지는 측정할 수 있고, 재가중할 수 있다. 기전을 담는 공변량은 둘이다: 마지막 진짜 관측으로부터의 Δt (15/25/45 ms 로 구간화) 와 §6.10 의 입력 전용 국소 활동 플래그다. 후자는 자기 행을 제외한 이웃 집합으로 계산되므로 결측 행에서도 정의된다. $\Delta t \times$ 활동으로 사후 계층화하고, 채점 샘플이 30 개 미만인 계층은 버리며, 모든 추정치 옆에 살아남은 커버리지를 함께 보고한다. 가중 격자는 모집단과 일관되게 만든다 (컷은 여기에도 적용한다). 한 계층 안에서 결측 행과 관측 행이 교환 가능하다는 가정은 없앤 척하지 않고 명시한다.

먼저, 적용 범위에 관한 결과. 이 분석의 도메인은 “해당 타겟의 진짜 관측이 두 행 이내에 있음” 이라는 $W=2$ 기준이다. 진짜 결측인 T_i 행 가운데 분할별로 54–68% 가 도메인 안이고, 진짜 결측인 V_{rot} 행 가운데는 4–6% 뿐이다. V_{rot} 간극이 긴 블록이기 때문이다 (살아남은 계층의 커버리지는 T_i 0.99, V_{rot} 0.73–0.76). 따라서 재가중된 V_{rot} 행은 결측 질량의 20 분의 1 에 대한 질문에 답하는 것이며, 우리는 거기서 아무것도 끌어내지 않는다.

둘째, 두 비교가 갈라지며 — 그 갈라짐 자체가 쓸모 있는 것이다. persistence — 온라인 시스템이 실제로 돌리는 기준선 — 를 상대로는 T_i 우위가 두 모집단 모두에서 4 개 분할 전부 재가중을 견딘다 (+0.28 ~ +0.44, 모든 CI 가 0 을 제외). MNAR 보정이 앓아가는 skill 은 많아야 0.12 이고 어떤 분할에서는 전혀 없다. 미래를 쓰는 PCHIP 을 상대로는 재가중된 점추정이 +0.14 ~ +0.28 에 머물지만, 고정 가중치의 넓은 CI 가 컷 모집단 2 개 분할에서 0 을 지난다 (2/4 유의; 포함 모집단은 4/4). 결측 지점은 더 큰 Δt 에 놓이는데, 그곳이 바로 양쪽 앵커가 가장 크게 도움이 되고 재가중 bootstrap 이 가장 얇은 곳이다. 따라서 정말 중요한 지점들에서 증거가 지지하는 주장은 다음과 같다: 진짜 결측이면서 도메인 안인 시점에서 나우캐스터는 두 모집단 모두에서 CES 단독의 어떤 인과 방법보다 유의하게 낮고, 오프라인 보간보다는 모집단 조건부 유의성 (컷 2/4, 포함 4/4) 으로 낮다. 원도 대조군도 같은 방식으로 거동한다 (PCHIP 대비 2/4 와 4/4, persistence 대비 4/4).

표 4: 관측 모집단에서 진짜 결측이면서 도메인 안인 모집단으로 재가중한 seq_v2 의 T_i skill(계층 가중치를 고정한 shot 군집 95% CI). 굵은 글씨 = CI 가 0 을 제외. 무가중은 표 2 의 헤드라인이다.

모집단	분할	PCHIP 대비		persistence 대비	
		무가중	결측 정합 (95% CI)	무가중	결측 정합 (95% CI)
컷	42	+0.174	+0.140 [-0.071, +0.290]	+0.360	+0.398 [+0.278, +0.518]
	1	+0.248	+0.164 [+0.062, +0.250]	+0.406	+0.366 [+0.299, +0.448]
	7	+0.257	+0.203 [-0.024, +0.346]	+0.403	+0.310 [+0.227, +0.398]
	123	+0.264	+0.283 [+0.069, +0.392]	+0.415	+0.381 [+0.246, +0.464]
포함	42	+0.225	+0.140 [+0.033, +0.250]	+0.423	+0.443 [+0.141, +0.623]
	1	+0.238	+0.217 [+0.086, +0.319]	+0.436	+0.383 [+0.273, +0.536]
	7	+0.292	+0.167 [+0.067, +0.265]	+0.406	+0.283 [+0.172, +0.380]
	123	+0.316	+0.221 [+0.050, +0.320]	+0.459	+0.337 [+0.164, +0.455]

표 5: 시간 (캠페인) 분할, 4 개 초기화, 뒤쪽 방전 97 개로 이루어진 TEST 블록. 항목은 skill_{PCHIP} 이며 **굵은 글씨** = PR4 PASS. 마지막 열은 같은 행 위에서 원도 대조군에 대한 seq_v2 의 짝지는 T_i skill 이다.

모집단	팔	T_i PCHIP 대비 (초기화 42 / 1 / 7 / 123)	PASS	T_i 인과 GP 대비	seq_v2 - 대조군
컷	원도 대조군 (OFF)	+0.027 / +0.091 / -0.001 / +0.061	2/4	0/4	—
	대조군, shot 별 표준화 (ON)	+0.103 / +0.107 / +0.094 / +0.107	4/4	—	—
	seq_v2	+0.187 / +0.174 / +0.181 / +0.177	4/4	4/4 (+0.11 ~ +0.12)	+0.164 / +0.091 / +0.182 / +0.124
포함	원도 대조군 (OFF)	+0.014 / +0.047 / +0.055 / +0.089	0/4	0/4	—
	seq_v2	+0.173 / +0.202 / +0.198 / +0.184	4/4	4/4 (+0.13 ~ +0.16)	+0.161 / +0.163 / +0.151 / +0.104

6.6 캠페인 이동을 견디는가?

무작위 분할이 하지 않지만 실제 배치가 하는 두 번째 일은 시간상 앞으로 나아가는 것이다. 641 개 방전 전부를 shot 번호 (30801–32751) 로 정렬하고 시간으로 엄격히 잘랐다: **train 416 shot [30801, 31991]**, **val 128 [32002, 32310]**, **test 97 [32312, 32751]** 이며 어떤 test shot 도 어떤 train shot 보다 앞서지 않는다. 나머지는 전부 헤드라인 프로토콜에 고정되어 바뀐 변수는 분할 규칙 하나뿐이다. 분할이 고정되어 있으므로 네 번의 실행은 초기화 시드만 달리하며, 이를 4 개 분할인 것처럼 제시하지 않고 그대로 밝힌다. 모집단마다 세 개의 팔을 둔다: 헤드라인에서 학습된 그대로의 원도 대조군 (학습 파일 전용 정규화), 고속 진단을 shot 별로 표준화한 같은 대조군 (컷 모집단), 그리고 seq_v2 이다 (표 5, 그림 4).

이 표에서 명시할 만한 것이 셋 있다. 첫째, 원도 모델의 오프라인 보간 대비 우위는 이동을 견디지 못한다: 2/4(컷) 와 0/4(포함) 초기화이며, 인과 GP 대비로는 0/4 다. 둘째, 이름이 지목되었던 그 수리가 작동한다: 각 방전의 고속 진단을 그 방전 자신의 평균·분산으로 적재 시점에 표준화하면 (타겟은 손대지 않는다) 컷 모집단의 관문이 2/4 에서 4/4 로 올라가고 짝지는 값은 +0.078, +0.018, +0.095, +0.049(3/4 유의) 이며 V_{rot} 은 변하지 않는다 (-0.003 ~ +0.008) — V_{rot} 헤드가 고속 진단을 애초에 보지 않으므로 기대되는 음성 대조다. 셋째, 그리고 이것이 이 절의 결과다: **시퀀스 나우캐스터는 붕괴하지 않는다**. 두 모집단 모두에서 4/4 초기화에 대해 PCHIP 을 이기고 (+0.17 ~ +0.20), 두 모집단 모두에서 4/4 로 인과 GP 를 이기며 (+0.11 ~ +0.16), 8/8 에서 원도 대조군을 이긴다. V_{rot} 은 원도 대조군이 0/4 인 자리에서 두 모집단 모두 4/4 로 persistence 를 이기고 (+0.31 ~ +0.34), 대조군 대비 V_{rot} 마진은 8/8 에서 유의하다 (+0.06 ~ +0.18).

대조군이 왜 나빠지는가 — 단언이 아니라 측정. 전이에 실패해야 하는 것은 고속 진단 경로다. CES 단독 보간 대비 우위를 사는 것이 바로 그 경로인 반면, CES 이력 경로는 두 기간 모두에서 같은 물리량을 같은 단위로 보기 때문이다. 대조군이 정규화된 그 단위에서 채널별 train→test 드리프트를 측정하면 이것이 확인된다: 위치 이동의 중앙값은 **BES 가 1.22σ , ECEI 가 0.53σ** 이고 척도 비는 각각 0.75 와 0.62 인 반면, **CES 타겟 자신은 0.115σ 에 척도 비 1.06** 이다. 고속 진단은 예측 대상보다 5–11× 더 이동한다. 학습 파일 전용 정규화 (§3) 는 무작위 분할에서는 올바른 누수 방지 선택이지만 캠페인 이동에서 바로 그것이 깨진다. shot 별 표준화는 그 방전 자신의 데이터만 쓰므로 누수가 없다. seq_v2 는 정의상 shot 별로 표준화하며—이것이 전이가 되는 두 이유 중 하나이고, 다른 하나는 도달 범위다 (§6.3).




그림 4: 캠페인 (시간) 분할: 원도 대조군의 보간 대비 우위는 붕괴하고, shot 별 표준화가 이를 복구하며, 시퀀스 나우캐스터는 두 모집단 모두에서 우위를 유지한다. 막대는 4 개 초기화의 평균이며 초기화별 점과 PR4 카운트를 함께 표시한다.

표 6: 스트레스 하의 두 주장, seq_v2, T_i . 항목은 PR4 통과 수 (컷 / 포함) 와 점추정 범위다.

평가	PCHIP 대비 (오프라인, 미래 사용)	인과 기준선 대비
무작위 분할, 관측 지점	4/4 / 4/4, +0.17 ~ +0.32	인과 GP 대비 4/4 / 4/4, +0.08 ~ +0.17
결측 지점으로 재가중 (§6.5)	2/4 / 4/4, +0.14 ~ +0.28	persistence 대비 4/4 / 4/4, +0.28 ~ +0.44
시간 캠페인 분할 (§6.6)	4/4 / 4/4, +0.17 ~ +0.20	인과 GP 대비 4/4 / 4/4, +0.11 ~ +0.16

두 개의 스트레스 테스트, 하나의 독법. 표 6 는 채택된 모델에 대해 둘을 나란히 놓는다. 실시간 시스템 이 실제로 돌릴 수 있는 기준선들에 대한 우위는 두 모집단 모두에서 두 스트레스 테스트를 모두 견딘다. 미래를 쓰는 보간에 대한 우위는 두 모집단 모두에서 시간 이동을 견디고, MNAR 재가중은 모집단 조건부 유의성으로 견딘다. 이 표의 원도 모델 판본—본 연구의 이전 초안이 보고했던 것—에서는 오프라인 우위가 두 테스트 모두 견디지 못했다. 그것을 바꾼 것이 시퀀스 프레이밍이며, 새 열이 원래부터 거기 있었던 것처럼 제시하지 않고 그대로 밝힌다.

남는 단서. 네 번의 캠페인 통과는 하나의 시간 test 블록 위의 초기화들이므로 이는 4 개 분할의 증거가 아니라 하나의 시간 분할의 증거이며, 컷 모집단 seq_v2 캠페인 실행 4 개 중 2 개는 30-epoch 상한에서 멈췄다.

6.7 $T_i \leftrightarrow V_{rot}$ 정보 비대칭

원도 대조군에 대한 통제된 입력 모달리티 절제—한 모달리티 그룹을 평가 시점에 0 으로 만들고, 재학습은 하지 않으며, persistence 와 보간은 실제 이력에서 계산—는 두 타겟이 왜 다르게 거동하는지를 설명하고 §4 의 라우팅을 확정된 프로토콜 아래에서 다시 근거 짓는다 (표 7, 그림 5).

- **이력은 두 타겟 모두에 필수불가결하다.** CES 이력이 없으면 원도 모델은 두 모집단의 두 타겟 모두에서 PCHIP 대비 -1 에서 -4 까지 떨어진다: 자기 앵커 없이 100 Hz 진단만으로 예측 가능한 타겟은 없다.
- T_i : **보간 대비 마진은 고속 진단 정보다 — 컷 모집단에서.** BES/ECEI/MC 를 0 으로 만들면 대조군은 보간기 아래로 떨어진다 ($-0.10 \sim -0.18$; 짝지은 변화 $-0.25 \sim -0.43$, 4/4 유의). 물리 채널은 충돌성 전자-이온 결합이며 ($t_{ei} \propto T_e^{3/2}/n_e$), ECEI 가 T_e 를, BES 가 n_e 구조를 공급한다.
- **포함 모집단에서는 같은 이력 전용 모델이 여전히 PCHIP 을 $+0.15 \sim +0.23$ 로 이기며,** 고속 채널이 더하는 것은 0.03–0.09 뿐이다 (2/4 유의). 보간기의 앵커에 스파이크가 끼어 있고, 학습된 모델은 보간이 할 수 없는 방식으로 그것을 할인하기 때문이다. 따라서 스파이크 포함 마진에는 고속 진단 정보가 아닌 스파이크 강건성 성분이 들어 있으며, 이것이 본 논문이 더 좋아 보이는 한쪽이 아니라 두 모집단을 보고하는 측정된 이유다. 고속 진단의 기여를 분리해 내는 쪽은 컷 모집단이다.

표 7: $W=2$ 윈도우 대조군의 평가 시점 모달리티 절제, TEST, 두 모집단: skill_{PCHIP}(4 개 분할 평균) 와 절제하지 않은 실행에 대한 짝지은 변화 (분할 42 / 1 / 7 / 123; * = 유의하게 악화).

입력	타겟	컷	포함
전체 (이력 + 고속 + 시간)	T_i	+0.173	+0.238
이력 + 시간만 (고속 없음)	T_i	-0.125; 짝지은 $-0.25^* / -0.38^* / -0.42^* / -0.43^*$	+0.201; 짝지은 $-0.03^* / -0.04 / -0.03 / -0.09^*$
고속 + 시간만 (이력 없음)	T_i	-2.11; 짝지은 $-4.6^* / -1.8^* / -2.3^* / -1.9^*$	-1.16; 짝지은 $-1.5^* / -3.4^* / -1.2^* / -1.1^*$
전체	V_{rot}	+0.213	+0.206
이력 + 시간만 (고속 없음)	V_{rot}	+0.213; 짝지은 $+0.000 \times 4$ (비트 동일)	+0.206; 짝지은 $+0.000 \times 4$ (비트 동일)
고속 + 시간만 (이력 없음)	V_{rot}	-2.89; 짝지은 $-5.4^* / -6.3^* / -1.8^* / -2.3^*$	-3.51; 짝지은 $-6.9^* / -7.8^* / -1.9^* / -2.2^*$




그림 5: 윈도우 대조군의 평가 시점 모달리티 절제, 두 모집단. 고속 진단을 0 으로 만들면 V_{rot} 은 비트 단위로 동일하고 컷에서는 T_i 마진이 사라진다. 이력을 0 으로 만들면 두 타겟 모두 붕괴한다.

- V_{rot} : 정보는 전적으로 CES 이력이며, 구조적으로도 측정으로도 그렇다. 고속 진단을 0 으로 만들어도 V_{rot} 출력은 8/8 모집단-분할 셀에서 비트 단위로 동일하고 (라우팅이 구조적이다), seq_v2 와 b3k8 의 V_{rot} 분기도 같은 교란 시험을 통과한다. 토로이달 회전은 우리 입력 중 어느 것도 관측하지 않는 운동량 원천—외부 NBI 토크와 고유 회전 구동 [50]—이 지배하며, Mirnov 신호는 100 Hz 로 샘플되어 회전의 대리가 될 수 있었을 kHz 모드 회전 주파수를 앨리어싱으로 잃는다 (§9).

이 비대칭은 절제 실험 이전에 물리로부터 예측되었고 절제로 확인되었다. V_{rot} 의 비승리는 모델의 실패가 아니라 진단 정보량에 관한 발견이며, §4 의 타겟별 라우팅을 정당화한다.

6.8 이력은 얼마나 필요한가? 관측 하나

윈도우 계열의 이력 윈도우는 원래 검토되지 않은 기본값이었다 ($W=4$). 우리는 그 단언을 곡선과 명시된 선택 규칙으로 대체했다: **24 회의 독립 실행**, $W \in \{2, 3, 4, 6, 8\} \times$ 시드 $\{42, 1, 7, 123\}$ 에 더해 *history-0* 지점 $\times 4$ 시드이며, 각각 헤드라인과 동일한 프로토콜 (유지값 제거, 파일당 상한 500, 스파이크 컷 없음—이 스윙은 컷보다 앞서며, 동결된 $W=2$ 실행이 §6.2 의 포함 모집단 대조군이다) 로 자기 held-out test 분할에서 채점된다. 세 가지 통제가 지점들을 비교 가능하게 만든다: 파일 단위 분할이 윈도우에 불변이고 (모든 실행이 시드별로 같은 96 개 test shot 을 평가한다), 파일당 상한이 시간 부분집합 증강— $W=2$ 의 240k 샘플에서 $W=8$ 의 30.1M 으로 폭발한다—이 소수의 긴 블록 방전에 지배되는 것을 막으며, 채점 모집단은 $W=2$ 에서 $W=8$ 까지 1.8% 만 줄어든다.

이력은 필수적이며, 그 첫 관측 하나가 사실상 전부를 담는다. 이전 CES 를 완전히 제거하면 T_i 는 PCHIP 아래로 내려가고 ($-0.026, 0/4$) V_{rot} 은 -0.78 이 된다. 단 하나의 과거 관측이 두 타겟을 곧바로 plateau 로 끌어 올리고 곡선은 거기서부터 평평하다: T_i 는 0.190–0.246, V_{rot} 은 0.190–0.206 범위인데, 한 지점 안에서의 시드 산포가 0.07–0.16 으로 곡선 전체보다 넓다. “plateau 에 도달하는 가장 작은 W ” 를 적

표 8: Window 스윙, 4 시드에 걸친 held-out test skill_{PCHIP} 평균 (PASS = shot 군집 95% CI 가 0 을 제외 하는 시드 수). History-0 은 $W=4$ 에서의 no_history 절제이며, $W=1$ 은 구성할 수 없다.

이력 관측 수	W	T_i skill	PASS	V_{rot} skill	PASS
0	4	-0.026	0/4	-0.783	0/4
1	2	+0.238	4/4	+0.206	0/4
2	3	+0.246	4/4	+0.203	1/4
3 4 (구 기본값)		+0.221	3/4	+0.190	1/4
5	6	+0.190	3/4	+0.205	1/4
7	8	+0.216	4/4	+0.204	2/4

표 9: 복잡도 사다리, T_i 에 대한 held-out TEST skill_{PCHIP}(4 개 분할 평균) 와 사전등록 규칙의 짝지은 판정, 두 모집단. 앵커 + Δ 모델은 $W=2$ 에서 persistence 로 붕괴한다 (기울기 향이 관측된 이력 행 두 개를 필요로 하는데 결코 발화하지 않는다).

팔	파라미터	컷	포함	b3k8 - 앵커 (T_i , 컷 / 포함)	b3k8 - seq_v2 (T_i , 컷 / 포함)
Persistence	0	-0.264	-0.288		
앵커 + Δ (명명된 항)	1,258	-0.261	-0.287	+0.35 ~ +0.42, 4/4* / +0.29 ~ +0.34, 4/4* 평균 +0.002 (모든 CI 가 0 포함) / 평균 -0.194 (4/4*)	
b3k8	21,498	+0.237	+0.126		
원도 대조군	201,258	+0.173	+0.238		
seq_v2 백본	357,570	+0.236	+0.268		

용하면 $W=2$ 가 나온다. 기존의 $W=4$ 는 두 타겟 모두에서 $W=2/W=3$ 값보다 아래이므로, 정확도를 근거로 더 긴 원도의 비용을 치를 이유는 데이터 안에 없다. 더 넓게 가야 할 방어 가능한 이유는 **커버리지** 하나다: 원도 샘플은 원도 안에 관측값이 있을 때만 채점되므로 $W=2$ 에서 $W=8$ 로 가면 $\Delta t > 15$ ms 채점 행이 $456 \rightarrow 1,958$ 개, $\Delta t > 45$ ms 가 $14 \rightarrow 135$ 개가 된다. 이는 더 긴 원도의 근거가 아니라, 도달 범위가 세그먼트 전체이고 W 가 하이퍼파라미터가 아닌 시퀀스 프레이밍의 근거다.

6.9 복잡도는 무엇을 사고, 크기는 도움이 되는가? 사다리와 폭 스윙

학습된 나우캐스터에 대한 정당한 비판 하나는 그 파라미터를 설명할 수 없다는 것이다. 유용한 답변은 같은 프로토콜 아래에서, TEST 채점 이전에 고정된 결정 규칙으로 복잡도가 무엇을 벌어들이는지 측정하는 것이다.

해석 가능한 사다리 칸. b3k8(§4) 는 작은 인과 GRU 가 낸 $z \in [-1, 1]^K$ 와 0 으로 초기화된 readout 으로 $\hat{y} = \text{이월값} + \sum_{k=1}^K w_k z_k + b$ 를 예측하므로, (i) $K+1$ 개 명명된 항으로의 분해가 귀속 근사가 아니라 정확하고, (ii) readout 이 볼 수 있는 모든 수는 K 개의 탐침 가능한 잠재 중 하나이며, (iii) 보정은 타겟 σ 단위로 $\sum_k |w_k| + |b|$ 에 의해 유계다. K 는 탐색된 유일한 변수였고 (검증만, 두 분할; $K=8$ 선택), 두 팔 모두 구속력 없는 상한과 같은 patience 규칙으로 멈춘다. 사전등록된 조건은 둘이다: 재학습된 명명된 항 앵커 + Δ 모델 (1,258 파라미터) 을 V_{rot} 손실 없이 4/4 분할에서 이길 것, 그리고 백본의 T_i skill 대비 평균 -0.05 이내에 머물 것.

- 컷에서는 백본의 T_i skill 전부가 유계 수 여덟 개와 persistence 로의 압축을 건딘다. b3k8 는 V_{rot} 손실 없이 4/4 분할에서 재학습된 앵커를 이기고, 백본에 대한 짝지은 T_i skill 은 -0.009, -0.005, +0.026, -0.004 이다 (평균 +0.002, 모든 CI 가 0 을 포함). PCHIP 대비 PR4 를 4/4 로 통과하고 인과 GP 도 4/4 로 이긴다. TEST 입력에 대한 선형 probe(타겟은 건드리지 않음) 는 T_i 잠재가 마지막 관측 T_i (R^2 0.47-0.75) 와 ECEI T_e 대리 지표 (0.31-0.48) 를 여러 차원에 분산해 부호화하며, 국소 BES 활동 (0.09-0.13) 이나 경과시간 (0.01-0.07) 은 거의 부호화하지 않음을 보인다. 학습된 보정은 예측 분산의 25-39% 를 설명한다. 이 과제에 필요한 것은 전체격자 인과 상태이며, 그 상태는 작다.
- 컷이 없으면 이 사다리 칸은 백본 대비 -0.16 ~ -0.21 을 치르고 (4/4 유의) 3/4 분할에서 원도 대조군 아래에 놓인다 — 잠재 여덟 개가 너무 적어서가 아니라, 유계 보정으로는 스파이크가 긴 이월값을 복구할 수 없기 때문이다: persistence 오차가 2 keV 를 넘는 행은 포함 모집단 test 행의 0.6-1.3% 인데 b3k8 의 T_i 제곱오차의 73-83% 를 담는다 (PCHIP 을 포함한 다른 모든 팔에서도 70-83% 다). 사다리 칸 조건은 거기서도 성립하지만 (앵커 대비 4/4) 백본 허용 조건은 컷 조건부이며, 우리는 그렇게 진술한다.

Complexity ladder and width scaling: the T_i skill is flat from 21k to 879k parameters (cut population); the interpretable rung equals the backbone only under the cut




그림 6: 복잡도 사다리와 폭 스위칭을 한 축에 놓은 그림 (TEST T_i skill 대 학습 가능 파라미터 수, 4 개 분할 평균). 컷에서는 21k 잠재 병목 모델이 백본의 곡선 위에 놓이고 곡선은 34k 에서 879k 파라미터까지 평평하다. 포함 모집단에서는 유계 보정 사다리 칸이 +0.126 으로 떨어진다.

- **용량을 더 사도 얻는 것이 없다.** seq_v2 의 T_i 인코더를 24 에서 260 유닛으로 넓히면 (34k / 49k / 114k / 358k / 879k 파라미터, 다른 설정은 전부 고정, 지점마다 TEST 1 회) T_i skill 평균은 +0.230 / +0.236 / +0.235 / +0.236 / +0.230(컷) 이고, 358k 백본에 대해 짝지은 평균은 ± 0.008 이내이며, 가장 넓은 지점이 유의하게 나은 것은 1/4 분할, 24 유닛까지 내려가도 $\geq 3/4$ 에서 유의하게 나쁜 쪽은 없다. V_{rot} 은 (분기가 고정되어) 움직이지 않는다 (+0.250 ~ +0.254). 사다리 칸과 함께 이것은 모델 크기 축을 닫는다: {100 Hz BES/ECEI/MC + CES 이력 + 시간} 에 든 T_i 정보는 ~50k 파라미터의 인과 순환 상태로 소진되며, 분할 간에 남는 분산 (시드 42 의 +0.14 ~ +0.17 대 시드 123 의 +0.23 ~ +0.28) 은 용량이 아니라 분할 분산이다.

6.10 우위는 고변동 국소 구간에 집중된다

타겟과 무관한 입력 측 국소 활동 대리 지표 (이웃 괄호 기울기가 크거나 국소 CES 이웃 분산이 높음, 타겟 행을 제외하고 계산) 를 사용해 각 TEST 분할을 “peak”(고활동; 분할당 T_i 4.1–4.6k 행, V_{rot} 2.4–2.9k 행) 와 bulk 행으로 나누고, 각각에서 shot 군집 bootstrap 으로 seq_v2 를 채점한다 (그림 7).

- T_i : peak 계층 skill_{PCHIP} 는 컷에서 +0.45 ~ +0.61, 포함에서 +0.62 ~ +0.72 이며, 미래 이웃을 가진 보간기를 상대로 8/8 PASS 다. bulk 는 컷에서 +0.09 ~ +0.20(PASS 4/4), 포함에서 +0.06 ~ +0.19(PASS 2/4) 를 닫는다. 매끄러운 bulk 에서는 보간이 거의 최적이며, 모델의 가치는 활동 구간에 있다 — 그리고 이 진술은 무조건적이다.
- V_{rot} : peak 계층 skill 은 +0.54 ~ +0.79(8/8 에서 점추정 양수, 각 모집단에서 PASS 2/4, persistence 대비로는 +0.75 ~ +0.86 에 8/8 PASS) 이고 bulk 에서는 ≈ 0 이다 (−0.07 ~ +0.15, PASS 0/8). 따라서 비대칭은 지역적이다: 전역적으로 V_{rot} 은 보간과 동물이지만, 매끄러운 과거 + 미래 보간이 가장 나쁜 고활동 국소 구간에서는 이력 기반 V_{rot} 예측기조차 가치를 더한다. 이를 전역 영가설의 뒤집힘이 아니라 유의성 기반이 얇은 지역적 강점으로 보고한다.

6.11 컷 임계값 민감도

스파이크 임계값을 2.5 와 4 keV 로 두고 백본을 재학습하면 (각각 4 개 분할, 자기 모집단에서 채점) T_i skill 평균이 +0.230 과 +0.232 로 3 keV 의 +0.236 에 대응하고, 모든 임계값에서 PCHIP 대비 PR4 4/4, 인과 GP 대비 4/4 이며, V_{rot} 은 +0.252 / +0.253 / +0.257 이다. 물리학자가 방어할 만한 범위 안에서 임계값은 무의미하다. 중요한 것은 꼬리 안의 어디에서 자르느냐가 아니라 두 모집단이다.

7 모델 선택 프로토콜

본 논문의 모든 모델 결정은 검증 데이터 위에서, 또는 해당 TEST 채점 이전에 문서로 확정된 결정 규칙 아래에서 이루어졌고, TEST 는 결정마다 한 번만 채점되었다.

The backbone's edge concentrates where interpolation is weakest: peak-stratified TEST skill, both populations




그림 7: seq_v2 의 peak 계층별 TEST skill, 두 모집단 (4 개 분할 평균, 분할별 점, PR4 카운트). 보간 대비 우위는 보간이 가장 약한 곳에 집중되며, V_{rot} skill 은 전적으로 peak 계층에 산다.

원도 계열. 그 아키텍처는 통제된 실험의 연속으로 도달했다. 각 실험은 데이터 계약을 보존해야 하는 하나의 변경이었고, 깨끗한 비증강 검증 skill_{PCHIP} 로 채점되었으며—증강된 검증 손실은 보간이 이미 강한 바로 그곳에서 평활화를 보상하므로 결코 쓰지 않았다—지금까지의 최고 점수를 개선할 때만 유지되었다. 이후 이력 길이는 §6.8 의 스위프로 정해졌고, 유지값은 §3.4 의 감사에 따라 학습에서 제거되었다.

백본 관문. 시퀀스 프레이밍은 §6.3 의 네 조건 관문 (4/4 분할에서 부호 유지, 통합 실행 군집 CI 가 0 을 제외, 예산 균등화에서도 부호 유지, V_{rot} 손실 없음) 이 먼저 고정되고 그 다음 충족된 뒤에야 채택되었다. 같은 규칙 아래에서 이후 탐색된 단 하나의 아키텍처 후보—각 타겟 자신의 과거 관측 스텝에 대한 관측 마스킹 인과 어텐션을 0 으로 초기화된 사영과 함께 seq_v2 에 추가한 것—은 4/4 분할에서 양수였으나 (백본 대비 +0.009, +0.013, +0.033, +0.020) $\geq 3/4$ 라는 사전 확정 기준에 대해 1/4 에서만 유의했으므로 승격되지 않았고, 백본은 seq_v2 로 남았다. 이 후보의 검증 이득은 탐색 분할에서 2/2 유의했는데, 이는 선택 분할 결과의 통상적 낙관이며 승격 기준을 TEST 에 두는 이유다.

사다리 칸과 폭 스위치 (§6.9) 은 두 갈래 판정과 서술적 독법 (천장 / 무릎) 을 어떤 TEST 채점 이전에 적어 두었고, 구성상 이 스위치 위에서 백본을 재선택하는 것은 허용되지 않았다. 전체 사전등록 문서와 배치별 실행 기록, 러너 스크립트는 공개 저장소에 있다.

8 배치 가능한가?

skill 점수와 쓸 만한 계측기 사이에는 두 가지가 놓여 있다. 측정 주기 안에서 돌아야 하고, 얼마나 믿어도 되는지를 말할 수 있어야 한다.

지연시간: 상태 유지형 1-스텝 추론은 여유를 두고 CPU 에 들어간다. CES 는 10ms 격자 위에 있으므로 온라인 결측 채움기는 한 스텝당 10ms 에서 획득과 제어가 이미 쓰는 몫을 뺀 시간을 갖는다. 순환 나우캐스터는 온라인에서 상태를 유지한 채 실행된다: 은닉 상태가 격자를 따라 이월되고 새 행마다 배치 1 의 순환 스텝 하나가 드는데, 이것이 실제로 중요한 수치다. 유틸리티의 노트북급 머신에서 워밍업 후 1,000 회 호출을 계측해 네트워크 순전파만 (특징 조립은 모델 밖이다) 잦 값으로, seq_v2 스텝은 **CPU 에서 중앙값 1.05ms, p99 1.61ms**(격자 주기의 16%; p95 1.35ms), GPU 에서 1.21 / 2.31ms 이다—이 크기에서 GPU 는 배치 1 에서 아무것도 사주지 않는다. 오프라인 채점이 쓰는 세그먼트 전체 재실행은 CPU 에서 100 행 (1s) 블록당 중앙값 2.9ms / p99 5.6ms, 300 행당 6.4 / 8.9ms, 즉 대량 재처리 기준 35–47k 행/s(GPU 47–63k 행/s) 이다. 배치 1 의 원도 대조군은 더 느리고 이 머신에서는 꼬리가 무겁다: $W=2$ 는 CPU 중앙값 3.8ms 이지만 p99 18.9ms(GPU 7.2 / 11.6ms), $W=4$ 는 4.0 / 8.1ms. 같은 벤치마크를 유틸리티 상태에서 두 번 돌린 결과는 절대값에서 최대 2× 차이가 났고 (다른 실행에서 seq_v2 스텝은 중앙값 / p99 0.51 / 0.99ms), 노트북의 전원 상태가 이 수치를 움직이기 때문이지만 순서—시퀀스 스텝 $\ll$ 원도 순전파,

CPU 로 충분—는 바뀌지 않았다. 따라서 실무 지침은 상태 유지형 나우캐스터를 제어 계산기의 CPU 에서 돌리라는 것이며, 10 ms 예산의 80% 이상이 획득과 제어에 남는다.

불확실성: 모델을 건드리지 않는 분포 무가정 구간. 핵융합 프로파일 데이터의 커뮤니티 표준은 사후분포를 돌려주는 가우시안 과정 회귀이고, 우리 모델은 점추정을 돌려준다. 분산 헤드나 분위 헤드를 붙이면 재학습이 필요하고 위의 모든 수치가 움직이므로, 대신 *split conformal prediction* 을 쓴다: 해당 실행 자신의 검증 분할에서 보정하고, 예측기는 아무것도 바꾸지 않으며, 분포 무가정 유한표본 주변 커버리지를 얻는다. 변형은 둘이다: 단일 분위 (*global*) 와 Δt 구간별 분위 (*Mondrian*). 동일한 절차를 PCHIP 과 persistence 에도 적용하므로 비교되는 것은 보정 기법이 아니라 구간의 품질이다. $\alpha = 0.10$, TEST, 두 모집단에서:

- **모델의 구간이 모든 셀에서 두 기준선의 구간을 이긴다** ($32/32$ 모집단 $\times$ 타겟 $\times$ 변형 $\times$ 분할). 폭과 빛나감을 함께 벌하는 Winkler 구간 점수 기준으로 컷 모집단의 T_i 는 1,272 대 1,554(PCHIP) 대 1,727(persistence), 포함 모집단은 2,290 대 2,851 대 3,120 이며, V_{rot} 은 150 대 164 대 179 이다 (global 변형, 4 개 분할 평균). 이는 더 나은 점추정에서 따라 나오는 것이 아니라 별개의 성질이다.
- **포함 모집단에서 모델의 T_i 구간은 실제로 PCHIP 의 것보다 넓은데** (반폭 224–255 대 211–241 eV) 그럼에도 점수는 더 좋다: 스파이크가 빛나감 별점을 부풀리는데 모델이 덜 빛나가기 때문이다. Mondrian 보정은 모든 T_i 팔을 $\approx 4\text{--}5\%$ 좁히고 V_{rot} 은 그대로 두며 어떤 판정도 바꾸지 않는다.
- **정직한 실패: 커버리지는 주변적이지 조건부가 아니다.** T_i 커버리지는 목표 0.90 에 대해 0.87–0.92 이고 (모든 팔에서 한 분할이 미달) V_{rot} 은 0.91–0.94 이며, shot 별 커버리지는 여전히 넓게 흩어진다. Conformal 은 교환가능성 아래에서 커버리지를 보장하는데, 보정과 test 는 서로소인 방전이다. shot 수준의 이동이 그 가정을 깬다. 배치된 계속기에는 통합 수치보다 이것이 더 중요하며, 이를 고치려면 현재 shot 수로는 지탱할 수 없는 shot 조건부 보정이 필요하다.

9 남은 개선 여지는 어디인가

본 논문의 부정 결과들은 이례적으로 구체적이며, 그 구체성이 그것들을 쓸모 있게 만든다: “이 문제는 어렵다” 가 아니라 어떤 변경이 이를 움직일지를 말한다. 용량은 배제되었고 (§6.9), 더 긴 원도도 배제되었으며 (§6.8), 도달 범위를 사는 프레이밍은 채택되었다 (§6.3). 남은 것은 데이터이고, 각 레버는 이미 이 데이터셋 안에 있는 증거로 지목된다.

1. CES 피팅 품질 메타데이터는 대리 지표를 측정으로 대체할 것이다. 두 모집단 보고가 존재하는 이유는 값 기준 컷이 “피팅이 실패했다” 의 대리 지표이기 때문이다: 어떤 방법도 예측할 수 없는 단일 표본 상향 사건을 제거하지만 한쪽 방향뿐이고 (하향 급락은 손대지 않는다) $\geq 2\times$ 상향 이상치의 19% 만 잡는다 (§3.5). 표본별 피팅 χ^2 이나 신호 수준이 있다면 품질 컷이 모든 팔에서 한꺼번에 값 컷을 대체하거나 동반할 수 있고, 두 모집단은 하나로 합쳐질 것이다. V_{rot} 자신의 스파이크 (1,000 km/s 를 넘는 119 행) 도 같은 규칙으로 처리될 것이다. 그때까지 persistence 기반 V_{rot} 비교는 §6.9 처럼 그 행들이 담은 제곱오차 비중을 보고한다.

2. Mirnov 정보는 플라스마에 없었던 것이 아니라 전처리에서 파괴되었다. §6.7 에서 자기 진단이 회전 정보를 운반하지 않는다고 결론짓는 것은 틀렸다. 동일한 10 ms 격자에서 연속 블록 내 lag-1 자기상관은 BES 가 +0.568, ECEI 가 +0.572 인 반면 Mirnov 코일은 -0.009 이고 블록의 82% 가 $|r| = 0.1$ 아래다: 이 격자 위에서 자기 채널은 백색잡음이다. 이는 dB/dt 가 kHz 모드 주파수로 진동하는 것을 앤티앨리어싱 필터 없이 100 Hz 로 데시메이션한 결과의 특징으로, 연속한 표본들의 상대 위상이 무작위가 된다. 우리 진단 집합에서 토로이달 회전의 대리가 될 수 있었던 유일한 물리량인 모드 회전 주파수가 모델보다 상류에서 버려진 것이며, 우리가 시도한 모든 파생 MC 특징 (적분, PCHIP 적분, $|MC|$, 이동 RMS) 이 실패한 이유이기도 하다: 이미 잃은 정보는 하류에서 복구할 수 없다. 해결책은 모델 변경이 아니라 전처리 변경이다: 원시 kHz Mirnov 시계열에서 계산한 원도별 RMS, 대역 파워, 모드 수, 모드 회전 주파수를 사전등록된 pilot-then-expand 규칙 아래 V_{rot} 분기로 라우팅하는 것. 이것이 V_{rot} 에 대해 우리가 지목할 수 있는 가장 가치 높은 실험이며, 아카이브된 데이터로 검정 가능하다.

3. 액추에이터 채널이 아예 없다. 토로이달 회전은 주입된 토크로 결정되는데, 이 데이터셋에는 토크 신호가 존재하지 않는다. 데이터가 그 단절을 정확히 보여준다: shot 사이에서 ECE 유래 T_e 대리 지표는 T_i 와 $r = +0.353(p = 3 \times 10^{-17})$ 으로 상관되지만 V_{rot} 과는 $r = +0.024(p = 0.58)$ 이고, shot 내부에서 T_i 상관관은 일관된 부호를 유지하는 반면 V_{rot} 상관관은 부호가 무작위다. 즉 T_e 는 가열 수준을 추적하지만 가열 수준은 회전에 닿지 않는다—파워는 토크가 아니며, 토크는 빔 에너지, 접선 반경, 주입 기하에 의존한다. NBI 토크 (또는 그것을 계산하는 빔별 파워와 기하) 를 더하는 일은 모델링 과제가 아니라 데이터 획득 과제이고, 회전의 자기상관이 아니라 원인을 다루는, 우리가 지목할 수 있는 유일한 레버다. 문헌에 이미 양성 대조가 있다: 빔 액추에이터를 입력으로 받는 DIII-D 의 순환 전방전 시뮬레이터는 회전의 시간 변화를 예측한다 [51]. 따라서 없는 채널은 측정되기만 하면 학습 가능하다.

이들 중 어느 것도 현재 결과가 천장에 있다는 진술이 아니다. 이들은 다음의 측정 가능한 이득이 있는 자리를 값싸게 시도할 수 있는 순서로 늘어놓은 것이며, 셋 모두 아카이브된 KSTAR 데이터에서 실행 가능하다.

10 한계

통계적 검정력. 재현의 단위는 shot 이며, 분할당 test shot 이 96 개 (T_i) / 60–66 개 (V_{rot}) 이므로 검정력이 모든 유의성 판정을 제약하고, shot 별 제공오차 차이는 두꺼운 꼬리를 갖는다 (소수의 방전이 bootstrap 산포를 지배한다. 포함 모집단에서는 행의 $\approx 1\%$ 가 모든 팔의 T_i 제공오차의 70–83% 를 담는다). **MNAR 낙관.** skill 은 관측 지점에서만 측정된다. §6.5 의 재가중은 두 모집단 모두에서 인과 비교에 대한 낙관의 상한을, 오프라인 비교에 대해서는 모집단 조건부 유의성으로 그 상한을 정하며, 결국 T_i 행의 54–68% 와 결국 V_{rot} 행의 4–6% 를 포괄한다. **오프라인 주장의 상한은 GP 동물이다.** 오프라인 GP 는 PCHIP 을 이기고 모델은 그것과 동률일 뿐이므로 (8 개 셀 중 1 개 유의), “미래를 쓰는 보간을 이긴다” 는 “사전등록된 보간들을 이긴다” 를 뜻하며 모든 오프라인 방법으로 확장되지 않는다. 다만 배치 가능한 가장 강한 방법인 인과 GP 로는 확장된다. **값 기준 컷은 대리 지표다.** 두 모집단이 피팅 실패 문제를 괄호로 묶지만, 이를 결말짓는 것은 피팅 품질 컷이며 (§9), V_{rot} 의 스파이크는 컷되지 않은 채로 남는다. **캠페인 전이는 하나의 시간 블록에 기댄다 (§6.6):** 4 개 분할이 아니라 4 개 초기화이며, 컷 모집단 실행 4 개 중 2 개는 epoch 상한에서 멈췄다. 원도 대조군을 전이시키는 수리인 shot 별 표준화는 오프라인 형태이고, 실제로 출하될 버전인 인과적 러닝 (확장 원도/EWMA) 추정기는 여기서 측정되지 않았다. **지표의 비대칭.** 보간은 shot 전체의 이웃을 쓰는 반면 원도 대조군은 두 행을, 백본은 세그먼트의 과거를 본다. 이는 인과 모델에 의도적으로 불리하지만 직접적인 해석은 어렵게 만든다. **단일 장치, 단일 모델 계열.** 모든 것이 하나의 장치, 하나의 진단 집합, 그리고 밀접하게 관련된 두 순환 계열에서 나왔다. 다른 토카막으로의 전이는 여기서 아무것도 확립되지 않았다. **불확실성은 조건부가 아니라 주변적으로 보정된다 (§8).** **지연시간**은 노트북급 머신 한 대에서 네트워크만 잔 값이며 전원 상태에 따라 실행 간 최대 $2\times$ 변동한다 (§8); 특징 조립과 획득 오버헤드는 포함되지 않는다. **범위.** 페데스탈 상단 프레임িং은 데이터 선정 (페데스탈 상단 CES 채널) 에서 물려받은 것이며, 반경 의존성 실험은 수행하지 않았고 사건 위상 분석 (ELM 주기, L–H 천이) 은 향후 과제다—§6.10 의 고변동 분석은 사건에 무관한 대리 지표다.

11 결론

우리는 희소한 KSTAR CES 타겟을 위한 인과적·누수 방지 멀티모달 나우캐스터— V_{rot} 분기가 고속 진단을 결코 보지 않는 전체격자 2 분기 순환 모델—를 만들고, 사전등록된 shot 군집 두-모집단 프로토콜 아래에서 의도적으로 불리한 기준 — 미래를 보는 보간, 그리고 미래를 보지 않는 방법 중 가장 강한 인과 GP — 에 대해 평가했다. 관측 모집단에서 모델은 이온온도에 대해 미래를 쓰는 PCHIP 을 유의하고 재현 가능한 skill 로 이기고 (4 개 독립 분할과 두 모집단에 걸쳐 $+0.17 \sim +0.32$), 가장 강한 오프라인 평활기와 동률이며, 두 타겟 모두에서 모든 인과 기준선을 — 8 개 셀 전부의 인과 GP 와 비인접 영역 ($\Delta t > 15$ ms) 을 포함해 — 이긴다.

배치에 대한 우리의 주장은 이제 두 스트레스 테스트 모두의 지지를 받는다. 진짜 결측이면서 도메인 안인 시점에서 모든 인과 방법 대비 우위는 8/8 모집단-분할 셀에서 재가중을 견딘다. 캠페인 경계를 가로질러서는 시퀀스 나우캐스터가 두 모집단 모두에서 4/4 초기화에 대해 PCHIP 과 인과 GP 를 앞서는데, 그것이 대체한 원도 대조군은 오프라인 우위를 완전히 잃었던 자리다. 그리고 그 차이는 단언이 아니라 측정이다: 고속 진단은 캠페인 사이에 타겟보다 $5\text{--}11\times$ 더 이동하고, shot 별 표준화가 대조군을 수리하며, 시퀀스 프레임িং은 구성상 shot 별로 표준화하고 과거 전체에 닿는다. 온라인 가상 센서는 미래를 읽는 보간

이 아니라 persistence 와 인과 평활기와 경쟁하며, 그 비교로 보면 나우캐스터는 중요한 지점에서 작동한다. 또한 모든 셀에서 적합한 채점 규칙으로 두 기준선의 구간을 이기는 보정된 구간을 내놓는다.

작동하지 않는 곳과 그 이유도 함께 보고한다. 회전은 전역적으로 보간과 동률이고 그 skill 은 과도 구간에 산다. 두 모집단 중 하나를 정의하는 값 기준 컷은 피팅 품질에 대한 한쪽 방향 대리 지표다. 재가중은 결측 T_i 행의 54-68% 와 결측 V_{rot} 행의 20 분의 1 에 닿는다. 예측 구간은 방전별이 아니라 주변적으로 보정된다. 그리고 45 ms 를 넘어서면 포함 모집단은 동률이다. 이 중 어느 것도 천장 논변이 아니며, 어느 것도 어깨를 으쓱하는 것으로 남겨두지 않았다. 각각은 구체적이고 검정 가능한 변경을 가리킨다—CES 피팅 품질 메타데이터, 100 Hz 데시메이션이 모델이 보기도 전에 파괴한 정보를 담고 있는 원시 kHz Mirnov 스트림에서 다시 계산한 원도별 특징, 그리고 데이터셋에 없지만 회전의 물리적 원인인 NBI 토크 채널. 그리고 모델 크기 축은 닫혔다: 21k 파라미터의 persistence+ 유계 보정 모델이 컷에서 백본과 대등하고, 26× 폭 스위프는 평평하다. 이와 함께 본 연구는 교정된 V_{rot} 평가 (54% 의 예측기 유지값, 전 구간 제거), 어느 한 모집단만으로는 왜 충분하지 않은지를 보이는 측정을 동반한 스펙트럼 피팅 실패의 두-모집단 처리, 배치 가능한 가장 강한 기준선을 넘어서게 하는 도달 범위를 지닌 전체격자 인과 프레이밍, 그리고 모든 결정 규칙이 그것이 결정할 수치보다 먼저 적힌 test 동결 선택 프로토콜을 기여한다.

재현성

분할은 디스크에 고정되고 재적재 시 검증된다. 정규화 통계는 학습 파일 전용이다 (시퀀스 계열은 여기에 shot 별 입력 표준화가 더해진다). 모델 선택은 test 데이터를 결코 읽지 않는다. bootstrap 은 고정 시드와 10,000 회 재표본을 쓴다. 인용된 모든 수치는 단일 수집 스크립트가 동결된 평가 산출물에서 읽어온다.

코드 가용성

전체 파이프라인, 배치별 실행 기록을 담은 사전등록 문서, 여기 보고된 모든 결과 뒤의 통제 실험 러너, 고정된 train/validation/test 분할, 그리고 동결된 평가 산출물에서 인용된 모든 수치를 재생성하는 수집기는 <https://github.com/iseungsang01/ml-intern-revision> 에서 공개되어 있다. 백본은 ces_prediction/experiments/seq/model_seq_v2.py, 해석 가능한 사다리 칸은 model_seq_b3.py, 원도 대조군은 ces_prediction/model_iter009.py(테스트 스위트에서 내용 해시로 보호) 이므로, 이 수치를 만든 코드가 공개된 코드와 어긋날 수 없다.

데이터 가용성

본 연구의 바탕이 되는 KSTAR 진단 데이터—641 개 방전, shot 30801-32751—는 코드와 함께 재배포되지 않는다. 이는 KSTAR 장치의 실험 데이터로 운영 기관의 데이터 정책을 따르며, 접근 요청은 그쪽으로 보내야 한다. 저장소에는 shot 파일이 갖춰진 뒤 분석을 재현하는 데 필요한 모든 것이 들어 있다: 정확한 파일 단위 분할 manifest, 보고된 모든 실행의 환경 설정, 그리고 bootstrap 통계를 계산하는 표본별 제곱오차 아카이브.

참고문헌

- [1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81:10D740, 2010. doi: 10.1063/1.3496991.
- [2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.
- [3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2):238–246, 1980. doi: 10.1137/0717021.
- [4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.
- [5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity

- transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.
- [6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.
 - [7] Minseok Kim, W.H. Ko, Sehyun Kwak, Semin Joung, Wonjun Lee, B. Kim, D. Kim, J.H. Lee, Choongki Sung, Yong-Su Na, and Y.-C. Ghim. Kinetic profile inference with outlier detection using support vector machine regression and Gaussian process regression. *Nuclear Fusion*, 64:106052, 2024. doi: 10.1088/1741-4326/ad7304.
 - [8] R. L. Dougherty, A. S. Edelman, and J. M. Hyman. Nonnegativity-, monotonicity-, or convexity-preserving cubic and quintic Hermite interpolation. *Mathematics of Computation*, 52(186):471–494, 1989. doi: 10.1090/S0025-5718-1989-0962209-1.
 - [9] C. H. Reinsch. Smoothing by spline functions. *Numerische Mathematik*, 10(3):177–183, 1967. doi: 10.1007/BF02162161.
 - [10] G. Kvernadze. Convergence and Gibbs’ phenomenon in cubic spline interpolation of discontinuous functions. *Journal of Computational and Applied Mathematics*, 92(2):173–188, 1998. doi: 10.1016/S0377-0427(97)00199-4.
 - [11] S. Eyheramendy, F. Elorrieta, and W. Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481(4):4311–4322, 2018. doi: 10.1093/mnras/sty2487.
 - [12] F. Elorrieta, S. Eyheramendy, and W. Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, 2019. doi: 10.1051/0004-6361/201935560.
 - [13] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, 3rd edition, 2007.
 - [14] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.
 - [15] Chris Bishop, C.M. Roach, and M. G. von Hellermann. Automatic analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 35:765–773, 1993. doi: 10.1088/0741-3335/35/6/010.
 - [16] J. Svensson, M. von Hellermann, and R. König. Analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 41:315–338, 1999. doi: 10.1088/0741-3335/41/2/016.
 - [17] Baoyue Chai, Yingying Li, Ze Chen, Wei Tao, Yixuan Zhou, Shifeng Mao, Zhengping Luo, Yi Yu, Bo Lyu, and Minyou Ye. Fast estimation of ion temperature from EAST charge exchange recombination spectroscopy using neural network. *Plasma Science and Technology*, 21:105103, 2019. doi: 10.1088/2058-6272/ab2674.
 - [18] A. Pavone, J. Svensson, A. Langenberg, U. Höfel, S. Kwak, N. Pablant, and R. C. Wolf. Neural network approximation of Bayesian models for the inference of ion and electron temperature profiles at W7-X. *Plasma Physics and Controlled Fusion*, 61:075012, 2019. doi: 10.1088/1361-6587/ab1d26.
 - [19] Mark D. Boyer and Jason D. Chadwick. Prediction of electron density and pressure profile shapes on NSTX-U using neural networks. *Nuclear Fusion*, 61:046024, 2021. doi: 10.1088/1741-4326/abe08b.
 - [20] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64:106061, 2024. doi: 10.1088/1741-4326/ad73e8.

- [21] Francisco A. Matos, Diogo R. Ferreira, and P. Carvalho. Deep learning for plasma tomography using the bolometer system at JET. *Fusion Engineering and Design*, 114:18–25, 2016. doi: 10.1016/j.fusengdes.2016.11.006.
- [22] Cong Wang, Weizhe Yang, Haiping Wang, Renjie Yang, Jing Li, Zhijun Wang, Yixiong Wei, Xianli Huang, Chenshu Hu, Zhaoyang Liu, Xinyao Yu, Changqing Zou, and Zhifeng Zhao. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 65:076022, 2025. doi: 10.1088/1741-4326/ade0ce.
- [23] Xishuo Wei, Shuying Sun, W. M. Tang, Zhihong Lin, Hongfei Du, and Ge Dong. Reconstruction of tokamak plasma safety factor profile using deep learning. *Nuclear Fusion*, 63:086020, 2023. doi: 10.1088/1741-4326/acdf00.
- [24] G.H. Zheng, Zongyu Yang, Songfen Liu, Rui Ma, Xinwen Gong, Ao Wang, Shuo Wang, and W.L. Zhong. Real-time equilibrium reconstruction by multi-task learning neural network based on HL-3 tokamak. *Nuclear Fusion*, 64:126041, 2024. doi: 10.1088/1741-4326/ad8014.
- [25] S. Joung, J. Kim, S. Kwak, J. Bak, S. Lee, H. Han, H. Kim, G. Lee, D. Kwon, and Y. Ghim. Deep neural network Grad-Shafranov solver constrained with measured magnetic signals. *Nuclear Fusion*, 2020.
- [26] Semin Joung, Young chul Ghim, Jaewook Kim, S. Kwak, Daeho Kwon, Chih-Jen Sung, Dong Ju Kim, Hyun-Seok Kim, J.G. Bak, and S.W. Yoon. GS-DeepNet: mastering tokamak plasma equilibria with deep neural networks and the Grad-Shafranov equation. *Scientific Reports*, 13:15799, 2023. doi: 10.1038/s41598-023-42991-5.
- [27] L. Jung, Jaewook Kim, and Jisung Kang. Machine learning-based plasma profile reconstruction in KSTAR. *Journal of the Korean Physical Society*, 88:1079 – 1087, 2026. doi: 10.1007/s40042-026-01580-1.
- [28] Joseph Abbate, Rory Conlin, and Egemen Kolemen. Data-driven profile prediction for DIII-D. *Nuclear Fusion*, 61:046027, 2021. doi: 10.1088/1741-4326/abe08d.
- [29] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2024. doi: 10.1088/1741-4326/ad142f.
- [30] Semin Joung, Jaewook Kim, S. Kwak, Kyeo reh Park, S.H. Hahn, Hyunsun Han, Hyun-Seok Kim, J.G. Bak, S. G. Lee, and Young chul Ghim. Imputation of faulty magnetic sensors with coupled Bayesian and Gaussian processes to reconstruct the magnetic equilibrium in real time. *Review of Scientific Instruments*, 89:10K106, 2018. doi: 10.1063/1.5038938.
- [31] Debashish Mohapatra, Bidyadhar Subudhi, and Raju Daniel. Real-time sensor fault detection in Tokamak using different machine learning algorithms. *Fusion Engineering and Design*, 151:111401, 2019. doi: 10.1016/j.fusengdes.2019.111401.
- [32] S. Kaldas, R. Rossi, I. Wyss, M. Gelfusa, and P. Gaudio. Developing autoencoder models for multi-diagnostic electron density processing in tokamaks within a scientific machine learning framework. *Journal of Fusion Energy*, 45, 2026. doi: 10.1007/s10894-026-00568-w.
- [33] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.
- [34] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Nian-nian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.

- [35] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.
- [36] M. Imříšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiland, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.
- [37] HyeonJun Noh, Chweeho Heo, Xiaotian Gao, and Yong-Su Na. PanoMHD: Multimodal modelling of plasma dynamics towards Tokamak control. 2026.
- [38] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.
- [39] Satya Narayan Shukla and Benjamin M. Marlin. Multi-time attention networks for irregularly sampled time series. 2021:14897–14911, 2021. doi: 10.48550/arxiv.2101.10318.
- [40] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. 32:5320–5330, 2019.
- [41] Rich Caruana. Multitask learning. *Machine Learning*, 28:41–75, 1997. doi: 10.1023/a:1007379606734.
- [42] Jiquan Ngiam, Aditya Khosla, Mingyu Kim, Juhan Nam, Honglak Lee, and Andrew Y. Ng. Multimodal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 2011.
- [43] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:423–443, 2018. doi: 10.1109/tpami.2018.2798607.
- [44] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Xing Chen, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [45] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. 2018. doi: 10.48550/arxiv.1802.04712.
- [46] Xingjian Shi, Zhoung Chen, Hao Wang, Dit-Yan Yeung, Wai Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. 2015. doi: 10.48550/arxiv.1506.04214.
- [47] Suman Ravuri, Karel Lenc, Matthew Willson, Dmitry Kangin, Rémi Lam, Piotr Mirowski, M. A. Fitzsimons, Maria Athanassiadou, Sheleem Kashem, Sam Madge, Rachel Prudden, Amol Mandhane, Aidan Clark, Andrew Brock, Karen Simonyan, Raia Hadsell, N. Robinson, Ellen Clancy, Alberto Arribas, and Shakir Mohamed. Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597: 672–677, 2021. doi: 10.1038/s41586-021-03854-z.
- [48] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.
- [49] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.
- [50] J. E. Rice, A. Ince-Cushman, J.S. deGrassie, L.-G. Eriksson, Y. Sakamoto, A. Scarabosio, A. Bortolon, K.H. Burrell, B.P. Duval, C. Fenzi-Bonizet, M. Greenwald, R. J. Groebner, G. T. Hoang, Y. Koide, E. S. Marmar, A. Pochelon, and Y. Podpaly. Inter-machine comparison of intrinsic toroidal rotation in tokamaks. *Nuclear Fusion*, 47:1618–1624, 2007. doi: 10.1088/0029-5515/47/11/025.

- [51] Ian Char, Youngseog Chung, Joseph Abbate, Egemen Kolemen, and Jeff Schneider. Full shot predictions for the DIII-D tokamak via deep recurrent networks. arXiv:2404.12416, 2024.