

# KSTAR 희소 전하교환분광 (CES) 신호의 멀티모달 나우캐스팅: 고속 진단은 미래를 보는 보간을 넘어 이온온도를 복원하지 만 토로이달 회전은 복원하지 못한다

이승상 (Seungsang Lee)  
서울대학교 원자핵공학과  
lss010330@snu.ac.kr

국문 초안 — 2026 년 8 월 9 일

## 초록

전하교환분광 (CES) 은 토카막에서 이온온도 ( $T_i$ ) 와 토로이달 회전 ( $V_{rot}$ ) 을 측정하는 핵심 진단이지만, 광자 수집 제약 때문에 느리고 간헐적으로 결측된다. 본 연구가 다루는 KSTAR 10 ms 격자에서는  $T_i$  의 8.2%,  $V_{rot}$  의 23.9% 가 결측되고 두 타겟은 서로 독립적으로 빠지며,  $V_{rot}$  은 여기에 더해 41.1% 가 계속기 유지값 (held) 이어서 격자의 65.0% 가 독립적인  $V_{rot}$  정보를 갖지 않는다. 본 논문은 항상 측정되는 고속 진단—빔방출분광 (BES), 전자사이클로트론방출영상 (ECEI), Mirnov 코일—과 불규칙한 과거 CES 이력을 결합하면, CES 가 결측된 시점에서 CES 자체의 시간 보간으로는 복원할 수 없는 정보를 회복할 수 있는지를 묻는다. 진단별 인코더, 명시적 불규칙 시간 특징, 타겟별 마스킹 손실, 물리 기반 타겟별 입력 라우팅, 그리고 실제로 관측된 시점에만 어텐션을 허용하는 하드 마스킹 이력 인코더—보간 자체의 귀납 편향을 파라미터 비용 0 으로 모델에 써 넣은 것—를 갖춘 소형 (20 만 파라미터) 멀티모달 신경망을 학습하고, 의도적으로 불리한 기준선과 비교한다: 오프라인 보간 (선형, 단조 3 차 PCHIP, 국소 AR) 은 타겟 시점 양쪽의 과거와 미래 CES 이웃을 모두 사용하는 반면, 모델은 엄격하게 인과적 (causal) 이다. 사전등록된 프로토콜—파일 단위 train/val/test 분할, 모델 선택이 전혀 접근하지 않는 test 셋, shot 군집 paired bootstrap(10,000 회 재표본)—하에서 모델은  $T_i$  에 대해 skill +0.18~+0.28 로 PCHIP 을 이기며, 독립적인 4 개 held-out 분할 모두에서 95% 신뢰구간이 0 을 제외한다. 반면  $V_{rot}$  은 같은 관문을 4 개 중 1 개에서만 통과하는데 이는 잡음만으로도 나올 수 있는 수준이므로 동물로 보고한다. 이어 결과를 두 방식으로 스트레스하며 둘은 같은 답을 준다: 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중하는 것과, 캠페인을 가로질러 시간으로 엄격히 재분할하는 것이다. 각각은 오프라인 보간 대비 우위를 제거하면서 모든 인과 기준선 대비 우위는 온전히 남긴다 (+0.29, +0.22). 따라서 두 주장을 뭉개지 않고 분리하며, 캠페인 이동 손실은 측정된 원인으로 추적한다: 고속 진단이 캠페인 사이에 예측 대상보다 5–11× 더 이동한다. 입력 절제 (ablation) 실험은 이 비대칭이 아키텍처가 아니라 물리에서 비롯됨을 보인다: 고속 진단만으로도 persistence 를 이기는  $T_i$  와 달리 (충돌성 전자-이온 결합으로  $T_e$ ,  $n_e$  가 정보를 운반),  $V_{rot}$  에 대해서는 평균 예측보다도 나쁘다 (지배적인 NBI 토크가 미관측이고, 100 Hz 로 샘플된 Mirnov 신호는 kHz 모드 회전을 엘리어싱으로 소실한다). 모델의 우위는 매끄러운 보간이 가장 취약한 고변동 국소 구간에 집중된다. 아울러 데이터 품질 감사 (관측된  $V_{rot}$  값의 54% 가 계기 유지값으로 판명) 와, 검증 손실이 아닌 깨끗한 보간 대비 skill 을 선택 게이트로 삼아 통계적으로 유의하지 않던 초기 결과를 유의한 헤드라인으로 끌어올린 아키텍처 선택 프로토콜을 문서화한다. 전체 파이프라인, 사전등록 문서, 평가 산출물을 공개한다.

## 1 서론

플라즈마 경계부의 이온온도  $T_i$  와 토로이달 회전  $V_{rot}$  은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근 등 토카막 성능과 안정성의 핵심 요소를 지배한다. 두 물리량의 표준 측정법은 전하교환분광 (CES) [1] 으로, 전하교환 선방출의 도플러 확장에서  $T_i$  를, 도플러 이동에서  $V_{rot}$  을 추정한다. CES 는 충분한 신호대 잡음비를 위해 광자를 적분해야 하므로 본질적으로 느리고, 개별 시점 측정은 노출-신호품질 문제로 자주

소실된다. 본 연구의 KSTAR 데이터에서는 균일한 10 ms 격자 위에서도  $T_i$  의 8.2%,  $V_{\text{rot}}$  의 23.9% 가 —서로 독립적으로—결측된다. 나아가  $V_{\text{rot}}$  은 41.1% 가 직전 관측값을 그대로 반복하는 유지값이어서 (§3.4), 격자의 35.0% 만이 독립적인  $V_{\text{rot}}$  측정값을 담고 있다. 우리 데이터셋에서 경험적으로 결측은 물리적으로 흥미로운 순간 (저신호 구간, ELM, 천이) 에 집중된다. 즉 Little and Rubin [2] 의 의미에서 무작위적이지 않은 결측 (MNAR) 이다.

한편 여러 고속 진단은 같은 플라스마를 결측 없이 관측한다: BES 는 밀도요동 구조를, ECEI 는 전자 온도를, Mirnov 코일은 자기요동을 측정한다. 이들 중 어느 것도  $T_i$  나  $V_{\text{rot}}$  을 직접 측정하지 않는다. 본 논문의 질문은 다음과 같다.

*CES* 가 결측된 10 ms 시점에서, 동시각 고속 진단과 불규칙한 과거 *CES* 이력만으로, *CES* 단독의 시간 보간이 복원할 수 없는  $T_i$ ,  $V_{\text{rot}}$  정보를 회복할 수 있는가?

긍정적 답은 데이터 기반 가상 센서 (*virtual sensor*) 를 정당화한다: 강한 역산 가정 없이 *CES* 결측을 온라인으로 채워, 끊임 없는 페데스탈 분석과 궁극적으로 실시간 활용을 가능하게 하는 모델이다.

**의도적으로 어려운 기준선.** 결측 채움의 자명한 기준선은 *CES* 채널 자체의 보간이다. 우리는 비교를 모델에 의도적으로 불리하게 설계했다: 보간 기준선 (선형, 단조 3 차 PCHIP [3], 국소 AR 참조) 은 오프라인으로, 타겟 시점 양쪽의—미래를 포함한—*CES* 이웃을 사용할 수 있다. 반면 모델은 엄격히 인과적이며, 타겟 시점의 고속 진단과 짧은 과거 *CES* 원도만 본다. 인과 모델이 미래를 쓰는 보간을 이긴다면, 고속 진단이 *CES* 의 시간 구조만으로는 답을 수 없는 *CES* 관련 정보를 운반한다는 뜻이다. 그리고 미래를 쓰는 보간을 이기는 모델은 당연히 (persistence, AR 등) 모든 인과 기준선을 이긴다.

기여.

1. **누수 방지 멀티모달 나우캐스팅 파이프라인:** 타겟별 마스킹 멀티태스크 손실 (두 타겟 동시 관측을 요구하던 필터가 버리던 라벨 행  $\approx 28\%$  를 복원), 명시적 불규칙 시간 특징, *CES* 이력 입력에서 타겟 시점의 완전 마스킹, 파일 (shot) 단위 분할, 학습 파일 전용 정규화 통계 (§3). 일반적이지 않은 유일한 구성요소는 **관측 마스킹 어텐션 풀링**이다 (§4): 각 타겟의 이력 어텐션 readout 은 그 타겟이 실제로 측정된 시점에만 가중치를 놓을 수 있으며, 이는 보간을 강하게 만드는 바로 그 귀납 편향을 파라미터 비용 0 으로 추가한 것이다.
2. **용량이 아니라 정보가 한계라는 진단 (§6.7):** 24-run window sweep 은 이전 *CES* 를 완전히 제거하면 두 타겟 모두 보간 기준선 아래로 떨어지고, 단 하나의 과거 관측이 모델의 전체 마진을 회복시키며, 관측 1 개 이후로는 skill 곡선이 평탄함을 보인다. 따라서 window 는 기본값을 물려받은 것이 아니라 명시된 규칙으로 선택된다.
3. **사전등록된 shot 군집 평가 프로토콜 (§5):** 모델 선택이 전혀 읽지 않는 test 셋을 갖춘 3 분할, 그리고 shot 군집 paired bootstrap—한 방전 내 인접 샘플은 강하게 상관되므로 재현 (replication) 의 단위 는 샘플이 아니라 방전이다.
4.  **$T_i$  에 대한 강건한 긍정 결과 (§6):** 인과 모델이 미래를 쓰는 PCHIP 보간을  $\text{skill}_{\text{PCHIP}} = +0.18 \sim +0.28$  로 이기며, 4 개 독립 held-out 분할 모두에서 shot 군집 95% CI 가 0 을 제외하고, 두 평가 모집단 (유지값 포함/제외) 모두에서 생존한다.
5.  **$V_{\text{rot}}$  에 대한 물리 기반 부정 결과:** 실패가 아니라 발견으로 보고한다. 고속 진단은 10 ms 에서 회전 정보를 사실상 운반하지 않으며 (미관측 NBI 토크, Mirnov 앨리어싱), 입력 절제로 확인된다. 따라서  $V_{\text{rot}}$  은 이력 자기상관의 한계에 머물러 보간과 동률이다 (4 개 중 1 개 분할만 유의 — 잡음이 만들어 낼 수 있는 수준). 이를  $T_i \leftrightarrow V_{\text{rot}}$  정보 비대칭이라 부른다.
6. **모델이 우위를 버는 위치의 진단:** skill 은 매끄러운 보간이 가장 약한 고변동 국소 구간에 집중된다. 그곳에서는  $V_{\text{rot}}$  조차 (연약하지만) 유의한 우위를 보이며, 절제 실험은  $T_i$  우위가 실제로 멀티모달 신호를 사용함을 보인다.
7. **보통 공개되는 두 주장을 분리하는 두 개의 스트레스 테스트 (§6.4, §6.5).** 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중하는 것과, 캠페인을 가로질러 시간으로 엄격히 재분할하는 것 — 둘 다 오프라인 보간 대비 우위를 제거하면서 (1/4, 0/4) 인과 기준선 대비 우위는 온전히 남긴다 (+0.29, +0.22). 온라인 가상 센서는 미래를 읽는 보간이 아니라 persistence 와 경쟁하며, 둘을 갈라 두는 것

이 배치 주장을 방어 가능하게 만든다. 캠페인 손실은 측정된 원인으로 추적된다 — BES 와 ECEI 가 캠페인 사이에  $1.22\sigma$ ,  $0.53\sigma$  이동하는 반면 CES 타겟은  $0.115\sigma$  — 이는 학습 파일 전용 정규화를 고발하고 그 수리를 지목한다. MNAR 분석에서는 이전에 말한 적 없는 적용 범위 사실도 나온다:  $W=4$  에서 결측  $T_i$  행의 54%( $V_{\text{rot}}$  은 4.8%) 만이 애초에 모델 도메인 안이다.

8. **측정된 배치 가능성 (§8):** 10 ms CES 주기 대비 CPU 에서 p99 추론 지연 6.4 ms — 그리고 이 크기의 모델에서는 GPU 가 batch 1 에서 오히려  $8\times$  느리다는 반직관적 결과 — 에 더해, 재학습이나 기존 수치 교란 없이 두 기준선의 구간을 8/8 시드-타겟 조합에서 이기는 분포 무가정 conformal 예측 구간.
9. **복잡도 사다리 (§6.8):** “이 모델은 설명하기에 너무 복잡하다” 에 반박이 아니라 측정으로 답한다. 완전 해석 가능한 1,258 파라미터 앵커 + 보정 모델이  $T_i$  마진의 31.5%,  $V_{\text{rot}}$  마진의 7% 를 회수하므로, 남은 20 만 파라미터가 정확히 무엇을 사는지 진술할 수 있다.
10. **두 가지 방법론적 산출물:** 관측된  $V_{\text{rot}}$  값의 54% 가 forward-fill 된 계기 유지값이며 학습도 오염시킴을 밝힌 데이터 품질 감사, 그리고 선택 게이트를 검증 손실이 아닌 깨끗한 보간 대비 skill 로 삼는 아키텍처 선택 프로토콜.

## 2 관련 연구

**핵융합 진단의 프로파일 피팅과 결측 보간.** 가우시안 과정 회귀 [4] 는 핵융합 프로파일 데이터의 피팅과 불확실성 정량화의 커뮤니티 표준 도구로서 KSTAR CES  $T_i$  프로파일에도 SVM 기반 이상치 제거와 결합되어 적용돼 있으며 [5–7], PCHIP 같은 단조 보간 [3, 8] 은 자연 3 차 스플라인 [9] 이 ELM-토포니파형 계단에서 Gibbs 형 진동을 보이기 때문에 [10] 과도 현상 근방에서 선호된다. 불규칙 표본 시계열에는 정확한 AR 형 영모형 (IAR/CIAR) 이 존재한다 [11, 12]. 우리는 이 사다리—persistence, 선형 보간 [13], PCHIP, 국소 AR—를 사전등록된 기준선으로 사용하며, PCHIP 을 헤드라인 비교 대상으로, Murphy 의 MSE skill 점수 [14] 를 지표로 삼는다. 본 연구의 기여는 이 문헌과 직교한다: 더 나은 CES 단독 보간이 아니라, 다른 진단들이 어떤 CES 단독 방법도 넘어서는 정보를 더하는지를, 인과 멀티모달 모델을 미래를 쓰는 보간과 맞세워 검증한다.

**핵융합에서의 신경망 진단 추론.** 신경망 진단 추론에는 세 갈래가 있으며, 각각에 대해 타겟 측정이 없을 때 어떻게 되는가? 를 묻는 것이 유익하다. 가장 오래된 갈래는 스펙트럼 피팅 가속이다—JET 전하교환 스펙트럼의 신경망 분석 [15, 16] 과 EAST CXRS 스펙트럼의 고속  $T_i$  추정 [17]. 이들은 최소자승 피팅 대비 수십 배의 속도를 얻지만, 구조상 해당 시점에 측정된 스펙트럼을 요구한다: CES 노출이 결측되면 입력 자체가 없다. 두 번째 갈래는 한 진단의 추론 파이프라인을 다른 진단으로 대체한다: W7-X 의 베이지안 모형 에뮬레이션 [18], NSTX-U 의 스칼라 파라미터 기반 프로파일 형상 예측 [19], 그리고—우리 타겟에 가장 가까운—EAST 의 X 선 결정 분광기로부터의  $T_i$  회전 프로파일 추론 [20]. Lin 등은 정확히 우리의 두 물리량을 예측하지만 입력이 또 다른 도플러 분광기, 즉 동일한 물리 정보 채널이고 같은 광자 통계 한계를 가지며, 매핑은 순간적이고 소스 진단의 가용성을 그대로 상속한다. 세 번째 갈래는 느린 재구성 코드의 종단간 대리모형이다: 볼로미터 단층촬영 [21], 선적분 진단 [22], 안전인자 프로파일 [23], 실시간 평형 [24], 그리고 KSTAR 자체의 신경망 Grad-Shafranov 솔버 [25, 26] 와 고속 EPED 파라미터화 프로파일 재구성 [27] — 후자는 CES 를 입력으로 쓰며 회전 확장을 명시된 향후 과제로 남긴다. 이들은 분석 지연 시간을 다루지, 측정 가용성을 다루지 않는다: 존재하는 데이터의 역산을 가속할 뿐이다. 가용성 문제에 더 가까운 두 연구가 있다. DIII-D 의 액추에이터 조건부 프로파일 예보 [28] 는 우리 모델처럼 인과적이고 이력 기반이지만, 제어를 위해 조밀하게 측정된 프로파일로부터 미래를 예보하며, 희소 채널의 복원이 아니다. RTCAKENN [29] 은 실시간으로 운동학 프로파일 (불순물 온도·회전 포함) 을 재구성하고 dropout 학습으로 Thomson/CER 입력 소실을 견디지만, 거기서 결측은 입력을 0 으로 만드는 강건성 조건인 반면, 우리 설정에서는 타겟 자신의 희소성이 문제 그 자체이며 타겟별 관측 플래그와 불규칙 시간 특징으로 명시적으로 추적된다. 세 갈래 모두의 공통 가정은 모델이 실행될 때 정보 소스가 존재한다는 것이다. 자기 자신의 측정이 없는 시점에서, 다른 채널들과 자신의 과거로부터 진단값을 복원하는 일은 이들의 범위 밖이다.

**교차 진단 재구성과 시간 조밀화 (가장 가까운 선행 연구).** 최근 한 계열은 다른 진단들로부터 특정 진단을 재구성한다. GP 기반 대체는 KSTAR 에서 고장난 자기 센서를 밀리초 이하로 복원하고 [30], ML 은 손상 센서를 탐지·보상하며 [31], 오토인코더는 중복 밀도 진단을 융합해 복원력을 얻고 [32], 시계열 외생

CES is sparse and the targets go missing independently; counting instrument holds, 65.0% of the grid carries no independent  $V_{\text{rot}}$  information




그림 1: 10 ms 격자에서의 CES 결측 구조.  $T_i$  와  $V_{\text{rot}}$  은 독립적으로 결측되며 ( $\approx 8\%$  /  $\approx 24\%$ ), 행 필터링이 아닌 타겟별 마스킹을 요구한다.

회귀는 EAST의 결측 전자온도를 채우며 [33], FusionMAE는 HL-3의 88개 채널에서 마스킹 채널 “가상 백업 진단”을 수행한다 [34]. 우리 프레임िंग에 가장 가까운 것으로, Diag2Diag는 DIII-D에서 다른 동시각 진단들로부터 Thomson 산란  $T_e/n_e$ 를 요동 진단 속도로 합성하고 [35], COMPASS에서는 고속 복사 진단으로부터 Thomson 프로파일의 시간 초해상이 시연되었으며 [36], PanoMHD는 제어를 위해 인과 트랜스포머로 멀티모달 신호 동역학을 모델링한다 [37]. 본 연구는 이 계열과 네 가지 축에서 다르며, 각 축은 인용 논문들의 명시된 범위에서 확인 가능하다: (i) 타겟 채널—이 계열의 모든 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성하고 (35과 36의 Thomson  $T_e/n_e$ , 33의 ECE형  $T_e$ , 34의 임의 마스킹 채널), CER/CES가 등장하는 경우에도 어디까지나 입력이며 [35] 희소 타겟이 아니다; (ii) 인과성—Diag2Diag와 COMPASS 연구는 기억 없는 동시각 매핑이고 FusionMAE는 원도 내 재구성인 반면, 우리 모델은 타겟 자신의 불규칙한 과거에 조건화되며 미래를 절대 읽지 않는다; (iii) 평가 기준—어느 것도, 결측 채움에서 현직 방법인 타겟 채널의 미래 사용 보간을, 사전등록된 shot 군집 프로토콜로 이겨야 할 기준선으로 세우지 않는다; (iv) 정보 분석—재구성 가능성이 타겟별로 검정되지 않고 가정되는 반면,  $T_i \leftrightarrow V_{\text{rot}}$  비대칭은 우리의 중심 발견이다. 요컨대 본 연구는 이 활발한 계열이 확립한 프로그램—항상 있는 진단으로 없는 측정을 재구성한다—을 이어받아 세 방향으로 확장한다: 전자 채널에서 희소 이온 채널로, 동시각의 기억 없는 매핑에서 타겟 자신의 불규칙 과거에 조건화된 인과 추정으로, 그리고 가정된 재구성 가능성에서 사전 등록 기준선에 대한 타겟별 검정으로. 우리가 아는 한 이 세 확장의 결합—희소 CXRS 이온 측정의 인과적 시간 결측 채움—은 아직 다뤄지지 않았으며, 우리는 이를 계열로부터의 이탈이 아니라 그 자연스러운 다음 단계로 제시한다.

**불규칙 시간·마스킹 멀티태스크 학습.** 본 설계는 불규칙 시계열 문헌의 표준 재료—관측 마스크와 감쇠 인지 순환 (GRU-D [38]), 연속시간 임베딩 위 어텐션 (mTAN [39]), 잠재 ODE 동역학 [40]—과 부분 라벨 멀티태스크 학습 [41], 후기 융합 멀티모달 구조 [42, 43], pre-LayerNorm 트랜스포머 [44], 어텐션 풀링 [45]을 차용한다. “나우캐스팅” 프레임िंग은 기계학습 기상 예보에서의 용법을 따른다 [46, 47]. 새로움은 개별 재료가 아니라, 물리적으로 불리한 평가 프로토콜 아래에서의 누수 방지 조합에 있다.

### 3 데이터와 문제 설정

#### 3.1 데이터셋

하드웨어 일관성을 위해 캠페인 #24000–#33000에서 우선 선정한 641개 KSTAR 방전 (shot) 파일을 사용하며, H-mode ELM 억제 (RMP) 구간을 타겟으로  $D_\alpha$  활동 구간 주변  $\sim 100$  ms 세그먼트를 절단한다. 모든 신호는 공통 10 ms 격자에 정렬된다. 각 행은 BES [48] 9 채널, ECEI [49] 4 채널, Mirnov 코일 2 채널, 시간, 그리고 두 CES 타겟  $T_i$ ,  $V_{\text{rot}}$  [1]을 제공한다. 이 격자에서  $T_i$ 는 약 8%,  $V_{\text{rot}}$ 은 약 24%의 행에서 독립적으로 결측된다 (그림 1).

#### 3.2 샘플 구성

이력 원도  $W=4$ 의 타겟 인덱스  $t$  학습 샘플은 `bes` ( $W, 9$ ), `ecei` ( $W, 4$ ), `mc` ( $W, 2$ ), `time_features` ( $W, 4$ ), `ces_history` ( $W, 4$ ), 정규화 타겟  $[T_i, V_{\text{rot}}] \in \mathbb{R}^2$ , 타겟별 관측 마스크  $m \in \{0, 1\}^2$ 로 구성된다. 네 개의 시간 특징—lookback 초, 행간 delta 초, 그리고 각각의  $\log(1+x)$  변환—은 불규칙 관측 패턴을 모델에 명시적으로 노출한다: 과거 CES 값의 신뢰도는 그것이 10 ms 전 값인지 200 ms 전 값인지에 강하게 의존한다.

CES 이력의 네 채널은 직전 정규화  $T_i$ , 직전 정규화  $V_{\text{rot}}$ , 그리고 타겟별 관측 플래그이다 (두 타겟이 독립적으로 결측되므로 관측 여부는 타겟별로 추적해야 한다).

### 3.3 설계 원칙

**가짜 라벨 금지.** 학습 행을 만들기 위해 타겟을 대체 (impute) 하지 않는다. 행은 진단 입력이 완전하고 CES 타겟 중 적어도 하나가 실제로 관측된 경우에만 유지된다.

**타겟별 마스킹 손실.** 손실은 타겟별로 마스킹된다:  $\mathcal{L} = \sum_{k \in \{T_i, V_{\text{rot}}\}} m_k (\hat{y}_k - y_k)^2 / \sum_k m_k$ . 한 타겟만 관측된 행도 그 타겟은 학습에 기여한다. 이전의 두-타겟-필수 필터는 라벨 행의  $\approx 28\%$  를 조용히 버렸다; 이를 제거한 것은 순수한 데이터 이득이다.

**누수 방지.** (i) 파일 단위 분할: 한 shot 내 인접 행은 강하게 자기상관되므로 분할은 shot 파일 단위로 이루어지고 디스크에 고정된다; (ii) 학습 파일 전용 정규화: 모든  $z$ -score 통계 (희소 타겟은 NaN-인지)는 학습 파일에서만 추정된다; (iii) 타겟 시점 마스킹: `ces_history` 에서 타겟 시점의 값과 관측 플래그를 모두 0 으로 만들어, 모델이 자신의 정답을 읽을 수 없게 한다.

### 3.4 데이터 품질 감사: 유지 (forward-fill) 된 $V_{\text{rot}}$ 값

후반 감사에서 관측된  $V_{\text{rot}}$  값의 54% 가 계기 유지값임이 밝혀졌다: 같은 연속 시간 블록 안에서 직전 관측과 비트 단위로 동일한 반복 (최대 1,214 행 연속, 641 개 중 499 개 파일 영향) 이다.  $V_{\text{rot}}$  의 고유 측정 주기가 행 주기보다 느려 값이 이월된 것으로, 독립적인 측정이 아니다.  $T_i$  는 영향이 없다 (0.0%). 유지값은 전 구간에서 평가에서 제외한다. 이 보정으로 보고되는 물리 단위  $V_{\text{rot}}$  RMSE 는 35–55% 커진다 (원시 단위 22–33  $\rightarrow$  35–46). 유지 타겟의 기준선 오차가 0 에 가까웠기 때문이다. 이하 모든 결론은 보정된 (진짜 측정만의) 평가를 사용하며,  $T_i$  헤드라인은 이 보정에 영향받지 않는다.

**유지값은 학습도 오염시킨다.** 초기의 단일 seed A/B 는 그렇지 않다고—유지값이 무해한 persistence 사전 역할을 한다고—시사했고, §6.2 의 헤드라인 계열은 그 가정 위에서 학습되었다. 4-seed paired 재학습이 이를 뒤집는다. 학습 시점에 유지값을 제거하면 (지도 타겟, `ces_history` 의 값 및 관측 플래그, 정규화 통계, 보간 기준선의 앵커에서 모두 제거; 파일 단위 분할은 대조군 manifest 에 고정하고 채점 표본은 행 단위로 일치시킴) 진짜 측정  $V_{\text{rot}}$  성능이 4 개 분할 전부에서 개선된다: 평균 paired skill +0.039 (데이터 수정만으로 MSE  $\approx 4\%$  감소), shot 군집 CI 4 개 중 3 개가 0 을 제외하며, 반대 방향은 없다.  $T_i$  는 영향이 없다 (평균 +0.004; 한 분할만 유의하게 개선, 악화는 없음). forward-fill 패딩이 “이력을 복사하는 것이 거의 최적” 이라고 모델에 능동적으로 가르치고 있었던 것이다. 따라서  $V_{\text{rot}}$  이 자기 과거에 의존하는 것은 실제 물리인 동시에 부분적으로는 계측 아티팩트이며, 정직한 서술은 두 몫을 모두 정량화해야 한다.

Window sweep (§6.7) 은 한 번도 시험된 적 없는 축에서 같은 효과를 재현한다: 유지값 제거의 이득이 window 길이에 따라 단조 감소한다 ( $W = 2, 3, 4, 6, 8$  에서 +0.088, +0.048, +0.035, +0.003, +0.006). 유지값이 있을 때 짧은 window 의 유일한 이력 슬롯은 정보가 없는 forward-fill 복사본인 경우가 많은 반면, 긴 window 는 그래도 진짜 관측에 닿는다 — 즉 유지값은 긴 window 에 상을 준 것이 아니라 짧은 window 를 벌하고 있었다. 보정하지 않으면 이 아티팩트 하나가 “ $V_{\text{rot}}$  은 긴 이력이 필요하다” 는 겉보기 추세 (+0.118  $\rightarrow$  +0.202) 를 만들어 내는데, 보정하면 사라진다.

따라서 이후 모든 실행에서 유지값 제거 학습을 규약으로 채택한다. 헤드라인에 대한 효과는 어떤 정도 바꾸지 않는 순개선이다: 유지값 제거로 재학습해도  $T_i$  는 여전히 4/4 분할에서 PASS 이고 (+0.184, +0.291, +0.238, +0.221),  $V_{\text{rot}}$  의 점추정은 모든 분할에서 상승하지만 (+0.203  $\rightarrow$  +0.226, +0.162  $\rightarrow$  +0.202, +0.100  $\rightarrow$  +0.143, +0.183  $\rightarrow$  +0.210) 3/4 에서 여전히 유의하지 않다. 즉 본 논문의 두 결론은 데이터 처리 방식에 불변이며, 이것이 사전등록된 계열을 헤드라인으로, 이 계열을 그 재현으로 보고하는 이유다.

## 4 모델

예측기는 201,258 개 파라미터의 소형 후기 융합 네트워크다. 이 문제의 병목은 용량이 아니라 정보다 (§6.7).

**진단별 인코더.** 각 모달리티 (BES, ECEI, MC) 는 시간 특징·이력과 함께 처리되는 전용 시간 인지 1-D CNN(Conv-BatchNorm-GELU 2 개 블록, 전역 평균 풀링, 96 차원 선형 사영) 으로 인코딩되며, 융합 전까지 각 진단의 채널 구조를 보존한다. 시간 특징만 처리하는 더 작은 CNN 이 하나 더 있다. 결측 제거로 센서 스트림의 유효 샘플링이 불규칙해져 균일 시간 간격을 가정하는 순환 구조가 부적합하므로 CNN 을 택했다.

**이력 인코더: 관측 마스킹 어텐션 풀링.** CES 이력은 시간 특징과 결합되어 1 층 양방향 GRU(은닉 64) 로 읽히고, 시점별 GRU 출력은 서로 독립인 두 개의 멀티헤드 가산 어텐션 *readout* [45] 으로 풀링된다 — 하나는  $T_i$  헤드로, 다른 하나는  $V_{rot}$  헤드로 라우팅된다. 윈도우는 엄격히 과거 전용이며 (타겟 행이 윈도우의 마지막 행이다, §3), 따라서 양방향성은 이력 구간 안에서만 작동할 뿐 미래 접근을 주지 않는다. 윈도우 내에서 각 이력 행을 그 뒤에 오는 행들의 맥락 속에서 평가하게 해줄 뿐이다.

일반적이지 않은 유일한 구성요소는 이 풀링 마스크다. 각 타겟의 softmax 이전에, 타겟별 관측 플래그가 0 인 모든 시점 — 완전히 마스킹된 타겟 행과, 그 타겟이 관측되지 않은 이력 행 — 은  $-\infty$  로 밀려난다. 그 결과 어텐션 질량은 해당 타겟이 실제로 측정된 행에만 놓일 수 있다. 두 타겟은 독립적으로 결측되므로 마스크도 독립이며, 윈도우 안에 관측 행이 하나도 없는 타겟은 전체 윈도우로 되돌아가  $\text{all}(-\infty)$  softmax 를 방지한다.

이것은 **보간의 귀납 편향을 어텐션에 직접 써 넣은 것이다**. PCHIP 와 선형 보간이 강한 이유는 정확히, 간극을 사이에 둔 관측된 표본만 쓰고 간극 자체는 결코 쓰지 않기 때문이다. 마스킹되지 않은 어텐션 풀은 0 으로 채워진 타겟 행과 측정값이 없는 이력 행에 가중치를 쓸 수 있어 readout 을 희석시키고, 그 역제를 플래그 채널을 통해 암묵적으로 학습하도록 network 에 떠넘긴다. 하드 마스킹은 같은 편향을 파라미터 비용 0 으로 직접 공급한다 — 바뀌는 것은 오직 각 풀이 가중할 수 있는 시점의 집합이며, 이는 §7 선택 프로토콜이 마지막으로 채택한 변경이었다.

**물리 기반 타겟별 라우팅.**  $T_i$  헤드는 고속 진단 + 시간 + 이력을 융합하지만,  $V_{rot}$  헤드는 이력과 시간만 융합하고 고속 진단을 의도적으로 배제한다. 절제 실험 (§6.6) 이 고속 진단에 10 ms 에서 쓸 만한 회전 정보가 없음을 보이기 때문이다. 풀링된 이력 요약은 타겟별 LayerNorm-Linear-GELU 블록으로 정규화·사영된 뒤 각 타겟의 MLP 헤드로 들어가며, 두 헤드는 입력 크기에 맞춰 설계되었다 ( $T_i$  72k,  $V_{rot}$  14k 파라미터). 출력은 정규화 단위로 유지된다 (역정규화는 평가에서만 수행).

**탐색에서 얻은 교훈 — 그리고 왜 용량이 레버가 아닌가.** 두 차례의 탐색 라운드에 걸친 ~40 회의 통제된 아키텍처 반복에서, 앞선 라운드의 안정성 전환점은 정규화 위치였고 (검증 손실 0.89 → 0.49), 어텐션 풀링은 가장 신뢰할 만한 단일 개선이자 최종 모델까지 살아남은 유일한 메커니즘이었으며, 공격적 용량 확장·복잡한 스킵 위상·추가 합성곱 추출기는 일관되게 held-out 성능을 개선하지 못했다. §6.7 와 함께 이 음성 결과가 이 문제는 용량이 아니라 정보에 의해 제한된다는 판단의 근거다.

## 5 평가 방법론

**지표.** 모든 오차는 물리 CES 단위로 역정규화되어 타겟별로 계산된다. 1 차 점수는 사전등록된 헤드라인 기준선에 대한 Murphy skill [14],  $\text{skill}_{\text{PCHIP}} = 1 - \text{MSE}_{\text{model}} / \text{MSE}_{\text{PCHIP}}$  (양수 = 모델 우위; 0 = 동률) 이다. 모든 팔 (모델과 모든 기준선) 은 동일한 (파일, 행) 샘플 집합에서 동일한 타겟별 유지 마스크로 채점된다. 보간은 타겟 자신의 값을 제외한다 (누수 없음). 각 shot 파일은  $\geq 0.5$  s 간극으로 분리된 복수의 측정 세그먼트를 포함하므로 (641 개 shot 전부; 파일당 중앙값 2 개, 간극 중앙값 6.3 s), 보간과 모델 입력 원도 모두 세그먼트 경계를 넘지 않으며, 경계 너머의 이웃이 필요한 시점에서는 persistence 값으로 예측한다 (커버리지 축소 없음, PR2).

**3 분할; 선택은 TEST 를 보지 않는다.** 파일들은 train/val/test 로 분할된다. test 셋은 아키텍처 탐색 이전에 예약되었고 모델 선택 과정에서 절대 읽지 않으므로, 헤드라인 수치에는 선택 편향 (winner’s curse) 이 없다. 표준 (시드 42) test 셋은 33,693 개 채점 샘플을 담는다: 관측  $T_i$  는 96 개 shot 에 걸쳐  $n = 32,787$ , 진짜 측정  $V_{rot}$  은 61 개 shot 에 걸쳐  $n = 10,729$  이다.  $V_{rot}$  표본이 적은 이유는 유지값을 제외했기 때문이며 (§3.4), 유지값을 측정값처럼 채점하면 27,437 로 부족지만 그 모집단은 민감도 확인용으로만 보고한다. 본 논문의 모든 수치는 단일 수집 스크립트가 동결된 실행 디렉터리에서 읽어오므로, 본문·표·그림이 서로 어긋날 수 없다.

표 1: 최종 모델, 표준 held-out test 분할 (시드 42), 진짜 측정 평가 기준 물리 단위 RMSE 사다리. 낮을수록 좋다. 두 보간만이 미래를 읽는다.  $V_{\text{rot}}$  RMSE 가  $\approx 23$  이 아니라  $\approx 35$  인 것은 유지값 포함 모집단에서는 유지 타겟의 기준선 오차가 0 에 가깝기 때문이다 (§3.4).

| 팔                 | 정보 접근          | $T_i$ RMSE   | $V_{\text{rot}}$ RMSE |
|-------------------|----------------|--------------|-----------------------|
| <b>모델 (나우캐스터)</b> | 고속 진단 + 과거 CES | <b>407.0</b> | <b>35.0</b>           |
| 선형 보간             | 과거 + 미래 CES    | 441.0        | 38.4                  |
| PCHIP 보간          | 과거 + 미래 CES    | 449.3        | 39.2                  |
| Persistence       | 마지막 관측 CES     | 504.3        | 44.4                  |
| AR (국소, 인과)       | 과거 CES 만       | 2425.9       | 91.5                  |

**사전등록.** test 수치를 보기 전에 네 규칙을 문서로 고정했다: **PR1** 헤드라인 비교 대상은 PCHIP(과도 현상에서의 단조성·무진동을 근거로 사전 선택; 사다리 전체 {persistence, 선형, PCHIP, AR} 도 보고); **PR2** 보간은 모델이 채점되는 모든 곳에서 예측하며, 미래 이웃이 없으면 persistence 로 후퇴 (모집단 축소 없음); **PR3** test 셋 최소 규모 ( $\geq 15$  shot,  $\geq 3,000$  관측  $T_i$  샘플; 충족); **PR4** 유의성은 skill 에 대한 shot 군집 bootstrap 95% CI 가 0 을 제외하는 것으로 정의.

**Shot 군집 paired bootstrap.** 한 방전 내 인접 CES 행은 강하게 상관된다. 샘플을 독립으로 취급하면 불확실성이 크게 과소평가된다. 샘플별 짝지는 오차  $SE_{\text{model}} - SE_{\text{PCHIP}}$  를 shot 단위로 집계하고, shot 전체를 복원추출로 재표본한다 (10,000 회, 고정 시드). 얻어진 CI 는 진짜 shot 간 일반화를 반영한다. 대가는 유효 표본 크기가 shot 수 ( $\approx 96$ ) 가 된다는 것이며, 이것이 전체 유의성 판정의 검정력을 제한한다.

**MNAR 문제와 그에 대한 우리의 대응.** 진짜 결측 시점에는 참값이 없으므로 skill 은 관측된 시점을 가려 측정한다. CES 결측은 MNAR 이므로 (저신호, ELM, 천이에서 탈락) 관측 시점 skill 은 진짜 결측 시점 성능의 낙관적 추정이다. 이를 명시하고 거기서 멈추면 논문의 핵심 수치에 크기를 모르는 보정항이 붙은 채로 남으므로, 멈추지 않는다. §6.4 에서 채점된 지점들을 실제로 결측인 지점들의 공변량 분포 위로 재가중하여 skill 이 얼마나 살아남는지를 보고하고, 아울러 이 모델을 애초에 적용할 수 있는 결측 모집단의 비율도 함께 보고한다.

## 6 결과

### 6.1 모델은 모든 인과 기준선을 압도한다

표 1 는 표준 test 분할에서의 물리 단위 RMSE 사다리를 보여준다. 모델은 두 타겟 모두에서 최저 RMSE 를 가지며, 인과 기준선—persistence 와 과거 전용 AR, 즉 실시간에서 실제로 사용 가능한 모든 것—을 큰 차이로 이긴다. 이는 본 논문에서 가장 강건한 결과다: 미래 CES 가 정의상 없는 온라인 환경에서 모델은 명백한 승자다.

### 6.2 헤드라인: $T_i$ 는 4 개 독립 분할에서 미래를 쓰는 보간을 이긴다

최종 아키텍처 (양방향 GRU 이력 인코더 + 타겟별 관측 마스킹 멀티헤드 어텐션,  $W=4$ ; §7 의 프로토콜 이 검증 skill 만으로 선택) 로 독립적인 4 개 held-out test 분할 (시드 42, 1, 7, 123; 뒤의 셋은 어떤 선택 단계에도 사용되지 않음) 을 평가했다. 표 2 에 두 평가 모집단을 함께 보고한다.

- $T_i$ : 두 평가 모집단 모두에서 4 개 분할 전부 PASS.  $skill_{\text{PCHIP}}$  는 진짜 측정 기준  $+0.18 \sim +0.28$  (유지값 포함 시  $+0.19 \sim +0.28$ ) 이며, 모든 shot 군집 CI 가 0 을 제외한다. 더 강한 선형 보간을 상대로는 마진이 좁아지지만 진짜 측정 기준 3/4 분할에서 살아남고 (시드 42 가  $+0.148$  로 n.s.; 나머지  $+0.167, +0.259, +0.234$  는 PASS), 유지값 포함 시에는 4/4 다. 사전등록된 PCHIP 비교만 인용하지 않고 이 시드 42 결과를 명시한다.
- $V_{\text{rot}}$ : 승리가 아니라 동률. 두 모집단 모두에서 점추정은 전부 양수지만 PR4 를 통과하는 것은 시드 1 뿐이다 (진짜 측정 기준  $+0.162 [+0.021, +0.257]$ ; 유지값 포함 시 0/4). 4 개 중 1 개 유의는 잡음이 만들어낼 수 있는 수준이므로 회전 채널의 승리는 주장하지 않는다.

Final model (seed 42): lowest RMSE in the full baseline ladder (physical units)



그림 2: 최종 모델 (시드 42, held-out test, 진짜 측정) 의 RMSE 사다리: 인과 모델이 두 타겟 모두 최저 RMSE 를 달성하여 인과 기준선을 결정적으로 이기고, 미래를 쓰는 보간도 앞선다. 표 1 와 같은 수치이며, 둘 다 같은 동결 산출물에서 생성된다.

표 2: Held-out test skill<sub>PCHIP</sub> 와 shot 군집 95% CI(10,000 회 재표본). 진짜 측정은 계기 유지값을 채점에서 제외한 것 (헤드라인, §3.4), 유지값 포함은 기존 모집단에서의 민감도 확인이다. 시드 1, 7, 123 은 모델 선택이 전혀 건드리지 않았다.

| 타겟        | 시드  | 진짜 측정만                          |      | 유지값 포함                 |      |
|-----------|-----|---------------------------------|------|------------------------|------|
|           |     | skill <sub>PCHIP</sub> (95% CI) | 판정   | skill <sub>PCHIP</sub> | 판정   |
| $T_i$     | 42  | +0.179 [+0.007, +0.302]         | PASS | +0.257                 | PASS |
|           | 1   | +0.197 [+0.091, +0.276]         | PASS | +0.194                 | PASS |
|           | 7   | +0.280 [+0.192, +0.347]         | PASS | +0.263                 | PASS |
|           | 123 | +0.263 [+0.109, +0.348]         | PASS | +0.280                 | PASS |
| $V_{rot}$ | 42  | +0.203 [-0.225, +0.362]         | n.s. | +0.154                 | n.s. |
|           | 1   | +0.162 [+0.021, +0.257]         | PASS | +0.109                 | n.s. |
|           | 7   | +0.100 [-0.586, +0.291]         | n.s. | +0.065                 | n.s. |
|           | 123 | +0.183 [-0.151, +0.265]         | n.s. | +0.127                 | n.s. |

- **사후 점검: 가장 강한 오프라인 팔은 GP 이고, 모델은 그것과 동률이다.** 사전등록 사다리 밖에서, 융합 커뮤니티의 표준 프로파일 피팅 도구인 GP 회귀를 바이트 동일 모집단 위에 사후 (post-hoc) 팔로 추가했다 (정확한 Matérn-3/2 + 백색잡음, 최근접 16+16 국소 적합, 표본별 주변우도 격자 선택 — 결정론적이며, 타겟 자신의 값은 절대 읽지 않고 PR2 fallback 을 그대로 상속한다). GP 는  $T_i$  4 개 분할 전부터 PCHIP 을 유의하게 이기는 (+0.21–+0.28) 가장 강한 오프라인 평활기로 판명됐고 — linear 가 PCHIP 을 이긴 기전을 한 걸음 더 간 것: 잡음 앵커를 정확히 통과하는 대신 잡음을 평균해 낸다 — 모델은 그것과 동률이다 (유의 승 1/4, 유의 패 0/4, 점추정  $-0.08 \pm 0.09$ ;  $V_{rot}$  은 전부 n.s.). 따라서 관측 모집단의 주장은 “사전등록된 보간들을 이기고, 미래를 읽는 표본별 튜닝 평활기와는 맞먹는다”이며, 배치 주장은 영향받지 않는다 — 미래 앵커 없는 GP 는 온라인에 존재하지 않는다. 동률을 해소할 수 있는 지목된 측정: 더 많은 test shot(시드 7 은 이미 해소한다), 그리고 아직 실행하지 않은 인과 과거-전용 GP 팔.

정직한 진행 기록: 초기 기준 모델은 유의하지 않았다 (단일 분할, +0.088, 95% CI  $[-0.221, +0.323]$ ). 아키텍처 탐색의 선택 게이트를 검증 손실에서 깨끗한 보간 대비 skill 로 바꾼 것이 최종 모델을 낳았고, 이것이 4 개 분할 모두에서 유의하다 (그림 4). 두 단계 모두 유지값 포함 모집단에서 채점했다. 초기 체크포인트가 평가된 적 있는 모집단이 그것뿐이며, 서로 다른 모집단에서 비교하는 것은 비교가 아니기 때문이다. 두 단계를 모두 보고한다.

### 6.3 skill 이 사는 곳, 그리고 큰 간극에서의 올바른 상대

마지막 관측 CES 이후 경과 시간  $\Delta t$  로 증화하면 실제 타겟의  $\geq 96\%$  가 작은 간극 영역 ( $\Delta t \leq 15$  ms) 에 있다. 시드별로는 넓은 구간의 표본이 수십 개뿐이라 이전에는 결론을 지탱할 수 없었다. 그래서 4 개 test 분

**Skill vs. PCHIP interpolation with shot-clustered 95% CI (B = 10,000) · genuine-measurement evaluation**




그림 3: 4 개 독립 held-out 분할에서 shot 군집 95% CI 와 함께 나타낸  $\text{skill}_{\text{PCHIP}}$  의 포레스트 플롯.  $T_i$  는 4 개 모두에서 0 을 제외;  $V_{\text{rot}}$  은 하나도 제외하지 못한다.




그림 4: 비유의 (기준 모델, +0.088 n.s.) 에서 유의 (최종 모델, +0.18~+0.28, PASS ×4) 로: 결정적 변화는 검증 손실이 아닌 깨끗한 skill 로 아키텍처를 선택한 것이었다.

할을 합치고 bootstrap 을 물리적 방전 단위로 군집화해, 두 분할에 모두 등장하는 shot 이 두 번이 아니라 한 번 세어지도록 했다. 이로써 처음으로 넓은 구간에 CI 를 붙일 수 있게 되었다 (표 3).

이는 PCHIP 비교만으로는 답할 수 없는 질문을 강제한다.  $\Delta t$  가 커질수록 PCHIP 의 문제는 쉬워진다 — 간극을 사이에 둔 두 실측값을 잇기만 하면 된다. 반면 우리 문제는 과거만으로 외삽해야 하므로 어려워진다. 더 결정적으로, 실행 시점에는 미래 앵커가 없으므로 PCHIP 은 애초에 선택지가 아니다. 큰 간극에서 배치된 나우캐스터가 실제로 이겨야 하는 상대는 가장 좋은 인과 기준선, persistence 다. 따라서 둘 다 보고한다.

확신도가 높은 순으로 세 가지를 읽어낼 수 있다.

$T_i$  의 승리는 인접 이력에 국한되지 않는다. 분할을 합치자 비인접 영역이 처음으로 측정 가능해졌고, 그곳에서도 모델은 미래를 쓰는 PCHIP 을 이긴다:  $\Delta t > 15 \text{ ms}$  전체에서 +0.191 [+0.10, +0.28] 이며, (15, 25], (25, 35], (55, 105] 구간이 각각 단독으로 유의하다. 이는 이전 초안이 할 수 없던 더 강한 주장이며, 간극 메우기가 가장 덜 자명한 영역이다.

가장 넓은 간극에서는 보간이 실제로 이긴다 — 단, 미래를 볼 수 있기 때문이다. 105 ms 를 넘으면 모델은 PCHIP 보다 유의하게 나쁘다 (−0.542, CI 전체가 0 아래). 이를 그대로 보고한다. 같은 구간에서 인과 기준선 대비로는 동물이고 (+0.266, 하한이 0),  $\Delta t > 45 \text{ ms}$  전체로 묶으면 persistence 를 유의하게 이기면서 (+0.271 [+0.12, +0.41]) PCHIP 과는 동물이다 (−0.057, n.s.). 따라서 올바른 진술은 “모델이 큰 간극에서 실패한다”가 아니라 “큰 간극 영역은 양측 보간의 영역이고, 양측 보간은 실시간 시스템이 가질 수 없는 바로 그 것이다”이다.

표 3: 간극 증화 skill, 4 개 test 분할 통합, shot 군집 95% CI(진짜 측정). PCHIP 은 미래 앵커를 읽지만 persistence 는 읽지 않는다. 굵은 글씨 = CI 가 0 을 제외.

| $\Delta t$   | $n$     | shot | PCHIP 대비 (미래 사용)             | persistence 대비 (인과)          |
|--------------|---------|------|------------------------------|------------------------------|
| $T_i$        |         |      |                              |                              |
| $\leq 15$ ms | 134,629 | 298  | <b>+0.262</b> [+0.20, +0.31] | <b>+0.407</b> [+0.36, +0.45] |
| (15, 25]     | 2,987   | 259  | <b>+0.183</b> [+0.05, +0.30] | <b>+0.384</b> [+0.28, +0.48] |
| (25, 35]     | 784     | 122  | <b>+0.402</b> [+0.21, +0.57] | <b>+0.564</b> [+0.41, +0.68] |
| (35, 55]     | 395     | 98   | +0.143 [-0.21, +0.41]        | +0.169 [-0.15, +0.45]        |
| (55, 105]    | 163     | 57   | <b>+0.282</b> [+0.03, +0.49] | <b>+0.287</b> [+0.04, +0.51] |
| > 105 ms     | 167     | 62   | <b>-0.542</b> [-2.07, -0.08] | +0.266 [-0.00, +0.46]        |
| 전체 > 15 ms   | 4,496   | 272  | <b>+0.191</b> [+0.10, +0.28] | <b>+0.388</b> [+0.32, +0.46] |
| 전체 > 45 ms   | 435     | 105  | -0.057 [-0.45, +0.21]        | <b>+0.271</b> [+0.12, +0.41] |
| $V_{rot}$    |         |      |                              |                              |
| $\leq 15$ ms | 51,457  | 195  | +0.209 [-0.02, +0.29]        | <b>+0.368</b> [+0.17, +0.45] |
| 전체 > 15 ms   | 1,756   | 161  | +0.027 [-0.20, +0.24]        | <b>+0.309</b> [+0.13, +0.47] |

$V_{rot}$  은 보간과 동률이지만 모든 인과 대안을 이긴다. §6.2 의 전역  $V_{rot}$  동률은 미래를 쓰는 방법과의 동률이다. persistence 대비로는 작은 간극에서 유의하게 우수하고 (+0.368) 15 ms 를 넘어서도 유의하게 우수하다 (+0.309). 온라인 가상 센서에는 이쪽이 실질적인 비교이며, 그 기준에서 회전 채널은 헤드라인이 동률이라 부르더라도 유용하다.

#### 6.4 실제로 결측인 지점에서는 얼마나 살아남는가?

위의 모든 수치는 관측된 CES 지점에서 측정된 것이다. 나우캐스터가 메우려는 지점은 결측이고, CES 결측은 무작위가 아니므로 두 모집단은 다르다. 참값이 없는 곳의 오차를 측정할 수는 없다. 그러나 관측 행과 결측 행 양쪽에서 계산 가능한 공변량 위에서 skill 이 어떻게 변하는지는 측정할 수 있고, 그것으로 재가중할 수 있다. 이 문제의 결측 기전을 나르는 공변량은 둘이다: 마지막 진짜 관측 이후 경과 시간  $\Delta t$  (결측 지점은 구조적으로 탈락 구간 더 깊숙이 있다) 와, §6.9 의 입력 전용 국소 활동 플래그 (ELM/천이 측) 다. 후자가 결측 행에서도 정의되는 이유는 정확히, 그것이 자기 행을 제외한 이웃 집합에서 계산되기 때문이다.  $\Delta t \times$  활동도로 사후 증화하고, 채점 표본이 30 개 미만인 층은 믿는 대신 버리며, 그 결과 커버리지를 모든 추정치 옆에 함께 보고한다. 가정 — 한 층 안에서 결측 행과 관측 행이 교환 가능하다는 것 — 은 숨기지 않고 명시한다. 대조 확인으로, 이 격자에서 계산한 활동도 비율은 동결 산출물에 저장된 플래그와  $T_i$  에서 0.004,  $V_{rot}$  에서 0.009 이내로 일치한다. 즉 재가중의 양쪽이 같은 변수를 쓴다.

**첫째, 이전에 말한 적 없는 적용 범위 사실.** 표본이 애초에 예측 가능하려면 해당 타겟의 관측값이 모델 window 안에 있어야 한다. 진짜 결측인  $T_i$  행 중 이 의미에서 **도메인 내인 것은 54.1%**,  $V_{rot}$  행 중에서는 4.8% 뿐이다. 즉  $W=4$  에서 이 방법은 실제  $T_i$  간극 문제의 절반 정도와  $V_{rot}$  문제의 한 귀퉁이를 다룬다 — 잘 못 예측해서가 아니라 적용 자체가 불가능해서다. 이는 정확도 한계가 아니라 커버리지 한계이고 구조적으로 고칠 수 있으며 (§9), §6.7 의 window 문제를 다시 연다:  $W$  는 skill 에는 무관하지만 실제 결측의 얼마를 닿을 수 있는지에 결정적이다.

**둘째, 낙관 편향 자체는 작다 — 인과 비교에 대해서는.** 도메인 내 결측 지점으로 한정했을 때 (층 커버리지 95–100%):

두 비교가 갈라지며, 그 갈라짐이 이 절에서 가장 쓸모 있는 결과다. persistence — **온라인 시스템이 실제로 돌리는 기준선** — 대비로는  $T_i$  우위가 재가중 후에도 4 개 분할 전부에서 +0.29 로 살아남고, 점 추정이 놀랍도록 안정적이며 모든 CI 가 0 을 제외한다. MNAR 보정 비용은 0.06–0.12 에 불과하다. **미래를 쓰는 PCHIP 대비로는 살아남지 못한다** (재가중 후 4 개 중 1 개만 유의). 이는 §6.3 과 기계적으로 일관된다 — 결측 지점은 더 큰  $\Delta t$  에 있고, 그곳이 바로 양측 앵커가 가장 크게 돕고 인과 외삽기가 가장 불리한 지점이다.

따라서 근거가 뒷받침하는 주장을, 중요한 지점에 대해 그대로 진술한다: 진짜 결측이면서 도메인 내인 시점에서, 이 나우캐스터는 어떤 인과적 CES 전용 방법보다도 유의하게 낮고, 오프라인 보간을 이긴다는 것은 입증되지 않는다. 오프라인 비교는 관측 모집단에 대해 더 어렵고 더 유익한 기준으로 남아 헤드

표 4: 관측 모집단에서 진짜 결측·도메인 내 모집단으로 재가중한 skill. shot 군집 95% CI(2,000 회 재표본; 층 가중치를 고정한 상태의 오차 변동성을 포괄).

| 타겟                    | 시드  | 관측 가중  | 결측 정합 (95% CI)                 | 낙관 편향  |
|-----------------------|-----|--------|--------------------------------|--------|
| $T_i$ vs. persistence | 42  | +0.349 | <b>+0.292</b> [+0.162, +0.415] | +0.056 |
|                       | 1   | +0.380 | <b>+0.308</b> [+0.143, +0.429] | +0.072 |
|                       | 7   | +0.405 | <b>+0.293</b> [+0.192, +0.441] | +0.112 |
|                       | 123 | +0.415 | <b>+0.293</b> [+0.155, +0.392] | +0.121 |
| $T_i$ vs. PCHIP       | 42  | +0.146 | +0.061 [-0.075, +0.267]        | +0.084 |
|                       | 1   | +0.188 | +0.132 [-0.064, +0.274]        | +0.056 |
|                       | 7   | +0.280 | <b>+0.211</b> [+0.050, +0.374] | +0.069 |
|                       | 123 | +0.264 | +0.175 [-0.025, +0.290]        | +0.090 |

표 5: 시간 (캠페인) 분할, 4 개 초기화. Test 구간은 모든 팔에게 더 어렵지만 (PCHIP RMSE 601 대 무작위 분할 449) skill 이 그것을 정규화하므로, 이는 보간 대비 손실이다.

| 초기화 시드 | $T_i$                   |                | $V_{rot}$    |                |
|--------|-------------------------|----------------|--------------|----------------|
|        | PCHIP 대비 (95% CI)       | persistence 대비 | PCHIP 대비     | persistence 대비 |
| 42     | +0.051 [-0.083, +0.135] | <b>+0.275</b>  | -0.061       | <b>+0.223</b>  |
| 1      | +0.044 [-0.111, +0.145] | <b>+0.270</b>  | -0.005       | <b>+0.264</b>  |
| 7      | -0.148 [-0.396, -0.000] | <b>+0.123</b>  | -0.156       | <b>+0.153</b>  |
| 123    | -0.018 [-0.188, +0.093] | <b>+0.223</b>  | -0.056       | <b>+0.226</b>  |
| 평균     | -0.018 (0/4 PASS)       | +0.222         | -0.069 (0/4) | +0.216         |

라인을 유지하지만, 배치에 관해 우리가 하는 주장은 그것이 아니다.  $V_{rot}$  도 같은 양상이나 훨씬 얇은 기반 위에 있으므로 (persistence 대비 4 개 중 2 개 유의, 결측의 4.8% 만 도메인 내) 회전에 대해서는 배치 결론을 내지 않는다.

## 6.5 캠페인 이동에서도 살아남는가?

배치가 무작위 분할과 다르게 하는 두 번째 것은 시간상 앞으로 나아간다는 점이다. 그래서 641 개 방전을 shot 번호로 정렬하고 (30801–32751, 연속) 시간으로 엄격히 자른다: **train 416 shot [30801, 31991]**, **val 128 [32002, 32310]**, **test 97 [32312, 32751]** 이며 어떤 test shot 도 어떤 train shot 보다 앞서지 않는다. 나머지는 헤드라인 프로토콜에 고정했으므로 바뀐 변수는 분할 규칙뿐이다. 분할이 고정이므로 네 실행은 초기화 시드만 달리한다 — 여기서의 재현은 분할이 아니라 초기화에 대한 것이며, 이를 “4 개 시드” 로 제시하지 않고 그대로 밝힌다.

**두 개의 독립적인 스트레스 테스트가 같은 답을 준다.** 표 6 에 나란히 놓았다. 미래를 쓰는 보간 대비 우위는 무작위 분할의 관측 모집단에 국한된 성질이며 어느 스트레스 테스트도 통과하지 못한다. 실시간 시스템이 실제로 돌릴 수 있는 기준선 대비 우위는 둘 다 통과한다.

**왜 나빠지는가 — 주장이 아니라 측정.** 이 양상은 특정한 기전을 함의한다: 전이에 실패해야 하는 것은 고속 진단 경로다. CES 전용 보간 대비 우위를 사는 것이 바로 그 경로이기 때문이며, 반면 CES 이력 경로는 두 기간에서 같은 물리량을 같은 단위로 본다. 모델이 정규화된 단위로 채널별 train→test 드리프트를 재면 이것이 확인된다: 위치 이동의 중앙값은 **BES**  $1.22\sigma$ , **ECEI**  $0.53\sigma$  이고 스케일 비는 각각 0.75, 0.62 인데, **CES 타겟 자체는**  $0.115\sigma$ , **스케일 비** 1.06 이다. 고속 진단이 예측 대상보다 5–11× 더 이동한다. 인코더는 정규화된 범위에서 표준편차 이상 벗어난 입력을 받고 있는 반면 이력 경로는 온전하며, 그래서 persistence 대비 마진은 대체로 유지된다.

이는 우리 자신의 설계 선택 하나를 유용한 방식으로 고발한다. 학습 파일 전용 통계로 정규화하는 것 (§3) 은 무작위 분할에서는 올바른 누수 방지 선택이며, 캠페인 이동에서 깨지는 것이 정확히 그것이다. 표적화된 수리는 고속 진단의 shot 별 또는 인과적 running 표준화다: 해당 shot 자신의 데이터만 쓰므로 누수가 없고 실행 시점에 사용 가능하다. 확실한 승리처럼 제시하지 않고 정직한 주의를 하나 덧붙인다 —

표 6: 스트레스 하의 두 주장. 하나만 강건하며, 그것이 배치에 중요한 쪽이다.

| 평가                 | PCHIP 대비 (오프라인, 미래 사용) | persistence 대비 (인과) |
|--------------------|------------------------|---------------------|
| 무작위 분할, 관측 지점      | +0.18~+0.28, 4/4       | +0.35~+0.42         |
| 결측 지점으로 재가중 (§6.4) | +0.06~+0.21, 1/4       | +0.29, 4/4          |
| 시간 캠페인 분할 (§6.5)   | -0.15~+0.05, 0/4       | +0.12~+0.28         |

표 7: 입력 모달리티 절제 (검증 분할, persistence 대비 skill, 물리 단위). 고속 진단 단독은 진짜  $T_i$  정보를 운반하지만  $V_{\text{rot}}$  에는 파국적으로 무정보하다.

| 모델 입력                        | $T_i$ skill | $V_{\text{rot}}$ skill |
|------------------------------|-------------|------------------------|
| 전체 (이력 + 고속 + 시간)            | +0.43       | +0.30                  |
| 이력만 ( <i>no fast</i> )       | +0.46       | +0.29                  |
| 고속 진단만 ( <i>no history</i> ) | +0.37       | -0.64                  |

shot 별 표준화는 절대 수준 정보도 버리는데 그것이  $T_i$  정보를 나눌 수 있으므로 (BES 높음 ↔ 밀도 높음) 무작위 분할 skill 을 전이와 맞바꿀 수 있다. 이 절충은 가정이 아니라 통제 실험의 대상이며, 그래서 실제로 수행했다.

**수리는 작동하고, 절충은 작지만 실재한다.** 각 방전의 고속 진단을 그 방전 자신의 평균 분산으로 적재 시점에 표준화하는 것—타겟은 건드리지 않으므로 물리 단위 역변환과 모든 기준선은 불변—이 위 실험들에 대한 단일 통제 변수다. 캠페인 분할에서 손실의 대부분을 되찾는다: 짝지은  $T_i$  skill 이 4/4 초기화에서 +0.10~+0.29 개선 (평균 +0.155), 95% CI 가 모두 0 을 제외하며, PCHIP 대비 관문은 0/4 에서 2/4 로 바뀐다 (+0.18, +0.14, +0.19, +0.08). 수리 전 팔은 4 개 중 2 개에서 보간보다 아래였다.  $V_{\text{rot}}$  은 변하지 않는데 (평균 -0.019) 이는 예상된 음성 대조군이다:  $V_{\text{rot}}$  헤드는 구조상 고속 진단이 차단돼 있으므로 그 채널을 어떻게 표준화해도 닿지 않는다. 무작위 (헤드라인) 분할에서 대응 대조군과 짝지으면 **어느 시드에서도 유의한 손실이 없다** (평균 -0.036, 최악 시드 -0.127 이며 CI 상한 +0.008). 따라서 정직한 진술은 “공짜”가 아니라 “측정 가능한 비용 없음”이다. 이는 기제도 인과적으로 확정한다: 캠페인 손실이 두 시기 사이 물리의 변화였다면 입력의 수준 이동을 제거하는 것으로 회복될 수 없었다. 배치까지 남은 간극은 온라인 추정기가 방전의 미래를 볼 수 없어 그 분산을 계산할 수 없다는 점이며, 따라서 shot 별 표준화는 이 계열의 오프라인 상한이고 배치 가능한 형태는 확장 원도/EWMA 추정기다—이는 아직 측정하지 않았다.

## 6.6 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭

통제된 입력 모달리티 절제 (동일한 학습 예산; 한 번에 한 모달리티 그룹을 0 으로; persistence 는 항상 실제 이력에서 계산) 는 두 타겟이 다르게 행동하는 이유를 설명한다 (표 7, 그림 5).

- $T_i$ : **고속 진단이 진짜 정보를 운반한다.** 고속 단독으로도 persistence 를 큰 폭으로 이긴다 (+0.37, 즉 전체 모델 +0.43 의 대부분). 물리적 채널은 충돌성 전자-이온 결합 ( $t_{ei} \propto T_e^{3/2}/n_e$ ) 이다: ECEI 가  $T_e$  를, BES 가  $n_e$  구조를 공급한다.
- $V_{\text{rot}}$ : **정보가 거의 전적으로 CES 이력에 있다.** 고속 단독은 -0.64 이고 평균 예측 대비  $R^2 = -0.06$  이다 — 입력을 무시하고 평균을 내놓는 것보다 엄격히 나쁘다. 토로이달 회전은 우리 입력이 관측하지 못하는 운동량 소스—외부 NBI 토크와 고유 (intrinsic) 회전 구동 [50]—이 지배하며, Mirnov 신호는 100 Hz 로 샘플되어 회전을 대리할 수 있었을 kHz 모드 회전 주파수가 앨리어싱으로 사라진다.

이 비대칭은 절제 이전에 물리로 예측되었고 절제로 확인되었다.  $V_{\text{rot}}$  의 비-승리는 모델 실패가 아니라 진단 정보 내용에 관한 발견이며, §4 의 타겟별 라우팅을 동기화한다.

## 6.7 이력은 얼마나 필요한가? 관측 하나

이력 window 는 원래 검토된 적 없는 기본값 ( $W = 4$ ) 이었다. 우리는 이 주장을 곡선과 명시적 선택 규칙으로 대체한다: **24 개의 독립 실행** ( $W \in \{2, 3, 4, 6, 8\} \times \text{seed} \{42, 1, 7, 123\}$ ) 에 *history-0* 점  $\times$  4 seed 를 더




그림 5: 모달리티 절제: 고속 진단 단독은  $T_i$  에서 persistence 를 이기지만  $V_{rot}$  에서는 평균보다 훨씬 나쁘다 — 정보 비대칭.

표 8: Window sweep, 4 seed 평균 held-out test skill<sub>PCHIP</sub> (PASS = shot 군집 95% CI 가 0 을 제외한 seed 수). History-0 은  $W=4$  에서의 no\_history 절제로, 센서 window 는 그대로 두고 CES 이력 텐서만 0 으로 만든다.  $W=1$  은 구성 불가.

| 이력 관측 수      | $W$ | $T_i$ skill | PASS | $V_{rot}$ skill | PASS |
|--------------|-----|-------------|------|-----------------|------|
| 0            | 4   | -0.026      | 0/4  | -0.783          | 0/4  |
| 1            | 2   | +0.238      | 4/4  | +0.206          | 0/4  |
| 2            | 3   | +0.246      | 4/4  | +0.203          | 1/4  |
| 3 4 (기준 기본값) |     | +0.221      | 3/4  | +0.190          | 1/4  |
| 5            | 6   | +0.190      | 3/4  | +0.205          | 1/4  |
| 7            | 8   | +0.216      | 4/4  | +0.204          | 2/4  |

해, 각각 자기 held-out test 분할에서 헤드라인과 동일한 프로토콜로 채점했다. 세 가지 통제를 가정이 아니라 데이터에서 직접 검증했다: 파일 단위 분할은 window 에 불변이며 (24 개 실행 전부가 seed 당 동일한 96 개 test shot 을 평가), 새로 도입한 shot 당 표본 상한이 시간 부분집합 증강— $W=2$  에서 24 만 샘플이  $W=8$  에서 3,010 만으로 폭발한다—으로 인해 소수의 긴 블록 방전이  $W$  가 클수록 학습 표본을 더 강하게 지배하는 것을 막고, 채점 표본은  $W=2 \rightarrow W=8$  에서 1.8% 만 줄어든다. 학습은 전 구간 유지값 제거 (§3.4) 다. 이는 필수적인데, 유지값은 직전 판독의 문자 그대로의 복사본이라 오염 상태에서는 긴 window 가 단지 같은 숫자의 복사본을 더 공급할 뿐이기 때문이다. 모든 실행은 최종 아키텍처를 쓴다.

**이력은 필수적이고, 그 첫 관측이 사실상 전부를 운반한다.** 이전 CES 를 완전히 제거하면  $T_i$  는 PCHIP 아래로 (-0.026, 0/4),  $V_{rot}$  은 -0.78, 즉 PCHIP MSE 의  $\approx 1.8$  배로 떨어진다. 따라서 고속 진단만으로는 보간 동물에도 이르지 못한다 — 모델의 마진 전체가 고속 진단과 과거 CES 의 결합에서 나온다. 그런데 단 하나의 과거 관측이 두 타겟을 동시에 최대치로 끌어올리고 ( $T_i$  +0.238 4/4,  $V_{rot}$  +0.206), 그 뒤로 곡선은 평탄하다 —  $T_i$  는 0.190–0.246,  $V_{rot}$  은 0.190–0.206(폭 0.016) 인데, 점 하나 안의 seed 산포가 0.07–0.16 으로 곡선 전체 폭보다 넓다. 이것이 정보 제한 해석의 가장 날카로운 진술이다: 이력을 더 주어도, (§4) 더 표현력 있는 인코더를 써도 결과는 움직이지 않지만, 관측 하나를 지우면 결과가 무너진다.

**선택 규칙과 그 답.** “plateau 에 도달하는 최소  $W$ ” 를 적용하면  $W=2$  가 나온다. 두 타겟 모두 이미 그 지점에서 plateau 이고, 기존  $W=4$  는 두 타겟 모두에서  $W=2/W=3$  보다 낮다. 정확도를 근거로 더 긴 window 에 비용을 지불할 이유는 데이터에 없다. 더 넓게 갈 유일하게 방어 가능한 이유는 **skill 이 아니라 커버리지**다: 표본은 window 안에 관측값이 있을 때만 채점되므로,  $W=2$  는 직전 행에 해당 판독이 없는 타겟을 조용히 누락시킨다. 총 채점 수는 거의 변하지 않지만 ( $V_{rot}$  52.1k  $\rightarrow$  53.2k), 어려운 부분집합은 크게 늘어난다 —  $W=2 \rightarrow W=8$  에서  $\Delta t > 15$  ms 가 456  $\rightarrow$  1,958,  $\Delta t > 45$  ms 가 14  $\rightarrow$  135 이다. 넓은 window 는 긴 간극 표본을 더 잘 예측하는 것이 아니라, 그것들을 애초에 4–10 배 더 많이 예측한다.

표 9: 복잡도 사다리: held-out test skill<sub>PCHIP</sub>, 유지값 제거 학습, 진짜 측정 평가. 마지막 열은 해석 가능한 모델이 회수한 persistence → 전체 모델 격차의 비율.

| 팔                              | 파라미터    | 시드 42  | 1      | 7      | 123    | 격차 회수        |
|--------------------------------|---------|--------|--------|--------|--------|--------------|
| $T_i$                          |         |        |        |        |        |              |
| Persistence                    | 0       | -0.260 | -0.320 | -0.251 | -0.256 | —            |
| <b>앵커 +<math>\Delta</math></b> | 1,258   | -0.107 | -0.138 | -0.097 | -0.109 | <b>31.5%</b> |
| 전체 모델                          | 201,258 | +0.238 | +0.184 | +0.291 | +0.221 | 100%         |
| $V_{\text{rot}}$               |         |        |        |        |        |              |
| Persistence                    | 0       | -0.283 | -0.297 | -0.287 | -0.307 | —            |
| <b>앵커 +<math>\Delta</math></b> | 1,258   | -0.253 | -0.269 | -0.241 | -0.278 | <b>7.0%</b>  |
| 전체 모델                          | 201,258 | +0.227 | +0.202 | +0.143 | +0.210 | 100%         |

**정직한 주의.** 이들은 *paired* 가 아닌 독립 실행이므로 곡선 위의 모든 차이는 seed 잡음 안에 있다. 주장은 window 들 사이의 순위가 아니라 window 효과의 부재다. 또한 shot 당 상한 때문에 절대 skill 은 상한이 없던 §6.2 헤드라인 계열과 직접 비교할 수 없다. 이 sweep 은 모든 점이 같은 상한을 공유하는 곡선 내부 비교를 위해 설계되었다.

## 6.8 복잡도는 무엇을 사는가? 1,258 파라미터까지 내려가는 사다리

이 모델에 대한 정당한 비판은, 그것이 태스크에서 유도된 구조가 아니라 탐색의 퇴적물이며 20 만 파라미터가 설명 불가능하다는 것이다. 쓸모 있는 대답은 “작은 모델도 된다” 를 보이는 것이 아니라 복잡도가 무엇을 버는지 측정하는 것이다. 그래서 이 태스크가 허용하는 가장 해석 가능한 예측기를 만들어 같은 기준에 올렸다.

**앵커 + $\Delta$**  모델은 각 타겟을 이름 붙는 세 항의 합으로 예측한다: persistence 형태의 앵커 (최근접 관측 CES 를 학습된 스무딩 가중으로 관측 평균 쪽으로 혼합), 기울기 항 (최근 관측 2 점의 기울기  $\times$  갭), 그리고 진단별 변화율 항 (BES/ECEI/MC 요약통계  $\rightarrow$  변화율  $\times$  갭). 파라미터는 **1,258 개**로 전체 모델의 0.6% 다. 학습되는 항은 전부 0 으로 초기화되므로 학습이 정확히 *persistence* 에서 출발하고, 도달한 skill 은 문자 그대로 학습이 더한 값이다. `decompose()` 가 항별 기여를 반환하므로 모든 예측을 “앵커 + 이만큼의 기울기 + 이만큼의 BES 기반 변화율” 로 읽을 수 있다. 동일한 프로토콜, 유지값 제거, 같은 4 개 분할에서 학습 재점했다.

세 가지가 따라 나오며, 4 개 독립 분할에 걸친 일관성 ( $T_i$  28–36%) 이 이들을 말할 수 있게 만든다.

- **복잡도는 값을 하고 있고, 그 값을 정량화할 수 있다.** 파라미터 0.6% 의 완전 해석 가능한 예측기가 persistence 대비  $T_i$  마진의 약 1/3,  $V_{\text{rot}}$  마진의 7% 를 회수한다. 나머지가 학습된 멀티모달 인코더가 사는 것이며, *paired shot* 군집 비교는 앵커를 4/4 분할에서 기각한다.
- **해석 가능한 단은 허수아비가 아니다.**  $-0.113$  은 persistence ( $-0.272$ ) 보다 훨씬 위이므로 이름 붙는 항들의 형태도 실제로 무언가를 학습한다 — 다만 충분하지 않을 뿐이다.
- **부족분은 모델이 아니라 문제에 대한 정보다.** 앵커는 갭에 대해 선형이다. 그것이 회수 가능한 신호의 1/3 만 잡는다는 것은 구조가 상당히 비선형·비국소적이라는 뜻이므로, 더 설명 가능한 모델은 선형 항을 더 얻을 것이 아니라 다른 함수 형태가 필요하다.  $V_{\text{rot}}$  의 7% 는 그 신호가 애초에 국소 기울기가 아니라는 뜻이다.

## 6.9 우위는 고변동 국소 구간에 집중된다

타겟과 무관한 입력 측 국소 활동 대리변수 (타겟 행을 제외하고 계산한 큰 이웃 괄호 기울기 및/또는 높은 국소 CES 이웃 분산) 로 평가를 “피크”(고활동) 와 벌크 영역으로 나누면 (검증 분할, shot 군집 CI; 그림 6):

- $T_i$ : 전역  $+0.27 \rightarrow$  피크  **$+0.70$**  (CI  $[+0.50, +0.85]$ , PASS; 124 개 shot 의 4,764 행). 보간은 매끄러운 벌크에서 거의 최적이고, 모델의 가치는 활동 구간에 있다.




그림 6: 전역 대 고변동 (“피크”) skill 과 shot 군집 95% CI. 보간이 가장 약한 곳에 모델의 우위가 집중되며,  $V_{rot}$  은 전역 동률에도 불구하고 피크에서 통과한다.

- $V_{rot}$ : 전역 +0.13 → 피크 +0.44 (CI [+0.07, +0.73], PASS, 세 가지 민감도 설정에서 강건하나 하한이 낮음). 따라서 비대칭은 지역적이다: 전역적으로  $V_{rot}$  은 보간과 동률이지만, 매끄러운 과거 + 미래 보간이 가장 나쁜 고활동 구간에서는 이력 기반  $V_{rot}$  예측기도 가치를 더한다. 이는 낙관 주의가 붙는 검증 분할에서의 지역적 강점으로 보고하며, 전역 영결과의 반전이 아니다.
- 피크 한정 절제 (BES/ECEI/MC 를 0 으로) 는  $T_i$  를 유의하게 해치지만 (딱지은 차이 CI  $\gg 0$ )  $V_{rot}$  은 불변이다:  $T_i$  피크 우위는 실제로 멀티모달 신호를 사용하고,  $V_{rot}$  피크 우위는 이력 기반이다.

**$V_{rot}$  결과의 분해: 예측기 유지값이 피크의 일부다.** 관측된  $V_{rot}$  모집단의 절반 이상이 forward-fill 유지값이므로 (§3.4) 피크 구분과 유지값 패턴이 얽혀 있을 수 있다. 그래서 held-out test 분할에서 유지값 포함 처리로 두 축을 직접 교차했다 (평가 전용; 유지값 판정은 로더 자신의 규칙으로 재계산하고 행 단위로 정렬). 두 가지가 나왔고 첫 번째는 예상과 반대였다. **피크는 벌크보다 유지값이 더 많다** (4 개 분할 전부: 68/62/71/73% 대 58/51/48/46%). forward-fill 계단—평평, 평평, 도약—자체가 큰 국소 기울기이므로, CES 이웃으로 만든 활동 검출기는 예측기의 유지 패턴을 부분적으로 검출한다. **그리고 전역  $V_{rot}$  수치는 부호가 서로 다른 세 영역의 평균이다.** 실제로 측정된 고활동 행에서 모델은 미래를 쓰는 PCHIP 대비 +0.55→+0.63(4/4 에서 양수, 1/4 에서 유의—행 약 2-3 천 개, shot 약 63 개), **인과 기준선 대비 +0.75→+0.82 로 4/4 유의다.** 진짜 측정된 조용한 벌크에서는 보간과 동률 ( $\approx 0$ , 4 개 전부) 이다. 유지값 행에서는 -48 에서 -411 까지 진다—이는 모델의 실패가 아니라 구조적이다. PCHIP 은 정의상 직전 값인 그 값을 정확히 통과하므로 어떤 인과 방법도 그곳에서는 이길 수 없다. 채점 모집단을 진짜 측정 행으로 한정하면 모든 분할이 상승하지만 (+0.154 → +0.201, +0.109 → +0.126, +0.065 → +0.098, +0.127 → +0.170) 사전 등록 관문에는 도달하지 못한다. 즉 유지값 희석은 실재하지만  $V_{rot}$  이 동률인 이유의 전부는 아니며, 검정력이 그 이유다. 유지값이 사실상 없는  $T_i$  는 깨끗한 대조군으로 피크 집중을 4/4 분할에서 재현하므로 (+0.59→+0.68, 전부 유의) 집중 현상 자체는 이 아티팩트에 의존하지 않는다. 이를 더 날카롭게 할 측정은 유지값을 배제한 활동 검출기이며, 아직 실행하지 않았다.

## 7 아키텍처 선택 프로토콜

최종 아키텍처는 고정된 프로토콜 아래 수행한 일련의 통제 실험으로 도달했다. 각 후보는 하드 데이터 게약 (인터페이스, 마스킹, 누수 규칙) 을 보존해야 하는 하나의 통제된 변경이며, 스모크 검증 후 완전히 학습한 다음 깨끗한, 비증강 검증  $skill_{PCHIP}$  로 채점했다—증강 검증 손실은 절대 쓰지 않고, 어떤 test 분할도 쓰지 않는다. 최고 점수를 갱신하면 **유지 (keep)**, 아니면 **폐기 (discard)** 하고 model.py 를 최고 스냅샷으로 되돌렸다. 학습 실패는 아키텍처 품질의 증거가 아니라 수리 신호로 취급했다. 따라서 선택은 회귀 위에 쌓이지 않는다.

게이트의 선택은 보기보다 중요하다. 증강된 검증 손실은 본 논문이 보고하는 양이 아니다. temporal-subset 증강은 이력이 촘촘한 쉬운 구간을 복제하므로, 그 분포에서 제곱오차를 최소화하는 것은 예측을 평활화하도록 보상한다—그런데 평활한 예측은 미래를 쓰는 보간이 이미 잘하는 영역이다. 후보를 깨끗한 보간 대비 skill 로 직접 채점하면 선택 게이트가 보고 지표와 일치하고, 보간이 약한 곳에서 이기는 모델이 선택된다. 이 한 가지 변경이 그림 4 의 비유의  $\rightarrow$  유의 진행을 낳았다. 우리는 이를 과학적 기여가 아닌 방법론으로 문서화한다.

## 8 배치 가능한가?

skill 점수와 쓸 수 있는 계측 사이에는 두 가지가 놓여 있다. 측정 주기 안에서 돌아야 하고, 얼마나 믿어야 하는지를 말해야 한다. 둘 다 지금까지 보고된 적이 없고, 둘 다 독자가 예상하지 못할 답이 나온다.

**지연: CPU 에서는 들어가고, GPU 는 틀린 장치다.** CES 는 10 ms 격자 위에 있으므로 온라인 결측 채움에는 스텝당 10 ms 에서 수집과 제어가 이미 쓰는 몫을 뺀 시간이 있다. 네트워크 순전파만 측정하고 (특징 조립은 모델 밖이라 제외), warmup 이후 1,000 회 반복, batch 1 에서, 실시간 루프의 마감을 결정하는 꼬리는  $W=4$  CPU 에서  $p99 = 6.4\text{ms}$  ( $W=2$  는  $8.7\text{ms}$ ), 중앙값  $2.8\text{ms}$  다 — 한 격자 주기의 64–87%. 같은 기계에서 CUDA 는 batch 1 에서 약  $8\times$  느리고 (중앙값 21 ms, p99 43–72 ms) 예산을 몇 배 초과한다. 파라미터 20 만 개로는 커널 실행 오버헤드를 상쇄할 것이 없다. 이를 두 가지 방식으로 검증했다 — 호출별 측정 (호출 사이 장치를 유휴로 만들며, 10 ms 루프의 현실적 모형) 과 연속 amortized 측정 — 그리고 둘이 일치하므로 GPU 를 유휴로 만든 데서 생긴 아티팩트가 아니다. 실무 지침은 기본값의 반대다: 이 모델은 제어 컴퓨터의 CPU 에서 돌려라. 대량 재처리도 여기서는 CPU 가 유리하지만 (batch 512 에서 48k 대 24k samples/s) 이 비교는 노트북 GPU 와 매우 작은 신경망에 특정한 것이므로 일반화하지 않는다.

**불확실성: 모델을 건드리지 않는 분포 무가정 구간.** 핵융합 프로파일 데이터의 표준 도구는 사후분포를 반환하는 GP 회귀인데 우리 모델은 점을 반환한다. 분산이나 분위 헤드를 붙이면 재학습이 필요하고 점 예측이 움직여 위의 모든 수치를 교란하므로, 대신 *split conformal prediction* 을 쓴다. 검증 분할에서 캘리브레이션하고, 예측기는 전혀 바꾸지 않으며, 분포 무가정 유한표본 주변 커버리지를 준다. 두 변형: 단일 분위수 (*global*) 와  $\Delta t \times$  활동도 층별 분위수 (*Mondrian*, §6.4 과 같은 공변량). PCHIP 과 persistence 에 동일한 절차를 적용하므로 비교되는 것은 캘리브레이션 기법이 아니라 구간 품질이다.  $\alpha = 0.10$  에서:

- **모델의 구간이 모든 시드·타겟·변형에서 두 기준선을 이긴다** (각 8/8). 폭과 실패를 함께 벌하는 Winkler 구간 점수 기준으로 persistence 의 약 0.80 배다. 이는 점 예측이 더 낫다는 사실에서 따라 나오지 않는 별개의 성질이다.
- **증화가 도움이 된다:** Mondrian 은 평균 구간을 넓히면서도 구간 점수를 모든 곳에서 개선한다. 즉  $\Delta t$  와 활동도가 필요하다고 말하는 곳에 폭을 배치한다.
- **정보 비대칭이 불확실성에도 약하게 나타난다.** 커버리지를 맞춘 상태에서 모델은 구간을  $T_i$  에 대해 persistence 폭의 0.884 배로 줄이지만  $V_{\text{rot}}$  에 대해서는 0.937 배에 그친다 — 점 예측과 같은 방향이 되 크기는 훨씬 작다. 모델은 자기가 모르는 것을 부분적으로 안다.
- **정직한 실패: 커버리지는 주변적이지 조건부가 아니다.**  $T_i$  는 4 개 중 2 개 분할에서 미달하고 (목표 90% 에 대해 87.0–88.9%), shot 별 커버리지는 10 분위  $\approx 50$ –68% 에서 90 분위 100% 까지 퍼진다. Conformal 은 교환 가능성 하의 주변 커버리지를 보장하는데, 캘리브레이션과 test 는 서로 다른 방전이고 shot 수준 분포 이동이 그 가정을 깬다. 배치된 계측에는 통합 수치보다 이쪽이 더 중요하며, 해결하려면 현재 shot 수로는 지탱되지 않는 shot 조건부 캘리브레이션이 필요하다.

## 9 남은 개선 여지는 어디에 있는가

본 논문의 음성 결과들은 이례적으로 구체적이며, 그 구체성이 쓸모를 만든다. 이들은 “이 문제는 어렵다”가 아니라 어떤 변경이 문제를 움직이는가를 말한다. 용량은 배제되었고 (§4), 더 긴 이력도 배제되었다 (§6.7). 남은 것은 세 개의 구체적 레버이고, 각각 이 데이터셋 안의 증거로 지목되며, 모두 추정기가 아니라 측정 또는 커버리지에 대한 변경이다.

1. **깊이가 아니라 도달 범위 ( $T_i$  에 대한 최대 즉효).** 진짜 결측인  $T_i$  행의 54.1%,  $V_{rot}$  행의 4.8% 만이  $W=4$  window 안에 관측값을 가지므로 나머지는 방법을 적용할 수 없다 (§6.4). Window sweep 이 보이는 올바른 대응은 skill 을 전혀 사지 못하는 더 긴 연속 window 가 아니라 (§6.7) 더 넓은 도달 범위다:  $W=2 \rightarrow W=8$  에서 총 채점 수는 거의 그대로인데  $\Delta t > 15$  ms 부분집합은  $456 \rightarrow 1,958$ ,  $\Delta t > 45$  ms 는  $14 \rightarrow 135$  로 늘어난다. 둘을 분리해 — 이력 슬롯은 2-3 개로 유지하되 더 넓은 span 에서 뽑아 — 용량이 나 분포 이동 비용 없이 도메인을 넓힐 수 있어야 한다. skill 이 이력 길이에 평탄하므로 이는 적용 가능성의 거의 공짜 확장이며, 실제 문제 중 다루는 비율을 직접 키우는 유일한 변경이다.

2. **Mirnov 정보는 플라스마에 없는 것이 아니라 전처리가 파괴한 것이다.** §6.6 에서 자기 진단이 회전 정보를 전혀 나르지 않는다고 결론짓는 것은 틀렸다. 동일한 10 ms 격자에서 연속 블록 내 lag-1 자기상관은  $BES +0.568$ ,  $ECEI +0.572$  인데 Mirnov 코일은  $-0.009$  이고 블록의 82% 가  $|r| = 0.1$  미만이다. 즉 자기 채널은 이 격자 위에서 백색잡음이다. 이는 kHz 모드 주파수로 진동하는  $dB/dt$  가 안티앨리어싱 필터 없이 100 Hz 로 데시메이션되어 연속 표본의 상대 위상이 무작위가 된 신호다. 우리 진단 세트에서 토로이달 회전을 대리할 수 있었던 유일한 양인 모드 회전 주파수가 모델 상류에서 폐기된 것이며, 우리가 시도한 모든 MC 파생 특징 (적분, PCHIP 적분,  $|MC|$ , 이동 RMS) 이 실패한 이유이기도 하다. 이미 잃은 정보는 하류에서 복원되지 않는다. 해법은 모델 변경이 아니라 전처리 변경이다 — 원 kHz Mirnov 시계열에서 계산한 window 별 RMS, 대역 파워, 모드 번호. 이는  $V_{rot}$  에 대해 우리가 지목할 수 있는 가장 가치 있는 실험이며, 아카이브된 데이터로 검증 가능하다.

3. **구동기 채널이 아예 없다.** 토로이달 회전은 주입 토크가 결정하는데, 이 데이터셋에는 토크 신호가 없다. 데이터가 그 단절을 정확히 보여준다: shot 간에 ECE 유래  $T_e$  대리변수는  $T_i$  와  $r = +0.353$  ( $p = 3 \times 10^{-17}$ ) 로 상관되지만  $V_{rot}$  와는  $r = +0.024$  ( $p = 0.58$ ) 이고, shot 내에서도  $T_i$  상관은 부호가 일관되는 반면  $V_{rot}$  상관은 부호가 무작위다. 즉  $T_e$  는 가열 수준을 추적하지만 가열 수준은 회전에 닿지 않는다 — 파워는 토크가 아니며, 토크는 빔 에너지-접선 반경-주입 기하에 의존한다. NBI 토크 (또는 그것을 계산하는 빔별 파워와 기하) 를 추가하는 것은 모델링이 아니라 데이터 확보의 문제이며, 회전의 자기상관이 아니라 원인을 다루는 우리가 지목할 수 있는 유일한 레버다. 양성 대조군도 문헌에 있다: 빔 액추에이터를 입력으로 받는 DIII-D 순환 전체-방전 시뮬레이터는 회전의 전개를 예측한다 [51] — 즉 이 채널은 측정만 되면 학습 가능하다.

이 중 어느 것도 현재 결과가 천장에 도달했다는 진술이 아니다. 이들은 다음의 측정 가능한 이득이 있는 지점들이며, 시도 비용이 낮은 순으로 정렬되어 있고, 셋 모두 아카이브된 KSTAR 데이터에서 실행 가능하다.

## 10 한계

**통계적 검정력.** 재현 단위는 shot 이며, test 에  $\approx 96(T_i) / 91(V_{rot})$  개뿐이다. 검정력이 모든 유의성 판정을 제한하고, shot 별 제곱오차 차이는 두꺼운 꼬리를 가진다 (소수의 방전이 bootstrap 산포를 지배). **MNAR 낙관성.** skill 은 관측 시점에서만 측정되며, 진짜 결측 시점은 더 어려울 수 있다. **오프라인 주장의 상한은 GP 동물이다.** 사후 GP 팔 (§6.2) 은 사전등록된 PCHIP 을 모든 분할에서 이기고 모델은 그것과 동률에 그친다. 따라서 “미래를 쓰는 보간을 이긴다” 는 “사전등록된 보간들을 이긴다” 로 읽어야 하며, 모든 오프라인 방법으로 일반화되지 않는다. **CES 적합실패 아티팩트는 헤드라인을 부풀리는 게 아니라 끌어내린다.** 분광 적합실패 값 ( $T_i > 3$  keV; 전역  $p_{99} = 2,089$  eV) 은 사전등록 모집단에 남아 있다. 이들을 모든 팔에서 동일하게 제거하는 짝지은 민감도 점검 (행의 0.4–0.6%) 은 4/4 PASS 를 유지한 채 skill 을 약 2 배로 키운다 ( $+0.18 \rightarrow +0.28 \rightarrow +0.36 \rightarrow +0.59$ ): 스파이크는 어느 팔에도 예측 불가능해 MSE 비율을 1 쪽으로 끌어당기므로, 헤드라인은 이 아티팩트에 대해 보수적이다. **지표 비대칭.** 보간은 shot 전체 이웃을 쓰는 반면 모델은  $W=4$  이력만 본다. 의도적으로 모델에 불리한 설계지만 해석을 복잡하게 한다. **단일 장치-단일 모델 계열.** window 민감도는 이제 특성화되었고 (§6.7) 아키텍처 민감도도 부분적으로 그러하나 (paired 프로토콜 하의 전체 격자 시퀀스 재프레이밍), 그 전부가 하나의 장치와 하나의 후기 융합 계열 위에 있다. 다른 토카막의 진단 세트로의 전이는 여기서 확립되지 않는다. 우리 자신의 헤드라인 모델에 대해서도 보고한다: 재프레이밍에 동일한 관측 차단  $V_{rot}$  라우팅을 결합하고 유지값 없이 shot 별 표준화로 학습한 전체 격자 시퀀스 변형이 4 개 분할 전부에서 사전등록 모델보다 높은  $T_i$  skill 에 도달한다 (짝지은 평균  $+0.045$ ,  $1/4$  에서 유의). 학습 비용은 약  $1/10$  이다. 이를 중심으로 헤드라인을 다시 쓰지는 않는다—사전등록 프로토콜은 모델을 미리 지명하며 4 개 중 1 개의 유의성은 주장을 지탱하지 못한다—그러나 다음에 쌓아 올릴 방향은 이쪽이다. **캠페인 전이는 실제 한계였고, 지목된 수리는 이제 작동한다 (§6.5):** 이전 방전으로

학습하면 이후 방전에서 오프라인 보간을 이기지 못했고 (0/4), 규명된 원인—학습 파일 전용 정규화에 대한 고속 진단 드리프트—은 shot 별 표준화로 수리된다 (짜지는  $T_i$  평균 +0.155 개선, 4/4 초기화, 헤드라인 유의 손실 없음). 남은 미검증은 그 수리의 배치 가능한 형태다: 온라인 추정기는 방전의 미래를 볼 수 없으므로 실제로 출하될 판은 인과적 running(확장 원도/EWMA) 변형이다. **불확실성은 주변적으로만 캘리브레이션된다** (§8): shot 별 커버리지가  $\approx 50\%$  에서 100% 까지 퍼지므로 방전 단위 신뢰 진술은 아직 뒷받침되지 않는다. **큰 간극 구간**은 이제 4 개 분할을 통합해 shot 군집 CI 를 갖지만 (§6.3), 가장 넓은 구간은 여전히 62 개 shot 의 167 개 표본이며 그 구간에서 모델은 미래를 쓰는 PCHIP 보다 유의하게 나쁘다. **범위**. 페데스탈-상단 프레이밍은 데이터 선택 (페데스탈-상단 CES 채널) 에서 상속된 것이며, 반경 방향 의존성 실험은 수행하지 않았다. 이벤트 위상 분석 (ELM 주기, L-H 천이) 은 향후 과제다—§6.9 의 고변동 분석은 이벤트 불특정 대리 분석이다.

## 11 결론

우리는 최소한 KSTAR CES 타겟을 위한 인과적-누수 방지 멀티모달 나우캐스터를 구축하고, 의도적으로 불리한 기준선—미래를 보는 보간—에 대해 사전등록된 shot 군집 프로토콜로 평가했다. 관측 모집단에서 모델은 이온온도에 대해 미래를 쓰는 PCHIP 을 유의하고 재현된 skill(+0.18+0.28, 4 개 독립 분할) 로 이기고 — 가장 강한 오프라인 평활기인 사후 GP 팔과는 동률이며 (§6.2) — 두 타겟 모두에서 모든 인과 기준선을 큰 차이로 이긴다—이전에는 검정력이 없어 아무 말도 할 수 없었던 비인접 영역 ( $\Delta t > 15$  ms) 을 포함해서다.

배치에 관해 우리가 하려는 주장은 더 좁고 더 잘 뒷받침된다. 두 개의 독립적인 스트레스 테스트 — 진짜 결측 지점의 공변량 분포로 재가중하는 것, 그리고 캠페인을 가로질러 시간으로 엄격히 재분할하는 것 — 이 같은 답을 준다: 인과 방법 대비 우위는 둘 다 통과하고 (+0.29, +0.22) 오프라인 보간 대비 우위는 어느 것도 통과하지 못한다 (1/4, 0/4). 이 둘은 상대가 다른 별개의 주장이고, 이런 결과가 과대 판매되는 주된 경로가 바로 그 둘을 뭉개는 것이다. 온라인 가상 센서는 미래를 읽는 보간이 아니라 persistence 와 경쟁하며, 그 비교에서 이 나우캐스터는 중요한 지점에서 작동한다. MNAR 보정 비용은 0.06–0.12 에 불과하다. 또한 측정 주기 안에서 돌아가고 (CPU p99 6.4 ms) 두 기준선의 구간을 정식 채점 규칙으로 이기는 캘리브레이션된 구간을 내놓는다.

작동하지 않는 지점과 그 이유도 함께 보고한다.  $W=4$  에서 결측  $T_i$  행의 54%, 결측  $V_{rot}$  행의 4.8% 만 이 모델의 도메인 안에 있고, 105 ms 를 넘으면 양측 보간이 실제로 이기며, 회전은 전역적으로 보간과 동률이고, 예측 구간은 주변적으로만 캘리브레이션되며, 캠페인 경계를 넘으면 오프라인 보간 대비 우위가 완전히 사라진다. 이 중 어느 것도 천장 논변이 아니며, 어깨를 으쓱하고 넘긴 것도 없다. 각각은 구체적이고 검증 가능한 변형을 지목한다—깊이는 유지한 채 이력의 도달 범위를 넓히는 것, 100 Hz 데시메이션이 모델에 닿기도 전에 파괴한 정보를 원 kHz Mirnov 신호에서 window 별 특징으로 되살리는 것, 데이터셋에는 없지만 회전의 물리적 원인인 NBI 토크 채널 (§9), 그리고 캠페인 결과에 대해서는 고속 진단의 shot 별 표준화 — 전이를 깨는 드리프트가 타겟의  $0.115\sigma$  대비 BES  $1.22\sigma$  이기 때문이다 (§6.5). 이와 함께 본 연구는 보정된  $V_{rot}$  평가 (54% 계기 유지값이며 학습도 오염시킴을 보임), 관측 마스킹 어텐션 풀링, 모델의 불투명성 가격을 “해석 가능한 1,258 파라미터가 회수하는  $T_i$  마진의 31.5%” 로 매기는 복잡도 사다리, 깨끗한 보간 대비 skill 을 게이트로 삼는 아키텍처 선택 프로토콜을 기여한다.

### 재현성

분할은 디스크에 고정되고 재로드 시 검증된다; 정규화 통계는 학습 파일 전용이다; 모델 선택은 test 데이터를 읽지 않는다; bootstrap 은 고정 시드와 10,000 회 재표본을 쓴다; 모든 헤드라인 수치는 동결된 평가 산출물에서 읽는다.

### 코드 공개

전체 파이프라인, 본 논문의 모든 결과를 만든 통제 실험 러너, 고정된 학습/검증/test 분할, 그리고 인용된 모든 수치를 동결 산출물에서 재생성하는 수집기를 <https://github.com/iseungsang01/ml-intern-revision> 에 공개한다. 출판 아키텍처는 ces\_prediction/model\_iter009.py 로 커밋되어 있고 테스트가 내용 해시로 고정하므로, 이 수치를 만든 코드와 공개된 코드가 어긋날 수 없다.

## 데이터 공개

본 연구의 KSTAR 진단 데이터 — 641 개 방전, shot 30801–32751 — 는 코드와 함께 재배포하지 않는다. KSTAR 장치의 실험 데이터로서 운영 기관의 데이터 정책을 따르며, 접근 요청은 해당 기관으로 해야 한다. 저장소에는 shot 파일이 확보된 뒤 분석을 재현하는 데 필요한 것이 모두 들어 있다: 파일 단위 분할 manifest, 보고된 모든 run 의 환경 설정, 그리고 bootstrap 통계를 계산하는 샘플별 제공오차 아카이브.

## 참고문헌

- [1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81:10D740, 2010. doi: 10.1063/1.3496991.
- [2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.
- [3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2):238–246, 1980. doi: 10.1137/0717021.
- [4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.
- [5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.
- [6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.
- [7] Minseok Kim, W.H. Ko, Sehyun Kwak, Semin Joung, Wonjun Lee, B. Kim, D. Kim, J.H. Lee, Choongki Sung, Yong-Su Na, and Y.-C. Ghim. Kinetic profile inference with outlier detection using support vector machine regression and Gaussian process regression. *Nuclear Fusion*, 64:106052, 2024. doi: 10.1088/1741-4326/ad7304.
- [8] R. L. Dougherty, A. S. Edelman, and J. M. Hyman. Nonnegativity-, monotonicity-, or convexity-preserving cubic and quintic Hermite interpolation. *Mathematics of Computation*, 52(186):471–494, 1989. doi: 10.1090/S0025-5718-1989-0962209-1.
- [9] C. H. Reinsch. Smoothing by spline functions. *Numerische Mathematik*, 10(3):177–183, 1967. doi: 10.1007/BF02162161.
- [10] G. Kvernadze. Convergence and Gibbs’ phenomenon in cubic spline interpolation of discontinuous functions. *Journal of Computational and Applied Mathematics*, 92(2):173–188, 1998. doi: 10.1016/S0377-0427(97)00199-4.
- [11] S. Eyheramendy, F. Elorrieta, and W. Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481(4):4311–4322, 2018. doi: 10.1093/mnras/sty2487.
- [12] F. Elorrieta, S. Eyheramendy, and W. Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, 2019. doi: 10.1051/0004-6361/201935560.
- [13] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, 3rd edition, 2007.

- [14] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.
- [15] Chris Bishop, C.M. Roach, and M. G. von Hellermann. Automatic analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 35:765–773, 1993. doi: 10.1088/0741-3335/35/6/010.
- [16] J. Svensson, M. von Hellermann, and R. König. Analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 41:315–338, 1999. doi: 10.1088/0741-3335/41/2/016.
- [17] Baoyue Chai, Yingying Li, Ze Chen, Wei Tao, Yixuan Zhou, Shifeng Mao, Zhengping Luo, Yi Yu, Bo Lyu, and Minyou Ye. Fast estimation of ion temperature from EAST charge exchange recombination spectroscopy using neural network. *Plasma Science and Technology*, 21:105103, 2019. doi: 10.1088/2058-6272/ab2674.
- [18] A. Pavone, J. Svensson, A. Langenberg, U. Höfel, S. Kwak, N. Pablant, and R. C. Wolf. Neural network approximation of Bayesian models for the inference of ion and electron temperature profiles at W7-X. *Plasma Physics and Controlled Fusion*, 61:075012, 2019. doi: 10.1088/1361-6587/ab1d26.
- [19] Mark D. Boyer and Jason D. Chadwick. Prediction of electron density and pressure profile shapes on NSTX-U using neural networks. *Nuclear Fusion*, 61:046024, 2021. doi: 10.1088/1741-4326/abe08b.
- [20] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64:106061, 2024. doi: 10.1088/1741-4326/ad73e8.
- [21] Francisco A. Matos, Diogo R. Ferreira, and P. Carvalho. Deep learning for plasma tomography using the bolometer system at JET. *Fusion Engineering and Design*, 114:18–25, 2016. doi: 10.1016/j.fusengdes.2016.11.006.
- [22] Cong Wang, Weizhe Yang, Haiping Wang, Renjie Yang, Jing Li, Zhijun Wang, Yixiong Wei, Xianli Huang, Chenshu Hu, Zhaoyang Liu, Xinyao Yu, Changqing Zou, and Zhifeng Zhao. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 65:076022, 2025. doi: 10.1088/1741-4326/ade0ce.
- [23] Xishuo Wei, Shuying Sun, W. M. Tang, Zhihong Lin, Hongfei Du, and Ge Dong. Reconstruction of tokamak plasma safety factor profile using deep learning. *Nuclear Fusion*, 63:086020, 2023. doi: 10.1088/1741-4326/acdf00.
- [24] G.H. Zheng, Zongyu Yang, Songfen Liu, Rui Ma, Xinwen Gong, Ao Wang, Shuo Wang, and W.L. Zhong. Real-time equilibrium reconstruction by multi-task learning neural network based on HL-3 tokamak. *Nuclear Fusion*, 64:126041, 2024. doi: 10.1088/1741-4326/ad8014.
- [25] S. Joung, J. Kim, S. Kwak, J. Bak, S. Lee, H. Han, H. Kim, G. Lee, D. Kwon, and Y. Ghim. Deep neural network Grad-Shafranov solver constrained with measured magnetic signals. *Nuclear Fusion*, 2020.
- [26] Semin Joung, Young chul Ghim, Jaewook Kim, S. Kwak, Daeho Kwon, Chih-Jen Sung, Dong Ju Kim, Hyun-Seok Kim, J.G. Bak, and S.W. Yoon. GS-DeepNet: mastering tokamak plasma equilibria with deep neural networks and the Grad-Shafranov equation. *Scientific Reports*, 13:15799, 2023. doi: 10.1038/s41598-023-42991-5.
- [27] L. Jung, Jaewook Kim, and Jisung Kang. Machine learning-based plasma profile reconstruction in KSTAR. *Journal of the Korean Physical Society*, 88:1079 – 1087, 2026. doi: 10.1007/s40042-026-01580-1.
- [28] Joseph Abbate, Rory Conlin, and Egemen Kolemen. Data-driven profile prediction for DIII-D. *Nuclear Fusion*, 61:046027, 2021. doi: 10.1088/1741-4326/abe08d.

- [29] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2024. doi: 10.1088/1741-4326/ad142f.
- [30] Semin Joung, Jaewook Kim, S. Kwak, Kyeo reh Park, S.H. Hahn, Hyunsun Han, Hyun-Seok Kim, J.G. Bak, S. G. Lee, and Young chul Ghim. Imputation of faulty magnetic sensors with coupled Bayesian and Gaussian processes to reconstruct the magnetic equilibrium in real time. *Review of Scientific Instruments*, 89:10K106, 2018. doi: 10.1063/1.5038938.
- [31] Debashish Mohapatra, Bidyadhar Subudhi, and Raju Daniel. Real-time sensor fault detection in Tokamak using different machine learning algorithms. *Fusion Engineering and Design*, 151:111401, 2019. doi: 10.1016/j.fusengdes.2019.111401.
- [32] S. Kaldas, R. Rossi, I. Wyss, M. Gelfusa, and P. Gaudio. Developing autoencoder models for multi-diagnostic electron density processing in tokamaks within a scientific machine learning framework. *Journal of Fusion Energy*, 45, 2026. doi: 10.1007/s10894-026-00568-w.
- [33] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.
- [34] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Nian-nian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.
- [35] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.
- [36] M. Imříšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiland, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.
- [37] HyeongJun Noh, Chweeho Heo, Xiaotian Gao, and Yong-Su Na. PanoMHD: Multimodal modelling of plasma dynamics towards Tokamak control. 2026.
- [38] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.
- [39] Satya Narayan Shukla and Benjamin M. Marlin. Multi-time attention networks for irregularly sampled time series. 2021:14897–14911, 2021. doi: 10.48550/arxiv.2101.10318.
- [40] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. 32:5320–5330, 2019.
- [41] Rich Caruana. Multitask learning. *Machine Learning*, 28:41–75, 1997. doi: 10.1023/a:1007379606734.
- [42] Jiquan Ngiam, Aditya Khosla, Mingyu Kim, Juhan Nam, Honglak Lee, and Andrew Y. Ng. Multimodal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 2011.
- [43] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:423–443, 2018. doi: 10.1109/tpami.2018.2798607.
- [44] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Xing Chen, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.

- [45] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. 2018. doi: 10.48550/arxiv.1802.04712.
- [46] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. 2015. doi: 10.48550/arxiv.1506.04214.
- [47] Suman Ravuri, Karel Lenc, Matthew Willson, Dmitry Kangin, Rémi Lam, Piotr Mirowski, M. A. Fitzsimons, Maria Athanassiadou, Sheleem Kashem, Sam Madge, Rachel Prudden, Amol Mandhane, Aidan Clark, Andrew Brock, Karen Simonyan, Raia Hadsell, N. Robinson, Ellen Clancy, Alberto Arribas, and Shakir Mohamed. Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597: 672–677, 2021. doi: 10.1038/s41586-021-03854-z.
- [48] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.
- [49] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.
- [50] J. E. Rice, A. Ince-Cushman, J.S. deGrassie, L.-G. Eriksson, Y. Sakamoto, A. Scarabosio, A. Bortolon, K.H. Burrell, B.P. Duval, C. Fenzi-Bonizec, M. Greenwald, R. J. Groebner, G. T. Hoang, Y. Koide, E. S. Marmor, A. Pochelon, and Y. Podpaly. Inter-machine comparison of intrinsic toroidal rotation in tokamaks. *Nuclear Fusion*, 47:1618–1624, 2007. doi: 10.1088/0029-5515/47/11/025.
- [51] Ian Char, Youngseog Chung, Joseph Abbate, Egemen Kolemen, and Jeff Schneider. Full shot predictions for the DIII-D tokamak via deep recurrent networks. arXiv:2404.12416, 2024.