10 ms 하전교환분광 결측의 인과 나우캐스팅:
미래 보간보다 낮은 오차의 LSTM과 그것이 계산하는 20모수 물리 필터

이승상 (Seungsang Lee)
서울대학교 원자핵공학과
lss010330@snu.ac.kr

국문 원고 — 2026년 11월 10일

초록

배경 전하교환분광(CES)은 토카막에서 이온온도(T_i)와 토로이달 회전(V_{rot})을 측정하는 핵심 진단이지만, 광자 수집 제약 때문에 느리고 간헐적으로 결측된다. 본 연구의 KSTAR 10 ms 격자(641개 방전)에서 T_i의 8.2%, V_{rot}의 23.9%가 *서로 독립적으로* 결측되고, V_{rot}은 여기에 더해 41.1%가 계측기 유지값(held)이어서 격자의 65.0%가 독립적인 V_{rot} 정보를 갖지 않는다(§3, §3.4). 결측 채움의 현직 방법은 CES 채널 자체의 보간이고, 그것은 빈 시각 *양쪽*의 이웃을 읽으므로 온라인에서는 쓸 수 없다.

질문 항상 측정되는 고속 진단—빔방출분광(BES), 전자사이클로트론방출영상(ECEI), Mirnov 코일—과 불규칙한 과거 CES 이력만 쓰는 엄격히 *인과적인* 추정기가, 빈 10 ms 행을 그 미래를 읽는 보간보다 낮은 오차로 채울 수 있는가(§1).

설계 소형(0.36M 파라미터) 2분기 인과 LSTM이 한 방전 세그먼트의 모든 격자 행을 읽고, 희소한 타겟은 행을 버리는 대신 타겟별 마스킹 손실로 감독하며, V_{rot} 분기는 구조적으로 고속 진단에서 차단된다—이 라우팅은 두 보존식에서 나온 것이지 튜닝의 산물이 아니다(§4).

프로토콜 사전등록: 유지값 제거 학습·채점, 파일 단위 분할, 모델 선택이 전혀 건드리지 않는 test 셋, shot 군집 paired bootstrap(10,000회 재표본), 그리고 T_i 스펙트럼 피팅 실패(>3 keV, 0.53%)를 결측으로 처리하거나 그대로 두는 *두 개의 공동 1차 모집단*—무조건적 주장은 둘 다에서 성립해야 한다(§5, §6.3).

주 결과 나우캐스터의 T_i skill은 미래를 쓰는 단조 3차 PCHIP 보간 대비 $\mathrm{skill}_{\mathrm{PCHIP}} = +0.17 \sim +0.26$(스파이크 컷)과 $+0.23 \sim +0.32$(스파이크 포함)로 두 모집단 각각의 독립적인 4개 held-out 분할 모두에서 95% 구간이 0을 제외하고, 인과 가우시안 과정 대비 $+0.08 \sim +0.17$로 8개 셀 전부에서 구간이 0을 제외하며, 오프라인 GP 대비 짝지은 skill은 $-0.05 \sim +0.11$로 8셀 중 7셀에서 구간이 0을 포함한다. 모든 방전을 한 번씩 시험하는 사전등록 shot 단위 반복 5겹 재현(100회 실행)에서 겹침 보정 구간은 $[+0.19, +0.25]$(컷)·$[+0.19, +0.31]$(포함)이다. 두 스트레스 테스트를 견딘다: 채점 지점을 진짜 결측 지점의 공변량 분포로 재가중해도 persistence 대비 skill은 $+0.28 \sim +0.44$로 8/8 셀에서 구간이 0을 넘고, 캠페인을 가로지르는 엄격한 시간 분할에서도 PCHIP 대비 $+0.17 \sim +0.20$으로 두 모집단 4/4 초기화에서 구간이 0을 넘는다(§6, §6.5, §6.6).

회전 반대 방향의 증거가 회전이다. 고속 진단을 0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하고, PCHIP 대비 평균 제곱 오차 skill은 꼬리가 실어 나르며(등록된 두 단계 bootstrap에서 컷 $[+0.07, +0.70]$), 중앙값에서는 persistence 대비 오차 비가 0.94–1.00으로 3/4 분할에서 구간이 1을 포함한다. 이 정보 비대칭을 미관측 NBI 토크와 10 ms 광자 바닥에 귀속시키며, 그 진술은 표준 CES 10 ms 격자·코어에서 페데스탈 상단까지에 한정한다(§6.7, §6.11).

식 그다음 나우캐스터가 무엇을 계산하는지를 묻는다. 사전등록된 4단계 판독(동결 행의 식, 학습된 식, 전수 행 야코비안, 교정된 형태)은 T_i 분기를 20개 모수의 물리 필터 식으로 적는다: 직전 측정 이후 공백이 길수록 이득이 커지는 관측 필터(새 측정 직후 $K_0 = 0.27$–0.30, 긴 공백 뒤 $K_\infty = 0.48$–0.53, 전이 $s_K = 39$–47 ms)에, 각 고속 채널의 직전 100 ms 기준선

대비 편차에 대한 선형 응답을 $\theta = 2.9$–3.0σ 너머에서 차단한 항($\sum a_{\mathrm{BES}} = +48 \sim +53$, $\sum a_{\mathrm{ECEI}} = +44 \sim +50\,\mathrm{eV}/\sigma$)을 더한 것이다. 동일한 프로토콜로 처음부터 학습한 이 식은 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 72–78%, persistence 대비 skill의 87–90%를 유지하고(등록 문턱 0.70), 앞선 증분 형태의 식보다 모든 분할에서 paired $+0.034 \sim +0.042$ 위에 있으며 구간이 0을 넘는다. 남은 22–28%는 신경망의 비선형 사건 처리로, 고속 채널 이력의 어떤 저차 함수로도 재현되지 않는다(§4.4).

중앙값과 분포 부수 결과 둘이 추정 대상을 가른다. 학습 본류 척도의 Student-t 잡음을 쓰는 사전등록 유지-또는-점프 필터가 중앙값 추정량이고(T_i에서 8개 분할–모집단 칸 모두 persistence의 0.91×), 나우캐스터는 평균 추정량이며, Student-t 분포 head는 보정되어 있다(점 기준 대비 CRPS 이득 T_i $+0.229 \cdot V_{\mathrm{rot}}$ +0.363, 50 %/90 % 포함률 0.49–0.51 / 0.91–0.92, 컷)(§6.10, §6.11, §6.12).

한계 집계 skill은 꼬리 통계이고, 오프라인 주장의 상한은 오프라인 GP이며, 값 기준 컷은 피팅 품질의 대리 지표이고, 모든 것이 한 장치·한 캠페인이다(§8).

공개 전체 파이프라인, 사전등록 문서, 평가 산출물을 공개한다.

한 값은 한 자리에서만 정의된다. 같은 수치를 여러 절에서 되풀이하면 그 자체가 절 불일치의 자리가 되므로, 이 원고는 값마다 정의 절을 하나만 두고 다른 절에서는 그 절을 가리킨다. 위 초록의 괄호가 그 자리다. 값이 어긋나 보이면 정의 절이 옳다. 인용된 모든 수치는 동결된 평가 산출물에서 단일 수집 스크립트(`collect_paper_numbers.py`)가 읽어 온다.

목차

심사자용 한 쪽 요약 — 이 논문이 답하는 것 전부 **4**

1 서론 **5**

2 관련 연구 **7**

3 데이터와 문제 설정 **10**
3.1 데이터셋 10
3.2 학습 예제의 두 가지 프레이밍 10
3.3 설계 원칙 10
3.4 데이터 품질 감사 1: 유지(forward-fill)된 V_{rot} 값 11
3.5 데이터 품질 감사 2: T_i 스펙트럼 피팅 실패와 두 모집단 11

4 모델 **11**
4.1 추정 대상, 손실, 그리고 환원 불가능한 하한 11
4.2 두 보존식이 입력 라우팅을 정한다 12
4.3 모델이 놓인 시간 척도 13
4.4 전체격자 인과 시퀀스 백본 13
4.5 윈도 대조군: 관측 마스킹 어텐션 풀링 14
4.6 해석 가능한 사다리 칸 15
4.7 최적화 설정, 그리고 그 근거의 현황 15

5 평가 방법론 **16**

6 결과 **17**
6.1 나우캐스터는 모든 인과 기준선 가운데 RMSE가 가장 낮다 17
6.2 헤드라인: T_i의 미래를 쓰는 보간 대비 skill은 두 모집단 모두에서 4개 독립 분할에 걸쳐 CI가 0을 제외한다 18
6.3 전체격자 프레이밍 대 윈도 대조군: 백본 관문 19
6.4 skill이 사는 곳: 간극 영역 20
6.5 실제로 결측인 지점에서는 이 중 얼마가 살아남는가? 20
6.6 캠페인 이동을 견디는가? 21
6.7 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭 22
6.8 복잡도는 무엇을 사고, 크기는 도움이 되는가? 사다리와 폭 스윕 23
6.9 skill은 고변동 국소 구간에 집중된다 23
6.10 집계 skill은 꼬리에서 온다: 중앙값 행에서 나우캐스터는 앵커를 그대로 옮긴다 23
6.11 물리 필터가 중앙값 추정량이다: 이중 판독 25
6.12 예측 분포: 두꺼운 꼬리를 가진 한 봉우리, 보정된 채로 보고한다 26
6.13 컷 임계값 민감도 27
6.14 문맥·구조·비용: 무엇이 skill을 정하고 무엇이 값을 정하는가 27

7 남은 개선 여지는 어디인가 **28**

8 한계 **29**

9 결론 **31**

심사자용 한 쪽 요약 — 이 논문이 답하는 것 전부

이 쪽에만 있는 값은 없다. 아래 모든 수치는 본문의 정의 절에서 왔고, 괄호 안이 그 자리다.

문제. KSTAR의 10 ms 격자에서 CES는 T_i의 8.2%, V_{rot}의 23.9%를 비운다. 두 타겟은 *서로 독립적으로* 빠지고(§3), V_{rot}은 41.1%가 계측기 유지값이어서 실제로 독립적인 회전 측정을 담은 행은 35.0%뿐이다 (§3.4). 그리고 결측은 아무 데나 있지 않다—저신호 구간, ELM, 천이 같은 물리적으로 흥미로운 순간에 몰린다. 즉 무작위적이지 않은 결측(MNAR)이다. 같은 플라즈마를 BES·ECEI·Mirnov는 결측 없이 본다. 셋 중 어느 것도 T_i나 V_{rot}을 직접 측정하지는 않는다.

지금 하는 일과 이 논문이 하는 일. 결측 채움의 현직 방법은 CES 채널 자체의 시간 보간이고, 그것은 타겟 시점 *양쪽*의 이웃을 쓴다—즉 미래를 읽으므로 온라인에서는 쓸 수 없다. 이 논문은 미래를 읽지 않는 모델이 미래를 읽는 그 방법을 이기는지를 묻는다. 이겼다면 고속 진단이 CES의 시간 구조에 없는 CES 정보를 운반한다는 뜻이고, 그 뜻은 CES 단독으로는 도달할 수 없다.

판정은 착수 전에 고정되었다. 이력 길이 W=2는 24-run 스윕의 plateau 최소 규칙으로, 계측기 유지값 제거는 학습과 채점 양쪽에, 분할은 파일 단위로, 유의성은 shot 군집 paired bootstrap 10,000회로, 그리고 T_i 스펙트럼 피팅 실패 0.53%는 *두 개의 공동 1차 모집단*으로—모든 팔에서 결측 처리하거나, 모든 곳에서 유지하거나—정해졌다. 무조건적 주장은 두 모집단 모두에서 성립해야 한다. test 셋은 모델 선택이 한 번도 읽지 않았다(§5, §6.3).

답 넷. *하나*, T_i의 skill은 미래를 쓰는 PCHIP 대비 +0.17 ∼ +0.32로 두 모집단의 4개 분할 여덟 셀 전부에서 신뢰구간이 0을 제외하고, 배치 가능한 가장 강한 기준선인 인과 GP 대비로도 +0.08 ∼ +0.17로 8/8에서 신뢰구간이 0을 제외한다(§6). *둘*, V_{rot}은 네 분할 관문을 1/4·2/4만 통과해 구간이 0을 포함하는 것으로 적었고, 모든 방전을 한 번씩 채점하는 사전등록 재현에서야 평균 제곱 오차 skill의 구간이 0을 제외한다(PCHIP 대비 컷 $[+0.07, +0.70]$; 중앙값은 persistence 대비 오차 비 0.94–1.00으로 구간이 1을 포함). 어느 쪽이든 튜닝 부족이 아니다. 고속 진단 입력을 전부 0으로 만들어도 V_{rot} 출력은 *비트 단위로* 동일하다(§6.7). *셋*, 그 나우캐스터가 계산하는 것은 20개 모수의 물리 필터 식으로 적힌다—공백이 길수록 이득이 커지는 관측 필터(K_0 0.27–0.30, K_∞ 0.48–0.53, s_K 39–47 ms)에 100 ms 기준선 대비 사건 응답(θ 2.9–3.0σ 차단, $\sum a_{\mathrm{BES}}$ +48 ∼ +53·$\sum a_{\mathrm{ECEI}}$ +44 ∼ +50 eV/σ)을 더한 것—고, 같은 프로토콜로 처음부터 학습한 그 식이 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 72–78%, persistence 대비 87–90%를 낸다(§4.4). 남은 22–28%는 비선형 사건 처리다. *넷*, 남은 손실은 추정기 문제가 아니다—21k 파라미터 모델이 백본과 대등하고 폭을 26× 넓혀도 skill은 ±0.01 안에서 움직이며, 신경 과정·타 장치 사전학습 transformer·4-초기화 앙상블로 바꿔도 T_i skill 변화는 −0.09 ∼ +0.03으로 어느 팔도 두 모집단 모두에서 0.02 띠를 넘지 못한다(§6.8). 다만 그 T_i skill은 꼬리에서 온다: 오차 상위 사분위에서 오차 비가 1 아래로 내려가고 중앙값 행에서는 persistence와 같다(§6.10). 손실의 척도를 타겟의 재현성 한계에 고정한 Huber 손실이 그 중앙값을 8% 내리고 집계 skill을 지키는 유일한 모델 쪽 레버였다. 학습 모델이 아닌 물리 필터—본류 척도 Student-t 측정의 유지-또는-점프 필터—는 T_i 중앙값을 모든 분할에서 persistence의 0.91×로 내려, 중앙값은 필터에서, 평균은 나우캐스터에서 따로 보고한다(§6.11).

그리고 이 논문은 스스로 멈춘다. 반증 지점 여섯을 착수 전에 적어 두었고 (표 1), 그중 둘은 실제로 걸렸다—회전은 네 분할 관문을 통과하지 못해 구간이 0을 포함하는 것으로 강등되었고(재현에서 평균 skill의 구간이 0을 제외한 뒤에도 중앙값의 persistence 대비 오차 비 0.94–1.00은 남는다), 오프라인 GP 대비 짝지은 skill −0.05 ∼ +0.11의 구간이 8셀 중 7셀에서 0을 포함하므로 "미래를 쓰는 보간 대비 skill이 0을 넘는다"를 "모든 오프라인 방법 대비 0을 넘는다"로 넓혀 적지 않는다. 걸린 것을 걸렸다고 적은 자리가 이 원고에서 가장 정보가 많은 자리다.

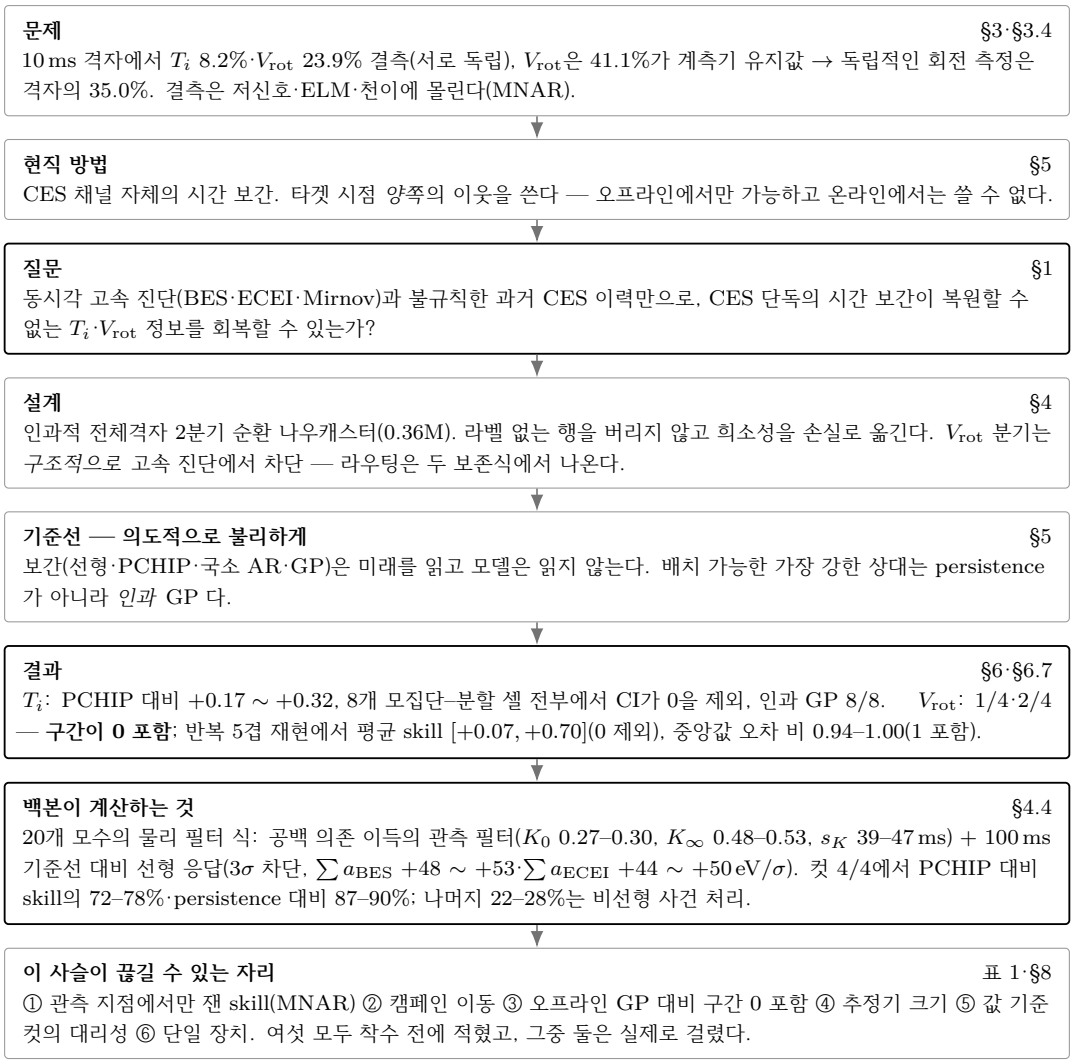


그림 1. 논증 사슬 — 어느 마디가 무엇으로 지탱되는가. 굵은 테두리는 이 논문이 직접 판정하는 세 마디다.

1 서론

플라즈마 경계부의 이온온도 T_i와 토로이달 회전 $V_{\rm rot}$은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근 등 토카막 성능과 안정성의 핵심 요소를 지배한다. 두 물리량의 표준 측정법은 전하교환분광(CES) [1]으로, 전하교환 선방출의 도플러 확장에서 T_i를, 도플러 이동에서 $V_{\rm rot}$을 추정한다. CES는 충분한 신호대잡음비를 위해 광자를 적분해야 하므로 본질적으로 느리고, 개별 시점 측정은 노출·신호품질 문제로 자주 소실된다. 본 연구의 KSTAR 데이터에서는 균일한 10 ms 격자 위에서도 T_i의 8.2%, $V_{\rm rot}$의 23.9%가 —서로 *독립적으로*— 결측된다. 나아가 $V_{\rm rot}$은 41.1%가 직전 관측값을 그대로 반복하는 유지값이어서(§3.4), 격자의 35.0%만이 독립적인 $V_{\rm rot}$ 측정값을 담고 있다. 우리 데이터셋에서 경험적으로 결측은 물리적으로 흥미로운 순간(저신호 구간, ELM, 천이)에 집중된다. 즉 Little and Rubin [2]의 의미에서 무작위적이지 않은 결측(MNAR)이다.

한편 여러 고속 진단은 같은 플라즈마를 결측 없이 관측한다: BES는 밀도요동 구조를, ECEI는 전자온도를, Mirnov 코일은 자기요동을 측정한다. 이들 중 어느 것도 T_i나 $V_{\rm rot}$을 직접 측정하지 않는다. 본 논문의 질문은 다음과 같다.

> *CES가 결측된 10 ms 시점에서, 동시각 고속 진단과 불규칙한 과거 CES 이력만으로, CES 단독의 시간 보간이 복원할 수 없는 T_i, $V_{\rm rot}$ 정보를 회복할 수 있는가?*

긍정적 답은 데이터 기반 *가상 센서(virtual sensor)*를 정당화한다: 강한 역산 가정 없이 CES 결측을 온라인으로 채워, 끊김 없는 페데스탈 분석과 궁극적으로 실시간 활용을 가능하게 하는 모델이다.

표 1. 사전등록된 반증 지점 여섯. 각 행은 착수 전에 문서로 고정되었고, 마지막 열이 실제로 관측된 것이다. 둘은 걸렸다.

주장	틀렸다면 관측되는 것	그때 하는 일	미리 적힌 곳	실제로 관측된 것
T_i 나우캐스팅이 미래를 쓰는 보간을 이긴다	8개 모집단–분할 셀 중 하나라도 95% CI가 0을 포함	무조건적 주장을 철회하고 모집단 조건부로 강등한다	§5	**8/8 통과.** $\text{skill}_{\text{PCHIP}} = +0.17 \sim +0.32$
V_{rot} 도 같은 관문을 통과한다	4개 분할 중 통과가 3개 미만	동률로 보고하고 원인을 절제 실험으로 지목한다	§5	**걸렸다.** 1/4·2/4 → 구간이 0 포함; 재현(새 분할 8벌)에서 평균 skill $[+0.07, +0.70]$(0 제외), 중앙값 오차 비 0.94–1.00(1 포함). 고속 진단 0에도 출력 비트 동일
우위가 진짜 결측 지점에서도 남는다	결측 공변량으로 재가중하면 CI가 0을 포함	우위를 관측 지점 조건부로 한정한다	§6.5	인과 대비 8/8 유지, PCHIP 대비 2/4(컷)·4/4(포함)
캠페인 경계를 넘어도 남는다	시간 분할에서 보간 대비 우위 소멸	우위를 캠페인 내부로 한정한다	§6.6	윈도 대조군은 **실제로 소멸**(2/4·0/4), 시퀀스 백본은 4/4 유지
모든 오프라인 방법을 이긴다	어떤 오프라인 평활기와 동률이거나 진다	주장을 "사전등록된 보간들"로 좁힌다	§8	**걸렸다.** 오프라인 GP 대비 $-0.05 \sim +0.11$, 8셀 중 7셀에서 구간이 0 포함 → 주장 축소
남은 손실이 추정기 용량 때문이다	폭을 넓히면 skill이 오른다	크기 축을 열린 레버로 남긴다	§6.8	34k→879k 에서 ± 0.01 미만 → **크기 축은 닫혔다**

의도적으로 어려운 기준선. 결측 채움의 자명한 기준선은 CES 채널 자체의 보간이다. 우리는 비교를 모델에 의도적으로 불리하게 설계했다: 보간 기준선(선형, 단조 3차 PCHIP [3], 국소 AR 참조, 그리고 가우시안 과정)은 *오프라인*으로, 타겟 시점 *양쪽*의—미래를 포함한—CES 이웃을 사용할 수 있다. 반면 모델은 엄격히 인과적이며, 타겟 시점까지의 고속 진단과 과거 CES 이력만 본다. 인과 모델이 미래를 쓰는 보간을 이긴다면, 고속 진단이 CES의 시간 구조만으로는 담을 수 없는 CES 관련 정보를 운반한다는 뜻이다. 그리고 미래를 쓰는 보간을 이기는 모델은 당연히 모든 인과 기준선을 이긴다. 배치 가능한 가장 강한 경쟁자는 persistence가 아니라 과거만 쓰는 평활기이므로, *인과* GP 팔을 추가하고 그에 대한 모델의 성능을 따로 보고한다.

기여. 논증은 한 방향으로 흐른다: 문제(결측 CES 행, 비인과 보간에 맞선 인과 나우캐스트), T_i 결과와 그 재현, 반대 증거로서의 $T_i \leftrightarrow V_{\text{rot}}$ 비대칭, 나우캐스터가 계산하는 식, 그리고 한 출력에 접히지 않는 두 추정 대상.

1. **결측 10 ms CES 이온온도의 인과 나우캐스트는 비인과 보간보다 오차가 낮고, 재현된다** (§6.2). 미래를 쓰는 PCHIP 대비 skill은 4개 held-out 분할에서 $+0.17 \sim +0.26$(컷)이고, 사전등록 반복 5겹 재현에서 그 겹침 보정 95% 구간은 $[+0.19, +0.25]$로 0을 제외한다.
2. **나우캐스터가 계산하는 식, 등록되고 보존됨** (§4.4). 사전등록 4단계 판독은 T_i 분기를 20개 모수의 물리 필터로 적고, 동일한 프로토콜로 처음부터 학습한 그 식은 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 72–78%를 유지한다(등록 문턱 0.70).
3. **반대 증거로서의 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭** (§6.7, §6.11). 고속 진단을 0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하다. PCHIP 대비 평균 제곱 오차 skill의 등록된 두 단계 95% 구간은 $[+0.07, +0.70]$(컷)으로 0을 제외하고 꼬리가 실어 나르며, 이 진술은 토크가 관측되지 않는 표준 CES 10 ms 격자에 한정한다.
4. **평균과 중앙값은 다른 추정량에서, 그리고 보정된 분포** (§6.10, §6.11, §6.12). Student-t 잡음을 쓰는 사전등록 유지-또는-점프 필터의 백본 대비 T_i 중앙값 오차 skill은 $+0.06 \sim +0.39$로 두 모집단 모두 4/4 분할에서 95% 구간이 0을 제외한다. 나우캐스터는 평균 추정량이고, Student-t head가 보정된 불확실성을 나른다.

5. **오프라인 주장과 배치 주장을 분리하는 두 스트레스 테스트** (§6.5, §6.6). 채점 지점을 진짜 결측 행으로 재가중하면 T_i의 persistence 대비 skill은 $+0.28 \sim +0.44$로 8/8 분할–모집단 셀에서 95% 구간이 0을 제외하고, PCHIP 대비 skill도 엄격한 캠페인 분할에서 구간이 0 위에 있다.
6. **천장은 추정기가 아니라 입력 집합이다** (§6.9, §6.8, §6.14). persistence에 유계 보정을 더한 21,498 파라미터 모델의 백본 대비 짝지은 T_i skill은 컷에서 $+0.002$로 모든 분할의 95% 구간이 0을 포함한다. 폭, 모델군, 50 ms 너머의 문맥은 닫힌 축이다.
7. **평가 방법론 하나, §5에 전부 기술**: 배치마다 채점되는 예측 장부를 둔 사전등록, 두 공동 1차 모집단, shot 군집 paired bootstrap, Nadeau–Bengio 겹침 보정 구간, 그리고 두 단계(학습 반복 × 방전) bootstrap. 각 조각은 다른 분야에 선례가 있고(§2), 새것이 아니라 결합으로 보고한다.

2 관련 연구

핵융합 진단의 프로파일 피팅과 결측 보간. 가우시안 과정 회귀 [4]는 핵융합 프로파일 데이터의 피팅과 불확실성 정량화의 커뮤니티 표준 도구로서 KSTAR CES T_i 프로파일에도 SVM 기반 이상치 제거와 결합되어 적용돼 있으며 [5–7], PCHIP 같은 단조 보간 [3, 8]은 자연 3차 스플라인 [9]이 ELM·톱니파형 계단에서 Gibbs형 진동을 보이기 때문에 [10] 과도 현상 근방에서 선호된다. 불규칙 표본 시계열에는 정확한 AR형 영모형(IAR/CIAR)이 존재한다 [11, 12]. 우리는 이 사다리—persistence, 선형 보간 [13], PCHIP, 국소 AR—를 사전등록된 기준선으로 사용하며, PCHIP을 헤드라인 비교 대상으로, Murphy의 MSE skill 점수 [14]를 지표로 삼는다. persistence 기준선은 핵융합 프로파일 예보에 선례가 있다—Abbate et al. [15]는 기계학습 예측기와 물리 기반 예측기 모두 분포 밖으로 외삽하면 "프로파일이 변하지 않는다"는 가정보다 못하다고 보고한다—그리고 persistence 기준 대비 skill 점수는 우주기상 예보의 표준이다 [16]. 그러나 persistence와 비인과 보간 대비 Murphy skill을 평가 기준으로 세운 핵융합 선례, 그리고 기상학적 의미의 "나우캐스팅" 용어는 찾지 못했다. 본 연구의 기여는 이 문헌과 직교한다: 더 나은 CES 단독 보간이 아니라, *다른 진단들*이 어떤 CES 단독 방법도 넘어서는 정보를 더하는지를, 인과 멀티모달 모델을 미래를 쓰는 보간과 맞세워 검정한다.

핵융합에서의 신경망 진단 추론. 신경망 진단 추론에는 세 갈래가 있으며, 각각에 대해 *타겟 측정이 없을 때 어떻게 되는가?*를 묻는 것이 유익하다. 가장 오래된 갈래는 스펙트럼 피팅 가속이다—JET 전하교환 스펙트럼의 신경망 분석 [17, 18]과 EAST CXRS 스펙트럼의 고속 T_i 추정 [19], 그리고 *우리와 같은 진단*에서 나온 가장 최근 구성원인 NN-CES—물리 제약 신경망이 KSTAR CES 스펙트럼에서 T_i와 회전을 빔 변조 없이 직접 추출한다 [20]. 이들은 최소자승 피팅 대비 수십 배의 속도를 얻지만, 구조상 해당 시점에 측정된 스펙트럼을 요구한다: CES 노출이 결측되면 입력 자체가 없다. NN-CES는 본 연구에 가장 가까운 선행 연구이므로 구분을 한 문장으로 적는다—*NN-CES는 측정이 있는 시각을 더 잘 읽고, 본 연구는 측정이 없는 시각을 채운다.* 입력이 CES 자신의 스펙트럼인 이상 노출이 결측된 시각에는 정의되지 않으며, 그 시각이 우리 문제의 전부다. 그리고 둘의 관계는 경쟁이 아니라 보완이다: 빔 변조를 요구하지 않는 분석은 결측 자체를 줄이고, 그것이 산출하는 적합 품질 메타데이터는 §7의 첫 번째 레버가 요구하는 바로 그 값이다. 두 번째 갈래는 한 진단의 추론 파이프라인을 다른 진단으로 대체한다: W7-X의 베이지안 모형 에뮬레이션 [21], NSTX-U의 스칼라 파라미터 기반 프로파일 형상 예측 [22], 그리고—우리 타겟에 가장 가까운—EAST의 X선 결정 분광기로부터의 T_i·회전 프로파일 추론 [23]. Lin 등은 정확히 우리의 두 물리량을 예측하지만 입력이 또 다른 도플러 분광기, 즉 동일한 물리 정보 채널이고 같은 광자 통계 한계를 가지며, 매핑은 순간적이고 소스 진단의 가용성을 그대로 상속한다. 세 번째 갈래는 느린 재구성 코드의 종단간 대리모형이다: 볼로미터 단층촬영 [24], 선적분 진단 [25], 안전인자 프로파일 [26], 실시간 평형 [27], 그리고 KSTAR 자체의 신경망 Grad–Shafranov 솔버 [28, 29]와 고속 EPED 파라미터화 프로파일 재구성 [30] — 후자는 CES를 *입력*으로 쓰며 회전 확장을 명시된 향후 과제로 남긴다. 이들은 분석 *지연시간*을 다루지, 측정 *가용성*을 다루지 않는다: 존재하는 데이터의 역산을 가속할 뿐이다. 가용성 문제에 더 가까운 두 연구가 있다. DIII-D의 액추에이터 조건부 프로파일 예보 [31]는 우리 모델처럼 인과적이고 이력 기반이지만, 제어를 위해 *조밀하게* 측정된 프로파일로부터 미래를 예보하며, 희소 채널의 복원이 아니다. RTCAKENN [32]은 실시간으로 운동학 프로파일(불순물 온도·회전 포함)을 재구성하고 dropout 학습으로 Thomson/CER 입력 소실을 견디지만, 거기서 결측은 입력을 0으로 만드는 강건성 조건인 반면, 우리 설정에서는 타겟 자신의 희소성이 문제 그

자체이며 타겟별 관측 플래그와 불규칙 시간 특징으로 명시적으로 추적된다. 세 갈래 모두의 공통 가정은 모델이 실행될 때 정보 소스가 존재한다는 것이다. *자기 자신의* 측정이 없는 시점에서, 다른 채널들과 자신의 과거로부터 진단값을 복원하는 일은 이들의 범위 밖이다.

교차 진단 재구성과 시간 조밀화 (가장 가까운 선행 연구). 최근 한 계열은 다른 진단들로부터 특정 진단을 재구성한다. GP 기반 대체는 KSTAR에서 고장난 자기 센서를 밀리초 이하로 복원하고 [33], ML은 손상 센서를 탐지·보상하며 [34], 오토인코더는 중복 밀도 진단을 융합해 복원력을 얻고 [35], 시계열 외생 회귀는 EAST의 결측 전자온도를 채우고 [36], CNN–BiGRU–트랜스포머는 EAST에서 외생 신호로 결측 유효전하 Z_{eff}를 복원하며 [37]—양방향이므로 비인과이고, 저자들 스스로 오프라인 신호 복원이라 적는다—, FusionMAE는 HL-3의 88개 채널에서 마스킹 채널 "가상 백업 진단"을 수행한다 [38]. 우리 프레이밍에 가장 가까운 것으로, Diag2Diag는 DIII-D에서 다른 동시각 진단들로부터 Thomson 산란 T_e/n_e를 요동 진단 속도로 합성하고 [39], COMPASS에서는 고속 복사 진단으로부터 Thomson 프로파일의 시간 초해상이 시연되었으며 [40], TCV의 모델 기반 관측기는 확장 칼만 필터 안에서 저속 Thomson 산란의 사이 구간을 고속 간섭계로 채우고—인과적이며 대상은 전자 밀도다 [41]—, PanoMHD는 제어를 위해 인과 트랜스포머로 멀티모달 신호 동역학을 모델링한다 [42]. 본 연구는 이 계열과 네 가지 축에서 다르며, 각 축은 인용 논문들의 명시된 범위에서 확인 가능하다: (i) *타겟 채널*—이 계열의 모든 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성하고(39과 40의 Thomson T_e/n_e, 36의 ECE형 T_e, 38의 임의 마스킹 채널), CER/CES가 등장하는 경우에도 어디까지나 *입력*이며 [39] 희소 타겟이 아니다; (ii) *인과성*—Diag2Diag(동시각 입력을 각 Thomson 시점에 사상하는 기억 없는 다층 퍼셉트론으로, 보간·persistence 기준선 없이 측정점에 대해서만 채점된다)와 COMPASS 연구는 동시각 매핑이고 FusionMAE는 윈도 내 재구성인 반면, 우리 모델은 타겟 자신의 불규칙한 과거에 조건화되며 미래를 절대 읽지 않는다; (iii) *평가 기준*—어느 것도, 결측 채움에서 현직 방법인 타겟 채널의 *미래 사용* 보간을, 사전등록된 shot 군집 프로토콜로 이겨야 할 기준선으로 세우지 않는다; (iv) *정보 분석*—재구성 가능성이 타겟별로 검정되지 않고 가정되는 반면, $T_i \leftrightarrow V_{\mathrm{rot}}$ 비대칭은 우리의 중심 발견이다. 요컨대 본 연구는 이 활발한 계열이 확립한 프로그램—항상 있는 진단으로 없는 측정을 재구성한다—을 이어받아 세 방향으로 확장한다: 전자 채널에서 *희소 이온 채널*로, 동시각의 기억 없는 매핑에서 *타겟 자신의 불규칙 과거에 조건화된 인과 추정*으로, 그리고 가정된 재구성 가능성에서 *사전등록 기준선에 대한 타겟별 검정*으로. 문헌 점검(OpenAlex·arXiv·Crossref, 2026-11-09, 전문 검색 미완)에서 이 세 확장의 결합—희소 CXRS 이온 측정의 인과적 시간 결측 채움—의 선례를 DIII-D·JET·ASDEX Upgrade·EAST·KSTAR 어디에서도 찾지 못했다. 우리는 이를 계열로부터의 이탈이 아니라 그 자연스러운 다음 단계로 제시하며, "찾지 못했다"는 "없다"가 아니다.

차별점을 실명으로 대조한다. 위 세 단락의 대비를 표 2에 한자리로 모은다. 각 행은 인접 연구를 실명으로 적고, 그 차이가 *구조*(설계가 다른 것을 한다)인지 *배치*(같은 재료를 다르게 놓은 것)인지를 구분하며, 마지막 열에 그 판단을 확정하는 근거—해당 논문이 명시한 범위—를 적는다. "최초"라는 낱말은 이 원고 어디에서도 주장으로 쓰지 않는다. 범위를 좁히는 것은 남는 주장을 약하게 만들기 위해서가 아니라 반증 가능하게 만들기 위해서다.

불규칙 시간·마스킹 멀티태스크 학습. 본 설계는 불규칙 시계열 문헌의 표준 재료—관측 마스크와 감쇠 인지 순환 (GRU-D [45]), 연속시간 임베딩 위 어텐션 (mTAN [46]), 잠재 ODE 동역학 [47]—과 부분 라벨 멀티태스크 학습 [48], 후기 융합 멀티모달 구조 [49, 50], pre-LayerNorm 트랜스포머 [51], 어텐션 풀링 [52]을 차용한다. "나우캐스팅" 프레이밍은 기계학습 기상 예보에서의 용법을 따른다 [53, 54]. 새로움은 개별 재료가 아니라, 물리적으로 불리한 평가 프로토콜 아래에서의 누수 방지 조합에 있다.

방법의 계보. 우리가 기대는 방법은 저마다 다른 분야의 표준이며, 주장하는 대신 출처를 적는다. 데이터를 읽기 전에 분석 계획을 고정하는 것은 Nosek and Lakens [55]의 등록보고서 논리와, 그것을 기계학습이 받아들인 NeurIPS 사전등록 워크숍 [56]을 따른다. 반복 교차검증의 겹침 보정은 Nadeau and Bengio [57]이고, 보통의 교차검증 구간이 과소포함하는 이유는 Bates et al. [58]이 준다. 방전을 군집으로 재표집하고 학습 반복을 바깥 수준으로 두는 것은 Saravanan et al. [59]과 Ren et al. [60]의 계층 bootstrap이고, 그 구조는 시드와 시험 예제 위의 Multi-Bootstrap [61], 그리고 십년 규모 예측에서 시작 날짜와 앙상블 구성원을

표 2. 실명 대조. 구조 = 대상·조건화·검정 대상 자체가 다름. 배치 = 같은 재료를 다른 평가 규칙 아래 놓음.

#	차별점	실명 인접자	구조/배치	확정 근거
1	측정이 *없는* 시각을 채운다(측정이 있는 시각을 더 잘 읽는 것이 아니라)	NN-CES [20](KSTAR CES 스펙트럼에서 T_i·회전을 빔 변조 없이 추출), JET·EAST 스펙트럼 신경망 분석 [17–19]	구조	이 갈래의 입력은 CES 자신의 스펙트럼이므로 노출이 결측된 시각에는 정의되지 않는다. 우리 입력은 다른 진단과 타겟 자신의 과거다. 둘은 경쟁이 아니라 보완이며, NN-CES가 내는 적합 품질 메타데이터는 §7의 1번 레버다
2	교차 진단 재구성 계열에서 재구성 대상이 *희소 이온* 채널이다(CES T_i·V_{rot})	Diag2Diag [39], COMPASS 시간 초해상 [40], FusionMAE [38], EAST 결측 T_e [36]	구조	이 계열의 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성한다. CER/CES가 등장하는 경우에도 어디까지나 *입력*이며 [39] 희소 타겟이 아니다
3	타겟 자신의 *불규칙한 과거*에 조건화된 인과 추정이고, 미래를 절대 읽지 않는다	Diag2Diag·COMPASS(동시각 무기억 매핑), FusionMAE(윈도 내 재구성), PanoMHD [42](인과이지만 결측 채움이 아님)	구조	우리 입력은 타겟별 관측 플래그와 경과시간(staleness)을 명시 채널로 나르고, 타겟 시점은 전부 마스킹되어 누수가 구조적으로 불가능하다(§3.2)
4	이겨야 할 기준선을 *타겟 채널의 미래 사용 보간*으로 세우고 그것을 착수 전에 등록한다	위 전부, 그리고 프로파일 GP·스플라인 문헌 [3, 5, 6]	배치	어느 구성원도 결측 채움의 현직 방법(타겟 채널 자체의 양쪽 이웃 보간)을 넘어야 할 관문으로 두지 않는다. 이 배치가 "고속 진단이 CES 밖 정보를 나르는가"를 답이 갈리는 물음으로 만든다(§5)
5	재구성 가능성을 *가정하지 않고 타겟별로 검정*한다	RTCAKENN [32](결측은 입력 강건성 조건), DIII-D 액추에이터 조건부 예보 [31](조밀 프로파일에서 미래 예보)	구조	같은 모델·같은 손실에서 T_i는 통과하고 V_{rot}은 통과하지 못한다. 고속 진단 절제에서 V_{rot} 출력이 비트 단위로 동일하다는 것이 그 검정의 결과다(§6.7)
6	계측기 유지값을 채점에서 제거하고, 스펙트럼 피팅 실패를 *두 공동 1차 모집단*으로 괄호 친다	이 계열에서는 대조 사례를 찾지 못했다. 형식 자체는 비열등성 시험의 두 분석 집합이다 [43, 44]	배치	V_{rot}은 41.1%가 직전 값의 반복이므로, 제거하지 않으면 채점이 모델의 예측이 아니라 계측기의 반복을 채점한다(§3.4). 피팅 실패 0.53%는 컷의 선택만으로 결론을 뒤집을 수 있어 두 모집단 모두에서 성립할 것을 요구한다(§3.5)

재표집하는 skill 점수 bootstrap [62]의 것이다. 우리가 선례를 찾지 못한 것은 이 결합(교차검증 반복 × 방전 군집 × skill 비율)이다. skill 점수는 Murphy의 것이고 [14], 예측 분포의 적절 채점은 Gneiting and Raftery [63]를 따르며, 신경망이 모수를 출력하고 우도로 맞춘 Student-t 예측 분포를 CRPS로 채점하는 것은 기상 앙상블 후처리에서 왔다 [64, 65]. 학습된 순환 신경망을 가중치가 아니라 입출력 응답으로 읽는 것은 Sussillo and Barak [66]를, 학습된 망을 닫힌 식으로 바꾸어 그 식을 따로 검정하는 것은 Cranmer et al. [67]를 따른다. 보존 검정은 Maheswaranathan and Sussillo [68]의 절차("recovering greater than 90% of the RNN's performance increase over the baseline")를, 효과의 사전 지정 비율을 보존하는 비열등성 형식 [69]으로 쓴 것이며, 우리가 선례를 찾지 못한 것은 그 둘을 미리 확정한 문턱과 결합한 경우, 그리고 둘 중 어느 하나라도 핵융합 예측기에 적용한 경우다. 가중치 크기가 중요도가 아니라는 것은 optimal brain damage의 결과이며 [70], Allen and Bishop [71]은 1992년에 토카막 가둠 신경망에서 가중치 대신 응답을 읽어 같은 결론에 이르렀다. 물리 필터의 Student-t 측정 모형은 Roth et al. [72]과 Agamennoni et al. [73]의 강건 칼만 필터링이다. 핵융합 진단 시계열에는 베이지안 필터링으로 푸는 상태공간 Student-t 과정(DIII-D; 74), 상호작용 다중 모형 추정기(ASDEX Upgrade ECE; 75), 측정된 이온·전자 온도 위의 앙상블 칼만 필터(LHD; 76)의 선례가 있다. 우리가 선례를 찾지 못한 것은 전하교환 시계열에 유지-또는-점프 사전분포와 Student-t 잡음을 함께 쓴 경우다. 동료 심사를 거친 핵융합 기계학습에서 점검이 찾은 것은 모델들에 걸쳐 동일하게 재표집한 시험 방전을 중앙값과 사분위 범위로 보고한 사례이고 [77], 방전으로 군집한 짝지은 skill 차이의 구간, 사전등록된 분석 계획, persistence나 보간 대비 Murphy 형식 skill, 순환 신경망의 응답 기반 판독은 찾지 못했다. 이를 "없다"가 아니라 "선례를 찾지 못했다"로 적는다: 점검(전문 검색을 포함한 OpenAlex, arXiv, Crossref; 2026-11-10)은 대부분 초록을 읽었다.

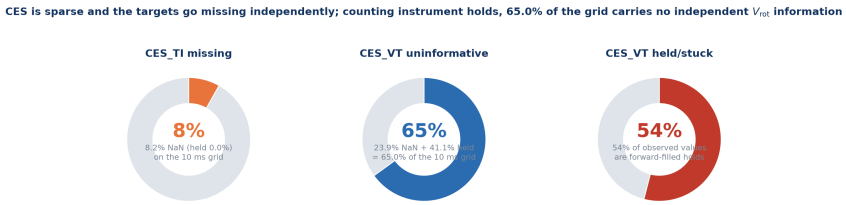


그림 2. 10 ms 격자에서의 CES 결측 구조. T_i와 V_{rot}은 독립적으로 결측되며(8.2% / 23.9%), 행 필터링이 아닌 타겟별 마스킹을 요구한다. 계측기 유지값까지 세면 격자의 65.0%가 독립적인 V_{rot} 정보를 갖지 않는다.

3 데이터와 문제 설정

3.1 데이터셋

데이터 제공 측이 하드웨어 일관성과 H-mode ELM 억제(RMP) 구간을 기준으로 선정한 641개 KSTAR 방전(shot) 파일(shot 30801–32751)을 공통 10 ms 격자에 정렬해 사용한다: 총 247,207행(파일당 중앙값 339행). 각 행은 BES [78] 9채널, ECEI [79] 4채널, Mirnov 코일 2채널, 시간, 그리고 두 CES 타겟 T_i, V_{rot} [1]을 제공한다. 이 격자에서 T_i는 8.2%, V_{rot}은 23.9%의 행에서 서로 독립적으로 결측된다(그림 2). 행은 ≥ 0.5 s의 시간 간극에서 연속 세그먼트로 묶이며(이 임계값은 이봉(bimodal) delta 분포의 골에 놓인다: ∼247k개의 행간 delta 중 $(0.1, 0.5)$ s 구간은 82개뿐이고, 세그먼트 안에서는 스텝의 99.4%가 10 ms다), 전형적인 파일은 **주 세그먼트 하나**(중앙값 301행 ≈ 3.0 s; 10–90분위 1.3–7.0 s; 두 개인 파일 28개, 10행보다 긴 것이 없는 파일 20개)와 그로부터 중앙값 6.3 s 간극으로 떨어진 고립 단일행 몇 개(전체 1,279개, 대개 $t = 0$의 첫 행)로 이루어진다. 어떤 arm도—보간이든 모델 입력이든—간극을 넘지 않는다.

3.2 학습 예제의 두 가지 프레이밍

윈도 프레이밍(우리의 대조군, §4)은 타겟 인덱스 t의 샘플을 직전 W개 격자 행으로 구성한다: `bes` $(W, 9)$, `ecei` $(W, 4)$, `mc` $(W, 2)$, `time_features` $(W, 4)$, `ces_history` $(W, 4)$, 정규화 타겟 $[T_i, V_{\mathrm{rot}}] \in \mathbb{R}^2$, 그리고 타겟별 관측 마스크 $m \in \{0, 1\}^2$. 네 개의 시간 특징—lookback 초, 행간 delta 초, 그리고 각각의 $\log(1{+}x)$ 변환—은 불규칙 관측 패턴을 명시적으로 노출한다(과거 CES 값의 신뢰도는 그것이 10 ms 전 값인지 200 ms 전 값인지에 강하게 의존한다). CES 이력의 네 채널은 직전 정규화 T_i, 직전 정규화 V_{rot}, 그리고 타겟마다 하나씩의 관측 플래그다. 본문 전체에서 $W{=}2$이다(§6.14).

전체격자 시퀀스 프레이밍(우리의 주 모델)은 고속 진단에 결측이 없다는 점을 이용해, 연속 세그먼트의 입력이 완전한 모든 행을—라벨 유무와 무관하게—맥락으로 유지한다. 각 스텝은 엄격히 인과적인 22개 채널을 담는다: z-score된 15개 고속 채널, $\log(1{+}\Delta t_{\mathrm{prev}})$, 그리고 타겟별로 t 이전 행에서 이월된 마지막 관측값, $\log(1{+}$경과시간$)$, 과거 관측 존재 여부 플래그. 타겟은 병렬 관측 마스크와 함께 z-score되며, 희소성은 전적으로 손실에서 처리된다. 두 프레이밍 어느 쪽도 모델이 타겟 행 자신의 값을 읽게 하지 않는다.

3.3 설계 원칙

가짜 라벨 금지. 학습 행을 만들기 위해 타겟을 대체(impute)하지 않는다. 윈도 프레이밍에서 행은 진단 입력이 완전하고 CES 타겟 중 *적어도 하나*가 실제로 관측된 경우에만 유지되며, 시퀀스 프레이밍에서 라벨 없는 행은 맥락으로만 기여한다.

타겟별 마스킹 손실. 손실은 타겟별로 마스킹된다: $\mathcal{L} = \sum_{k \in \{T_i, V_{\mathrm{rot}}\}} m_k \, (\hat{y}_k - y_k)^2 / \sum_k m_k$. 한 타겟만 관측된 행도 그 타겟은 학습에 기여한다. 두-타겟-필수 필터는 라벨 행의 ≈28%를 조용히 버렸을 것이며, 이를 제거한 것은 순수한 데이터 이득이다.

누수 방지. (i) *파일 단위 분할*: 한 shot 내 인접 행은 강하게 자기상관되므로 분할은 shot 파일 단위로 이루어지고 디스크에 고정된다; (ii) *학습 파일 전용 정규화*: 모든 z-score 통계(희소 타겟은 NaN-인지)는 학습 파일에서만 추정되며, 시퀀스 모델은 여기에 더해 각 방전의 고속 진단을 *그 방전 자신의* 평균·분산으로 표준화한다—다른 방전도 타겟도 사용하지 않는다(왜 중요한지는 §6.6); (iii) *타겟 시점 마스킹*: 타겟 행 자신의 값과 관측 플래그는 입력에 결코 들어가지 않는다.

3.4 데이터 품질 감사 1: 유지(forward-fill)된 V_{rot} 값

관측된 V_{rot} 값의 54%가 계측기 유지값이다: 같은 연속 시간 블록 안에서 직전 관측과 비트 단위로 동일한 반복(최대 1,214행 연속; 641개 중 499개 파일 영향)이다. V_{rot}의 고유 측정 주기가 행 주기보다 느려 생기는 현상으로, 독립적인 측정이 아니다. V_{rot}은 소수점 다섯 자리까지 기록되고 서로 다른 값 사이의 최소 간격이 4×10^{-5}이므로 "연속 동일"에는 측정 가능한 위양성 통로가 없으며, T_i는 영향이 없다(226,991행 중 1행). 확정된 프로토콜에서 유지값은 *모든 곳에서* 제거된다—지도 타겟, 이력·이월 입력과 그 관측 플래그, 정규화 통계, 그리고 모든 기준선의 보간 앵커에서—따라서 어떤 팔도 forward-fill로 공짜 점수를 받을 수 없다. 본 논문의 모든 수치는 진짜 측정만을 사용하며, 유지값이 *학습*도 오염시키므로(forward-fill 계단은 이력을 복사하는 것이 거의 최적이라고 모델에 가르친다) 유지값 제거는 민감도 한 줄이 아니라 프로토콜이다.

3.5 데이터 품질 감사 2: T_i 스펙트럼 피팅 실패와 두 모집단

관측된 T_i의 p99는 2,089 eV, p99.9는 9,601 eV이고 최댓값은 14,984 eV다. 이 먼 꼬리는 플라즈마 물리가 아니라 실패한 스펙트럼 피팅이다. **1,197행(0.53%)이 3 keV를 초과**하며 274개 방전에서 951개의 런을 이룬다. 런의 85%는 단일 행이고 5행 이상 지속하는 것은 2%뿐이며, 런 정점의 중앙값은 관측된 이웃 평균의 13×다(IQR 6–26×). 이런 행은 어떤 방법으로도 예측 불가능하며, 공정한 비교에는 더 나쁘게도 *보간 앵커로 쓰인* 스파이크가 그 이웃에서 보간을 오염시킨다. 두 가지 대응이 모두 방어 가능하고 각각 비판의 여지가 있다: >3 keV를 모든 팔에서 결측으로 처리하면 어떤 방법도 예측할 수 없는 행을 제거하지만 "어려운 행을 없앴다"는 비판을 부르고, 그대로 두면 스파이크 앵커를 먹인 채 오프라인 기준선에 핸디캡을 준다. 그래서 우리는 **두 개의 공동 1차 모집단**을 사전등록했다: *컷*(>3 keV 값을 적재 시점에 결측으로 처리하며, 지도·이력 입력·정규화 통계·모든 기준선의 앵커에 동일하게 적용)과 *포함*(컷 없음). **어떤 주장은 두 모집단 모두에서 성립할 때만 조건 없이 진술한다**. 한쪽에서만 성립하는 결과는 모집단을 명시해 보고한다. 이 형식은 비열등성 시험의 것으로, 거기서는 전체 분석 집합과 계획서 순응 집합이 동등한 중요도를 지니고 비슷한 결론에 이를 것이 기대된다 [43]. 두 모집단은 서로 다른 추정 대상(estimand)을 정의하므로 [44] 어느 쪽도 다른 쪽의 민감도 분석으로 읽지 않는다. 임계값은 2.5–4 keV 범위에서 무의미하다(§6.13). 값 기준 컷은 CES 피팅 품질 메타데이터가 확보되기 전까지 쓰는, 물리적으로 동기가 있는 대리 지표("3 keV 초과는 KSTAR 이온온도가 아니다")이며 한쪽 방향뿐이다 —같은 감사는 어떤 값 컷도 건드리지 못하는 단일 표본 *하향* 급락(양쪽 이웃의 $\frac{1}{2}$ 이하인 4,965행)을 함께 찾아내고, 컷이 제거하는 것은 $\geq 2\times$ 상향 이상치의 19%뿐이다. V_{rot}에도 피팅 실패 스파이크가 있으나(16개 shot에서 1,000 km/s를 넘는 119행, 그중 101행은 한 방전의 한 블록), 프로토콜은 V_{rot}을 컷하지 않고 persistence 기반 V_{rot} 비교마다 그 행들이 담는 제곱오차 비중을 보고한다.

4 모델

주 모델 `seq_v2`는 **357,570 파라미터**의 인과 시퀀스 나우캐스터이며, 그것이 대체한 윈도 모델은 201,258 파라미터의 후기 융합 네트워크로 짝지은 대조군으로 유지된다. 이 절은 그 두 모델을 기술하기 전에 *무엇을 추정하는가, 왜 그 입력이 그 타겟에 배선되는가, 어떤 시간 척도 위에서 동작하는가*를 먼저 정한다. 셋 다 뒤의 결과 절이 측정한 양이 아니라 그 측정을 해석 가능하게 만드는 전제이며, 라우팅에 관해서는 설계 선택이 아니라 보존식의 결과다.

4.1 추정 대상, 손실, 그리고 환원 불가능한 하한

모델은 각 격자 시각 t에서 정규화된 타겟 $y_t = [T_i, V_{\mathrm{rot}}]_t$를 그 시각까지의 관측 이력 $x_{\leq t}$로부터 추정한다. 손실은 타겟별 관측 마스크 $m_{t,c} \in \{0, 1\}$ 위의 마스킹 평균제곱오차이며, 여기에 정규화 영점 z_0 아래의 T_i 예측을 억제하는 물리 페널티가 더해진다:

$$\mathcal{L} = \frac{\sum_t \sum_{c \in \{T_i, V_{\mathrm{rot}}\}} m_{t,c} \left(\hat{y}_{t,c} - y_{t,c}\right)^2}{\sum_t \sum_c m_{t,c}} \; + \; \lambda \, \overline{\mathrm{ReLU}\big(z_0 - \hat{y}_{t,T_i}\big)}, \qquad \lambda = 0.1. \tag{1}$$

식 (1)의 첫 항을 최소화하는 추정량은 조건부 기댓값 $\mathbb{E}[y_t \mid x_{\leq t}]$이므로, 본 연구가 보고하는 것은 조건부 분포의 평균이지 그 분포 전체가 아니다. 불확실성은 별도로, 예측 분포 head로 다룬다(§6.12).

표 3. 식 (4)의 항별 감사. 641개 방전 전수, 확정 데이터 처리(스파이크 컷 후 유지값 제거), 624개 연속 블록. r은 모달리티 표준화 평균과 타겟(또는 그 한 스텝 증분) 사이의 lag 0 통합 Pearson 상관이다.

항	물리	우리 데이터에 있는가	판정
$\partial L/\partial t$	회전 변화율	연속 관측쌍의 차분	측정됨
T_{NBI}	빔 토크	0-D 채널이 존재하지 않음	부재(§6.7)
$T_{\mathrm{NTV}} \sim \delta B^2$	비축대칭 제동	Mirnov, 100 Hz 데시메이트	음성 종결
$\nabla\cdot\Pi_\varphi$	난류 운동량 유속	BES가 밀도요동을 봄	**측정 → 널**
T_{int}	잔여응력	∇T_i 필요, 스칼라만 보유	도달 불가

이 목표에는 추정기가 제거할 수 없는 하한이 있다. 타겟은 광자 적분 스펙트럼 피팅의 산물이므로 스스로 측정 잡음 σ_{meas}를 지니며, 참 물리량을 완벽히 맞히는 예측자라도

$$\mathrm{RMSE}^2 \;=\; \sigma_{\mathrm{meas}}^2 \;+\; b^2 \tag{2}$$

를 기록한다(b는 물리적 오차). 관측 계열 자체에서 차분 기반 추정기로 잰 σ_{meas}는 컷 모집단 T_i에서 **46.4–129.9 eV**이다(4차 차분 상한 129.9, 상위 5% 절사 68.7, 강건 MAD 46.4). 백본의 RMSE 157.8 eV는 이 범위와 같은 자릿수이며, 두 끝값이 3배 가까이 벌어지는 이유가 손실의 성격을 결정한다: **4차 차분 제곱질량의 46.6%(V_{rot}은 65.6%)가 상위 1%의 한 스텝 변화에 몰려 있다.** 따라서 식 (1)의 총합은 *꼬리 통계*이고, 폭과 계열이 평평하다는 뒤의 결과(§6.8)는 정보의 고갈이 아니라 이 사실의 귀결로 읽어야 한다. 본류에서는 모델이 여전히 타겟 자체 산포의 2.3–3.4배 위에 있다.

$\lambda = 0.1$은 본 연구가 유도한 값이 아니라 윈도 파이프라인에서 물려받은 설정이며, 이를 유도로 바꾸는 방법은 위반율 목표를 정하고 승수를 제약 최적화로 푸는 것이다. 현재 판본은 그 대신 페널티가 결과를 만들지 않는다는 사실만 보고한다: 사다리의 모든 팔이 동일한 λ로 학습되며, 해석 가능한 칸 `b3k8`는 persistence에서 출발하는 구성상 페널티가 거의 활성화되지 않는데도 백본과 동급이다(§6.8).

4.2 두 보존식이 입력 라우팅을 정한다

`seq_v2`의 V_{rot} 분기는 고속 진단을 보지 않는다. 이는 모델링 취향이 아니라 두 전송 방정식을 항별로 읽은 결과다. 이온 에너지와 토로이달 각운동량은

$$\frac{\partial}{\partial t}\left(\tfrac{3}{2} n_i T_i\right) + \nabla\cdot\mathbf{q}_i = Q_{ei}\,(T_e - T_i) + S_i, \tag{3}$$

$$\frac{\partial}{\partial t}\left(n_i m_i \langle R^2\rangle \omega_\varphi\right) + \nabla\cdot\Pi_\varphi = T_{\mathrm{NBI}} + T_{\mathrm{NTV}} + T_{\mathrm{int}} + \cdots \tag{4}$$

를 따르며, 두 식 모두 *값*이 아니라 *변화율*을 구속한다. 그러므로 회전에 대해 물어야 할 것은 고속 진단이 V_{rot}과 상관되는가가 아니라 dV_{rot}/dt와 상관되는가이다. 식 (4)의 각 항을 우리가 보유한 채널에 대조하면 표 3가 된다.

T_{NTV}는 이미 닫힌 항이다: Mirnov는 100 Hz로 데시메이트되어 |MC|와 이동 RMS 같은 진폭 대리 지표가 모두 도움이 되지 않았다 (§6.7). 남아 있던 유일한 항은 난류 운동량 유속이며, BES가 그것이 올라타는 밀도요동을 보므로 원리상 도달 가능하다. 측정 결과는 널이다:

$$\underbrace{r\big(\mathrm{BES},\, dV_{\mathrm{rot}}/dt\big) = -0.006, \qquad r\big(\mathrm{ECEI},\, dV_{\mathrm{rot}}/dt\big) = -0.003}_{\text{운동량식}} \quad \text{대} \quad \underbrace{+0.070, \qquad +0.078}_{\text{에너지식}(dT_i/dt)}$$

값 수준에서도 같은 비대칭이 나타난다(BES→T_i +0.341, ECEI→T_i +0.311 대 V_{rot} +0.027, +0.005). *같은 측정이 에너지식에서는 신호를 잡으므로 회전의 널은 방법의 한계가 아니다.* T_{NBI}가 데이터셋에 없고 T_{NTV}가 닫혔으며 T_{int}가 도달 불가인 상태에서 마지막 항까지 널이므로, 우리 입력이 식 (4)을 통해 V_{rot}에 닿을 경로는 남아 있지 않다. 인코더에서 분기를 나누는 설계는 이 감사의 구현이며, 그 결과 15개 고속 채널을 전부 교란해도 V_{rot} 출력이 비트 단위로 동일하다(§6.7). 남은 레버는 모델이 아니라 취득이다(§7).

4.3 모델이 놓인 시간 척도

세 개의 시간이 이 문제를 규정한다. 첫째, 격자 간격 $\Delta t = 10\,\mathrm{ms}$이므로 Nyquist 주파수는

$$f_{\mathrm{Nyq}} = \frac{1}{2\,\Delta t} = 50\ \mathrm{Hz} \tag{5}$$

이다. Mirnov가 담아야 할 모드 회전은 kHz 대역이고(본 데이터셋의 방전들에서 보고된 EHO 조화파는 약 4와 8 kHz이다), 반앨리어싱 필터 없이 100 Hz로 데시메이트된 dB/dt는 표본화 정리상 그것을 표현할 수 없다. §6.7의 lag-1 자기상관 -0.009(BES $+0.568$ 대비)는 이 사실의 *확인*이지 그 근거가 아니다.

둘째, 전자와 이온을 결합시키는 시간이다. Braginskii 전자 충돌시간 $\tau_e = 3.44\times10^{5}\,T_e^{3/2}/(Z\,n_e\ln\Lambda)$(초, T_e는 eV, n_e는 cm^{-3})로부터 온도 평형화 시간은

$$\tau_{\mathrm{eq}} \simeq \frac{m_i}{2m_e}\,\tau_e \tag{6}$$

이다. 중수소, $\ln\Lambda = 17$, $Z = 1$에서 τ_{eq}는 $T_e = 0.5$–$3\,\mathrm{keV}$와 $n_e = 2$–$5\times10^{19}\,\mathrm{m}^{-3}$ 범위에서 8.3–305 ms이고, 관측된 T_i 중앙값 593 eV에 대응하는 구석에서는 **8–59 ms**이다. 본 연구가 측정한 연속 인과 문맥의 포화점은 약 50 ms이며, 두 수는 같은 자릿수다. 이는 자릿수 수준의 정합성 진술이고 그 이상이 아니다: 식 (6)의 플라즈마 파라미터는 인용값이며(BES와 ECEI는 계측기 단위이므로 본 연구는 n_e와 T_e를 물리 단위로 갖지 않는다) 앞의 상수에는 order-unity 관례가 있다.

셋째, 신호가 스스로를 닮아 있는 시간이다. 641개 파일에서 잰 자기상관의 $1/e$ 시간은 T_i 159 ms, BES 161 ms, ECEI 147 ms로 서로 10% 이내에서 일치한다. V_{rot}은 그렇지 않다: 관측의 54%가 계측기 유지값이므로 유지값을 제거하면 16 ms, 유지하면 300 ms를 넘어 19배 이상 벌어진다. **V_{rot}의 완화 시간은 이 데이터셋에서 측정 불가능하다.** T_i는 641개 파일에서 유지값이 1행뿐이라 이 문제를 겪지 않는다. 유지값 병리는 값의 54%뿐 아니라 그 물리량의 동역학을 특징지을 능력까지 앗아간 것이며, 이는 그 자체로 하나의 취득 과제다(§7). 이 자기상관들은 추세를 제거하지 않고 계산되어 방전 포락선이 지배하므로 수송 시간 τ_E나 τ_φ로 인용하지 않는다.

4.4 전체격자 인과 시퀀스 백본

`seq_v2`는 세그먼트의 22채널 격자 시퀀스(§3.2: 그림 3, 셀은 그림 4) 위에서 서로 독립인 두 개의 인과 LSTM을 돌린다. T_i 분기(2층, 160 유닛)는 전체 상태—고속 진단, 두 타겟의 이월값, 경과시간 플래그, Δt—를 읽고, V_{rot} 분기(1층, 64 유닛)는 *고속이 아닌 7개 채널만* 읽는다: Δt와 타겟별 이월값, 경과시간, 관측 플래그. 이 배선이 §4.2의 항별 감사를 그대로 구현한 것이다. 각 분기는 LayerNorm과 작은 GELU 헤드로 끝나며, 출력은 행별 정규화 $[T_i, V_{\mathrm{rot}}]$이고 손실은 식 (1)를 세그먼트의 모든 라벨 행에 대해 적용한 것이다. 이 프레이밍에서 두 가지가 따라 나온다. 첫째, 모델이 과거로 뻗는 *도달 범위*가 고정 윈도가 아니라 세그먼트 전체다—§6.3에서 이 모델을 모든 윈도 변형과 가르는 바로 그 양이다. 둘째, 라우팅이 *인코더* 수준에서 성립한다: 순환 상태를 공유하면 헤드를 어떻게 배선하든 고속 진단 정보가 V_{rot} 헤드로 흘러들지만, 여기서는 15개 고속 채널을 전부 교란해도 V_{rot} 출력이 비트 단위로 동일하다(§6.7).

백본이 계산하는 것. 동결된 `seq_v2` 체크포인트 30벌에 대한 사전등록 판독에서 가중치 크기는 안정된 정보를 주지 않았다(첫 층 열 노름은 고속 채널 15개에서 평평하고, 가장 큰 가중치는 영향이 가장 작은 입력에 붙어 있으며, 채널별 순위는 분할 간에 재현되지 않는다). 반면 입출력 응답은 정보를 준다: T_i 출력은 과거 관측된 T_i의 지수가중 평균에 고속 채널에 대한 동시각 응답을 더한 것이고, forget 게이트의 기억은 격자 1.3 스텝이다. 동결된 TEST 행에서 채점하면 맞춤 모수가 없는 이동 평균 하나가 persistence 대비 백본 skill의 73–82%(컷)를 내고, 10 ms 증분 15개에 대한 ridge 선형 항을 더하면 77–85%가 된다(4/4 분할이 등록 문턱 0.75 이상). 그 증분 항을 가진 식을 20개 모수로 두고 동일한 프로토콜로 처음부터 학습하면—$\hat{y}_t = m_t + \sum_c a_c\,\kappa\tanh(\Delta x_{c,t}/\kappa) + b_0$, 직전 측정 이후 공백 s에 대한 관측 이득 $K(s) = K_\infty + (K_0 - K_\infty)e^{-s/s_K}$—모든 컷 분할에서 같은 물리량이 돌아오지만($K_0 = 0.30$–0.31, $K_\infty = 0.52$–0.54, $s_K = 37$–40 ms, $\sum a_{\mathrm{BES}} = +43 \sim +51$, $\sum a_{\mathrm{ECEI}} = +39 \sim +46\,\mathrm{eV}/\sigma$, $\sum a_{\mathrm{MC}} \approx 0$), 이 식은 백본의 PCHIP 대비 skill의 50–66%(컷)만 유지해 등록 문턱 0.70에 못 미치고, 교차항 하나를 더해도 0.001 미만이 더해진다. 이어서 동결된 TEST 행 전부에 대한 출력의 야코비안이, 빠진 것은 상태 의존 항이

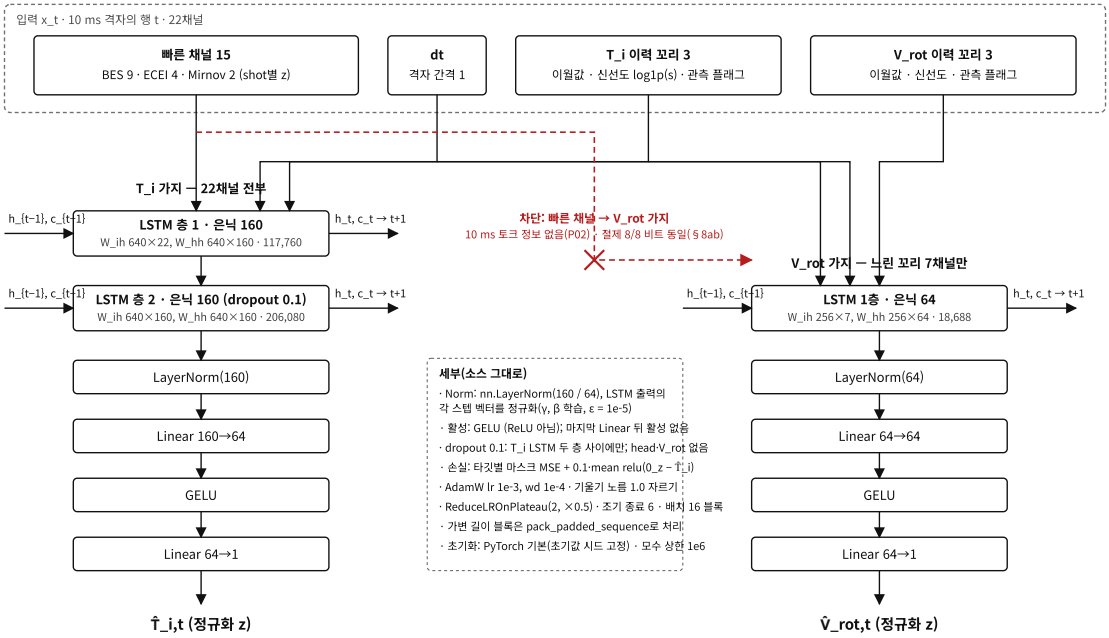


그림 3. 격자 행 t 하나에 대한 `seq_v2`. 입력 22채널(고속 15: BES, ECEI, Mirnov, shot별 z; Δt; 이월값·신선도·관측 플래그의 이력 꼬리 둘)이 두 인과 LSTM 분기로 들어간다. T_i 분기는 22채널 전부를 읽고(2층, 160 유닛; 모수 117,760 + 206,080), V_{rot} 분기는 느린 꼬리 7채널만 읽으며(1층, 64 유닛; 18,688), 각각 스텝별 LayerNorm과 Linear–GELU–Linear head(마지막 층 뒤 활성 없음)가 따른다. 고속 채널에서 V_{rot} 분기로 가는 붉은 점선 경로는 구조상 존재하지 않는다. 순환 상태 (h, c)는 $t-1 \to t \to t+1$로 전달되고, 손실은 CES가 실제로 측정된 행의 타겟별 마스크 MSE에 $0.1\,\mathrm{relu}(0_z - \hat{T}_i)$를 더한 것이다. 총 모수 357,570.

아니라 형태임을 보였다: 백본의 고속 채널 응답은 현재값에서 직전 10스텝 평균을 뺀 $\approx$100 ms 고역 통과이고, 그 이득은 2σ까지 평탄하다가 3σ 너머에서 꺼지며, 직전 증분에 의존하지 않는다. 정확히 그 형태로, 같은 20개 모수로 다시 학습하면—$\hat{y}_t = m_t + \sum_c a_c\, d_{c,t}\, \sigma\big((\theta - |d_{c,t}|)/0.5\sigma\big) + b_0$, $d_{c,t} = x_{c,t} - \overline{x}_{c,\,t-10..t-1}$—이 식은 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 72–78%, persistence 대비 skill의 87–90%를 유지하고, 증분 형태의 식보다 모든 분할에서 paired $+0.034 \sim +0.042$만큼 위에 있으며(CI가 0 위), $\theta = 2.9$–3.0σ, $\sum a_{\mathrm{BES}} = +48 \sim +53$, $\sum a_{\mathrm{ECEI}} = +44 \sim +50\,\mathrm{eV}/\sigma$, $K_0 = 0.27$–0.30을 학습한다. 남은 PCHIP skill의 4분의 1은 신경망의 비선형 사건 처리이며, 고속 채널 이력의 저차 함수로는 재현되지 않는다. 이는 모델에 대한 측정이고, 헤드라인 수치는 여전히 백본의 것이다.

4.5 윈도 대조군: 관측 마스킹 어텐션 풀링

대조군은 각 모달리티(BES, ECEI, MC)를 W=2 윈도 위의 전용 시간 인지 1-D CNN으로 인코딩하고, CES 이력을 양방향 GRU(은닉 64)로 읽은 뒤 시점별 출력을 타겟마다 하나씩 두 개의 독립적인 멀티헤드 가산 어텐션 readout으로 풀링하되, *하드 마스킹*하여 어텐션 질량이 그 타겟이 실제로 측정된 행에만 놓이도록 한다—보간 자신의 귀납 편향(관측된 표본만 사용)을 파라미터 비용 0으로 어텐션에 써 넣은 것이다. T_i 헤드는 고속 진단·시간·이력을 융합하고, V_{rot} 헤드는 이력과 시간만 융합한다. 두 모델이 공유하는 모든 것—데이터 계약, 유지값 제거 처리, 타겟별 마스킹, 분할, 채점 모집단—은 동일하게 고정되므로 두 모델의 비교는 행 단위로 짝지어진다.

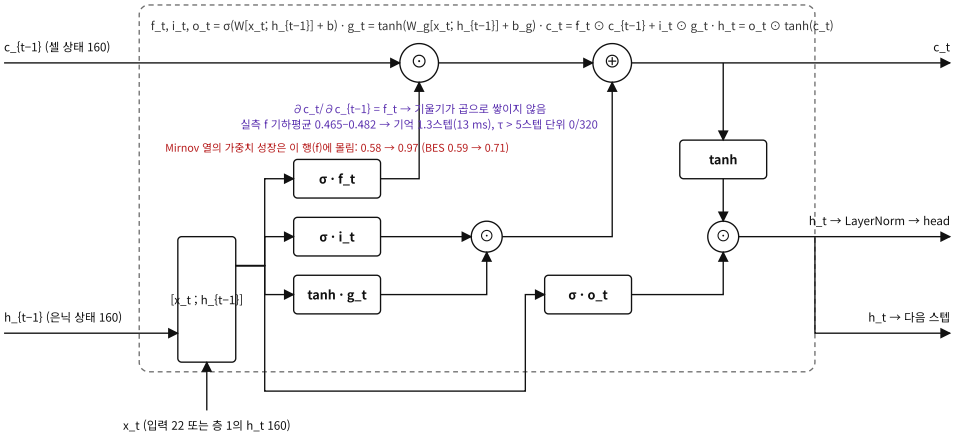


그림 4. LSTM 셀 하나(T_i 분기 1층, 160 유닛). 셀 상태는 forget 게이트로 곱해지고 게이트된 후보가 더해져 $c_t = f_t \odot c_{t-1} + i_t \odot g_t$이므로 $\partial c_t/\partial c_{t-1} = f_t$이고, 기억 길이는 야코비안의 누적 곱이 아니라 f가 정한다. 보라색: 동결 가중치에서 실측한 값(기하평균 f 0.465–0.482, 기억 1.3스텝; $\tau > 5$스텝 유닛 320개 중 0). 붉은색: 학습 중 Mirnov 입력 열이 자라는 자리(forget 게이트 행, 0.58 → 0.97; BES는 0.59 → 0.71).

4.6 해석 가능한 사다리 칸

`b3k8`(§6.8)는 `seq_v2`의 프레이밍과 라우팅을 유지하되 각 헤드를 *정확한* 분해로 대체한다: $\hat{y} =$ 이월값 $+ \sum_k w_k z_k + b$, 여기서 $z \in [-1, 1]^K$는 작은 인과 GRU(64/32 유닛, T_i는 K=8, V_{rot}은 4)의 tanh 잠재이고 readout은 0으로 초기화되어 학습이 정확히 persistence에서 시작한다. 파라미터는 21,498개로 백본의 6%다.

4.7 최적화 설정, 그리고 그 근거의 현황

학습은 AdamW($\eta = 10^{-3}$, weight decay 10^{-4}), 배치 16 세그먼트, gradient norm clipping 1.0, 검증 마스킹 MSE에 대한 `ReduceLROnPlateau` (patience 2, factor 0.5)와 조기 종료(patience 6, 최대 30 epoch; 확정 실행은 14–25 epoch에서 멈췄다)를 사용한다.

이 값들은 *유도된 것이 아니라* 윈도 파이프라인에서 물려받은 것이며, 본 연구는 그 사실을 감추지 않는다. 데이터와 구조의 축은 전부 통제 실험으로 닫혔지만 (윈도 크기 §6.14, 유지값 처리 §3.4, 두 모집단 §3.5, 복잡도와 폭 §6.8), 최적화 축은 그런 측정을 거치지 않았다. 현재 이 설정을 방어하는 증거는 하나뿐이며 그것은 간접적이다: 백본 관문의 *예산 균등화* 조건은 두 모델을 고정 10 epoch로 학습시키고 검증 기반 체크포인트 선택을 금지하는데, 그 조건에서도 백본의 짝지은 T_i 이득은 4개 분할 전부 양수였다(+0.063, +0.033, +0.045, +0.030; §6.3). 즉 결론은 학습 일정의 인공물이 아니다.

손실 축은 이후 하나의 통제 실험으로 측정되었다(§6.10): 척도를 타겟의 10 ms 재현성 한계에 고정한 Huber 손실은 컷 모집단에서 집계 skill을 지키면서 중앙값 오차를 8–10% 줄였고, 백본의 손실은 사전등록 규칙에 따라 MSE로 남았다. 그 실험이 함께 가르친 것은 선택 규칙의 결합이다: 목적함수를 바꾼 팔을 val MSE로 고르면 꼬리가 지배하는 포함 모집단에서 거의 학습되지 않은 체크포인트(epoch 2–4)가 선택된다. 목적함수와 체크포인트 선택 지표는 한 쌍이며, 어느 하나를 바꾸면 다른 하나를 어떻게 두었는지가 결과의 일부다.

"왜 배치 16인가"는 이제 측정된 답을 갖는다. 경사 잡음 척도 $B_{\text{simple}} = \operatorname{tr}\Sigma/|G|^2$는 그래디언트의 신호와 잡음이 맞먹는 배치 크기이며, 표본 단위를 학습 루프가 실제로 뽑는 단위인 블록으로 두면 학습셋 위에서 정확히 계산된다. 즉 g_i를 블록 i의 마스킹 손실 그래디언트라 할 때

$$G = \frac{1}{N}\sum_i g_i, \qquad \operatorname{tr}\Sigma = \frac{1}{N}\sum_i \|g_i\|^2 - \|G\|^2, \qquad B_{\text{simple}} = \frac{\operatorname{tr}\Sigma}{\|G\|^2} \tag{7}$$

이다. 학습 중 일곱 시점에서 452개 학습 블록 전부에 대해 계산한 결과 초기값 이후 B_{simple}의 중앙값은 **33.6 블록**(기하평균 28.4, 범위 6.0–61.4)이다. **배치 16은 측정된 잡음 척도의 절반쯤에 있다.** B_{simple} 아래에서는

배치 크기와 스텝 수가 대체로 선형으로 교환되므로, 16은 낭비도 아니고 명백히 열등하지도 않으며, 32로 늘리면 같은 데이터 효율에서 스텝 수가 대략 절반이 되고 60을 크게 넘으면 예제를 낭비하기 시작한다.

이는 자릿수 진술이다. $\frac{1}{N}\sum_i \|g_i\|^2$와 $\operatorname{tr}\Sigma$는 첫 epoch 이후 단조롭게 감소하지만(10.5 → 7.5, 10.3 → 7.3) $\|G\|^2$가 0.15에서 1.74 사이를 오가며, 이 값은 452개 블록 전부에서 정확히 계산되므로 그 진동은 측정 오차가 아니라 Adam 궤적이 epoch 경계에서 어디에 있는지에 대한 실제 성질이다. 반면 안정적인 것은 잡음 비중이다: 첫 epoch 이후 블록 하나의 그래디언트 에너지 가운데 **86–98%가 잡음**이고 신호는 2–14%에 그친다. 측정은 dropout을 끈 상태에서 수행하였으므로(표본추출 잡음만 재기 위함이다) 실제 학습 루프의 유효 잡음 척도는 위 값 *이상*이며, 이 수는 계산 비용과 스텝 수의 교환에 관한 것이지 최종 skill에 관한 것이 아니다.

두 번째 측정인 μP—폭에 따라 최적 학습률이 이동하지 않는 파라미터화—는 아직 수행하지 않았다. 그것을 쓰면 §6.8의 폭 스윕이 평평한 이유가 "용량이 도움이 되지 않는다"인지 "학습률이 그 폭에 맞지 않았다"인지의 구분이 구성상 불필요해진다.

탐색이 가르쳐 준 것. 윈도 계열에 대한 두 라운드의 통제된 아키텍처 반복에서(선택은 깨끗한 검증 skill만으로), 살아남은 메커니즘은 어텐션 풀링 하나뿐이었고 용량 확장·스킵 위상·추가 추출기는 한 번도 도움이 되지 않았다. 확정된 프로토콜 아래에서 같은 교훈이 두 번 더 반복된다: `seq_v2`에 관측 마스킹 인과 어텐션을 더한 것은 작고 일관되게 양수이지만 유의하지 않은 이득이었고(§6.3), `seq_v2`의 5점 폭 스윕은 평평하다(§6.8). 이 문제의 병목은 용량이 아니라 정보이며, 식 (2)와 표 3가 그 병목이 각각 어디에 있는지를 타겟별로 말해 준다.

5 평가 방법론

지표. 모든 오차는 물리 CES 단위로 역정규화되어 타겟별로 계산된다. 1차 점수는 사전등록된 헤드라인 기준선에 대한 Murphy skill [14], $\text{skill}_{\text{PCHIP}} = 1 - \text{MSE}_{\text{model}}/\text{MSE}_{\text{PCHIP}}$ (양수 = 모델 우위; 0 = 동률)이다. 모든 팔(모델과 모든 기준선)은 *동일한* (파일, 행) 샘플 집합에서 동일한 타겟별 유지 마스크로 채점되며, 어떤 짝지은 비교 이전에도 모집단 키가 비트 단위로 동일함을 검증한다. 보간은 타겟 자신의 값을 제외한다(누수 없음). 보간도 모델 입력도 세그먼트 경계를 넘지 않으며, 경계 너머의 이웃이 필요한 지점에서는 보간이 persistence 값을 대신 예측한다(모집단 축소 없음, PR2).

기준선 사다리. persistence와 국소 과거 전용 AR은 최초 사전등록의 인과 기준이고, 선형·PCHIP· 가우시안 과정(정확한 Matérn-3/2 + 백색잡음, 최근접 16+16 국소 적합, 표본별 주변우도 격자 선택, PR2 fallback을 그대로 상속)은 미래를 읽는다. 인과 쪽에는 **인과 GP**를 추가한다: 같은 GP를 과거 이웃 16개로 제한하고 NaN 조건을 동일하게 두어 채점 모집단이 움직이지 않게 한 것이다. 이것이 배치 가능한 가장 강한 기준선임은 분명하며(시드 42 T_i RMSE 164.3 대 persistence 197.2, 컷 모집단), "배치 가능한 모든 인과 방법을 이긴다"는 persistence가 아니라 이 기준선에 대해 판정한다.

3분할; 선택은 TEST를 보지 않는다. 파일들은 train/val/test로 분할된다. 모든 분할의 test 파일은 어떤 아키텍처 탐색 *이전에* 예약되었고 모델 선택 과정에서 절대 읽지 않는다. 표준(시드 42) test 셋은 컷 모집단에서 96개 shot에 걸친 관측 T_i n = 32,589행과 60개 shot에 걸친 진짜 V_{rot} n = 10,463행을 담는다(포함 모집단은 32,721 / 10,461). 4개 분할(시드 42, 1, 7, 123)은 각각 96개 shot에 걸쳐 T_i 32.6–35.9k행, 60–66개 shot에 걸쳐 V_{rot} 10.5–14.5k행을 담는다. 본 논문의 모든 수치는 단일 수집 스크립트가 동결된 실행 디렉터리에서 읽어오므로, 본문·표·그림이 서로 어긋날 수 없다.

사전등록. 이 논문에서 "사전등록"의 뜻은 하나다: 한 배치의 가설·판정 규칙·수치 예측을 그 배치를 실행하기 전에 프로젝트 저장소에 커밋하고 그 커밋을 기록해 두었다는 것이며, 제3자 등록소는 없다. 해당 test 수치를 보기 전에 문서로 고정한 규칙들은 다음과 같다. **PR1** 헤드라인 비교 대상은 PCHIP(과도 현상에서의 단조성·무진동을 근거로 사전 선택; 사다리 전체도 함께 보고); **PR2** 보간은 모델이 채점되는 모든 곳에서 예측하며, 미래 이웃이 없으면 persistence로 후퇴하고 그 후퇴 비율을 보고한다(채점된 T_i 행의 0.3–0.4%, 그러나 **채점된 V_{rot} 행의 40–44%**이므로 V_{rot}의 "PCHIP 대비"는 5분의 2가 "persistence 대비"다); **PR3**

test 셋 최소 규모(≥15 shot, ≥3,000 관측 T_i 샘플; 전부 충족); **PR4** 유의성은 skill에 대한 shot 군집 bootstrap 95% CI가 0을 제외하는 것으로 정의. 확정된 프로토콜은 여기에 다음을 더한다: 유지값 제거 학습·채점; 24-run 스윕의 plateau 최소 규칙에 따른 W=2(§6.14); 윈도 계열의 파일당 샘플 상한 500; §3.5의 두 공동 1차 모집단; 그리고 백본 관문, 단 하나의 어텐션 후보, 해석 가능한 사다리 칸, 폭 스윕에 대해 *TEST 채점 이전에 확정한 모델 결정 규칙*(§6.3). 임계값 민감도(2.5/3/4 keV)도 보고한다.

Shot 군집 paired bootstrap. 한 방전 내 인접 CES 행은 강하게 상관된다. 샘플을 독립으로 취급하면 불확실성이 크게 과소평가된다. 샘플별 짝지은 오차 $\mathrm{SE}_{\mathrm{model}} - \mathrm{SE}_{\mathrm{PCHIP}}$를 shot 단위로 집계하고, shot 전체를 복원추출로 재표본한다(10,000회, 고정 시드). 얻어진 CI는 진짜 shot 간 일반화를 반영한다. 대가는 유효 표본 크기가 shot 수(T_i는 ≈96, V_{rot}은 60–66)가 된다는 것이며, 이것이 전체 검정력을 제한한다. 모델 대 모델 비교(백본 대 대조군, 사다리 칸 대 백본)도 같은 행 위에서 같은 paired bootstrap을 사용한다.

네 분할 너머의 재현. 통과한 분할의 수는 검정이 아니며(우연만으로 4/4가 나올 확률은 1/16), 네 동결 분할은 TRAIN 방전 대부분을 공유하므로 그 위의 구간은 너무 좁다. 그래서 사전등록된 두 재현이 백본을 639개 방전 전체의 shot 단위 반복 5겹 교차검증으로 다시 돌렸다(겹마다 TEST 128·VAL 128·TRAIN 383 방전, 반복마다 모든 방전이 한 번씩 TEST, 반복 10회 가운데 8회는 합산 판독 규칙을 등록한 뒤 실행, 총 100회 GPU 실행, 헤드라인과 같은 환경). 판독 두 가지를 수치 이전에 등록했다. (i) *겹 수준*: 겹 skill 평균에 Nadeau–Bengio 겹침 보정 t-구간 $\bar{S} \pm t_{0.975,\,n-1}\sqrt{(1/n + n_{\mathrm{test}}/n_{\mathrm{train}})\,s^2}$을 씌운다[57]. $n_{\mathrm{test}}/n_{\mathrm{train}} = 0.33$에서 보통 구간보다 약 2× 넓고, 겹을 늘려도 0으로 줄지 않는다[58]. (ii) *합산*: 한 반복의 TEST 다섯 겹을 이어 붙여 모든 방전을 하나의 비율 skill로 한 번에 채점하고, 반복 하나를 먼저 뽑고(학습 분할 변동) 그 반복의 방전을 다시 뽑는(shot 변동) 두 단계 bootstrap—학습 반복을 바깥 수준으로 둔 Saravanan et al. [59]·Ren et al. [60]의 계층 bootstrap이고, 구조는 Multi-Bootstrap [61]과 십년 규모 예측의 skill 점수 bootstrap [62]의 것이며, 표준 조각의 결합이지 새것으로 주장하지 않는다—의 2.5 백분위수가 0을 넘으면 *통과*로 본다. 반복과 방전은 교차 요인으로 재표집된다(모든 방전이 모든 반복에서 채점된다). 교차 배열의 bootstrap은 정확하지 않고 그 분산 추정은 편향되며 [80] 편향의 방향은 과대추정이므로 [81] 구간은 보수적이다. T_i에서는 둘이 소수 둘째 자리까지 일치한다. 약 80개 방전짜리 겹의 점수가 큰 오차 방전 몇 개에 좌우되는 V_{rot}(겹 간 표준편차 0.18)에서는 겹 수준 구간이 0을 걸치고 합산 구간은 걸치지 않는다. 등록은 규칙을 적은 뒤에 돌린 반복 8회의 합산 두 단계 판독을 재현의 판정 기준으로 지명했고, 표 6는 둘 다 보고한다.

MNAR 문제와 그에 대한 우리의 대응. 진짜 결측 시점에는 참값이 없으므로 skill은 *관측된* 시점을 가려 측정한다. CES 결측은 MNAR이므로(저신호, ELM, 천이에서 탈락) 관측 시점 skill은 진짜 결측 시점 성능의 낙관적 추정이다. §6.5에서 채점된 지점들을 *실제로 결측인* 지점들의 공변량 분포 위로 재가중하여 skill이 얼마나 살아남는지를 보고하고, 아울러 결측 모집단 중 애초에 이 분석의 도메인 안에 있는 비율도 함께 보고한다.

6 결과

6.1 나우캐스터는 모든 인과 기준선 가운데 RMSE가 가장 낮다

표 4는 표준 test 분할에서의 물리 단위 RMSE 사다리를 보여준다. `seq_v2`는 미래를 읽지 않는 모든 방법 가운데 두 타겟 모두에서 최저 RMSE를 가지며, 배치 가능한 가장 강한 팔인 인과 GP보다 RMSE가 4%(T_i)와 18%(V_{rot}) 낮고, 미래를 쓰는 보간들보다도 낮다. T_i RMSE가 더 낮은 유일한 팔은 잡음 앵커를 통과하는 대신 평균해 내는 오프라인 GP다(T_i 153.8 대 157.8; 짝지은 skill $-0.05 \sim +0.11$, 8셀 중 7셀에서 CI가 0을 포함, §6.2). 이는 본 논문에서 가장 강건한 결과다: 미래 CES가 정의상 없는 모든 온라인 환경에서 시퀀스 나우캐스터의 오차가 가장 낮다.

표 4. 물리 단위 RMSE 사다리. 표준 held-out test 분할(시드 42), 컷 모집단, 진짜 측정만(n = 32,589 T_i, 10,463 $V_{\rm rot}$). 낮을수록 좋다. 아래쪽 세 행은 미래를 읽는다. 포함 모집단에서는 `seq_v2` 363.0 / 23.7, PCHIP 412.4 / 30.2, 인과 GP 394.6 / 28.8, persistence 478.0 / 33.4(T_i / $V_{\rm rot}$)로, 피팅 실패 스파이크가 모든 T_i RMSE를 두 배 이상으로 키우지만 순서는 바꾸지 않는다.

팔	정보 접근	T_i RMSE (eV)	$V_{\rm rot}$ RMSE (km/s)
`seq_v2` (나우캐스터)	고속 진단 + 과거 CES, 세그먼트 전체	**157.8**	**23.6**
윈도 대조군 (W=2)	고속 진단 + 과거 CES 2행	169.2	26.1
인과 GP	과거 CES 이웃 16개	164.3	28.8
Persistence	마지막 관측 CES	197.2	33.4
AR (국소, 인과)	과거 CES만	472.2	51.0
GP (오프라인)	과거 + 미래 CES	153.8	24.7
선형 보간	과거 + 미래 CES	169.8	29.0
PCHIP 보간	과거 + 미래 CES	173.6	30.2

표 5. `seq_v2`의 held-out test skill$_{\rm PCHIP}$와 shot 군집 95% CI(10,000회 재표본), 두 모집단. 마지막 열은 같은 행 위에서 인과 GP에 대해 짝지은 skill이다. 굵은 글씨 = PASS(CI가 0을 제외).

타겟	분할	컷: skill$_{\rm PCHIP}$ (95% CI)	포함: skill$_{\rm PCHIP}$ (95% CI)	인과 GP 대비 (컷 / 포함)
T_i	42	+**0.174** [+0.097, +0.236]	+**0.225** [+0.109, +0.293]	+**0.078** / +**0.154**
	1	+**0.248** [+0.188, +0.295]	+**0.238** [+0.153, +0.302]	+**0.133** / +**0.169**
	7	+**0.257** [+0.199, +0.302]	+**0.292** [+0.232, +0.344]	+**0.138** / +**0.123**
	123	+**0.264** [+0.188, +0.320]	+**0.316** [+0.186, +0.392]	+**0.105** / +**0.149**
$V_{\rm rot}$	42	+**0.390** [+0.077, +0.591]	+**0.384** [+0.066, +0.586]	+**0.331** / +**0.324**
	1	+0.183 [−0.028, +0.280]	+**0.195** [+0.000, +0.286]	+0.130 / +**0.143**
	7	+0.135 [−0.358, +0.269]	+0.132 [−0.362, +0.266]	+0.020 / +0.018
	123	+0.305 [−0.049, +0.437]	+0.304 [−0.065, +0.433]	+**0.134** / +0.132

6.2 헤드라인: T_i의 미래를 쓰는 보간 대비 skill은 두 모집단 모두에서 4개 독립 분할에 걸쳐 CI가 0을 제외한다

표 5은 두 공동 1차 모집단에서 4개 독립 held-out 분할(시드 42, 1, 7, 123 — 뒤의 셋은 어떤 선택 단계에도 쓰이지 않았다)에 대한 백본의 성능을 PCHIP 대비와 인과 GP 대비로 보고한다. 그림 5는 PCHIP 대비 신뢰구간을 보여준다.

- T_i: **두 모집단 모두에서 4개 분할 전부 PASS.** skill$_{\rm PCHIP}$는 컷에서 +0.17 ∼ +0.26, 포함에서 +0.23 ∼ +0.32이며 모든 shot 군집 CI가 0을 제외한다. 8개 모집단–분할 셀 전부에서 *인과* GP 대비(+0.08 ∼ +0.17)와 persistence 대비(+0.36 ∼ +0.46) skill도 CI가 0을 넘는다. 이것이 본 논문의 무조건적 주장이다. 오프라인 GP를 상대로는 백본의 짝지은 skill이 −0.05 ∼ +0.11로 8개 중 7개 셀에서 CI가 0을 포함하므로, 관측 모집단에 대한 주장은 "사전등록된 보간들과 배치 가능한 모든 인과 방법 대비 skill이 0을 넘고, 미래를 쓰며 표본별로 튜닝된 평활기 대비로는 구간이 0을 포함한다"로 읽힌다. 재현(표 6)은 모든 판정을 재현한다: PCHIP 대비 겹 수준 겹침 보정 구간 [+0.19, +0.25](컷)·[+0.19, +0.31](포함), 합산 두 단계 구간 [+0.19, +0.25]·[+0.19, +0.29], 그리고 100개 겹 중 96개가 단독으로 통과한다.
- $V_{\rm rot}$: **네 분할 셈에서는 구간이 0을 포함, 재현에서는 등록된 구간이 0을 제외.** 두 모집단 모두에서 점추정은 모든 분할에서 양수지만, PR4를 통과하는 것은 1/4(컷)과 2/4(포함)이다—둘 다 시드 42, 그리고 포함 모집단의 시드 1이 [+0.000, +0.286]이다. persistence 대비로는 두 모집단 모두 3/4 분할에서 통과하고 (+0.30 ∼ +0.50; 시드 7의 CI는 0에 닿는다) 인과 GP 대비로는 2/4다. 4개 중 1–2개 유의는 잡음이 만들어 낼 수 있는 수준이므로 네 분할 셈만으로는 회전의 주장을 세울 수 없다. 재현의 새 분할 8벌에서 방전 단위로 채점하면 등록된 두 단계 bootstrap 아래 $V_{\rm rot}$의 skill은 PCHIP 대비 [+0.07, +0.70](컷)·[+0.05, +0.68](포함), persistence 대비 [+0.28, +0.76]·[+0.14, +0.75], 인과 GP 대비 [+0.05, +0.70]·[+0.02, +0.68]로 모든

표 6. 헤드라인의 사전등록 재현: shot 단위 반복 5겹 교차검증(반복 10회, 반복마다 모든 방전이 한 번씩 TEST, 100회 실행). 겹 수준: 50개 겹 skill 평균의 Nadeau–Bengio 겹침 보정 95% t-구간과, 자체 shot 군집 CI가 0을 제외하는 겹의 수. 합산: 규칙을 등록한 뒤 돌린 반복 8회에 대해, 반복별 합산 skill의 두 단계(반복, 그다음 그 반복의 방전) bootstrap 95% 구간. 굵은 글씨 = 구간이 0을 제외.

타겟	대비	컷: 겹 수준 (통과)	컷: 합산	포함: 겹 수준 (통과)	포함: 합산
T_i	PCHIP	$[+\mathbf{0.186}, +\mathbf{0.253}]$ (50/50)	$[+\mathbf{0.188}, +\mathbf{0.248}]$	$[+\mathbf{0.188}, +\mathbf{0.307}]$ (46/50)	$[+\mathbf{0.192}, +\mathbf{0.294}]$
	persistence	$[+\mathbf{0.368}, +\mathbf{0.410}]$ (50/50)	$[+\mathbf{0.369}, +\mathbf{0.408}]$	$[+\mathbf{0.361}, +\mathbf{0.445}]$ (50/50)	$[+\mathbf{0.364}, +\mathbf{0.438}]$
	인과 GP	$[+\mathbf{0.084}, +\mathbf{0.138}]$ (47/50)	$[+\mathbf{0.085}, +\mathbf{0.132}]$	$[+\mathbf{0.067}, +\mathbf{0.170}]$ (40/50)	$[+\mathbf{0.076}, +\mathbf{0.157}]$
	오프라인 GP	$[-0.044, +0.020]$ (1/50)	$[-0.043, +0.014]$	$[-0.026, +0.094]$ (12/50)	$[-0.017, +0.075]$
V_{rot}	PCHIP	$[-0.021, +0.405]$ (15/50)	$[+\mathbf{0.072}, +\mathbf{0.701}]$	$[-0.053, +0.391]$ (11/50)	$[+\mathbf{0.046}, +\mathbf{0.683}]$
	persistence	$[+\mathbf{0.190}, +\mathbf{0.601}]$ (42/50)	$[+\mathbf{0.277}, +\mathbf{0.763}]$	$[+\mathbf{0.159}, +\mathbf{0.587}]$ (38/50)	$[+\mathbf{0.139}, +\mathbf{0.747}]$
	인과 GP	$[-0.060, +0.512]$ (11/50)	$[+\mathbf{0.045}, +\mathbf{0.701}]$	$[-0.096, +0.502]$ (10/50)	$[+\mathbf{0.023}, +\mathbf{0.683}]$
	오프라인 GP	$[-0.234, +0.312]$ (0/50)	$[-0.119, +0.635]$	$[-0.268, +0.300]$ (0/50)	$[-0.139, +0.609]$

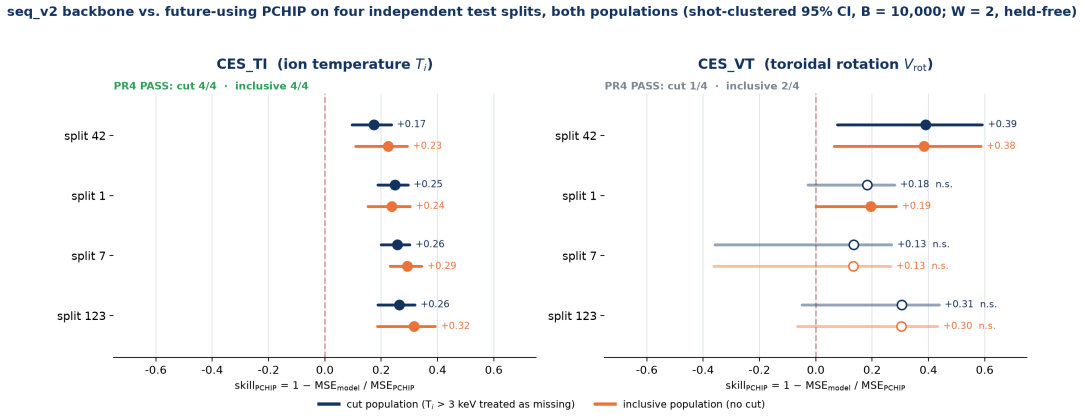


그림 5. 두 모집단, 4개 독립 held-out 분할에 걸친 `seq_v2`의 skill$_{\text{PCHIP}}$와 shot 군집 95% CI의 forest plot. T_i는 8개 셀 전부에서, V_{rot}은 3개 셀에서 0을 제외한다.

구간이 0을 제외하고, 새 모델 8벌이 전부 양수다(PCHIP 대비 컷 $+0.28 \sim +0.59$, 포함 $+0.09 \sim +0.56$). 겹 수준 겹침 보정 구간은 여전히 0을 걸치는데(컷 $[-0.02, +0.41]$), 80개 방전짜리 겹의 비율이 큰 오차 방전 몇 개에 좌우되기 때문이다. 이 효과는 평균 제곱 오차의, 꼬리가 실어 나르는 효과이며(§6.10), 중앙값에서 V_{rot}의 persistence 대비 오차 비는 0.94–1.00으로 3/4 분할에서 구간이 1을 포함한다—10 ms 광자 바닥이다(§6.11). 두 진술을 함께 적는다.

– **왜 포함 모집단의 수치가 더 높은가.** 컷이 없으면 모든 팔이 PCHIP을 상대로 *더 좋은* 점수를 받는다(백본 평균 +0.268 대 +0.236, 대조군 +0.238 대 +0.173). 스파이크가 보간 앵커를 오염시키기 때문이다: 학습된 모델은 스파이크가 낀 이웃값을 할인할 수 있지만 보간은 그럴 수 없다. §6.7이 이 성분을 정량화하며, 이것이 어느 한 모집단만 인용하지 않는 이유다.

6.3 전체격자 프레이밍 대 윈도 대조군: 백본 관문

시퀀스 프레이밍은 사전등록된 네 조건 관문 아래에서 채택되었다. 관문은 컷 모집단에서 분할 시드 × 초기화 시드의 4 × 4 격자로 한 번만 채점하였고, 각 실행을 해당 분할의 W=2 윈도 대조군과 행 단위로 짝지었다. 짝지은 T_i skill은 **16/16 실행**에서 양수이고(13/16에서 CI가 0 위), 통합 평균은 $+\mathbf{0.081}$, 실행 군집 95% CI는 $[+0.067, +0.096]$으로 0을 제외한다. 예산을 균등화한 팔(고정 10 epoch, 최종 가중치, 검증 선택 없음)은 4/4 분할에서 부호를 유지하고($+0.063$, $+0.033$, $+0.045$, $+0.030$) 어떤 실행에도 유의한 V_{rot} 열세가 없으므로 네 조건이 모두 성립한다. 이 프레이밍이 사는 것은 도달 범위다: 윈도 대조군의 인과 GP 대비 skill은 +0.041로 3/4 분할에서 CI가 0을 포함하고(컷), 백본은 $+0.08 \sim +0.17$로 두 모집단 모두 4/4에서 CI가 0 위다. 모든 모델 결정은 검증 데이터 위에서, 또는 해당 TEST 채점 이전에 문서로 확정한 규칙 아래에서 이루어졌고,

표 7. 간극 계층별 skill. 4개 test 분할 통합, shot 군집 95% CI, `seq_v2`. 굵은 글씨 = CI가 0을 제외. 샘플이 50개 미만인 행은 채점하지 않는다.

Δt	n (컷 / 포함)	shot 수	컷: PCHIP 대비	포함: PCHIP 대비
T_i				
≤ 15 ms	134,546 / 135,317	301	**+0.239** [+0.197, +0.274]	**+0.299** [+0.244, +0.347]
> 15 ms	3,422 / 3,334	265 / 263	**+0.268** [+0.187, +0.337]	**+0.206** [+0.108, +0.290]
> 45 ms	460 / 429	104 / 101	**+0.267** [+0.092, +0.414]	−0.004 [−0.304, +0.246]
V_{rot}				
≤ 15 ms	51,689	197	**+0.233** [+0.020, +0.318]	**+0.233** [+0.020, +0.317]
> 15 ms	466 / 456	130	**+0.418** [+0.104, +0.680]	**+0.432** [+0.128, +0.696]
> 45 ms	14	7	—	—

TEST는 결정마다 한 번만 채점되었다. 같은 규칙 아래에서 이후 탐색된 단 하나의 아키텍처 후보—각 타겟 자신의 과거 관측 스텝에 대한 관측 마스킹 인과 어텐션을 `seq_v2`에 추가한 것—의 백본 대비 짝지은 T_i skill은 +0.009, +0.013, +0.033, +0.020으로 1/4 분할에서 CI가 0 위이며, 사전 확정 기준은 $\geq 3/4$이므로 승격되지 않았다.

6.4 skill이 사는 곳: 간극 영역

마지막 관측 CES로부터의 경과시간 Δt로 계층화하면, 채점 타겟의 ≥96%가 인접 영역($\Delta t \leq 15$ ms)에 있다. 분할별로는 넓은 구간에 수백 개 샘플밖에 없으므로 *4개 test 분할을 통합*하고 bootstrap을 물리적 방전 단위로 군집한다(표 7). Δt가 커질수록 PCHIP의 과제는 *쉬워지고*(간극을 사이에 둔 두 실제 관측을 보간한다) 우리 과제는 어려워지므로, 이 영역은 인과 방법이 이길 것으로 기대하기 가장 어려운 곳이다.

T_i의 skill은 인접 이력에 국한되지 않는다. 15 ms를 넘어서도 백본의 미래를 쓰는 PCHIP 대비 skill은 두 모집단에서 +0.268과 +0.206이고(두 CI 모두 0 위), 거기서 persistence 대비 skill은 +0.40과 +0.43이다(CI [+0.34, +0.45], [+0.35, +0.52]). 45 ms를 넘어서면 PCHIP 대비 skill은 컷에서 +0.267 [+0.09, +0.41], 포함 모집단에서 −0.004(CI [−0.30, +0.25])다: 101개 shot의 429행은 소수의 스파이크 앵커 행이 한 계층을 지배할 수 있는 바로 그 지점이며, 우리는 이 0을 포함하는 구간을 그대로 보고한다.

V_{rot}의 보간 대비 skill은 보간에게 가장 어려운 그 한 곳에서 0을 제외한다. 0을 포함하는 전역 V_{rot} 구간은 인접 영역의 것이다. $\Delta t > 15$ ms에서는 백본의 PCHIP 대비 skill이 두 모집단에서 +0.418 [+0.10, +0.68]과 +0.432 [+0.13, +0.70]이고(130개 shot) — 본 논문에서 유일하게 0을 제외하는 무조건적 V_{rot} 구간이다 — ≤ 15 ms에서는 persistence 대비 skill이 +0.39 [+0.21, +0.45]다. 가장 넓은 구간은 14행뿐이라 채점하지 않는다.

6.5 실제로 결측인 지점에서는 이 중 얼마가 살아남는가?

지금까지의 모든 것은 마침 *관측된* CES 지점에서 측정된 것이다. 참값이 없는 곳에서 오차를 측정할 수는 없다. 그러나 관측 행과 결측 행 *모두*에서 계산 가능한 공변량 위에서 skill이 어떻게 변하는지는 측정할 수 있고, 재가중할 수 있다. 기전을 담는 공변량은 둘이다: 마지막 진짜 관측으로부터의 Δt(15/25/45 ms로 구간화)와 §6.9의 입력 전용 국소 활동 플래그다. 후자는 자기 행을 제외한 이웃 집합으로 계산되므로 결측 행에서도 정의된다. $\Delta t\times$ 활동으로 사후 계층화하고, 채점 샘플이 30개 미만인 계층은 버리며, 모든 추정치 옆에 살아남은 커버리지를 함께 보고한다. 가중 격자는 모집단과 일관되게 만든다(컷은 여기에도 적용한다). 한 계층 안에서 결측 행과 관측 행이 교환 가능하다는 가정은 없앤 척하지 않고 명시한다.

먼저, 적용 범위에 관한 결과. 이 분석의 도메인은 "해당 타겟의 진짜 관측이 두 행 이내에 있음"이라는 W=2 기준이다. 진짜 결측인 T_i 행 가운데 분할별로 **54–68%가 도메인 안**이고, 진짜 결측인 V_{rot} 행 가운데는 **4–6%뿐**이다. V_{rot} 간극이 긴 블록이기 때문이다(살아남은 계층의 커버리지는 T_i 0.99, V_{rot} 0.73–0.76).

표 8. 관측 모집단에서 진짜 결측이면서 도메인 안인 모집단으로 재가중한 `seq_v2`의 T_i skill(계층 가중치를 고정한 shot 군집 95% CI). 굵은 글씨 = CI가 0을 제외. *무가중*은 표 5의 헤드라인이다.

		PCHIP 대비		persistence 대비	
모집단	분할	무가중	결측 정합 (95% CI)	무가중	결측 정합 (95% CI)
컷	42	+0.174	+0.140 [−0.071, +0.290]	+0.360	**+0.398** [+0.278, +0.518]
	1	+0.248	**+0.164** [+0.062, +0.250]	+0.406	**+0.366** [+0.299, +0.448]
	7	+0.257	+0.203 [−0.024, +0.346]	+0.403	**+0.310** [+0.227, +0.398]
	123	+0.264	**+0.283** [+0.069, +0.392]	+0.415	**+0.381** [+0.246, +0.464]
포함	42	+0.225	**+0.140** [+0.033, +0.250]	+0.423	**+0.443** [+0.141, +0.623]
	1	+0.238	**+0.217** [+0.086, +0.319]	+0.436	**+0.383** [+0.273, +0.536]
	7	+0.292	**+0.167** [+0.067, +0.265]	+0.406	**+0.283** [+0.172, +0.380]
	123	+0.316	**+0.221** [+0.050, +0.320]	+0.459	**+0.337** [+0.164, +0.455]

표 9. 시간(캠페인) 분할, 4개 초기화, 뒤쪽 방전 97개로 이루어진 TEST 블록. 항목은 $\text{skill}_{\text{PCHIP}}$이며 **굵은 글씨** = PR4 PASS. 마지막 열은 같은 행 위에서 윈도 대조군에 대한 `seq_v2`의 짝지은 T_i skill이다.

모집단	팔	T_i PCHIP 대비 (초기화 42 / 1 / 7 / 123)	PASS	T_i 인과 GP 대비	`seq_v2` − 대조군
컷	윈도 대조군 (OFF)	+0.027 / **+0.091** / −0.001 / **+0.061**	2/4	0/4	—
	대조군, shot별 표준화 (ON)	**+0.103** / **+0.107** / **+0.094** / **+0.107**	4/4	—	—
	`seq_v2`	**+0.187** / **+0.174** / **+0.181** / **+0.177**	4/4	4/4 (+0.11 ∼ +0.12)	**+0.164** / **+0.091** / **+0.182** / **+0.124**
포함	윈도 대조군 (OFF)	+0.014 / +0.047 / +0.055 / +0.089	0/4	0/4	—
	`seq_v2`	**+0.173** / **+0.202** / **+0.198** / **+0.184**	4/4	4/4 (+0.13 ∼ +0.16)	**+0.161** / **+0.163** / **+0.151** / **+0.104**

따라서 재가중된 V_{rot} 행은 결측 질량의 20분의 1에 대한 질문에 답하는 것이며, 우리는 거기서 아무것도 끌어내지 않는다.

둘째, 두 비교가 갈라지며 — 그 갈라짐 자체가 쓸모 있는 것이다. persistence — 온라인 시스템이 실제로 돌리는 기준선 — 를 상대로는 T_i skill이 두 모집단 모두에서 4개 분할 전부 재가중을 견딘다(+0.28 ∼ +0.44, 모든 CI가 0을 제외). MNAR 보정이 앗아가는 skill은 많아야 0.12이고 어떤 분할에서는 전혀 없다. **미래를 쓰는 PCHIP**을 상대로는 재가중된 점추정이 +0.14 ∼ +0.28에 머물지만, 고정 가중치의 넓은 CI가 컷 모집단 2개 분할에서 0을 지난다(2/4 유의; 포함 모집단은 4/4). 결측 지점은 더 큰 Δt에 놓이는데, 그곳이 바로 양쪽 앵커가 가장 크게 도움이 되고 재가중 bootstrap이 가장 얇은 곳이다. 따라서 정말 중요한 지점들에서 증거가 지지하는 주장은 다음과 같다: *진짜 결측이면서 도메인 안인 시점에서 나우캐스터는 두 모집단 모두에서 CES 단독의 어떤 인과 방법보다 유의하게 낮고, 오프라인 보간보다는 모집단 조건부 유의성(컷 2/4, 포함 4/4)으로 낮다.* 윈도 대조군도 같은 방식으로 거동한다 (PCHIP 대비 2/4와 4/4, persistence 대비 4/4).

6.6 캠페인 이동을 견디는가?

무작위 분할이 하지 않지만 실제 배치가 하는 두 번째 일은 시간상 앞으로 나아가는 것이다. 641개 방전 전부를 shot 번호(30801–32751)로 정렬하고 시간으로 엄격히 잘랐다: **train 416 shot [30801, 31991], val 128 [32002, 32310], test 97 [32312, 32751]**이며 어떤 test shot도 어떤 train shot보다 앞서지 않는다. 나머지는 전부 헤드라인 프로토콜에 고정되어 바뀐 변수는 분할 규칙 하나뿐이다. 분할이 고정되어 있으므로 네 번의 실행은 *초기화* 시드만 달리하며, 이를 4개 분할인 것처럼 제시하지 않고 그대로 밝힌다. 모집단마다 세 개의 팔을 둔다: 헤드라인에서 학습된 그대로의 윈도 대조군(학습 파일 전용 정규화), 고속 진단을 shot별로 표준화한 같은 대조군(컷 모집단), 그리고 `seq_v2`이다(표 9).

이 표에서 명시할 만한 것이 셋 있다. 첫째, *윈도* 모델의 오프라인 보간 대비 skill은 이동을 견디지 못한다: −0.001 ∼ +0.091로 CI가 0을 넘는 초기화는 2/4(컷)와 0/4(포함)이며, 인과 GP 대비로는 0/4다. 둘째, 이름이 지목되었던 그 수리가 작동한다: 각 방전의 고속 진단을 *그 방전 자신의* 평균·분산으로 적재 시점에 표준화하면(타겟은 손대지 않는다) 컷 모집단의 관문이 2/4에서 4/4로 올라가고 짝지은 값은 +0.078, +0.018,

표 10. W=2 윈도 대조군의 평가 시점 모달리티 절제, TEST, 두 모집단: $\text{skill}_{\text{PCHIP}}$(4개 분할 평균)와 절제하지 않은 실행에 대한 짝지은 변화 (분할 42 / 1 / 7 / 123; * = 유의하게 악화).

입력	타겟	컷	포함
전체 (이력 + 고속 + 시간)	T_i	+0.173	+0.238
이력 + 시간만 (*고속 없음*)	T_i	−0.125; 짝지은 −0.25* / −0.38* / −0.42* / −0.43*	+0.201; 짝지은 −0.03* / −0.04 / −0.03 / −0.09*
고속 + 시간만 (*이력 없음*)	T_i	−2.11; 짝지은 −4.6* / −1.8* / −2.3* / −1.9*	−1.16; 짝지은 −1.5* / −3.4* / −1.2* / −1.1*
전체	V_{rot}	+0.213	+0.206
이력 + 시간만 (*고속 없음*)	V_{rot}	+0.213; 짝지은 +0.000 ×4 (**비트 동일**)	+0.206; 짝지은 +0.000 ×4 (**비트 동일**)
고속 + 시간만 (*이력 없음*)	V_{rot}	−2.89; 짝지은 −5.4* / −6.3* / −1.8* / −2.3*	−3.51; 짝지은 −6.9* / −7.8* / −1.9* / −2.2*

+0.095, +0.049(3/4 유의)이며 V_{rot}은 변하지 않는다(−0.003 ∼ +0.008) —V_{rot} 헤드가 고속 진단을 애초에 보지 않으므로 기대되는 음성 대조다. 셋째, 그리고 이것이 이 절의 결과다: **시퀀스 나우캐스터는 붕괴하지 않는다**. PCHIP 대비 skill은 +0.17 ∼ +0.20으로 두 모집단 모두 4/4 초기화에서 CI가 0을 넘고, 인과 GP 대비 skill은 +0.11 ∼ +0.16(두 모집단 모두 4/4에서 CI가 0을 넘음), 윈도 대조군 대비 짝지은 skill은 +0.09 ∼ +0.18(8/8에서 CI가 0을 넘음)이다. V_{rot}의 persistence 대비 skill은 +0.31 ∼ +0.34로 두 모집단 모두 4/4에서 CI가 0을 넘는데, 윈도 대조군의 구간은 4/4에서 0을 포함한다. 대조군 대비 V_{rot} 마진은 +0.06 ∼ +0.18로 8/8에서 CI가 0을 넘는다.

대조군이 왜 나빠지는가 — 단언이 아니라 측정. train 기간과 test 기간 사이에서, 대조군이 정규화된 단위로 잰 위치 이동의 중앙값은 **BES가 1.22 σ**, **ECEI가 0.53 σ**이고(척도 비 0.75와 0.62) CES 타겟은 **0.115 σ**(척도 비 1.06)로 드리프트가 5–11× 크다. 따라서 학습 파일 전용 정규화는 캠페인 경계를 넘어 전이되지 않고, `seq_v2`가 정의상 쓰며 그 방전 자신의 데이터만 읽는 shot별 표준화는 전이된다.

두 개의 스트레스 테스트, 하나의 독법. 실시간 시스템이 실제로 돌릴 수 있는 기준선들에 대한 skill은 두 모집단 모두에서 두 스트레스 테스트를 CI가 0을 넘는 채로 견딘다(재가중에서 persistence 대비 +0.28 ∼ +0.44, 캠페인 분할에서 인과 GP 대비 +0.11 ∼ +0.16). *미래를 쓰는* 보간에 대한 skill은 두 모집단 모두에서 시간 이동을 견디고(+0.17 ∼ +0.20, CI가 0을 넘음), MNAR 재가중은 모집단 조건부 유의성으로 견딘다 (+0.14 ∼ +0.28, 컷 2/4·포함 4/4에서 CI가 0을 넘음).

6.7 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭

윈도 대조군에 대한 통제된 입력 모달리티 절제—한 모달리티 그룹을 *평가 시점에* 0으로 만들고, 재학습은 하지 않으며, persistence와 보간은 실제 이력에서 계산—는 두 타겟이 왜 다르게 거동하는지를 설명하고 §4의 라우팅을 확정된 프로토콜 아래에서 다시 근거 짓는다(표 10).

- **이력은 두 타겟 모두에 필수불가결하다.** CES 이력이 없으면 윈도 모델은 두 모집단의 두 타겟 모두에서 PCHIP 대비 −1에서 −4까지 떨어진다: 자기 앵커 없이 100 Hz 진단만으로 예측 가능한 타겟은 없다.
- T_i: **보간 대비 마진은 고속 진단 정보다 — 컷 모집단에서.** BES/ECEI/MC를 0으로 만들면 대조군은 보간기 *아래로* 떨어진다(−0.10 ∼ −0.18; 짝지은 변화 −0.25 ∼ −0.43, 4/4 유의). 물리 채널은 충돌성 전자–이온 결합이며($t_{ei} \propto T_e^{3/2}/n_e$), ECEI가 T_e를, BES가 n_e 구조를 공급한다.
- **포함 모집단에서는 같은 이력 전용 모델의 PCHIP 대비 skill이 여전히** +0.15 ∼ +0.23**이며**, 고속 채널이 더하는 것은 0.03–0.09뿐이다 (2/4 유의). 보간기의 앵커에 스파이크가 끼어 있고, 학습된 모델은 보간이 할 수 없는 방식으로 그것을 할인하기 때문이다. 따라서 스파이크 포함 마진에는 고속 진단 정보가 아닌 *스파이크 강건성* 성분이 들어 있으며, 이것이 본 논문이 더 좋아 보이는 한쪽이 아니라 두 모집단을 보고하는 측정된 이유다. 고속 진단의 기여를 분리해 내는 쪽은 컷 모집단이다.
- V_{rot}: **정보는 전적으로 CES 이력이며, 구조적으로도 측정으로도 그렇다.** 고속 진단을 0으로 만들어도 V_{rot} 출력은 8/8 모집단–분할 셀에서 *비트 단위로 동일*하고(라우팅이 구조적이다), `seq_v2`와 `b3k8`의 V_{rot} 분기도 같은 교란 시험을 통과한다. 토로이달 회전은 우리 입력 중 어느 것도 관측하지 않는 운동량 원천—외부 NBI 토크와 고유 회전 구동 [82]—이 지배하며, Mirnov 신호는 100 Hz로 샘플되어 회전의 대리가 될 수 있었을 kHz 모드 회전 주파수를 앨리어싱으로 잃는다(§7).

이 비대칭은 절제 실험 이전에 물리로부터 예측되었고 절제로 확인되었다. V_{rot}의 영결과는 모델의 실패가 아니라 진단 정보량에 관한 발견이며, §4의 타겟별 라우팅을 정당화한다. 이 진술에는 범위가 있다: 표준 CES 10 ms 격자, 코어에서 페데스탈 상단까지, NBI 토크 미관측 조건에서 성립한다. 가장자리 E_r와 가장자리 회전은 ELM 주기 안에서 밀리초 이하 분해능으로 움직인다고 알려져 있고 [83, 84], 10 ms 단일 시선 노출은 그것을 분해하지 못하므로, 여기의 어떤 결과도 ELM 주기 안의 가장자리에 대해 말하지 않는다.

6.8 복잡도는 무엇을 사고, 크기는 도움이 되는가? 사다리와 폭 스윕

모델 크기 축과 모델군 축은 닫혔다. 각각 같은 프로토콜 아래에서, TEST 채점 이전에 고정한 결정 규칙으로 측정되었다. 해석 가능한 사다리 칸 `b3k8`(§4.6; 21,498 파라미터)의 백본 대비 짝지은 T_i skill은 컷 모집단에서 -0.009, -0.005, $+0.026$, -0.004이고(평균 $+0.002$, 모든 CI가 0을 포함) 포함 모집단에서 $-0.16 \sim -0.21$이다(평균 -0.194, 4/4 분할에서 CI가 0 아래). 포함 모집단에서는 유계 보정이 스파이크가 낀 이월값을 복구할 수 없다: persistence 오차가 2 keV를 넘는 행은 포함 모집단 test 행의 0.6–1.3%인데 `b3k8`의 T_i 제곱오차의 73–83%를 담는다(PCHIP을 포함한 다른 모든 팔에서는 70–83%다). `seq_v2`의 T_i 인코더를 24에서 260 유닛으로 넓히면(34k / 49k / 114k / 358k / 879k 파라미터, 26× 범위) T_i skill 평균은 $+0.230$ / $+0.236$ / $+0.235$ / $+0.236$ / $+0.230$(컷)으로 358k 백본 대비 평균 ± 0.008 이내이고, V_{rot}은 변하지 않는다($+0.250 \sim +0.254$). 네 초기화를 평균하면 T_i skill은 짝지은 값으로 컷 모집단에서 $+0.020$(4/4 분할에서 CI가 0 위), 포함 모집단에서 $+0.007$(2/4)만큼 변하며, 이는 사전등록된 0.02 띠의 경계에 있고 그것을 넘지 않는다. 오프라인 모델군 카드(gap-filling, 백본의 양방향판을 상대로 채점)에서 shot 인코딩 신경 과정과 타 장치에서 사전학습한 transformer(그리고 같은 transformer의 무작위 초기화)는 T_i skill을 $-0.094 \sim +0.026$만큼 바꾸고 어느 팔도 두 모집단 모두에서 0.02 띠를 넘지 못하며, 같은 shot의 V_{rot} 라벨이 없으면 모든 팔의 학습 평균 대비 skill은 $-0.003 \sim -0.040$이다.

6.9 skill은 고변동 국소 구간에 집중된다

타겟과 무관한 입력 측 국소 활동 대리 지표(이웃 괄호 기울기가 크거나 국소 CES 이웃 분산이 높음, 타겟 행을 *제외*하고 계산)를 사용해 각 TEST 분할을 "peak"(고활동; 분할당 T_i 4.1–4.6k행, V_{rot} 2.4–2.9k행)와 bulk 행으로 나누고, 각각에서 shot 군집 bootstrap으로 `seq_v2`를 채점한다(그림 6).

- T_i: peak 계층 $\mathrm{skill}_{\mathrm{PCHIP}}$는 컷에서 $+0.45 \sim +0.61$, 포함에서 $+0.62 \sim +0.72$이며, 미래 이웃을 가진 보간기를 상대로 **8/8 PASS**다. bulk는 컷에서 $+0.09 \sim +0.20$(PASS 4/4), 포함에서 $+0.06 \sim +0.19$(PASS 2/4)를 담는다. 매끄러운 bulk에서는 보간이 거의 최적이며, 모델의 가치는 활동 구간에 있다 — 그리고 이 진술은 무조건적이다.
- V_{rot}: peak 계층 skill은 $+0.54 \sim +0.79$(8/8에서 점추정 양수, 각 모집단에서 PASS 2/4, persistence 대비로는 $+0.75 \sim +0.86$에 8/8 PASS)이고 bulk에서는 ≈ 0이다($-0.07 \sim +0.15$, PASS 0/8). 따라서 비대칭은 *지역적*이다: 네 분할 셈으로는 전역 V_{rot} 구간이 3/4·2/4 분할에서 0을 포함하지만(재현의 합산 판독은 뒤에 평균 skill을 0 위에 둔다, §6.2), 매끄러운 과거+미래 보간이 가장 나쁜 고활동 국소 구간에서는 이력 기반 V_{rot} 예측기조차 가치를 더한다. 이를 전역 영가설의 뒤집힘이 아니라 유의성 기반이 얇은 지역적 강점으로 보고한다.

6.10 집계 skill은 꼬리에서 온다: 중앙값 행에서 나우캐스터는 앵커를 그대로 옮긴다

MSE 기반 skill은 제곱오차의 합으로 정해지고 그 합은 소수의 큰 오차가 좌우한다: 백본의 T_i 제곱오차 상위 1% 행이 전체의 48%(컷)와 83%(포함)를 담는다(PCHIP도 51%·87%로 같다). 따라서 "T_i에서 $+0.24$"는 그 자체로 *전형적인* 행에서 모델의 오차가 보간보다 작다는 뜻이 아니다. 이를 가르기 위해 동결된 TEST 산출물을 재학습 없이 세 강건 공동 지표로 다시 채점했다(규칙과 각 결과가 쓰게 될 문장은 채점 전에 고정): 중앙값 절대오차 skill $M_1 = 1 - \mathrm{medAE}_{\mathrm{model}}/\mathrm{medAE}_{\mathrm{PCHIP}}$(shot 군집 가중 중앙값 bootstrap), 타겟의 10 ms 재현성 한계(T_i 129.9 eV, V_{rot} 16.4 km/s)에서 자른 Huber 손실의 skill M_2, 양쪽 1% 절삭 MSE의 skill M_3.

T_i skill은 꼬리에서 온다. PCHIP 대비 M_1은 모집단 × 타겟 × 분할 16개 셀 전부에서 음수이고 전부 유의하다(컷 T_i -0.198, 포함 -0.562). 행의 절반에서 모델의 오차는 PCHIP 이상이며(승률 0.48), 오차

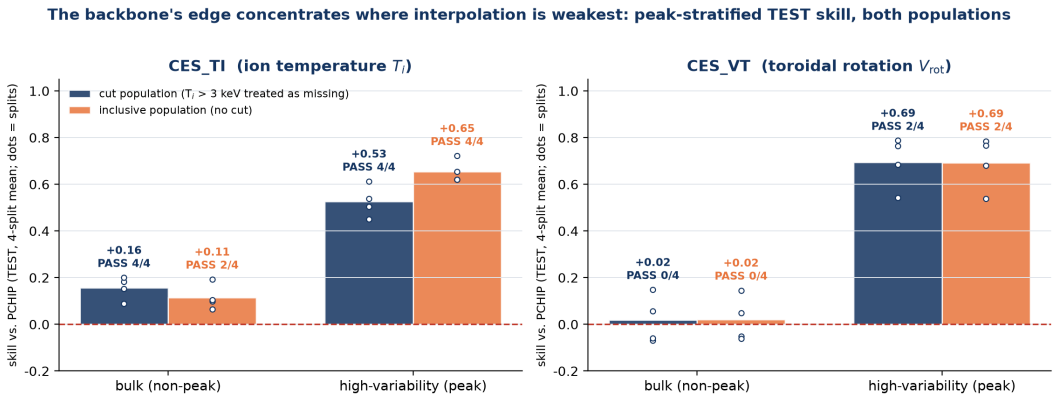


그림 6. `seq_v2`의 peak 계층별 TEST skill, 두 모집단(4개 분할 평균, 분할별 점, PR4 카운트). 보간 대비 skill은 보간이 가장 약한 곳에 집중되며, V_{rot} skill은 전적으로 peak 계층에 산다.

표 11. 전형적인 행의 오차. 4개 test 분할 통합(301개 shot), 컷 모집단, 물리 단위의 절대오차 분위수. M_1은 PCHIP 대비 중앙값 절대오차 skill(shot 군집 95% CI), 승률은 행별로 모델 오차가 PCHIP 오차보다 작은 행의 비율. T_i 백본의 중앙값 47 eV는 타겟 자체의 10 ms 본류 산포(인접 관측 차이의 MAD, 46.4 eV)와 같다. Huber 팔은 §6.10의 마지막 단락이다.

타겟	팔	중앙값	q75	q90	M_1 vs PCHIP	승률
T_i [eV]	`seq_v2` 백본 (MSE 손실)	47.2	101.0	202.4	-0.198 $[-0.259, -0.135]$	0.48
	`seq_v2` Huber 손실	**43.4**	**93.8**	**193.3**	-0.101	
	persistence	46.1	116.6	262.7		
	인과 GP	44.4	106.7	219.8		
	PCHIP (미래 사용)	39.4	105.4	236.6		
V_{rot} [km/s]	`seq_v2` 백본 (MSE 손실)	4.3	10.0	21.4	-0.488 $[-0.604, -0.387]$	0.40
	`seq_v2` Huber 손실	**3.8**	**9.2**	**19.8**	-0.333	
	persistence	3.7	9.3	20.9		
	인과 GP	3.8	9.3	20.0		
	PCHIP (미래 사용)	2.9	7.8	18.3		

비율 모델/PCHIP의 분위수 사다리는 q50에서 1.20, q70에서 1.01, q75에서 0.96, q99에서 0.78로 내려간다 — 오차 비가 1 아래로 내려가는 것은 오차 상위 사분위, 즉 피팅 실패·천이·ELM 행에서 시작한다. 같은 꼬리에서는 $M_2(+0.156$, 유의)와 $M_3(+0.210$, 유의)가 양수이므로 상위 1%만의 효과는 아니다. 중앙값 행의 그림은 더 단순하다: 백본의 47 eV는 persistence의 46 eV이자 타겟 자체의 본류 산포 46.4 eV다. *전형적인 행에서 나우캐스터는 마지막 관측값을 그 잡음째 옮긴다*, 그리고 그 행에서 PCHIP가 20% 더 나은 이유는 미래 이웃과의 평균이 그 잡음을 반으로 줄이기 때문이다 — 어떤 인과 방법도 가질 수 없는 이득이다. 본류 순위(비인과 GP 38.5 < PCHIP 39.4 < 인과 GP 44.4 < persistence 46.1 ≈ 백본 47.2)는 정확히 각 방법이 평균하는 잡음 표본 수의 순위다.

V_{rot}의 미성립은 꼬리 인공물이 아니다. 사전등록은 "집계에서는 동률이지만 중앙값에서는 이긴다"는 결과를 V_{rot}의 구제 경로로 적어 두었다. 그 반대가 관측되었다: $M_1 = -0.488$(컷)·-0.518(포함)로 4/4 분할에서 유의하게 음수이고, 중앙값 행에서는 persistence보다도 나쁘다(4.3 대 3.7 km/s). 0을 포함하는 집계 구간은 본류의 손실을 꼬리의 이득(peak 계층 $+0.54 \sim +0.79$, §6.9)이 상쇄한 결과이며, 이는 §6.7의 항별 감사와 같은 결론이다.

손실의 영향함수가 그 본류를 움직인다. *하나의* 변수 — 학습 손실의 영향함수 — 를 바꾸었고, 잔차의 척도 δ는 타겟 자체의 10 ms 재현성 한계(컷: T_i 129.9 eV, V_{rot} 16.4 km/s; 포함 274.3 eV)에 고정하였다: Huber 손실(안쪽은 r^2, 바깥은 $2\delta|r| - \delta^2$)이며 다른 모든 것은 백본 그대로다. 자기 검증 목적함수로 선택하면 Huber

표 12. 얼린 TEST 행에서의 이중 판독(재학습 없음). 중앙값 추정량: 순수 Student-t 유지-또는-점프 필터. 평균 추정량: 학습 모델(MSE guard가 성립하는 컷에서는 앵커+잔차, 포함에서는 `seq_v2`). M_1은 중앙값 AE skill(shot 군집 짝지은 bootstrap). 개수는 $M_1 \geq +0.05$이고 CI > 0인 분할(백본 대비), 또는 $M_1 > 0$이고 CI > 0인 분할(persistence 대비)이다. 범위는 네 분할에 걸친다.

표적	모집단	중앙값 / persistence	`seq_v2` 대비 M_1	persistence 대비 M_1	`seq_v2` 대비 MSE
T_i	컷	0.911–0.920	+0.06–+0.14, **4/4**	+0.08–+0.09, **4/4**	−0.30–−0.41
	포함	0.906–0.915	+0.22–+0.39, **4/4**	+0.09, **4/4**	−0.35–−0.47
$V_{\rm rot}$	컷	0.939–1.000	+0.09–+0.23, **4/4**	0.00–+0.06, 1/4	−0.06–−0.51
	포함	0.938–1.003	+0.09–+0.27, **4/4**	0.00–+0.06, 1/4	−0.06–−0.52

팔의 MSE 백본 대비 T_i 중앙값 절대오차 skill은 컷 모집단에서 $M_1 = +0.128$ $[+0.114, +0.141]$이고(4/4 분할에서 CI가 0 위) 풀링 MSE 차는 +0.007로 구간이 0을 포함하며(유의 열세 0/4), T_i 중앙값은 persistence의 0.894×다. 포함 모집단에서는 $M_1 = +0.285$ $[+0.250, +0.322]$(4/4)이지만 한 분할에 CI가 0 아래인 T_i MSE 차 −0.040이 남으므로(epoch 상한을 60에서 100으로 올려도 변하지 않는다), 사전등록 규칙에 따라 Huber 팔은 **컷 모집단 조건부 강건 칸**이고 백본의 손실은 MSE로 남는다. 표 11의 Huber 행은 같은 손실을 검증 MSE로 선택한 것으로, 컷 모집단 중앙값을 8–10% 내리고(T_i 47.2에서 43.4 eV, $V_{\rm rot}$ 4.3에서 3.8 km/s) 짝지은 MSE skill은 −0.004 / −0.007로 구간이 0을 포함한다.

6.11 물리 필터가 중앙값 추정량이다: 이중 판독

§6.10는 남은 여지를 중앙값 행에 두었다. 거기서 백본은 persistence와 같을 뿐이다. 그 행은 필터가 맞춰진 영역이다: 천천히 변하는 수준을 잡음을 통해 보고, 가끔 점프한다. 그래서 학습된 측정 모형이 아니라 *물리적* 측정 모형이 중앙값을 갖는지 물었다. 셀은 표적별 스칼라 상태공간 필터로, CES 이력만으로 인과적으로 돈다. 사전은 수준을 유지하되 율 λ, 분산 σ_J^2로 점프를 허용하고, 측정은 TRAIN에서 잰 표적의 10 ms 본류 산포(T_i 컷 / 포함 0.116 / 0.071 표적 표준편차, $V_{\rm rot}$ 0.060)를 척도로 하는 Student-t($\nu_0 = 3$)다. 모수는 모두 사전등록이 정하며, 끝단 학습으로도 어느 것도 7% 넘게 움직이지 않으므로 측정된 플라스마 양으로 보고하지 않는다. 그 본류 척도의 Student-t 잡음을 쓰는 순수 필터의 중앙값 절대오차는 T_i에서 persistence의 **0.916**× / **0.911**×, $V_{\rm rot}$에서 **0.975**× / **0.976**×다(컷 / 포함).

한 출력은 두 목적을 담지 못한다. 백본의 MSE 학습 잔차를 필터에 더하면($y = a + r$) 컷 모집단에서 물리 칸의 막대를 넘고(백본 대비 M_1 +0.077 ∼ +0.117, 4/4, MSE 유의 열세 ≤ 1/4) 포함 모집단의 MSE guard는 0.0014 차로 놓친다. 그리고 등록된 세 변형—단순 잔차, 검증 중앙값 오차로 고른 그 체크포인트, 필터의 분산 이득으로 가중한 잔차—각각에서 결합 출력은 필터의 중앙값을 되돌린다($V_{\rm rot}$ persistence의 1.07–1.21×). 따라서 이 계열 안에서, 집계도 지켜야 하는 출력은 조용한 행을 움직인다.

이중 판독. 사전등록된 귀결은 같은 행에서 중앙값과 평균을 서로 다른 추정량으로 보고하는 것이다(표 12). T_i에서 물리 필터는 **무조건부로** 중앙값 추정량이다: 중앙값 skill이 백본 대비 +0.06 ∼ +0.39, persistence 대비 +0.08 ∼ +0.09로 두 모집단 모두 4/4 분할에서 CI가 0을 넘고, persistence의 0.906–0.920×에 분할 간 폭 ±0.007로 앉는다(학습된 팔은 모두 ±0.1 이상). $V_{\rm rot}$에서는 백본 대비 중앙값 skill이 +0.09 ∼ +0.27로 두 모집단 4/4 분할에서 CI가 0을 넘고, persistence 대비 중앙값 오차 비는 분할별 0.94–1.00×로 3/4 분할에서 구간이 1을 포함한다. 이 구간은 필터를 TRAIN에서 맞춰도 1을 포함한 채 남는다. 우도로 맞춘 점프 통계(5–13 Hz)와 우도로 맞춘 잡음 법칙(Student-t, $\nu \to 2$, 중심 폭 2.2 km s^{-1})을 넣어도 중앙값은 persistence의 0.97–0.98×에 머물고, 구간이 1을 제외하는 분할은 많아야 2/4이다. 그 이유는 측정되어 있다. 10 ms 산포는 광자 바닥에 있다: T_i 상대 산포와 도플러 속도 산포의 비가 8/8 분할–모집단 칸에서 가우스 선 맞춤의 $\sqrt{2}$이고, 두 채널의 잡음은 서로 독립이다. 라벨 사이에서 필터의 예측분포는 이월값을 중심으로 대칭이므로, 중앙값 최적점은 마지막 값이다. 따라서 1을 포함하는 이 구간은 추정기가 아니라 10 ms CES 측정의 한계다. 필터는 사건 행에서 늦기 때문에 백본 대비 집계 MSE skill이 −0.06 – −0.52이며, 바로 그래서 평균 추정량이 아니다. 배치 진술은 이렇게 된다: 중앙값은 필터에서, 평균은 나우캐스터에서, 둘 사이의 맞교환은 한 출력에 숨기지 않고 잰다.

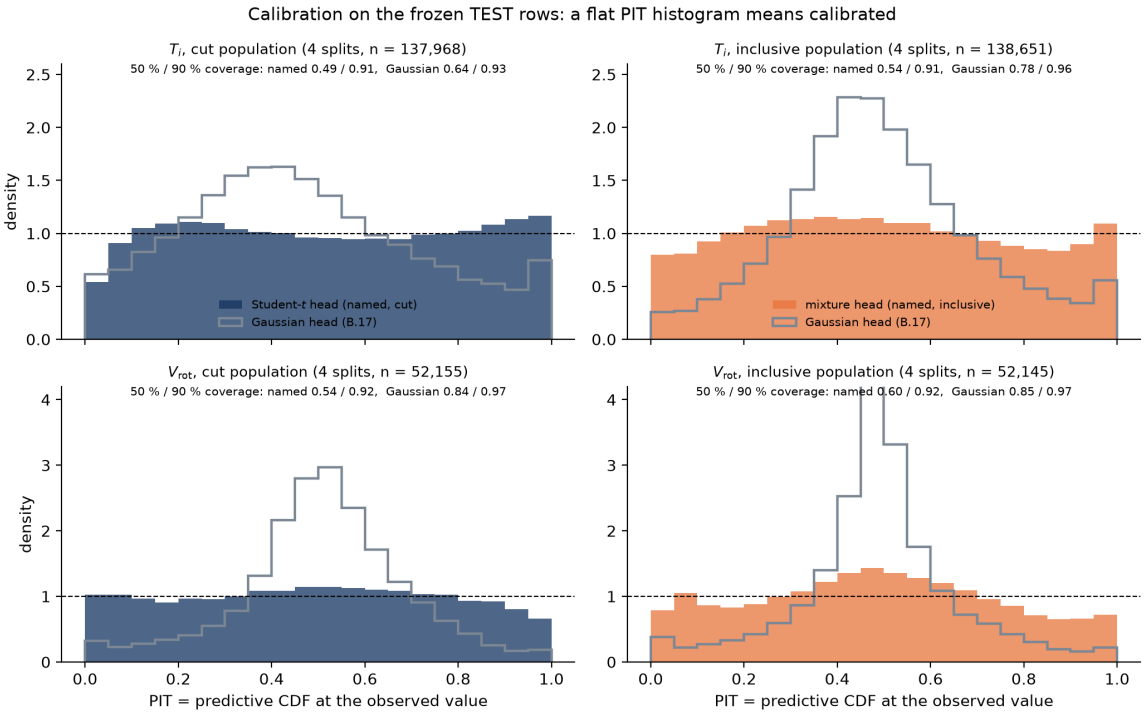


그림 7. 얼린 TEST 행의 PIT 히스토그램(네 분할 합산). 채움: 등록이 지명한 팔(컷 모집단은 Student-t, 포함 모집단은 혼합). 외곽선: 가우스 head. 밀도 1에서 평평하면 보정된 것이고, 가운데가 솟으면 본류에서 구간이 너무 넓은 것이다.

6.12 예측 분포: 두꺼운 꼬리를 가진 한 봉우리, 보정된 채로 보고한다

제어에 쓰는 나우캐스트에는 불확도가 필요하므로, 백본의 출력 head를 음의 로그 우도로 학습하는 예측 분포로 바꾸었다(나머지는 그대로이며, 사후 평균은 같은 점 예측 채점을 거친다). 우도 계열 세 가지를 차례로 등록하였다: 이분산 가우스, 두 성분 가우스 혼합, ν를 학습하는 Student-t. 기준은 백본의 점 예측에 백본 자신의 TEST RMSE를 폭으로 준 분포이며, 기준에 유리한 oracle 선택이다. 등록은 네 가지 guard(CRPS 이득, 중앙 50 %·90 % 포함률, 백본 대비 사후 평균 MSE 손실 없음)와 보고할 팔을 수치보다 먼저 정하였다.

가우스는 기각된다. 중앙 50 % 구간이 행의 0.62–0.80을 덮는다 (그림 7). 꼬리 행에 부풀려진 가우스 폭 하나는 본류에 너무 넓다. $V_{\rm rot}$에서는 우도 가중이 $|v| > 1000\,\mathrm{km\,s^{-1}}$의 맞춤 실패 행에 끌려 사후 평균의 백본 대비 MSE skill이 $-0.03 \sim -0.09$로 컷 분할 3/4에서 CI가 0 아래다.

지명된 팔은 보정되어 있다. 컷 모집단에서 Student-t head의 혼합 대비 CRPS 차는 +0.009로 동률 폭 0.02 안에 있으며 모수가 적어 지명되었다. 기준 대비 CRPS 이득은 +0.229(T_i), +0.363($V_{\rm rot}$)이고 모든 분할에서 CI가 0을 넘으며, 50 % / 90 % 포함률은 0.48–0.51 / 0.91–0.92이다. 포함 모집단에서는 혼합만 guard를 통과한다(+0.444 / +0.351, 포함률 0.53–0.55 / 0.90–0.91). 거기서 t의 위치는 재하강 추정량이어서, 3 keV를 넘는 맞춤 실패 행에서 본류에 머물러 그 제곱을 MSE로 고스란히 치른다(peak 행 −0.134). 혼합은 넓은 성분의 가중으로 평균을 옮긴다.

분포가 물리에 대해 말하는 것. 혼합은 두 봉우리를 쓰지 않는다. 두 봉우리 검정은 어느 행에서도 성립하지 않고, 둘째 성분은 가중 ≈ 0.07의 넓은 성분이다. 맞춘 t 꼬리는 T_i에서 $\nu = 2.8$–3.5이고 $V_{\rm rot}$에서는 $\nu > 2$ 하한에 붙는다. 따라서 나우캐스트 오차는 두꺼운 꼬리를 가진 한 봉우리다: 좁은 광자 잡음 중심에 사건과 맞춤 실패가 만드는 드문 큰 이탈이 얹힌 모양이며, 물리 필터가 측정 모형으로 필요로 한 것과 같은 모양이다(§6.11). T_i 예측 폭은 사건 행에서 1.2× 커진다. $V_{\rm rot}$ 폭은 마지막 라벨 이후 경과 시간과 함께 커지지 않으므로, $V_{\rm rot}$ 불확도는 라벨 사이에 쌓이는 분산이 아니라 방전별 척도다. 그림 8은 TEST 방전 하나에서 구간을 보여 준다.

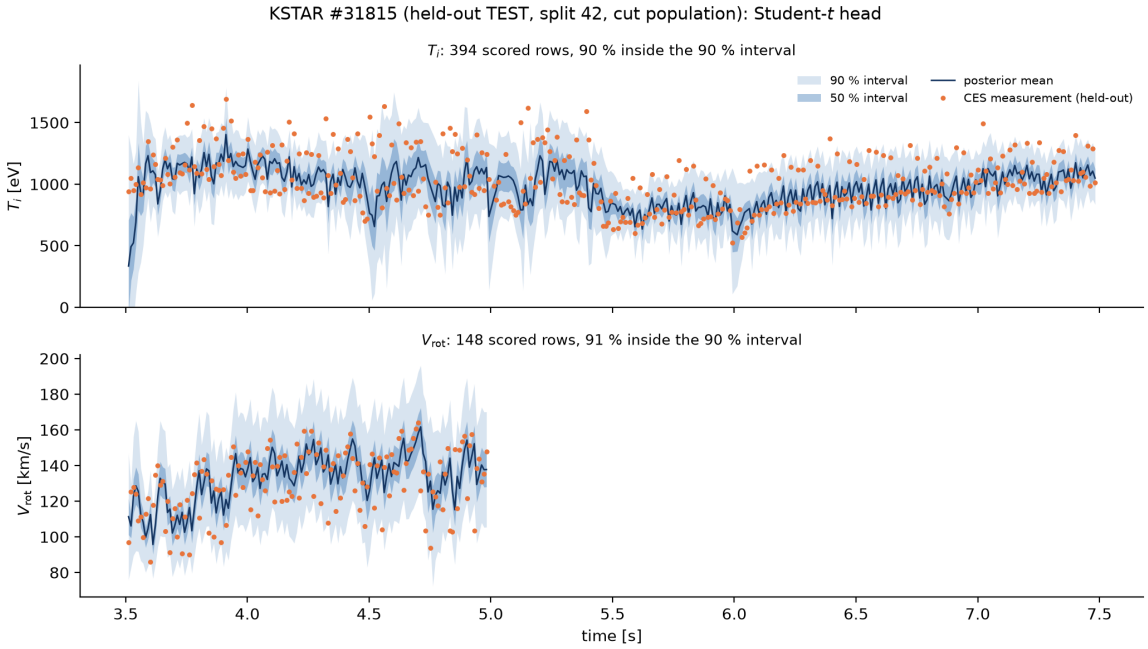


그림 8. TEST 방전 #31815(분할 42, 컷 모집단)에서 Student-t head의 사후 평균과 중앙 50 % / 90 % 예측 구간, 그리고 CES 측정값. T_i 축은 0에서 잘랐으며 첫 행의 구간은 그 아래로 내려간다.

6.13 컷 임계값 민감도

스파이크 임계값을 2.5와 4 keV로 두고 백본을 재학습하면(각각 4개 분할, 자기 모집단에서 채점) T_i skill 평균이 +0.230과 +0.232로 3 keV의 +0.236에 대응하고, 모든 임계값에서 PCHIP 대비 PR4 4/4, 인과 GP 대비 4/4이며, V_{rot}은 +0.252 / +0.253 / +0.257이다. 물리학자가 방어할 만한 범위 안에서 임계값은 무의미하다. 중요한 것은 꼬리 안의 어디에서 자르느냐가 아니라 두 모집단이다.

6.14 문맥·구조·비용: 무엇이 skill을 정하고 무엇이 값을 정하는가

이력 길이, 연속 문맥, 연산자 계열, 비용을 따로 움직였고, 각각 사전등록된 규칙 아래에서 쟀다. 윈도 계열에서 24-run 스윕($W \in \{2, 3, 4, 6, 8\}$과 history-0 지점, 각각 분할 시드 4개; 유지값 제거, 파일당 상한 500, 포함 모집단)은 과거 CES 관측이 없을 때 T_i skill 평균을 −0.026(PR4 0/4), V_{rot}을 −0.78에, 관측이 하나일 때 +0.238(4/4)과 +0.206에, 그보다 긴 모든 윈도에서 +0.190 ∼ +0.246과 +0.190 ∼ +0.206에 두며, 한 지점 안의 시드 산포가 0.07–0.16이므로 plateau 최소 규칙은 $W = 2$를 반환한다. 백본을 각 문맥 길이 r에서 비중첩 세그먼트로 학습하면(학습된 상태를 사후에 자르면 학습되지 않은 상태 재구축을 정보 부족으로 읽게 되며, 재학습은 그 결손의 최소 84%를 회복한다) 사전등록된 규칙—전체 문맥 대비 결손이 0.02 미만이고 유의한 결손이 4개 분할 중 1개 이하인 가장 작은 r—은 **5스텝 = 50 ms**를 반환한다. 301개 방전을 통합하면 인과 GP 대비 T_i skill은 20 ms에서 +0.057 [+0.027, +0.085], 50 ms에서 +0.104 [+0.079, +0.128], 630 ms에서 +0.143 [+0.118, +0.168]이고(4개 분할 평균 +0.055, +0.098, +0.138) 모든 구간이 0을 제외하며, 방전별 승률은 0.52, 0.64, 0.67이다. 과거 관측 하나와 50 ms의 연속 문맥은 서로 다른 자원이고, 윈도 계열은 어떤 W에서도 두 번째를 공급하지 못한다(윈도는 순서 없이 풀링되고 라벨 없는 행은 버려진다): W=2 대조군의 인과 GP 대비 skill은 +0.041(1/4 분할에서 CI가 0 위)이고 같은 2스텝으로 제한한 `seq_v2`는 +0.055(2/4)다. 도달 범위를 맞추면 순환 LSTM(357,570 파라미터), 확장 인과 합성곱(3,238), 띠 attention(295,746)의 인과 GP 대비 T_i skill은 +0.113, +0.119, +0.119로 4/4 분할에서 CI가 0 위다. 짝지은 계열 간 차이의 최대는 −0.023(70 ms 칸의 attention, 3/4 분할에서 CI가 0을 제외)이고 도달 범위를 20에서 70 ms로 옮기는 효과는 +0.060이며, 대각 상태공간 모형은 630 ms에서 +0.105로 순환의 +0.143에 못 미친다(통합). 온라인 1스텝 비용은 디스패치되는 연산자 수를 따른다(연산자당 약 2–3 μs): LSTM은 도달 범위와 무관하게 스텝당 111개, 도달 범위 15–63에서 확장 합성곱은 209–305개, 띠 attention은 473개이므로 아키텍처는 skill이 아니라 비용으로 정한다. 네트워크 순전파만 잰 값으로(워밍업 후 배치 1에서 1,000회 호출 계측, 노트북급 머신) 상태

유지형 `seq_v2` 스텝은 **CPU에서 중앙값 0.97 ms, p99 1.49 ms**이고(같은 벤치마크의 이전 실행에서는 중앙값 0.51–1.05 ms), 이것이 10 ms 주기 안에서 쓸 수 있다고 적는 근거다.

모델의 방전별 skill은 타겟이 움직이는 방전에서 양수다. 같은 문맥 사다리에서 70 ms의 통합 V_{rot} skill은 $+0.123$ $[+0.036, +0.248]$로 0을 제외하지만, 방전별 승률은 0.48이고 약 62개 방전 중 상위 5개를 제거하면 네 분할 모두에서 통합 skill이 0 이하로 내려간다(T_i: 승률 0.70, 가장 큰 단일 방전의 기여 9–16%). 검사한 공변량 11개 가운데 방전별 skill이 양수임을 예측하는 것은 방전 안에서 타겟이 움직이는 정도 하나이며, 그 산포의 3분위별 승률은 T_i 42% / 83% / 85%, V_{rot} 34% / 48% / 55%다.

7 남은 개선 여지는 어디인가

본 논문의 부정 결과들은 이례적으로 구체적이며, 그 구체성이 그것들을 쓸모 있게 만든다: "이 문제는 어렵다"가 아니라 *어떤 변경이 이를 움직일지*를 말한다. 용량은 배제되었고(§6.8), 더 긴 윈도도 배제되었으며(§6.14), 귀납 편향·타 장치 사전학습·앙상블도 배제되었고 (§6.8), 도달 범위를 사는 프레이밍은 채택되었다(§6.3). 모델 쪽에서 움직인 축은 손실의 영향함수 하나이며 그 이득은 본류의 것이다 (§6.10). 그 밖에 남은 것은 데이터이고, 각 레버는 이미 이 데이터셋 안에 있는 증거로 지목된다.

1. CES 피팅 품질 메타데이터는 대리 지표를 측정으로 대체할 것이다. 두 모집단 보고가 존재하는 이유는 값 기준 컷이 "피팅이 실패했다"의 대리 지표이기 때문이다: 어떤 방법도 예측할 수 없는 단일 표본 상향 사건을 제거하지만 한쪽 방향뿐이고(하향 급락은 손대지 않는다) $\geq 2\times$ 상향 이상치의 19%만 잡는다(§3.5). 표본별 피팅 χ^2이나 신호 수준이 있다면 품질 컷이 모든 팔에서 한꺼번에 값 컷을 대체하거나 동반할 수 있고, 두 모집단은 하나로 합쳐질 것이다. 그 값을 얻는 경로는 이미 같은 장치 위에 있다: NN-CES는 빔 변조 없이 CES 스펙트럼을 분석하므로 노출마다 적합 진단값을 내놓으며 [20], 같은 이유로 변조 구간에서 오던 결측 자체를 줄인다. 이 레버는 우리 쪽 코드 변경이 아니라 CES 재분석 산출물의 확보다. V_{rot} 자신의 스파이크(1,000 km/s를 넘는 119행)도 같은 규칙으로 처리될 것이다. 그때까지 persistence 기반 V_{rot} 비교는 §6.8처럼 그 행들이 담는 제곱오차 비중을 보고한다.

2. 원시 Mirnov 스트림은 검정되었다: 등록한 특징은 V_{rot}을 담지 않는다. 동일한 10 ms 격자에서 연속 블록 내 lag-1 자기상관은 BES가 $+0.568$, ECEI가 $+0.572$인 반면 Mirnov 코일은 -0.009이고 블록의 82%가 $|r| = 0.1$ 아래다: 이 격자 *위에서* 자기 채널은 백색잡음이다. 이는 $\mathrm{d}B/\mathrm{d}t$가 kHz 모드 주파수로 진동하는 것을 앤티앨리어싱 필터 없이 100 Hz로 데시메이션한 결과의 특징으로, 연속한 표본들의 상대 위상이 무작위가 된다. 우리 진단 집합에서 토로이달 회전의 대리가 될 수 있었던 유일한 물리량인 모드 회전 주파수가 모델보다 상류에서 버려진 것이며, 우리가 시도한 모든 파생 MC 특징(적분, PCHIP 적분, $|MC|$, 이동 RMS)이 실패한 이유이기도 하다: 이미 잃은 정보는 하류에서 복구할 수 없다. 이 해석은 전처리 변경을 해결책으로 지목했고, 그 해결책을 사전등록 아래 검정하였다. 방전 12개의 원시 2 MHz 코일 스트림을 받았다. 이 스트림은 먼저 데시메이션 해석을 측정으로 바꾼다. 점검한 코일 24개 모두에서 shot 파일의 100 Hz 값은 그 격자 시각의 원시 표본 하나와 같다(시차 0, 차이는 0이거나 출력 자릿수 이내). 평균도 필터도 거치지 않은 한 점의 스냅숏이다. 그다음 인과적 10 ms 윈도 특징 15개(코일별 RMS 포락선과 다섯 대역 파워, 두 코일 교차 스펙트럼의 주 봉우리)를 V_{rot} 분기에 넣었다. 학습 방전은 6개, V_{rot} 라벨이 있는 시험 방전은 3개다. 짝지은 V_{rot} skill 변화는 컷 모집단 -0.128 $[-0.544, -0.105]$, 포함 모집단 -0.164 $[-0.473, -0.133]$이다. 두 구간 모두 0을 음의 쪽에서 제외하고, 시험 방전 3개 중 개선된 것은 0개다. 코일 물리 자체는 확인되었다: #32092의 가장자리 조화 진동이 4.39와 8.91 kHz에 나타난다. 그러나 10 ms 윈도의 주 모드 주파수는 CES 가장자리 회전의 행 단위 함수가 아니다. 방전 안에서 V_{rot}과의 Spearman 상관은 일곱 방전 중 여섯에서 $|\rho| \leq 0.11$이다. 기각의 범위는 학습 방전 6개에서 등록한 특징 15개다. 원시 스트림의 다른 함수(예: 여러 코일에 걸친 교차 위상 기울기)는 검정하지 않았다. 따라서 원시 Mirnov 특징은 10 ms V_{rot} 나우캐스트의 다음 실험으로 지목하지 않는다.

3. 액추에이터 채널은 없고, 10 ms에서는 있어도 거의 바꾸지 못한다. 토로이달 회전은 주입된 토크로 결정되는데, 이 데이터셋에는 토크 신호가 존재하지 않는다. 데이터가 그 단절을 정확히 보여준다: shot 사이에서

ECE 유래 T_e 대리 지표는 T_i와 $r = +0.353$($p = 3 \times 10^{-17}$)으로 상관되지만 V_{rot}과는 $r = +0.024$($p = 0.58$)이고, shot 내부에서 T_i 상관은 일관된 부호를 유지하는 반면 V_{rot} 상관은 부호가 무작위다. 즉 T_e는 가열 수준을 추적하지만 가열 수준은 회전에 닿지 않는다—파워는 토크가 아니며, 토크는 빔 에너지, 접선 반경, 주입 기하에 의존한다. NBI 토크는 회전 수준의 원인이다. 그러나 10 ms 나우캐스트의 레버는 아니다. 빔 파워는 계단 입력이어서 방전당 몇 번의 이온원 on/off 사이에서는 일정하고, 따라서 느린 띠에만 작용한다. 10 ms 증분 분산 가운데 300 ms 이동 평균이 나르는 몫은 V_{rot} 0.34%(사분위 범위 0.21–0.94%, 방전 20개), T_i 0.25%(방전 63개)다. 따라서 완벽한 토크 채널이 줄일 수 있는 10 ms 증분 분산은 약 1%가 상한이고, 토크가 정하는 수준은 10 ms 전 관측값으로 이미 입력에 있다. 이 채널은 다른 범위에서 의미를 갖는다: 파워 계단 뒤 100 ms 이상의 예보, 그리고 첫 CES 표본 이전의 cold start다. 문헌의 양성 대조도 그 종류다: 빔 액추에이터를 입력으로 받는 DIII-D의 순환 전방전 시뮬레이터는 회전의 시간 변화를 예측한다 [85].

4. 본류의 나머지는 미래 이웃의 몫이다. Huber 팔이 되찾은 뒤에도 중앙값 행에서 PCHIP와의 격차 4 eV가 남는다 (§6.10). 그 크기는 인접 두 관측을 평균할 때 잡음이 주는 폭과 같으므로, 인과 모델이 그 격차를 닫는 길은 이력의 잡음을 줄이는 것 — 즉 CES 재분석이 노출마다 내놓는 적합 품질로 이력을 가중하는 것 — 뿐이고, 이는 1번 레버와 같은 산출물에서 나온다. 그리고 모델군 카드의 라벨 0개 행(§6.8)은 3번 항목의 cold start 범위를 보여 준다: 같은 shot의 V_{rot} 라벨이 없으면 어떤 학습된 팔도 BES·ECEI·Mirnov만으로 학습 평균 위로 올라가지 못한다.

따라서 10 ms 나우캐스트에 남은 레버는 1번과 4번의 노출별 적합 품질이며, 641개 shot 파일에는 그 값이 없다. 2번은 등록한 범위 안에서 닫힌 경로이고, 3번은 100 ms 이상의 예보에 속한다.

8 한계

이 장의 결론. 다른 장에 흩어 둔 한계를 한자리에 모아 열세 항목으로 적는다. 항목마다 이 논문이 그것을 어떻게 다루는지를 함께 적고, *다루지 못하는 것은 다루지 못한다고* 적는다. 그리고 마지막 열은 그 한계를 뒤집으려면 무엇을 재야 하는지다—"정보가 부족하다"로 끝나는 줄은 이 표에 없다.

표 13: 한계 열세 항목. 마지막 열의 측정이 수행되고 그 결과가 반대로 나오면 해당 행의 진술은 철회된다.

#	한계	크기	이 논문이 하는 일	이것을 뒤집을 측정
1	V_{rot}에 대한 부정 결과는 방법의 한계가 아니라 *입력의* 한계다	크다	실패가 아니라 발견으로 보고한다. 고속 진단을 0으로 만들어도 출력이 비트 단위로 동일함을 보여 원인을 입력 쪽으로 확정한다(§6.7)	10 ms 나우캐스트에는 CES 분석의 노출별 적합 불확도(641개 파일에 없음). NBI 토크 채널은 100 ms 이상 예보에서만 레버다(300 ms 이상 띠 = 10 ms 증분 분산의 0.34%). 원시 2 MHz Mirnov의 등록 특징 15개는 검정되어 V_{rot} skill을 -0.128 $[-0.544, -0.105]$만큼 바꿨다(§7)
2	**통계적 검정력.** 재현의 단위는 shot이고 분할당 test shot이 96개(T_i)·60–66개(V_{rot})다. shot별 제곱오차 차이는 꼬리가 두껍다(포함 모집단에서 행의 ≈1%가 모든 팔의 T_i 제곱오차의 70–83%를 담는다)	크다	유의성 판정을 shot 군집 paired bootstrap으로 하고, 하나의 분할이 아니라 두 모집단 × 4개 독립 분할의 8개 셀 *전부*를 관문으로 둔다	같은 프로토콜을 더 많은 shot—다음 캠페인—에서 반복. 표본이 커져도 8/8이 유지되는지가 이 주장의 재현 시험이다
3	**MNAR 낙관.** skill은 관측 지점에서만 측정된다	중간	§6.5의 재가중이 두 모집단 모두에서 인과 비교에 대한 낙관의 상한을, 오프라인 비교에 대해서는 모집단 조건부 유의성으로 그 상한을 정한다	재가중은 결측 T_i 행의 54–68%에 닿지만 결측 V_{rot} 행의 4–6%에만 닿는다. 나머지에 닿으려면 V_{rot} 결측을 예측하는 공변량이 더 있어야 한다

(다음 쪽에 이어짐)

#	한계	크기	이 논문이 하는 일	이것을 뒤집을 측정
4	**오프라인 주장의 상한은 오프라인 GP다.** 오프라인 GP의 T_i RMSE는 PCHIP보다 낮고(153.8 대 173.6) 모델의 그에 대한 짝지은 skill은 $-0.05 \sim +0.11$로 8개 셀 중 7개에서 CI가 0을 포함한다	중간	"미래를 쓰는 보간 대비 skill"을 "사전등록된 보간들 대비 skill"로 좁혀 적는다. 배치 가능한 최강인 인과 GP로는 확장된다($+0.08 \sim +0.17$, 8/8에서 CI가 0을 넘음)	오프라인 GP를 넘으려면 CES의 시간 구조 밖에서 오는 정보가 더 필요하다—1행의 노출별 적합 불확도가 그 후보다
5	**값 기준 컷은 대리 지표다.** 두 공동 1차 모집단이 피팅 실패 문제를 괄호로 묶지만 V_{rot}의 스파이크는 컷되지 않은 채 남는다	중간	무조건적 주장을 두 모집단 모두에서 요구해, 컷의 선택이 결론을 정하지 못하게 한다(§6.13의 임계값 민감도 포함)	CES 피팅 품질 메타데이터(χ^2·신호세기)를 받아 값 기준 컷을 품질 기준 컷으로 바꾸는 것(§7). NN-CES 재분석 [20]이 그 값을 내는 경로다. 이것이 이 문제를 결말짓는다
6	**캠페인 전이는 하나의 시간 블록에 기댄다**	중간	4개 분할이 아니라 4개 초기화로 보고하고 그렇게 적는다. 컷 모집단 실행 4개 중 2개는 epoch 상한에서 멈췄다(§6.6)	윈도 대조군을 전이시키는 수리인 shot별 표준화는 오프라인 형태다. 실제로 출하될 *인과적 러닝*(확장 윈도·EWMA) 추정기는 여기서 측정되지 않았다
7	**지표의 비대칭.** 보간은 shot 전체의 이웃을, 윈도 대조군은 두 행을, 백본은 세그먼트의 과거를 본다	중간	인과 모델에 의도적으로 불리한 설계이므로 우위 방향의 해석은 안전하다	도달 범위를 맞춘 계열 대조(§6.14)가 이 비대칭을 부분적으로만 걷어낸다. 완전히 걷어내려면 모든 팔의 문맥 길이를 동일하게 고정한 스윕이 필요하다
8	**단일 장치, 단일 모델 계열.** 하나의 장치, 하나의 진단 집합, 밀접하게 관련된 두 순환 계열	크다	전이에 대해 아무것도 주장하지 않는다	다른 토카막의 CXRS 결측에 같은 프로토콜을 그대로 옮겨 재는 것. 그 전까지 이 결과의 범위는 KSTAR 2022 캠페인이다
9	**불확실성은 행을 합친 기준으로 보정된다.** 방전별 포함률은 재지 않았다	작다	예측 분포 head의 통합 포함률만 보고한다(§6.12)	방전별 조건부 보정을 같은 셀에서 재는 것
10	**지연시간과 범위.** 지연시간은 노트북급 머신 한 대에서 네트워크만 잰 값이고 전원 상태에 따라 실행 간 최대 2× 변동한다(§6.14). 페데스탈 상단 프레이밍은 데이터 선정에서 물려받은 것이다	작다	특징 조립·획득 오버헤드가 빠졌음을 명시한다. §6.9의 고변동 분석은 사건에 무관한 대리 지표라고 적는다	실제 제어 계산기에서 획득→특징→추론 전 구간을 재는 것, 그리고 반경 스캔과 사건 위상(ELM 주기·L–H 천이) 정렬 분석
11	**헤드라인 skill은 꼬리 통계다.** 중앙값 행에서 백본은 persistence와 같고 PCHIP보다 20% 나쁘다; V_{rot}은 중앙값에서 persistence보다도 나쁘다	크다	집계 skill 옆에 중앙값 절대오차를 공동 지표로 병기하고(§6.10), "전형적인 행에서 보간보다 오차가 작다"고 적지 않는다. 척도 고정 Huber 손실이 본류를 8–10%(자기 목적함수로 선택하면 13%) 되찾고 집계를 지킨다 — 컷 조건부로 보고한다	같은 규칙으로 포함 중앙값 이득이 $+0.285$로 오르지만 한 분할에 CI가 0 아래인 MSE 차(-0.040)가 남고, epoch 상한을 늘려도 없어지지 않는다. T_i 중앙값은 물리 필터가 무조건부로 갖고(§6.11), 집계 모델 안이 아니라 옆에 보고한다. V_{rot}에서 그 필터의 persistence 대비 중앙값 오차 비는 0.94–1.00으로 3/4 분할에서 구간이 1을 포함한다(10 ms 선 맞춤의 광자 바닥)
12	**비대칭 진술의 범위.** $T_i \leftrightarrow V_{\mathrm{rot}}$ 비대칭은 표준 CES 10 ms 격자, 코어에서 페데스탈 상단까지, NBI 토크 미관측 조건의 진술이다	중간	그 범위를 비대칭 절과 여기에 명시한다(§6.7). 가장자리 E_r와 회전은 ELM 주기 안에서 움직인다고 알려져 있다 [83, 84]	ELM 주기를 분해하는 측정에서 같은 절제를 반복하는 것. 거기서는 고속 채널이 회전 정보를 나를 수 있다

(다음 쪽에 이어짐)

#	한계	크기	이 논문이 하는 일	이것을 뒤집을 측정
13	**식은 백본의 4분의 3이고, 한 모집단에서 읽었다.** PCHIP 대비 skill의 22–28%는 20개 모수 형태가 재현하지 못하는 비선형 사건 처리이며, 물리 띠는 컷 모집단에서만 읽는다	중간	포함 모집단에서는 식이 PCHIP 대비 skill의 0.43–0.81을 유지하고 BES 이득이 피팅 실패 스파이크 아래에서 부호를 바꾼다고 적는다(§4.4)	사건 행의 은닉 상태 군집화 또는 2층 게이트 변형으로 남은 22–28%를 재는 것(둘 다 미등록)

9 결론

KSTAR의 빈 10 ms CES 행은, 이온온도에 관한 한, 미래를 읽는 보간보다 엄격히 인과적인 추정기로 더 낮은 오차로 채울 수 있다. 우리는 그 추정기—V_{rot} 분기가 고속 진단을 결코 보지 않는 전체격자 2분기 인과 LSTM—를 만들고, 사전등록된 shot 군집 두-모집단 프로토콜 아래에서 의도적으로 불리한 기준—미래를 보는 보간, 그리고 미래를 보지 않는 방법 중 가장 강한 인과 GP—에 대해 평가했다. 모델의 이온온도 skill은 미래를 쓰는 PCHIP 대비 4개 독립 분할과 두 모집단에 걸쳐 $+0.17 \sim +0.32$로 모든 구간이 0을 제외하고(모든 방전을 한 번씩 시험하는 사전등록 반복 5겹 재현에서 $[+0.19, +0.25]\cdot[+0.19, +0.31]$), 가장 강한 오프라인 평활기 대비 짝지은 skill은 $-0.05 \sim +0.11$로 8셀 중 7셀에서 구간이 0을 포함하며, 인과 GP 대비 skill은 $+0.08 \sim +0.17$로 8개 셀 전부에서 구간이 0을 넘는다(비인접 영역 $\Delta t > 15$ ms에서는 $+0.27\cdot+0.21$). 이 skill은 두 스트레스 테스트를 견딘다: 진짜 결측이면서 도메인 안인 시점에서 persistence 대비 skill은 $+0.28 \sim +0.44$로 8/8 셀에서 구간이 0을 넘고, 캠페인 경계를 가로질러서는 시퀀스 나우캐스터가 PCHIP 대비 $+0.17 \sim +0.20$, 인과 GP 대비 $+0.11 \sim +0.16$으로 4/4 초기화에서 구간이 0을 넘는데, 그것이 대체한 윈도 대조군은 그 자리에서 오프라인 우위를 잃었다(PCHIP 대비 구간이 0을 넘는 초기화 $2/4\cdot0/4$)—고속 진단은 캠페인 사이에 타겟보다 5–11× 더 이동하고, 시퀀스 프레이밍은 구성상 shot별로 표준화하고 과거 전체에 닿는다.

그 나우캐스터가 계산하는 것은 적어 내려갈 수 있다. 가중치 크기는 안정된 것을 아무것도 말해 주지 않았고 입출력 응답은 말해 주었으며, 등록된 4단계 판독이 그것을 20개 모수의 물리 필터로 바꾸었다: 직전 측정 이후 공백이 길수록 새 측정에 대한 이득이 커지는 관측 필터에, 각 고속 채널의 직전 100 ms 기준선 대비 편차에 대한 선형 응답을 학습된 문턱 너머에서 차단한 항을 더한 것이다. 동일한 프로토콜로 처음부터 학습한 이 식은 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 72–78%를 유지해 등록 문턱 0.70 위에 있다. 나머지는 신경망의 비선형 사건 처리다. 그것은 20개 모수 기술의 값이지, 이 입력들이 드러내는 빠진 항이 아니다. skill의 본류는 잡음 낀 앵커의 디노이징이고, 보간 대비 마진은 다음 CES 노출 전에 페데스탈 사건이 BES·ECEI에 먼저 비치는 행이 실어 나른다.

같은 식이 반대 결과를 설명한다. 회전에서는 고속 채널이 모델이 쓰는 것을 아무것도 나르지 않으므로—0으로 만들어도 V_{rot} 출력은 비트 단위로 동일하다—보간 대비 평균 제곱 오차 skill은 이력만이 실어 나르는 꼬리 효과이고(등록된 두 단계 bootstrap에서 PCHIP 대비 컷 95% 구간 $[+0.07, +0.70]$, 0을 제외), 중앙값에서는 persistence 대비 오차 비의 구간이 3/4 분할에서 1을 포함한다. 물리는 우리 입력이 관측하지 않는 것이다: 회전을 구동하는 NBI 토크, 그리고 10 ms 선 맞춤의 광자 바닥. 이 진술은 표준 CES 10 ms 격자·코어에서 페데스탈 상단까지에 한정하며, ELM 주기 안의 가장자리 회전은 다른 측정이다.

두 추정 대상은 따로 둔다. 집계 skill은 꼬리 통계이고—중앙값 행에서 나우캐스터는 persistence와 같다—학습 본류 척도의 Student-t 잡음을 쓰는 사전등록 유지-또는-점프 필터가 중앙값 추정량이다(T_i에서 8/8 셀 persistence의 0.91×). 집계도 함께 지켜야 하는 출력은 모두 그 중앙값을 되돌리므로 중앙값과 평균은 서로 다른 추정량으로 보고하고, Student-t 분포 head가 보정된 불확실성을 나른다(§6.12).

주장하지 않는 것과 그것을 뒤집을 것도 함께 보고한다. 오프라인 주장의 상한은 오프라인 GP다. 한 모집단을 정의하는 값 기준 컷은 피팅 품질의 한쪽 방향 대리 지표이고, CES 피팅 품질 메타데이터가 그것을 대체할 것이다. 재가중은 결측 T_i 행의 54–68%와 결측 V_{rot} 행의 20분의 1에 닿는다. 예측 구간은 행을 합친 기준으로 보정되며, 방전별 포함률은 재지 않았다. 45 ms를 넘어서면 포함 모집단의 구간은 0을 포함한다(-0.004, $[-0.30, +0.25]$). 식의 물리 띠는 컷 모집단에서만 읽는데, 피팅 실패 스파이크 아래에서는 포함 모집단의 BES 이득이 부호를 바꾸기 때문이다. 그리고 모든 것이 한 장치·한 캠페인이다. 모델 크기 축과 모델군 축은 닫혔다—21k 파라미터의 persistence+유계 보정 모델이 컷에서 백본과 대등하고, 26× 폭 스윕은 평평하며, shot 인코딩 신경 과정·타 장치 사전학습 transformer·4-초기화 앙상블은 T_i skill을

$-0.09 \sim +0.03$만큼 바꿀 뿐 어느 것도 두 모집단 모두에서 0.02 띠를 넘지 못한다—그래서 남은 것은 입력 쪽이다: 10 ms 나우캐스트에는 CES 분석이 내는 노출별 적합 불확도, 100 ms 이상의 예보에는 NBI 토크 채널이다. 원시 2 MHz Mirnov 스트림의 등록 특징은 검정되었고 V_{rot} skill을 -0.128 $[-0.544, -0.105]$만큼 바꿨다(§7). 이 모든 것을 떠받치는 평가—채점되는 예측 장부를 둔 사전등록, 방전 군집 구간, 겹침 보정 반복 교차검증, 두 단계 bootstrap—는 다른 분야의 표준 조각들을 조립한 것이다. 동료 심사를 거친 핵융합 기계학습에서 그 결합의 선례를 우리는 찾지 못했으며(§2), 그것은 결과가 아니라 믿음의 조건으로 보고한다.

재현성

분할은 디스크에 고정되고 재적재 시 검증된다. 정규화 통계는 학습 파일 전용이다(시퀀스 계열은 여기에 shot별 입력 표준화가 더해진다). 모델 선택은 test 데이터를 결코 읽지 않는다. bootstrap은 고정 시드와 10,000회 재표본을 쓴다. 인용된 모든 수치는 단일 수집 스크립트가 동결된 평가 산출물에서 읽어온다.

코드 가용성

전체 파이프라인, 배치별 실행 기록을 담은 사전등록 문서, 여기 보고된 모든 결과 뒤의 통제 실험 러너, 고정된 train/validation/test 분할, 그리고 동결된 평가 산출물에서 인용된 모든 수치를 재생성하는 수집기는 `https://github.com/iseungsang01/ml-intern-revision`에서 공개되어 있다. 백본은 `ces_prediction/experiments/seq/model_seq_v2.py`, 해석 가능한 사다리 칸은 `model_seq_b3.py`, 윈도 대조군은 `ces_prediction/model_iter009.py`(테스트 스위트에서 내용 해시로 보호)이므로, 이 수치를 만든 코드가 공개된 코드와 어긋날 수 없다.

데이터 가용성

본 연구의 바탕이 되는 KSTAR 진단 데이터—641개 방전, shot 30801–32751—는 코드와 함께 재배포되지 않는다. 이는 KSTAR 장치의 실험 데이터로 운영 기관의 데이터 정책을 따르며, 접근 요청은 그쪽으로 보내야 한다. 저장소에는 shot 파일이 갖춰진 뒤 분석을 재현하는 데 필요한 모든 것이 들어 있다: 정확한 파일 단위 분할 manifest, 보고된 모든 실행의 환경 설정, 그리고 bootstrap 통계를 계산하는 표본별 제곱오차 아카이브.

참고문헌

[1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81: 10D740, 2010. doi: 10.1063/1.3496991.

[2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.

[3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2):238–246, 1980. doi: 10.1137/0717021.

[4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.

[5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.

[6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.

[7] Minseok Kim, W.H. Ko, Sehyun Kwak, Semin Joung, Wonjun Lee, B. Kim, D. Kim, J.H. Lee, Choongki Sung, Yong-Su Na, and Y.-C. Ghim. Kinetic profile inference with outlier detection

using support vector machine regression and Gaussian process regression. *Nuclear Fusion*, 64: 106052, 2024. doi: 10.1088/1741-4326/ad7304.

[8] R. L. Dougherty, A. S. Edelman, and J. M. Hyman. Nonnegativity-, monotonicity-, or convexity-preserving cubic and quintic Hermite interpolation. *Mathematics of Computation*, 52(186):471–494, 1989. doi: 10.1090/S0025-5718-1989-0962209-1.

[9] C. H. Reinsch. Smoothing by spline functions. *Numerische Mathematik*, 10(3):177–183, 1967. doi: 10.1007/BF02162161.

[10] G. Kvernadze. Convergence and Gibbs' phenomenon in cubic spline interpolation of discontinuous functions. *Journal of Computational and Applied Mathematics*, 92(2):173–188, 1998. doi: 10.1016/S0377-0427(97)00199-4.

[11] S. Eyheramendy, F. Elorrieta, and W. Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481(4):4311–4322, 2018. doi: 10.1093/mnras/sty2487.

[12] F. Elorrieta, S. Eyheramendy, and W. Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, 2019. doi: 10.1051/0004-6361/201935560.

[13] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, 3rd edition, 2007.

[14] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.

[15] Joseph Abbate, Emiliano Fable, Giovanni Tardini, Rainer Fischer, and Egemen Kolemen. Combining physics-based and data-driven models for quantitatively accurate plasma profile prediction. *Nuclear Fusion*, 65:056014, 2025. doi: 10.1088/1741-4326/adc283.

[16] M. J. Owens, R. Challen, J. Methven, E. Henley, and D. R. Jackson. A 27 day persistence model of near-Earth solar wind conditions: A long lead-time forecast and a benchmark for dynamical models. *Space Weather*, 11(5):225–236, 2013. doi: 10.1002/swe.20040.

[17] Chris Bishop, C.M. Roach, and M. G. von Hellermann. Automatic analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 35:765–773, 1993. doi: 10.1088/0741-3335/35/6/010.

[18] J. Svensson, M. von Hellermann, and R. König. Analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 41:315–338, 1999. doi: 10.1088/0741-3335/41/2/016.

[19] Baoyue Chai, Yingying Li, Ze Chen, Wei Tao, Yixuan Zhou, Shifeng Mao, Zhengping Luo, Yi Yu, Bo Lyu, and Minyou Ye. Fast estimation of ion temperature from EAST charge exchange recombination spectroscopy using neural network. *Plasma Science and Technology*, 21:105103, 2019. doi: 10.1088/2058-6272/ab2674.

[20] J.K. Lee, W.H. Ko, H.H. Lee, B. Kim, Y.H. Lee, G.W. Shin, J. Kim, and J.M. Lee. Neural network-based analysis of charge exchange spectra in KSTAR. *Fusion Engineering and Design*, 222:115518, 2026. doi: 10.1016/j.fusengdes.2025.115518.

[21] A. Pavone, J. Svensson, A. Langenberg, U. Höfel, S. Kwak, N. Pablant, and R. C. Wolf. Neural network approximation of Bayesian models for the inference of ion and electron temperature profiles at W7-X. *Plasma Physics and Controlled Fusion*, 61:075012, 2019. doi: 10.1088/1361-6587/ab1d26.

[22] Mark D. Boyer and Jason D. Chadwick. Prediction of electron density and pressure profile shapes on NSTX-U using neural networks. *Nuclear Fusion*, 61:046024, 2021. doi: 10.1088/1741-4326/abe08b.

[23] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64: 106061, 2024. doi: 10.1088/1741-4326/ad73e8.

[24] Francisco A. Matos, Diogo R. Ferreira, and P. Carvalho. Deep learning for plasma tomography using the bolometer system at JET. *Fusion Engineering and Design*, 114:18–25, 2016. doi: 10.1016/j.fusengdes.2016.11.006.

[25] Cong Wang, Weizhe Yang, Haiping Wang, Renjie Yang, Jing Li, Zhijun Wang, Yixiong Wei, Xianli Huang, Chenshu Hu, Zhaoyang Liu, Xinyao Yu, Changqing Zou, and Zhifeng Zhao. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 65:076022, 2025. doi: 10.1088/1741-4326/ade0ce.

[26] Xishuo Wei, Shuying Sun, W. M. Tang, Zhihong Lin, Hongfei Du, and Ge Dong. Reconstruction of tokamak plasma safety factor profile using deep learning. *Nuclear Fusion*, 63:086020, 2023. doi: 10.1088/1741-4326/acdf00.

[27] G.H. Zheng, Zongyu Yang, Songfen Liu, Rui Ma, Xinwen Gong, Ao Wang, Shuo Wang, and W.L. Zhong. Real-time equilibrium reconstruction by multi-task learning neural network based on HL-3 tokamak. *Nuclear Fusion*, 64:126041, 2024. doi: 10.1088/1741-4326/ad8014.

[28] S. Joung, J. Kim, S. Kwak, J. Bak, S. Lee, H. Han, H. Kim, G. Lee, D. Kwon, and Y. Ghim. Deep neural network Grad-Shafranov solver constrained with measured magnetic signals. *Nuclear Fusion*, 2020.

[29] Semin Joung, Young chul Ghim, Jaewook Kim, S. Kwak, Daeho Kwon, Chih-Jen Sung, Dong Ju Kim, Hyun-Seok Kim, J.G. Bak, and S.W. Yoon. GS-DeepNet: mastering tokamak plasma equilibria with deep neural networks and the Grad–Shafranov equation. *Scientific Reports*, 13: 15799, 2023. doi: 10.1038/s41598-023-42991-5.

[30] L. Jung, Jaewook Kim, and Jisung Kang. Machine learning-based plasma profile reconstruction in KSTAR. *Journal of the Korean Physical Society*, 88:1079 – 1087, 2026. doi: 10.1007/s40042-026-01580-1.

[31] Joseph Abbate, Rory Conlin, and Egemen Kolemen. Data-driven profile prediction for DIII-D. *Nuclear Fusion*, 61:046027, 2021. doi: 10.1088/1741-4326/abe08d.

[32] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2024. doi: 10.1088/1741-4326/ad142f.

[33] Semin Joung, Jaewook Kim, S. Kwak, Kyeo reh Park, S.H. Hahn, Hyunsun Han, Hyun-Seok Kim, J.G. Bak, S. G. Lee, and Young chul Ghim. Imputation of faulty magnetic sensors with coupled Bayesian and Gaussian processes to reconstruct the magnetic equilibrium in real time. *Review of Scientific Instruments*, 89:10K106, 2018. doi: 10.1063/1.5038938.

[34] Debashish Mohapatra, Bidyadhar Subudhi, and Raju Daniel. Real-time sensor fault detection in Tokamak using different machine learning algorithms. *Fusion Engineering and Design*, 151:111401, 2019. doi: 10.1016/j.fusengdes.2019.111401.

[35] S. Kaldas, R. Rossi, I. Wyss, M. Gelfusa, and P. Gaudio. Developing autoencoder models for multi-diagnostic electron density processing in tokamaks within a scientific machine learning framework. *Journal of Fusion Energy*, 45, 2026. doi: 10.1007/s10894-026-00568-w.

[36] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.

[37] K. Jia, Z. Xu, Z. Wu, W. Gao, M. Wang, A. Ti, et al. Time series regression network using exogenous variables for missing effective ion charge reconstruction in EAST tokamak. *Nuclear Fusion*, 67:016012, 2026. doi: 10.1088/1741-4326/aeb432.

[38] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Niannian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.

[39] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.

[40] M. Imríšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiand, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.

[41] F. Pastore, F. Felici, T. O. S. J. Bosman, C. Galperti, O. Sauter, B. Vincent, and N. M. T. Vu. Model-based electron density estimation using multiple diagnostics on TCV. *Fusion Engineering and Design*, 192:113615, 2023. doi: 10.1016/j.fusengdes.2023.113615.

[42] HyeongJun Noh, Chweeho Heo, Xiaotian Gao, and Yong-Su Na. PanoMHD: Multimodal modelling of plasma dynamics towards Tokamak control. 2026.

[43] Committee for Proprietary Medicinal Products (CPMP). Points to consider on switching between superiority and non-inferiority. European Medicines Agency, CPMP/EWP/482/99, 2000.

[44] International Council for Harmonisation (ICH). Addendum on estimands and sensitivity analysis in clinical trials to the guideline on statistical principles for clinical trials E9(R1). ICH Harmonised Guideline E9(R1), Step 4, 2019.

[45] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.

[46] Satya Narayan Shukla and Benjamin M. Marlin. Multi-time attention networks for irregularly sampled time series. 2021:14897–14911, 2021. doi: 10.48550/arxiv.2101.10318.

[47] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. 32:5320–5330, 2019.

[48] Rich Caruana. Multitask learning. *Machine Learning*, 28:41–75, 1997. doi: 10.1023/a:1007379606734.

[49] Jiquan Ngiam, Aditya Khosla, Mingyu Kim, Juhan Nam, Honglak Lee, and Andrew Y. Ng. Multimodal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 2011.

[50] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:423–443, 2018. doi: 10.1109/tpami.2018.2798607.

[51] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Xing Chen, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.

[52] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. 2018. doi: 10.48550/arxiv.1802.04712.

[53] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. 2015. doi: 10.48550/arxiv.1506.04214.

[54] Suman Ravuri, Karel Lenc, Matthew Willson, Dmitry Kangin, Rémi Lam, Piotr Mirowski, M. A. Fitzsimons, Maria Athanassiadou, Sheleem Kashem, Sam Madge, Rachel Prudden, Amol Mandhane, Aidan Clark, Andrew Brock, Karen Simonyan, Raia Hadsell, N. Robinson, Ellen Clancy, Alberto Arribas, and Shakir Mohamed. Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597:672–677, 2021. doi: 10.1038/s41586-021-03854-z.

[55] Brian A. Nosek and Daniël Lakens. Registered reports: A method to increase the credibility of published results. *Social Psychology*, 45(3):137–141, 2014. doi: 10.1027/1864-9335/a000192.

[56] Luca Bertinetto, João F. Henriques, Samuel Albanie, Michela Paganini, and Gül Varol, editors. *Proceedings of the NeurIPS 2020 Workshop on Pre-registration in Machine Learning*, volume 148 of *Proceedings of Machine Learning Research*, 2021. PMLR. URL `https://proceedings.mlr.press/v148/`.

[57] Claude Nadeau and Yoshua Bengio. Inference for the generalization error. *Machine Learning*, 52:239–281, 2003. doi: 10.1023/A:1024068626366.

[58] Stephen Bates, Trevor Hastie, and Robert Tibshirani. Cross-validation: What does it estimate and how well does it do it? *Journal of the American Statistical Association*, 119(546):1434–1445, 2024. doi: 10.1080/01621459.2023.2197686.

[59] Varun Saravanan, Gordon J. Berman, and Samuel J. Sober. Application of the hierarchical bootstrap to multi-level data in neuroscience. *Neurons, Behavior, Data analysis, and Theory*, 3(5):1–25, 2020. doi: 10.1101/819334. Preprint: bioRxiv 819334.

[60] Shiquan Ren, Hong Lai, Wenjing Tong, Mostafa Aminzadeh, Xuezhang Hou, and Shenghan Lai. Nonparametric bootstrapping for hierarchical data. *Journal of Applied Statistics*, 37(9):1487–1498, 2010. doi: 10.1080/02664760903046102.

[61] Thibault Sellam, Steve Yadlowsky, Jason Wei, Naomi Saphra, Alexander D'Amour, Tal Linzen, Jasmijn Bastings, Iulia Turc, Jacob Eisenstein, Dipanjan Das, Ian Tenney, and Ellie Pavlick. The MultiBERTs: BERT reproductions for robustness analysis. In *International Conference on Learning Representations (ICLR)*, 2022. arXiv:2106.16163.

[62] L. Goddard, A. Kumar, A. Solomon, D. Smith, G. Boer, P. Gonzalez, V. Kharin, W. Merryfield, C. Deser, S. J. Mason, B. P. Kirtman, R. Msadek, R. Sutton, E. Hawkins, T. Fricker, G. Hegerl, C. A. T. Ferro, D. B. Stephenson, G. A. Meehl, T. Stockdale, R. Burgman, A. M. Greene, Y. Kushnir, M. Newman, J. Carton, I. Fukumori, and T. Delworth. A verification framework for interannual-to-decadal predictions experiments. *Climate Dynamics*, 40(1–2):245–272, 2013. doi: 10.1007/s00382-012-1481-2.

[63] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.

[64] Manuel Gebetsberger, Jakob W. Messner, Georg J. Mayr, and Achim Zeileis. Estimation methods for nonhomogeneous regression models: Minimum continuous ranked probability score versus maximum likelihood. *Monthly Weather Review*, 146(12):4323–4338, 2018. doi: 10.1175/MWR-D-17-0364.1.

[65] Stephan Rasp and Sebastian Lerch. Neural networks for postprocessing ensemble weather forecasts. *Monthly Weather Review*, 146(11):3885–3900, 2018. doi: 10.1175/MWR-D-18-0187.1.

[66] David Sussillo and Omri Barak. Opening the black box: Low-dimensional dynamics in high-dimensional recurrent neural networks. *Neural Computation*, 25(3):626–649, 2013. doi: 10.1162/neco_a_00409.

[67] Miles Cranmer, Alvaro Sanchez-Gonzalez, Peter Battaglia, Rui Xu, Kyle Cranmer, David Spergel, and Shirley Ho. Discovering symbolic models from deep learning with inductive biases. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020. arXiv:2006.11287.

[68] Niru Maheswaranathan and David Sussillo. How recurrent networks implement contextual processing in sentiment analysis. arXiv:2004.08013, 2020.

[69] Mark Rothmann, Ning Li, Gang Chen, George Y. H. Chi, Robert Temple, and Hsiao-Hui Tsou. Design and analysis of non-inferiority mortality trials in oncology. *Statistics in Medicine*, 22(2):239–264, 2003. doi: 10.1002/sim.1400.

[70] Yann LeCun, John S. Denker, and Sara A. Solla. Optimal brain damage. In *Advances in Neural Information Processing Systems 2 (NIPS 1989)*, pages 598–605. Morgan Kaufmann, 1990.

[71] L. Allen and C. M. Bishop. Neural network approach to energy confinement scaling in tokamaks. *Plasma Physics and Controlled Fusion*, 34(7):1291–1302, 1992. doi: 10.1088/0741-3335/34/7/008.

[72] Michael Roth, Emre Özkan, and Fredrik Gustafsson. A Student's t filter for heavy tailed process and measurement noise. In *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5770–5774, 2013. doi: 10.1109/ICASSP.2013.6638770.

[73] Gabriel Agamennoni, Juan I. Nieto, and Eduardo M. Nebot. Approximate inference in state-space models with heavy-tailed noise. *IEEE Transactions on Signal Processing*, 60(10):5024–5037, 2012. doi: 10.1109/TSP.2012.2208106.

[74] Katharina Rath, David Rügamer, Bernd Bischl, Udo von Toussaint, Cristina Rea, Andrew Maris, Robert Granetz, and Christopher G. Albert. Data augmentation for disruption prediction via robust surrogate models. *Journal of Plasma Physics*, 88(5):895880502, 2022. doi: 10.1017/S0022377822000769.

[75] H. van den Brand, M. R. de Baar, M. van Berkel, T. C. Blanken, F. Felici, E. Westerhof, M. Willensdorfer, The ASDEX Upgrade Team, and The EUROfusion MST1 Team. A model-based, multichannel, real-time capable sawtooth crash detector. *Plasma Physics and Controlled Fusion*, 58(7):075002, 2016. doi: 10.1088/0741-3335/58/7/075002.

[76] Yuya Morishita, Sadayoshi Murakami, Masayuki Yokoyama, and Genta Ueno. Data assimilation system based on integrated transport simulation of Large Helical Device plasma. *Nuclear Fusion*, 60(5):056001, 2020. doi: 10.1088/1741-4326/ab7596.

[77] Zander Keith, Chirag Nagpal, Cristina Rea, and R. Alex Tinguely. Risk-aware framework development for disruption prediction: Alcator C-Mod and DIII-D survival analysis. *Journal of Fusion Energy*, 43(1):21, 2024. doi: 10.1007/s10894-024-00413-y.

[78] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.

[79] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.

[80] Brandon D. Gallas, Andriy Bandos, Frank W. Samuelson, and Robert F. Wagner. A framework for random-effects ROC analysis: Biases with the bootstrap and other variance estimators. *Communications in Statistics - Theory and Methods*, 38(15):2586–2603, 2009. doi: 10.1080/03610920802610084.

[81] Art B. Owen. The pigeonhole bootstrap. *The Annals of Applied Statistics*, 1(2):386–411, 2007. doi: 10.1214/07-AOAS122.

[82] J. E. Rice, A. Ince-Cushman, J.S. deGrassie, L.-G. Eriksson, Y. Sakamoto, A. Scarabosio, A. Bortolon, K.H. Burrell, B.P. Duval, C. Fenzi-Bonizec, M. Greenwald, R. J. Groebner, G. T. Hoang, Y. Koide, E. S. Marmar, A. Pochelon, and Y. Podpaly. Inter-machine comparison of intrinsic toroidal rotation in tokamaks. *Nuclear Fusion*, 47:1618–1624, 2007. doi: 10.1088/0029-5515/47/11/025.

[83] E. Viezzer, M. Cavedon, P. Cano-Megias, E. Fable, E. Wolfrum, D. J. Cruz-Zabala, et al. Dynamics of the pedestal transport during edge localized mode cycles at ASDEX Upgrade. *Plasma Physics and Controlled Fusion*, 62:024009, 2020. doi: 10.1088/1361-6587/ab5b1d.

[84] M. Cavedon, T. Pütterich, E. Viezzer, F. M. Laggner, A. Burckhart, M. G. Dunne, R. Fischer, A. Lebschy, et al. Pedestal and E_r profile evolution during an edge localized mode cycle at ASDEX Upgrade. *Plasma Physics and Controlled Fusion*, 59:105007, 2017. doi: 10.1088/1361-6587/aa7ad0.

[85] Ian Char, Youngseog Chung, Joseph Abbate, Egemen Kolemen, and Jeff Schneider. Full shot predictions for the DIII-D tokamak via deep recurrent networks. arXiv:2404.12416, 2024.