

KSTAR 희소 전하교환분광 (CES) 신호의 멀티모달 나우캐스팅: 고속 진단은 미래를 보는 보간을 넘어 이온온도를 복원하지만 토로이달 회전은 복원하지 못한다

이승상 (Seungsang Lee)
서울대학교 원자핵공학과
lss010330@snu.ac.kr

국문 초안 — July 4, 2026

Abstract

전하교환분광 (CES) 은 토카막에서 이온온도 (T_i) 와 토로이달 회전 (V_{rot}) 을 측정하는 핵심 진단이지만, 광자 수집 제약 때문에 느리고 간헐적으로 결측된다. 본 연구가 다루는 KSTAR 10 ms 격자에서는 T_i 의 약 8%, V_{rot} 의 약 24% 가 결측되며, 두 타겟은 서로 독립적으로 빠진다. 본 논문은 항상 측정되는 고속 진단—빔방출분광 (BES), 전자사이클로트론방출영상 (ECEI), Mirnov 코일—과 불규칙한 과거 CES 이력을 결합하면, CES 가 결측된 시점에서 CES 자체의 시간 보간으로는 복원할 수 없는 정보를 회복할 수 있는지를 묻는다. 진단별 인코더, 명시적 불규칙 시간 특징, 타겟별 마스킹 손실, 물리 기반 타겟별 입력 라우팅을 갖춘 소형 (100 만 파라미터 미만) 멀티모달 신경망을 학습하고, 의도적으로 불리한 기준선과 비교한다: 오프라인 보간 (선형, 단조 3 차 PCHIP, 국소 AR) 은 타겟 시점 양쪽의 과거와 미래 CES 이웃을 모두 사용하는 반면, 모델은 엄격하게 인과적 (causal) 이다. 사전등록된 프로토콜—파일 단위 train/val/test 분할, 모델 선택이 전혀 접근하지 않는 test 셋, shot 군집 paired bootstrap(10,000 회 재표본)—하에서 모델은 T_i 에 대해 skill +0.20~+0.30 으로 PCHIP 을 이기며, 독립적인 4 개 held-out 분할 모두에서 95% 신뢰구간이 0 을 제외한다. 반면 V_{rot} 은 4 개 분할 모두에서 보간과 통계적으로 구별되지 않는다. 입력 절제 (ablation) 실험은 이 비대칭이 아키텍처가 아니라 물리에서 비롯됨을 보인다: 고속 진단만으로도 persistence 를 이기는 T_i 와 달리 (충돌성 전자-이온 결합으로 T_e , n_e 가 정보를 운반), V_{rot} 에 대해서는 평균 예측보다도 나쁘다 (지배적인 NBI 토카가 미관측이고, 100 Hz 로 샘플된 Mirnov 신호는 kHz 모드 회전을 앨리어싱으로 소실한다). 모델의 우위는 매끄러운 보간이 가장 취약한 고변동 국소 구간에 집중된다. 아울러 데이터 품질 감사 (관측된 V_{rot} 값의 54% 가 계기 유지값으로 판명) 와, 통계적으로 유의하지 않던 초기 결과를 유의한 헤드라인으로 끌어올린 LLM 기반 keep/discard 아키텍처 탐색 루프를 문서화한다. 전체 파이프라인, 사전등록 문서, 평가 산출물을 공개한다.

1 서론

플라즈마 경계부의 이온온도 T_i 와 토로이달 회전 V_{rot} 은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근 등 토카막 성능과 안정성의 핵심 요소를 지배한다. 두 물리량의 표준 측정법은 전하교환분광 (CES) [1] 으로, 전하교환 선방출의 도플러 확장에서 T_i 를, 도플러 이동에서 V_{rot} 을 추정한다. CES 는 충분한 신호 대잡음비를 위해 광자를 적분해야 하므로 본질적으로 느리고, 개별 시점 측정은 노출-신호품질 문제로 자주 소실된다. 본 연구의 KSTAR 데이터에서는 균일한 10 ms 격자 위에서도 T_i 의 약 8%, V_{rot} 의 약 24% 가—서로 독립적으로—결측되며, 우리 데이터셋에서 경험적으로 결측은 물리적으로 흥미로운 순간 (저신호 구간, ELM, 천이) 에 집중된다. 즉 Little and Rubin [2]의 의미에서 무작위적이지 않은 결측 (MNAR) 이다.

한편 여러 고속 진단은 같은 플라즈마를 결측 없이 관측한다: BES 는 밀도요동 구조를, ECEI 는 전자온도를, Mirnov 코일은 자기요동을 측정한다. 이들 중 어느 것도 T_i 나 V_{rot} 을 직접 측정하지 않는다. 본 논문의 질문은 다음과 같다.

CES 가 결측된 10ms 시점에서, 동시각 고속 진단과 불규칙한 과거 *CES* 이력만으로, *CES* 단독의 시간 보간이 복원할 수 없는 T_i , V_{rot} 정보를 회복할 수 있는가?

긍정적 답은 데이터 기반 가상 센서 (*virtual sensor*) 를 정당화한다: 강한 역산 가정 없이 *CES* 결측을 온라인으로 채워, 끊임 없는 페데스탈 분석과 궁극적으로 실시간 활용을 가능하게 하는 모델이다.

의도적으로 어려운 기준선. 결측 채움의 자명한 기준선은 *CES* 채널 자체의 보간이다. 우리는 비교를 모델에 의도적으로 불리하게 설계했다: 보간 기준선 (선형, 단조 3 차 PCHIP [3], 국소 AR 참조) 은 오프라인으로, 타겟 시점 양쪽의—미래를 포함한—*CES* 이력을 사용할 수 있다. 반면 모델은 엄격히 인과적이며, 타겟 시점의 고속 진단과 짧은 과거 *CES* 원도만 본다. 인과 모델이 미래를 쓰는 보간을 이긴다면, 고속 진단이 *CES* 의 시간 구조만으로는 답을 수 없는 *CES* 관련 정보를 운반한다는 뜻이다. 그리고 미래를 쓰는 보간을 이기는 모델은 당연히 (persistence, AR 등) 모든 인과 기준선을 이긴다.

기여.

1. **누수 방지 멀티모달 나우캐스팅 파이프라인:** 타겟별 마스킹 멀티태스크 손실 (두 타겟 동시 관측을 요구하던 필터가 버리던 라벨 행 $\approx 28\%$ 를 복원), 명시적 불규칙 시간 특징, *CES* 이력 입력에서 타겟 시점의 완전 마스킹, 파일 (shot) 단위 분할, 학습 파일 전용 정규화 통계 (§3).
2. **사전등록된 shot 군집 평가 프로토콜 (§5):** 모델 선택이 전혀 읽지 않는 test 셋을 갖춘 3 분할, 그리고 shot 군집 paired bootstrap—한 방전 내 인접 샘플은 강하게 상관되므로 재현 (replication) 의 단위 는 샘플이 아니라 방전이다.
3. T_i **에 대한 강건한 긍정 결과 (§6):** 인과 모델이 미래를 쓰는 PCHIP 보간을 $\text{skill}_{\text{PCHIP}} = +0.20 \sim +0.30$ 으로 이기며, 4 개 독립 held-out 분할 모두에서 shot 군집 95% CI 가 0 을 제외하고, 진짜 측정 값만의 재평가에서도 생존한다.
4. V_{rot} **에 대한 물리 기반 부정 결과:** 실패가 아니라 발견으로 보고한다. 고속 진단은 10ms 에서 회전 정보를 사실상 운반하지 않으며 (미관측 NBI 토크, Mirnov 앨리어싱), 입력 절제로 확인된다. 따라서 V_{rot} 은 이력 자기상관의 한계에 머물러 보간과 통계적으로 동물이다. 이를 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭이라 부른다.
5. **모델이 우위를 버는 위치의 진단:** skill 은 매끄러운 보간이 가장 약한 고변동 국소 구간에 집중된다. 그곳에서는 V_{rot} 조차 (연약하지만) 유의한 우위를 보이며, 절제 실험은 T_i 우위가 실제로 멀티모달 신호를 사용함을 보인다.
6. **두 가지 방법론적 산출물:** 관측된 V_{rot} 값의 54% 가 forward-fill 된 계기 유지값임을 밝힌 데이터 품질 감사 (및 보정된 평가), 그리고 선택 게이트를 검증 손실이 아닌 깨끗한 보간 대비 skill 로 삼는 LLM 기반 keep/discard 아키텍처 탐색 루프.

2 관련 연구

핵융합 진단의 프로파일 피팅과 결측 보간. 가우시안 과정 회귀 [4] 는 핵융합 프로파일 데이터의 피팅과 불확실성 정량화의 커뮤니티 표준 도구이며 [5, 6], PCHIP 같은 단조 보간 [3, 7] 은 자연 3 차 스플라인 [8] 이 ELM-툰니파형 계단에서 Gibbs 형 진동을 보이기 때문에 [9] 과도 현상 근방에서 선호된다. 불규칙 표본 시계열에는 정확한 AR 형 영모형 (IAR/CIAR) 이 존재한다 [10, 11]. 우리는 이 사다리—persistence, 선형 보간 [12], PCHIP, 국소 AR—를 사전등록된 기준선으로 사용하며, PCHIP 을 헤드라인 비교 대상으로, Murphy 의 MSE skill 점수 [13] 를 지표로 삼는다. 본 연구의 기여는 이 문헌과 직교한다: 더 나은 *CES* 단독 보간이 아니라, 다른 진단들이 어떤 *CES* 단독 방법도 넘어서는 정보를 더하는지를, 인과 멀티모달 모델을 미래를 쓰는 보간과 맞세워 검증한다.

핵융합에서의 신경망 진단 추론. 신경망 진단 추론에는 세 갈래가 있으며, 각각에 대해 타겟 측정이 없을 때 어떻게 되는가? 를 묻는 것이 유익하다. 가장 오래된 갈래는 스펙트럼 피팅 가속이다—JET 전하교환 스펙트럼의 신경망 분석 [14, 15] 과 EAST CXRS 스펙트럼의 고속 T_i 추정 [16]. 이들은 최소자승 피팅 대비 수십 배의 속도를 얻지만, 구조상 해당 시점에 측정된 스펙트럼을 요구한다: *CES* 노출이 결측되면 입

력 자체가 없다. 두 번째 갈래는 한 진단의 추론 파이프라인을 다른 진단으로 대체한다: W7-X의 베이직안 모형 에뮬레이션 [17], NSTX-U의 스칼라 파라미터 기반 프로파일 형상 예측 [18], 그리고—우리 타겟에 가장 가까운—EAST의 X선 결정 분광기로부터의 T_i 회전 프로파일 추론 [19]. Lin 등은 정확히 우리의 두 물리량을 예측하지만 입력이 또 다른 도플러 분광기, 즉 동일한 물리 정보 채널이고 같은 광자 통계 한계를 가지며, 매핑은 순간적이고 소스 진단의 가용성을 그대로 상속한다. 세 번째 갈래는 느린 재구성 코드의 종단간 대리모형이다: 볼로미터 단층촬영 [20], 선적분 진단 [21], 안전인자 프로파일 [22], 실시간 평형 [23], 그리고 KSTAR 자체의 신경망 Grad-Shafranov 솔버 [24, 25]와 고속 EPED 파라미터화 프로파일 재구성 [26]. 이들은 분석 지연시간을 다루지, 측정 가용성을 다루지 않는다: 존재하는 데이터의 역산을 가속할 뿐이다. 가용성 문제에 더 가까운 두 연구가 있다. DIII-D의 액추에이터 조건부 프로파일 예보 [27]는 우리 모델처럼 인과적이고 이력 기반이지만, 제어를 위해 조밀하게 측정된 프로파일로부터 미래를 예보하며, 희소 채널의 복원이 아니다. RTCAKERN [28]은 실시간으로 운동학 프로파일 (불순물 온도, 회전 포함)을 재구성하고 dropout 학습으로 Thomson/CER 입력 소실을 견디지만, 거기서 결측은 입력을 0으로 만드는 강건성 조건인 반면, 우리 설정에서는 타겟 자신의 희소성이 문제 그 자체이며 타겟별 관측 플래그와 불규칙 시간 특징으로 명시적으로 추적된다. 세 갈래 모두의 공통 가정은 모델이 실행될 때 정보 소스가 존재한다는 것이다. 자기 자신의 측정이 없는 시점에서, 다른 채널들과 자신의 과거로부터 진단값을 복원하는 일은 이들의 범위 밖이다.

교차 진단 재구성과 시간 조밀화 (가장 가까운 선행 연구). 최근 한 계열은 다른 진단들로부터 특정 진단을 재구성한다. GP 기반 대체는 KSTAR에서 고장난 자기 센서를 밀리초 이하로 복원하고 [29], ML은 손상 센서를 탐지·보상하며 [30], 오토인코더는 중복 밀도 진단을 융합해 복원력을 얻고 [31], 시계열 외생 회귀는 EAST의 결측 전자온도를 채우며 [32], FusionMAE는 HL-3의 88개 채널에서 마스킹 채널 “가상 백업 진단”을 수행한다 [33]. 우리 프레임에 가장 가까운 것으로, Diag2Diag는 DIII-D에서 다른 동시각 진단들로부터 Thomson 산란 T_e/n_e 를 요동 진단 속도로 합성하고 [34], COMPASS에서는 고속 복사 진단으로부터 Thomson 프로파일의 시간 초해상이 시연되었으며 [35], PanoMHD는 제어를 위해 인과 트랜스포머로 멀티모달 신호 동역학을 모델링한다 [36]. 본 연구는 이 계열과 네 가지 축에서 다르며, 각 축은 인용 논문들의 명시된 범위에서 확인 가능하다: (i) 타겟 채널—이 계열의 모든 구성원은 전자 물리량 또는 일반 조밀 채널을 재구성하고 (34과 35의 Thomson T_e/n_e , 32의 ECE 형 T_e , 33의 임의 마스킹 채널), CER/CES가 등장하는 경우에도 어디까지나 입력이며 [34] 희소 타겟이 아니다; (ii) 인과성—Diag2Diag와 COMPASS 연구는 기억 없는 동시각 매핑이고 FusionMAE는 원도 내 재구성인 반면, 우리 모델은 타겟 자신의 불규칙한 과거에 조건화되며 미래를 절대 읽지 않는다; (iii) 평가 기준—어느 것도, 결측 채움에서 현직 방법인 타겟 채널의 미래 사용 보간을, 사전등록된 shot 군집 프로토콜로 이겨야 할 기준선으로 세우지 않는다; (iv) 정보 분석—재구성 가능성이 타겟별로 검정되지 않고 가정되는 반면, $T_i \leftrightarrow V_{\text{rot}}$ 비대칭은 우리의 중심 발견이다. 조사한 문헌 내에서 어느 장치에서도 희소 CXRS 이온 측정의 인과적 시간 결측 채움은 찾지 못했다; 이는 우리의 문헌 조사 결과로서 진술하는 것이지, 그러한 시도가 존재하지 않는다는 주장이 아니다.

불규칙 시간-마스킹 멀티태스크 학습. 본 설계는 불규칙 시계열 문헌의 표준 재료—관측 마스크와 감쇠 인지 순환 (GRU-D [37]), 연속시간 임베딩 위 어텐션 (mTAN [38]), 잠재 ODE 동역학 [39]—과 부분 라벨 멀티태스크 학습 [40], 후기 융합 멀티모달 구조 [41, 42], pre-LayerNorm 트랜스포머 [43], 어텐션 풀링 [44]을 차용한다. “나우캐스팅” 프레임은 기계학습 기상 예보에서의 용법을 따른다 [45, 46]. 새로움은 개별 재료가 아니라, 물리적으로 불리한 평가 프로토콜 아래에서의 누수 방지 조합에 있다.

3 데이터와 문제 설정

3.1 데이터셋

하드웨어 일관성을 위해 캠페인 #24000–#33000에서 우선 선정한 641개 KSTAR 방전 (shot) 파일을 사용하며, H-mode ELM 억제 (RMP) 구간을 타겟으로 D_α 활동 구간 주변 ~ 100 ms 세그먼트를 절단한다. 모든 신호는 공통 10 ms 격자에 정렬된다. 각 행은 BES [47] 9 채널, ECEI [48] 4 채널, Mirnov 코일 2 채널, 시간, 그리고 두 CES 타겟 T_i , V_{rot} [1]을 제공한다. 이 격자에서 T_i 는 약 8%, V_{rot} 은 약 24%의 행에서 독립적으로 결측된다 (그림 1).

CES is sparse (targets go missing independently); over half of observed V_{rot} values are instrument holds




Figure 1: 10 ms 격자에서의 CES 결측 구조. T_i 와 V_{rot} 은 독립적으로 결측되며 ($\approx 8\%$ / $\approx 24\%$), 행 필터링이 아닌 타겟별 마스킹을 요구한다.

3.2 샘플 구성

이력 원도 $W=4$ 의 타겟 인덱스 t 학습 샘플은 `bes` ($W, 9$), `ecei` ($W, 4$), `mc` ($W, 2$), `time_features` ($W, 4$), `ces_history` ($W, 4$), 정규화 타겟 $[T_i, V_{\text{rot}}] \in \mathbb{R}^2$, 타겟별 관측 마스크 $m \in \{0, 1\}^2$ 로 구성된다. 네 개의 시간 특징—lookback 초, 행간 delta 초, 그리고 각각의 $\log(1+x)$ 변환—은 불규칙 관측 패턴을 모델에 명시적으로 노출한다: 과거 CES 값의 신뢰도는 그것이 10 ms 전 값인지 200 ms 전 값인지에 강하게 의존한다. CES 이력의 네 채널은 직전 정규화 T_i , 직전 정규화 V_{rot} , 그리고 타겟별 관측 플래그이다 (두 타겟이 독립적으로 결측되므로 관측 여부는 타겟별로 추적해야 한다).

3.3 설계 원칙

가짜 라벨 금지. 학습 행을 만들기 위해 타겟을 대체 (impute) 하지 않는다. 행은 진단 입력이 완전하고 CES 타겟 중 적어도 하나가 실제로 관측된 경우에만 유지된다.

타겟별 마스킹 손실. 손실은 타겟별로 마스킹된다: $\mathcal{L} = \sum_{k \in \{T_i, V_{\text{rot}}\}} m_k (\hat{y}_k - y_k)^2 / \sum_k m_k$. 한 타겟만 관측된 행도 그 타겟은 학습에 기여한다. 이전의 두-타겟-필수 필터는 라벨 행의 $\approx 28\%$ 를 조용히 버렸다; 이를 제거한 것은 순수한 데이터 이득이다.

누수 방지. (i) 파일 단위 분할: 한 shot 내 인접 행은 강하게 자기상관되므로 분할은 shot 파일 단위로 이루어지고 디스크에 고정된다; (ii) 학습 파일 전용 정규화: 모든 z -score 통계 (희소 타겟은 NaN-인지)는 학습 파일에서만 추정된다; (iii) 타겟 시점 마스킹: `ces_history` 에서 타겟 시점의 값과 관측 플래그를 모두 0 으로 만들어, 모델이 자신의 정답을 읽을 수 없게 한다.

3.4 데이터 품질 감사: 유지 (forward-fill) 된 V_{rot} 값

후반 감사에서 **관측된 V_{rot} 값의 54% 가 계기 유지값임**이 밝혀졌다: 같은 연속 시간 블록 안에서 직전 관측과 비트 단위로 동일한 반복 (최대 1,214 행 연속, 641 개 중 499 개 파일 영향) 이다. V_{rot} 의 고유 측정 주기가 행 주기보다 느려 값이 이월된 것으로, 독립적인 측정이 아니다. T_i 는 영향이 없다 (0.0%). 통제된 A/B 재학습 결과 학습은 오염되지 않았다—학습 시 유지값을 마스킹해도 진짜 측정 성능이 개선되지 않고 (오히려 약간 저하), 유지값은 무해한 persistence 사전 역할을 한다—따라서 유지값은 학습에는 남기되 평가에서 제외한다. 이 보정으로 보고되는 물리 단위 V_{rot} RMSE 는 35–55% 커진다 (원시 단위 22–33 $\rightarrow$ 35–46). 유지 타겟의 기준선 오차가 0 에 가까웠기 때문이다. 이하 모든 결론은 보정된 (진짜 측정만의) 평가를 사용하며, T_i 헤드라인은 이 보정에 영향받지 않는다.

4 모델

예측기는 소형 (100 만 파라미터 미만) 후기 융합 네트워크다. 이 문제의 병목은 용량이 아니라 일반화다.

진단별 인코더. 각 모달리티 (BES, ECEI, MC) 는 시간 특징·이력과 함께 처리되는 전용 시간 인지 1-D CNN 으로 인코딩되며, 융합 전까지 각 진단의 채널 구조를 보존한다. 결측 제거로 유효 샘플링이 불규칙해져 균일 시간 간격을 가정하는 순환 구조가 부적합하므로 CNN 을 택했다.

이력 인코더. CES 이력은 학습된 위치 임베딩을 갖춘 2 층 pre-LayerNorm 트랜스포머 [43] 와 멀티헤드 어텐션 풀링 [44] 으로 인코딩되어, 어텐션 가중 평균과 가중 표준편차를 함께 출력한다. 후자는 “최근 이력이 국소적으로 얼마나 변동하는가” 를 드러내며, §6.5는 바로 그곳에서 모델이 우위를 얻음을 보인다. (마스킹된) 타겟 시점과 관측 이웃들 사이의 self-attention 은 학습된 보간과 유사한 연산을 수행하며, 타겟별 관측 이웃 바이어스를 갖는다.

물리 기반 타겟별 라우팅. T_i 헤드는 고속 진단 + 시간 + 이력을 융합하지만, V_{rot} 헤드는 이력과 시간만 융합하고 고속 진단을 의도적으로 배제한다. 절제 실험 (§6.4) 이 고속 진단에 10 ms 에서 쓸 만한 회전 정보가 없음을 보이기 때문이다. 각 타겟은 자체 pre-LayerNorm MLP 헤드를 갖고, 출력은 정규화 단위로 유지된다 (역정규화는 평가에서만 수행).

탐색에서 얻은 교훈. ~40 회의 통제된 아키텍처 반복에서, pre-LayerNorm 이 안정성의 전환점이었고 (검증 손실 0.89 → 0.49), 어텐션 풀링이 가장 신뢰할 만한 단일 개선이었으며, 공격적 용량 확장·복잡한 스킵 위상·추가 합성곱 추출기는 일관되게 held-out 성능을 개선하지 못했다.

5 평가 방법론

지표. 모든 오차는 물리 CES 단위로 역정규화되어 타겟별로 계산된다. 1 차 점수는 사전등록된 헤드라인 기준선에 대한 Murphy skill [13], $skill_{PCHIP} = 1 - MSE_{model}/MSE_{PCHIP}$ (양수 = 모델 우위; 0 = 동률) 이다. 모든 팔 (모델과 모든 기준선) 은 동일한 (파일, 행) 샘플 집합에서 동일한 타겟별 유지 마스크로 채점된다. 보간은 타겟 자신의 값을 제외하며 (누수 없음), $\geq 0.5s$ 간극은 보간을 거부하고 persistence 로 후퇴한다.

3 분할; 선택은 TEST 를 보지 않는다. 파일들은 train/val/test 로 분할된다. test 셋은 아키텍처 탐색 이전에 예약되었고 탐색 루프가 절대 읽지 않으므로, 헤드라인 수치에는 선택 편향 (winner’s curse) 이 없다. 표준 test 셋은 96 개 shot 의 34,644 개 채점 샘플을 담는다 (관측 n : T_i 32,716, V_{rot} 27,437).

사전등록. test 수치를 보기 전에 네 규칙을 문서로 고정했다: **PR1** 헤드라인 비교 대상은 PCHIP(과도 현상에서의 단조성·무진동을 근거로 사전 선택; 사다리 전체 {persistence, 선형, PCHIP, AR} 도 보고); **PR2** 보간은 모델이 채점되는 모든 곳에서 예측하며, 미래 이웃이 없으면 persistence 로 후퇴 (모집단 축소 없음); **PR3** test 셋 최소 규모 (≥ 15 shot, $\geq 3,000$ 관측 T_i 샘플; 충족); **PR4** 유의성은 skill 에 대한 shot 군집 bootstrap 95% CI 가 0 을 제외하는 것으로 정의.

Shot 군집 paired bootstrap. 한 방전 내 인접 CES 행은 강하게 상관된다. 샘플을 독립으로 취급하면 불확실성이 크게 과소평가된다. 샘플별 짝지은 오차 $SE_{model} - SE_{PCHIP}$ 를 shot 단위로 집계하고, shot 전체를 복원추출로 대표본한다 (10,000 회, 고정 시드). 얻어진 CI 는 진짜 shot 간 일반화를 반영한다. 대가는 유효 표본 크기가 shot 수 (≈ 96) 가 된다는 것이며, 이것이 전체 유의성 판정의 검정력을 제한한다.

정직한 주의 (MNAR). 진짜 결측 시점에는 참값이 없으므로 skill 은 관측된 시점을 가려 측정한다. CES 결측은 MNAR 이므로 (저신호, ELM, 천이에서 탈락) 관측 시점 skill 은 진짜 결측 시점 성능의 낙관적 상한이다. 우리는 이를 숨기지 않고 명시한다.

6 결과

6.1 모델은 모든 인과 기준선을 압도한다

표 1는 표준 test 분할에서의 물리 단위 RMSE 사다리를 보여준다. 모델은 두 타겟 모두에서 최저 RMSE 를 가지며, 인과 기준선—persistence 와 과거 전용 AR, 즉 실시간에서 실제로 사용 가능한 모든 것—을 큰 차이로 이긴다. 이는 본 논문에서 가장 강건한 결과다: 미래 CES 가 정의상 없는 온라인 환경에서 모델은 명백한 승자다.

Table 1: 표준 held-out test 분할의 물리 단위 RMSE 사다리 (개선 전 기준 모델; 최종 모델은 더 개선됨, §6.2 참조). 낮을수록 좋다. 이 표의 V_{rot} RMSE 는 §3.4의 유지값 보정 이전 수치이며, 보정된 진짜 측정만의 V_{rot} RMSE 는 35–46 이다.

팔	정보 접근	T_i RMSE	V_{rot} RMSE
모델 (나우캐스터)	고속 진단 + 과거 CES	412.4	23.2
선형 보간	과거 + 미래 CES	422.7	24.0
PCHIP 보간	과거 + 미래 CES	431.8	24.5
Persistence	마지막 관측 CES	487.3	27.8
AR (국소, 인과)	과거 CES 만	1005.7	57.2

Final model (seed 42): lowest RMSE in the full baseline ladder (physical units)



Figure 2: 최종 모델 (시드 42, test 분할) 의 RMSE 사다리: 인과 모델이 두 타겟 모두 최저 RMSE 를 달성 하여 인과 기준선을 결정적으로 이기고, 미래를 쓰는 보간도 점추정에서 앞선다. 표 1은 초기 기준 모델의 동일 사다리로, 절대값이 다른 이유다.

6.2 헤드라인: T_i 는 4 개 독립 분할에서 미래를 쓰는 보간을 이긴다

최종 아키텍처 (GRU 이력 인코더 + 타겟별 멀티헤드 어텐션 헤드, $W=4$; §7의 탐색 루프가 검증 skill 만 으로 선택) 로 독립적인 4 개 held-out test 분할 (시드 42, 1, 7, 123; 뒤의 셋은 어떤 선택 단계에도 사용되 지 않음) 을 평가했다:

- T_i : 4 개 분할 모두 PASS. $\text{skill}_{\text{PCHIP}} = +0.270$ (95% CI [+0.144, +0.364]), +0.200, +0.271, +0.295; 모든 shot 군집 CI 가 PCHIP 과 선형 모두에 대해 0 을 제외한다. 진짜 측정만의 재평가에서도 생존 한다 (+0.225/ +0.204/ +0.285/ +0.288, 모두 PASS).
- V_{rot} : 어느 분할에서도 유의하지 않음. 점추정은 양수지만 모든 CI 가 0 을 포함한다. 우리는 승리가 아니라 동률을 주장한다.

정직한 진행 기록: 초기 기준 모델은 유의하지 않았다 (단일 분할, +0.088, n.s.). 아키텍처 탐색의 선택 게이트를 검증 손실에서 깨끗한 보간 대비 skill 로 바꾼 것이 최종 모델을 낳았고, 이것이 4 개 분할 모두에 서 유의하다 (그림 4). 두 단계를 모두 보고한다.

6.3 skill 이 사는 곳: 작은 간극이 지배한다

마지막 관측 CES 이후 경과 시간으로 총화하면, 실제 타겟의 $\geq 97\%$ 가 작은 간극 영역 ($\Delta t \leq 15$ ms) 에 있 으며 거기서 모델이 이긴다 (표준 분할에서 PCHIP 대비 T_i +0.08, V_{rot} +0.23). 매우 큰 간극 (>105 ms) 에 서는 미래 앵커를 가진 보간이 압도하지만, 해당 구간의 표본은 수십 개에 불과하고 구간별 CI 도 없어 결 론을 지탱하지 않는다. 검정력이 확보된 유일한 비교—작은 간극, 즉 나우캐스팅이 실제로 필요한 곳—는 모델의 손을 들어준다.




Figure 3: 4 개 독립 held-out 분할에서 shot 군집 95% CI 와 함께 나타낸 $\text{skill}_{\text{PCHIP}}$ 의 포레스트 플롯. T_i 는 4 개 모두에서 0 을 제외; V_{rot} 은 하나도 제외하지 못한다.




Figure 4: 비유의 (기준 모델, +0.088 n.s.) 에서 유의 (최종 모델, +0.20—+0.30, PASS $\times 4$) 로: 결정적 변화는 검증 손실이 아닌 깨끗한 skill 로 아키텍처를 선택한 것이었다.

6.4 $T_i \leftrightarrow V_{\text{rot}}$ 정보 비대칭

통제된 입력 모달리티 절제 (동일한 학습 예산; 한 번에 한 모달리티 그룹을 0 으로; persistence 는 항상 실제 이력에서 계산) 는 두 타겟이 다르게 행동하는 이유를 설명한다 (표 2, 그림 5).

- T_i : **고속 진단이 진짜 정보를 운반한다.** 고속 단독으로도 persistence 를 이긴다 (+0.16). 물리적 채널은 충돌성 전자-이온 결합 ($t_{ei} \propto T_e^{3/2}/n_e$) 이다: ECEI 가 T_e 를, BES 가 n_e 구조를 공급한다.
- V_{rot} : **정보가 거의 전적으로 CES 이력에 있다.** 고속 단독은 -3.31 (평균 예측보다 나쁨) 이다. 토로이달 회전은 우리 입력이 관측하지 못하는 운동량 소스—외부 NBI 토크와 고유 (intrinsic) 회전 구동 [49]—이 지배하며, Mirnov 신호는 100 Hz 로 샘플되어 회전을 대리할 수 있었을 kHz 모드 회전 주파수가 앨리어싱으로 사라진다.

이 비대칭은 절제 이전에 물리로 예측되었고 절제로 확인되었다. V_{rot} 의 비-승리는 모델 실패가 아니라 진단 정보 내용에 관한 발견이며, §4의 타겟별 라우팅을 동기화한다.

6.5 우위는 고변동 국소 구간에 집중된다

타겟과 무관한 입력 측 국소 활동 대리변수 (타겟 행을 제외하고 계산한 큰 이웃 괄호 기울기 및/또는 높은 국소 CES 이웃 분산) 로 평가를 “피크”(고활동) 와 벌크 영역으로 나누면 (검증 분할, shot 군집 CI; 그림 6):

- T_i : 전역 +0.52 $\rightarrow$ 피크 +0.86 (CI [+0.66, +0.93], PASS). 보간은 매끄러운 벌크에서 거의 최적이고, 모델의 가치는 활동 구간에 있다.

Table 2: 입력 모달리티 절제 (검증 분할, persistence 대비 skill, 물리 단위). 고속 진단 단독은 진짜 T_i 정보를 운반하지만 V_{rot} 에는 파국적으로 무정보하다.

모델 입력	T_i skill	V_{rot} skill
전체 (이력 + 고속 + 시간)	+0.36	+0.18
이력만 (<i>no fast</i>)	+0.39	+0.23
고속 진단만 (<i>no history</i>)	+0.16	-3.31




Figure 5: 모달리티 절제: 고속 진단 단독은 T_i 에서 persistence를 이기지만 V_{rot} 에서는 평균보다 훨씬 나쁘다 — 정보 비대칭.

- V_{rot} : 전역 +0.24 → 피크 **+0.69** (CI [+0.11, +0.87], PASS, 세 가지 민감도 설정에서 강건하나 하한이 얇음). 따라서 비대칭은 지역적이다: 전역적으로 V_{rot} 은 보간과 동률이지만, 매끄러운 과거 + 미래 보간이 가장 나쁜 고활동 구간에서는 이력 기반 V_{rot} 예측기도 가치를 더한다. 이는 낙관 주의가 붙은 검증 분할에서의 지역적 강점으로 보고하며, 전역 영결과의 반전이 아니다.
- 피크 한정 절제 (BES/ECEI/MC를 0으로)는 T_i 를 유의하게 해치지만 (짜지은 차이 CI $\gg 0$) V_{rot} 은 불변이다: T_i 피크 우위는 실제로 멀티모달 신호를 사용하고, V_{rot} 피크 우위는 이력 기반이다.

7 탐색 방법: LLM 기반 keep/discard 루프

최종 아키텍처는 LLM이 연구자 역할을 맡는 자동 연구 루프 (autoresearch 식 keep/discard 프로토콜에서 영감)로 발견되었다. 각 반복은: (i) 현재 제안을 스모크 검증하고 완전 학습한다; (ii) 깨끗한, 비증강 검증 $\text{skill}_{\text{PCHIP}}$ 로 채점한다—증강 검증 손실은 절대 쓰지 않고, 어떤 test 분할도 쓰지 않는다; (iii) 최고 점수를 갱신하면 **유지 (keep)**, 아니면 **폐기 (discard)** 하고 `model.py`를 최고 스냅샷으로 되돌린다; (iv) 실행 이력, 제안이 보존해야 하는 하드 데이터 계약 (인터페이스, 마스킹, 누수 규칙), 누적 프로젝트 지식을 LLM에 브리핑하고 하나의 통제된 변경을 요청한다. 따라서 루프는 절대 회귀 위에 쌓지 않으며, 학습 실패는 증거가 아닌 수리 신호로 취급된다. 이 루프의 구체적 기여는 그림 4의 비유의 → 유의 진행이다. 우리는 이를 과학적 기여가 아닌 재현성 인프라로 문서화한다.

8 한계

통계적 검정력. 재현 단위는 shot이며, test에 $\approx 96(T_i) / 91(V_{\text{rot}})$ 개뿐이다. 검정력이 모든 유의성 판정을 제한하고, shot 별 제곱오차 차이는 두꺼운 꼬리를 가진다 (소수의 방전이 bootstrap 산포를 지배). **MNAR 낙관성.** skill은 관측 시점에서만 측정되며, 진짜 결측 시점은 더 어려울 수 있다. **지표 비대칭.** 보간은 shot 전체 이웃을 쓰는 반면 모델은 $W=4$ 이력만 본다. 의도적으로 모델에 불리한 설계지만 해석을 복잡




Figure 6: 전역 대 고변동 (“피크”) skill 과 shot 군집 95% CI. 보간이 가장 약한 곳에 모델의 우위가 집중되며, V_{rot} 은 전역 동물에도 불구하고 피크에서 통과한다.

하게 한다. **단일 아키텍처와 원도.** W 와 아키텍처에 대한 민감도는 특성화되지 않았다. 큰 간극 구간은 수십 개의 표본과 CI 부재로 신뢰할 수 없다. **범위.** 페데스탈-상단 프레이밍은 데이터 선택 (페데스탈-상단 CES 채널) 에서 상속된 것이며, 반경 방향 의존성 실험은 수행하지 않았다. 이벤트 위상 분석 (ELM 주기, L-H 천이) 은 향후 과제다—§6.5의 고변동 분석은 이벤트 불특정 대리 분석이다.

9 결론

우리는 희소한 KSTAR CES 타겟을 위한 인과적-누수 방지 멀티모달 나우캐스터를 구축하고, 의도적으로 불리한 기준선—미래를 보는 보간—에 대해 사전등록된 shot 군집 프로토콜로 평가했다. 모델은 모든 인과 기준선을 결정적으로 이긴다. 이온온도에 대해서는 미래를 쓰는 PCHIP 보간도 유의하고 재현된 skill (+0.20–+0.30; 4 개 독립 분할) 로 이기는 반면, 토로이달 회전은 물리적으로 규명된 이유—고속 진단이 10 ms 에서 회전 정보를 운반하지 않음—로 보간과 동물이다. 우위는 결측 채움이 실제로 중요한 곳, 즉 작은 간극과 고변동 구간에 정확히 집중된다. 헤드라인 너머로, 본 연구는 보정된 V_{rot} 평가 (54% 계기 유지값), 정보 비대칭 절제, LLM 기반 keep/discard 탐색 프로토콜을 기여한다. 향후 과제는 검정력 한계 해소 (더 많은 test shot, 다중 캠페인 데이터), 고속 진단 정보의 한계 가치가 최대인 영역을 분리하는 bracket-distance 증화, 피크 가중 학습, 그리고 이력을 더 잘 활용하는 회전 측 개선이다—센서를 늘리는 것으로는, 입증된 바와 같이, 이 시간 규모에서 V_{rot} 을 도울 수 없기 때문이다.

재현성

분할은 디스크에 고정되고 재로드 시 검증된다; 정규화 통계는 학습 파일 전용이다; 탐색 루프는 test 데이터를 읽지 않는다; bootstrap 은 고정 시드와 10,000 회 대표본을 쓴다; 모든 헤드라인 수치는 동결된 평가 산출물에서 읽는다. 코드와 평가 산출물은 투고와 함께 제공되며, 공개 저장소 링크는 camera-ready 에 삽입한다.

References

- [1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81:10D740, 2010. doi: 10.1063/1.3496991.
- [2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.

- [3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2):238–246, 1980. doi: 10.1137/0717021.
- [4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.
- [5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.
- [6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.
- [7] R. L. Dougherty, A. S. Edelman, and J. M. Hyman. Nonnegativity-, monotonicity-, or convexity-preserving cubic and quintic Hermite interpolation. *Mathematics of Computation*, 52(186):471–494, 1989. doi: 10.1090/S0025-5718-1989-0962209-1.
- [8] C. H. Reinsch. Smoothing by spline functions. *Numerische Mathematik*, 10(3):177–183, 1967. doi: 10.1007/BF02162161.
- [9] G. Kvernadze. Convergence and Gibbs’ phenomenon in cubic spline interpolation of discontinuous functions. *Journal of Computational and Applied Mathematics*, 92(2):173–188, 1998. doi: 10.1016/S0377-0427(97)00199-4.
- [10] S. Eyheramendy, F. Elorrieta, and W. Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481(4):4311–4322, 2018. doi: 10.1093/mnras/sty2487.
- [11] F. Elorrieta, S. Eyheramendy, and W. Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, 2019. doi: 10.1051/0004-6361/201935560.
- [12] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, 3rd edition, 2007.
- [13] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.
- [14] Chris Bishop, C.M. Roach, and M. G. von Hellermann. Automatic analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 35:765–773, 1993. doi: 10.1088/0741-3335/35/6/010.
- [15] J. Svensson, M. von Hellermann, and R. König. Analysis of JET charge exchange spectra using neural networks. *Plasma Physics and Controlled Fusion*, 41:315–338, 1999. doi: 10.1088/0741-3335/41/2/016.
- [16] Baoyue Chai, Yingying Li, Ze Chen, Wei Tao, Yixuan Zhou, Shifeng Mao, Zhengping Luo, Yi Yu, Bo Lyu, and Minyou Ye. Fast estimation of ion temperature from EAST charge exchange recombination spectroscopy using neural network. *Plasma Science and Technology*, 21:105103, 2019. doi: 10.1088/2058-6272/ab2674.
- [17] A. Pavone, J. Svensson, A. Langenberg, U. Höfel, S. Kwak, N. Pablant, and R. C. Wolf. Neural network approximation of Bayesian models for the inference of ion and electron temperature profiles at W7-X. *Plasma Physics and Controlled Fusion*, 61:075012, 2019. doi: 10.1088/1361-6587/ab1d26.
- [18] Mark D. Boyer and Jason D. Chadwick. Prediction of electron density and pressure profile shapes on NSTX-U using neural networks. *Nuclear Fusion*, 61:046024, 2021. doi: 10.1088/1741-4326/abe08b.

- [19] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64:106061, 2024. doi: 10.1088/1741-4326/ad73e8.
- [20] Francisco A. Matos, Diogo R. Ferreira, and P. Carvalho. Deep learning for plasma tomography using the bolometer system at JET. *Fusion Engineering and Design*, 114:18–25, 2016. doi: 10.1016/j.fusengdes.2016.11.006.
- [21] Cong Wang, Weizhe Yang, Haiping Wang, Renjie Yang, Jing Li, Zhijun Wang, Yixiong Wei, Xianli Huang, Chenshu Hu, Zhaoyang Liu, Xinyao Yu, Changqing Zou, and Zhifeng Zhao. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 65:076022, 2025. doi: 10.1088/1741-4326/ade0ce.
- [22] Xishuo Wei, Shuying Sun, W. M. Tang, Zhihong Lin, Hongfei Du, and Ge Dong. Reconstruction of tokamak plasma safety factor profile using deep learning. *Nuclear Fusion*, 63:086020, 2023. doi: 10.1088/1741-4326/acdf00.
- [23] G.H. Zheng, Zongyu Yang, Songfen Liu, Rui Ma, Xinwen Gong, Ao Wang, Shuo Wang, and W.L. Zhong. Real-time equilibrium reconstruction by multi-task learning neural network based on HL-3 tokamak. *Nuclear Fusion*, 64:126041, 2024. doi: 10.1088/1741-4326/ad8014.
- [24] S. Joung, J. Kim, S. Kwak, J. Bak, S. Lee, H. Han, H. Kim, G. Lee, D. Kwon, and Y. Ghim. Deep neural network Grad-Shafranov solver constrained with measured magnetic signals. *Nuclear Fusion*, 2020.
- [25] Semin Joung, Young chul Ghim, Jaewook Kim, S. Kwak, Daeho Kwon, Chih-Jen Sung, Dong Ju Kim, Hyun-Seok Kim, J.G. Bak, and S.W. Yoon. GS-DeepNet: mastering tokamak plasma equilibria with deep neural networks and the Grad-Shafranov equation. *Scientific Reports*, 13:15799, 2023. doi: 10.1038/s41598-023-42991-5.
- [26] L. Jung, Jaewook Kim, and Jisung Kang. Machine learning-based plasma profile reconstruction in KSTAR. *Journal of the Korean Physical Society*, 88:1079 – 1087, 2026. doi: 10.1007/s40042-026-01580-1.
- [27] Joseph Abbate, Rory Conlin, and Egemen Kolemen. Data-driven profile prediction for DIII-D. *Nuclear Fusion*, 61:046027, 2021. doi: 10.1088/1741-4326/abe08d.
- [28] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2023. doi: 10.1088/1741-4326/ad142f.
- [29] Semin Joung, Jaewook Kim, S. Kwak, Kyeo reh Park, S.H. Hahn, Hyunsun Han, Hyun-Seok Kim, J.G. Bak, S. G. Lee, and Young chul Ghim. Imputation of faulty magnetic sensors with coupled Bayesian and Gaussian processes to reconstruct the magnetic equilibrium in real time. *Review of Scientific Instruments*, 89:10K106, 2018. doi: 10.1063/1.5038938.
- [30] Debashish Mohapatra, Bidyadhar Subudhi, and Raju Daniel. Real-time sensor fault detection in Tokamak using different machine learning algorithms. *Fusion Engineering and Design*, 151:111401, 2019. doi: 10.1016/j.fusengdes.2019.111401.
- [31] S. Kaldas, R. Rossi, I. Wyss, M. Gelfusa, and P. Gaudio. Developing autoencoder models for multi-diagnostic electron density processing in tokamaks within a scientific machine learning framework. *Journal of Fusion Energy*, 45, 2026. doi: 10.1007/s10894-026-00568-w.
- [32] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.

- [33] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Nian-nian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.
- [34] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.
- [35] M. Imříšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiland, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.
- [36] HyeonJun Noh, Chweeho Heo, Xiaotian Gao, and Yong-Su Na. PanoMHD: Multimodal modelling of plasma dynamics towards Tokamak control. 2026.
- [37] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.
- [38] Satya Narayan Shukla and Benjamin M. Marlin. Multi-time attention networks for irregularly sampled time series. 2021:14897–14911, 2021. doi: 10.48550/arxiv.2101.10318.
- [39] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. 32:5320–5330, 2019.
- [40] Rich Caruana. Multitask learning. *Machine Learning*, 28:41–75, 1997. doi: 10.1023/a:1007379606734.
- [41] Jiquan Ngiam, Aditya Khosla, Mingyu Kim, Juhan Nam, Honglak Lee, and Andrew Y. Ng. Multimodal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 2011.
- [42] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41:423–443, 2018. doi: 10.1109/tpami.2018.2798607.
- [43] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Xing Chen, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [44] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. 2018. doi: 10.48550/arxiv.1802.04712.
- [45] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. 2015. doi: 10.48550/arxiv.1506.04214.
- [46] Suman Ravuri, Karel Lenc, Matthew Willson, Dmitry Kangin, Rémi Lam, Piotr Mirowski, M. A. Fitzsimons, Maria Athanassiadou, Sheleem Kashem, Sam Madge, Rachel Prudden, Amol Mandhane, Aidan Clark, Andrew Brock, Karen Simonyan, Raia Hadsell, N. Robinson, Ellen Clancy, Alberto Arribas, and Shakir Mohamed. Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597: 672–677, 2021. doi: 10.1038/s41586-021-03854-z.
- [47] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.
- [48] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.

- [49] J. E. Rice, A. Ince-Cushman, J.S. deGrassie, L.-G. Eriksson, Y. Sakamoto, A. Scarabosio, A. Bortolon, K.H. Burrell, B.P. Duval, C. Fenzi-Bonizec, M. Greenwald, R. J. Groebner, G. T. Hoang, Y. Koide, E. S. Marmor, A. Pochelon, and Y. Podpaly. Inter-machine comparison of intrinsic toroidal rotation in tokamaks. *Nuclear Fusion*, 47:1618–1624, 2007. doi: 10.1088/0029-5515/47/11/025.