KSTAR 10 ms 전하교환분광 결측 채움: 같은 위치 고속 진단에서 읽는 이온온도, 자기 이력에서 읽는 회전, 그리고 20-parameter 대리 필터

이승상 (Seungsang Lee)
서울대학교 원자핵공학과 lss010330@snu.ac.kr

초록

전하교환분광(CES)은 KSTAR의 이온온도 T_i와 토로이달 회전 $V_{\rm rot}$을 한 채널(R = 2.198 m)에서 준다. 2022년 캠페인 방전 641개의 10 ms 격자에서 T_i 표본의 8.2%, $V_{\rm rot}$ 표본의 23.9%가 결측이다. 우리는 다음 CES 측정 없이 한 스텝을 채워야 할 때, 그 채널에서 1.5 cm 안에 있는 빔방출분광(BES)과 전자사이클로트론방출영상(ECEI) 채널이 과거 CES에 무엇을 더하는지 묻는다. 2분기 LSTM은 T_i에 대해 고속 채널(각 방전 자신의 통계로 표준화하며, 이는 오프라인 단계다)과 과거 CES를 읽고, $V_{\rm rot}$에 대해서는 과거 CES만 읽는다. T_i의 평균 제곱 오차 skill은 과거 CES의 인과 가우시안 과정 평활기 대비 +0.113 [+0.085, +0.132](95% 구간, 방전 639개의 재분할 8벌)이고, PCHIP 보간 대비 +0.221 [+0.188, +0.248]인데 그 절반가량은 과거 CES의 1-parameter 이동 평균이 이미 준다. 오프라인 가우시안 과정 대비로는 −0.010 [−0.043, +0.014]이다. 고속 채널은 동시각 100 ms 고역 통과 응답으로 들어오며, 그 위에 세운 20-parameter 대리 필터는 PCHIP 대비 skill의 72–78%를 유지한다. 이득은 꼬리에 있다. 중앙값 행에서 오차는 persistence와 같다. $V_{\rm rot}$에서는 고속 채널 증분과 $V_{\rm rot}$ 증분의 잡음 보정 상관이 10–200 ms의 모든 시차와 윈도에서 $|r| \le 0.044$로 묶인다(T_i: $\ge +0.13$). 피팅 실패에 앵커된 0.05%의 행을 빼면 이력만 쓰는 추정의 skill은 persistence 대비 +0.265 [+0.198, +0.326], 인과 평활기 대비 +0.151 [+0.038, +0.290]이며, 등록된 PCHIP 대비 skill은 그 행들이 실어 나른다. 한 장치, 한 캠페인, 한 채널의 결과다.

1. 서론

이온온도 T_i와 토로이달 회전 $V_{\rm rot}$은 페데스탈 구조, ELM 거동, 고성능 운전 영역 접근을 지배한다. 두 물리량은 전하교환분광(CES) [1]으로 측정되며, CES는 전하교환 선의 도플러 확장에서 T_i를, 도플러 이동에서 $V_{\rm rot}$을 추정한다. CES는 광자를 적분해야 하므로 느리고 간헐적으로 결측된다. KSTAR 10 ms 격자에서 T_i 관측의 8.2%, $V_{\rm rot}$ 관측의 23.9%가 서로 독립적으로 결측되고, $V_{\rm rot}$ 행의 41.1%는 여기에 더해 직전 값을 비트 단위로 반복하므로 독립적인 $V_{\rm rot}$ 측정을 담은 격자는 35.0%뿐이다. 결측률은 인접 스텝 변화의 오분위를 따라 0.77%에서 4.45%로 오르고, BES 세기 최하위 오분위에서 19.9%, 최상위 오분위에서 3.7%다. 즉 무작위적이지 않은 결측(MNAR)이다 [2]. 한편 빔방출분광(BES), 전자사이클로트론방출영상(ECEI), Mirnov 코일은 같은 플라즈마를 결측 없이 보지만, 어느 것도 T_i나 $V_{\rm rot}$을 측정하지 않는다. 본 논문의 질문은 이것이다. *CES가 결측된 10 ms 시점에서, 동시각 고속 진단은 불규칙한 과거 CES에 무엇을 더하는가?* 쓰임새는 다음 CES 노출을 기다릴 수 없는 추정이다. 오프라인에서는 양쪽 이웃을 읽는 잡음 인지 평활기가 같은 평균 오차에 이른다(§6.2).

비교 대상. 배치 가능한 비교 대상은 과거 CES만 읽는다. persistence, 이동 평균, 과거 CES 값 16개 위의 인과 가우시안 과정(GP)이다. 선형 보간, PCHIP [3] 보간, 오프라인 GP는 양쪽 이웃을 읽으며 오프라인 참조로 쓴다. PCHIP은 잡음 낀 앵커를 정확히 지나므로, 과거 CES만 쓰는 평활기도 이미 PCHIP 대비 이득을 얻는다(이동 평균의 PCHIP 대비 +0.05 ~ +0.17, 컷, 3/4 분할에서 구간이 0 제외). 따라서 고속 진단의 기여를 가르는 비교는 인과 GP다.

모든 결과는 두 공동 1차 모집단에서 보고한다. *컷*은 3 keV를 넘는 T_i 행 0.53%(스펙트럼 피팅 실패)를 모든 팔에서 결측으로 처리하고, *포함*은 그대로 둔다(§3). 포함 모집단의 추가 여유는 대부분 스파이크 처리에서 온다.

주장. *(1) 이온온도.* 같은 위치의 BES와 ECEI는 과거 CES에 동시각 과도 신호를 더한다. 인과 GP 대비 skill은 +0.113 [+0.085, +0.132](컷), +0.118 [+0.076, +0.157](포함)이고, 20-parameter 대리 필터는 PCHIP 대비 skill의 72–78%를 유지한다(컷. 그 형태는 사후에 골랐다). *(2) 회전.* 같은 채널은 10–200 ms에서 검출 가능한 $V_{\rm rot}$ 정보를 담지 않으며, 그 채널이 $V_{\rm rot}$에 닿게 하면 4/4 분할에서 skill을 잃는다. $V_{\rm rot}$은 자기 이력에서 추정하고(persistence 대비 skill +0.265 [+0.198, +0.326], 컷, 피팅 실패 행 제외), 그 10 ms 산포는 가우스 선 맞춤의 잡음 바닥과 맞는다. 평가(두 공동 1차 모집단, shot 군집 paired bootstrap, 겹침 보정 반복 교차검증 구간, 두 단계 bootstrap, §5)는 표준 조각을 조립한 것으로, 주장이 아니라 방법으로 기술한다. 코드와 평가 산출물은 공개하며, KSTAR shot 파일은 재배포할 수 없다.

2. 관련 연구

결측 채움과 기준선. GP 회귀 [4]는 핵융합 프로파일 피팅의 표준 도구로 [5, 6], KSTAR CES T_i 프로파일에도 적용되었다 [7]. PCHIP [3]은 계단에서 스플라인 진동을 피한다. 점수는 Murphy skill [8]이다. persistence 기준은 핵융합 프로파일 예보 [9]와 우주기상 [10]에 선례가 있다.

신경망 진단 추론. NN-CES는 빔 변조 없이 KSTAR CES 스펙트럼에서 T_i와 회전을 추출한다 [11]. 가장 가까운 선행 연구이며 해당 시점의 측정 스펙트럼을 필요로 한다. *NN-CES는 측정된 시점을 더 잘 읽고, 본 연구는 측정되지 않은 시점을 채운다.* Lin et al. [12]는 EAST에서 X선 결정 분광기를 T_i와 회전으로 사상하는데, 같은 광자 채널의 동시각 사상이다. RTCAKENN [13]은 운동 프로파일을 실시간으로 재구성하며 Thomson/CER 입력의 탈락을 견딘다. 거기서 결측은 강건성 조건이고, 여기서는 타겟 자신의 희소성이 문제다.

교차 진단 재구성. Diag2Diag는 DIII-D에서 동시각 진단으로 Thomson T_e/n_e를 합성하며 [14] 기억 없는 MLP를 쓴다. 관련 연구는 COMPASS에서 Thomson을 조밀화하고 [15], TCV에서 확장 칼만 필터로 Thomson 간격을 인과적으로 채우며 [16], EAST의 T_e와 Z_{eff}를 복원하고 [17, 18], HL-3에서 채널을 마스킹한다 [19]. 이들의 대상은 전자 채널이나 일반적인 조밀 채널이다. 본 연구는 이 계보를 희소한 이온 채널로, 타겟 자신의 불규칙한 과거를 조건으로 하는 추정으로, 사전등록 기준선에 대한 타겟별 검정으로 확장한다. 우리는 이 결합의 선례를 찾지 못했으며, "찾지 못함"은 "없음"이 아니다.

방법의 계보. 관측 마스크는 GRU-D [20]를 따른다. 겹침 보정 구간은 [21]의 것이고, 반복을 먼저 뽑고 방전을 다시 뽑는 재표집은 계층 bootstrap이며 [22], 대리 필터의 유지 검정은 [23]의 고정점 판독을 따른다.

3. 데이터와 문제 설정

10 ms 격자에 정렬한 KSTAR 방전 파일 641개(shot 30801–32751), 총 247,207행을 사용한다. 각 행은 BES [24] 9채널, ECEI [25] 4채널, Mirnov 코일 2채널, 시간, 두 CES 타겟을 담는다. T_i는 행의 8.2%, V_{rot}은 23.9%에서 서로 독립적으로 결측되므로 손실은 타겟별로 마스킹한다 (그림 1). 두 CES 타겟은 모두 $R = 2.198$ m의 2022년 채널이다. BES 9채널과 ECEI 4채널은 그 채널에서 약 1.5 cm 안에 있고, Mirnov 입력 둘은 한 토로이달 위치에 있는 폴로이달 배열 하나의 두 위치다. 행은 ≥ 0.5 s 간극에서 연속 세그먼트로 묶이며, 어떤 팔도 간극을 넘지 않는다.

유지된 V_{rot} 값. 관측된 V_{rot} 값의 54%는 직전 관측의 비트 단위 반복이다 (최대 1,214행 연속, 641개 중 499개 파일). 파일은 그 이유를 기록하지 않는다. T_i와 V_{rot}의 마스크는 행의 72.8%에서 일치하므로 두 채널은 따로 후처리된다. T_i의 유지값은 226,991행 중 1행이다. 유지값은 타겟, 이력 입력, 정규화 통계, 모든 기준선의 앵커 등 모든 *곳에서* 제거되므로, 어떤 팔도 forward-fill로 공짜 점수를 받지 않는다.

피팅 실패와 두 모집단. **T_i 1,197행(0.53%)이 3 keV를 초과한다**(274개 방전의 951개 런, 런의 85%는 단일 행). 이는

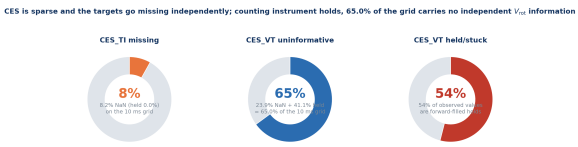


그림 1: 10 ms 격자의 CES 결측. T_i와 V_{rot}은 서로 독립적으로 결측되며(8.2% / 23.9%), 유지값까지 세면 격자의 65.0%가 독립적인 V_{rot} 정보를 갖지 않는다.

실패한 스펙트럼 피팅이며 보간 앵커도 오염시킨다. 우리는 **두 공동 1차 모집단**을 사전등록했다. *컷*(>3 keV를 모든 팔에서 결측 처리)과 *포함*(컷 없음)이며, 주장은 두 모집단 모두에서 성립할 때만 조건 없이 진술한다. 임계값은 2.5–4 keV에서 결과를 바꾸지 않는다(평균 T_i skill +0.230, +0.232, 3 keV에서는 +0.236).

4. 모델

주 모델 `seq_v2`는 357,570 파라미터의 시퀀스 나우캐스터다. 이 절은 무엇을 추정하는지, 왜 입력이 각 타겟에 그렇게 배선되는지, 모델이 어떤 시간 척도 위에 놓이는지, 그리고 그 T_i 분기의 20-parameter 대리 식을 정한다.

4.1. 추정 대상, 손실, 그리고 환원 불가능한 하한

격자 시각 t에서 모델은 정규화 타겟 $y_t = [T_i, V_{\mathrm{rot}}]_t$를 $x_{\leq t}$와 타겟별 관측 마스크 $m_{t,c} \in \{0,1\}$로부터 추정한다:

$$\mathcal{L} = \frac{\sum_{t,c} m_{t,c}\,(\hat{y}_{t,c} - y_{t,c})^2}{\sum_{t,c} m_{t,c}} + \lambda\,\overline{\mathrm{ReLU}(z_0 - \hat{y}_{t,T_i})}, \qquad \lambda = 0.1. \quad (1)$$

첫 항의 최소화 해는 $\mathbb{E}[y_t \mid x_{\leq t}]$이고, 둘째 항은 정규화 영점 z_0 아래의 T_i 예측을 억제한다. 한 타겟만 관측된 행도 그 타겟을 감독한다(두 타겟을 모두 요구하는 필터는 라벨 행의 ≈28%를 버린다). 타겟 자체가 잡음 σ_{meas}를 지닌 광자 적분 피팅이므로, 완벽한 물리 추정도 $\mathrm{RMSE}^2 = \sigma_{\mathrm{meas}}^2 + b^2$를 기록한다. 차분 estimator로 잰 컷 모집단 T_i의 σ_{meas}는 46.4–129.9 eV로 백본의 157.8 eV와 같은 자릿수이고, 4차 차분 제곱질량의 46.6%(V_{rot}은 65.6%)가 상위 1%의 한 스텝 변화에 있다. 즉 식 (1)는 *꼬리 통계*다(§6.5).

4.2. 두 보존식과 입력 라우팅

이온 에너지와 토로이달 각운동량은 다음을 따른다.

$$\partial_t\left(\tfrac{3}{2} n_i T_i\right) + \nabla\cdot\mathbf{q}_i = Q_{ei}\,(T_e - T_i) + S_i, \quad (2)$$

$$\partial_t\left(n_i m_i \langle R^2\rangle \omega_\varphi\right) + \nabla\cdot\Pi_\varphi = T_{\mathrm{NBI}} + T_{\mathrm{NTV}} + T_{\mathrm{int}} + \cdots \quad (3)$$

두 식 모두 변화율을 구속한다. 식 (3)의 항 가운데 NBI 토크와 NTV 토크는 여기에 채널이 없고(Mirnov dB/dt는 정적인 δB를 볼 수 없다), BES 세기는 운동량 유속 $\langle v_r v_\varphi\rangle$가

아니며, 잔여응력은 ∇T_i를 필요로 한다. 실측으로 고속 채널과 $dV_{\rm rot}/dt$의 상관은 $r = -0.006$(BES), -0.003(ECEI)이고, dT_i/dt와는 +0.070, +0.078이다(값 수준: T_i +0.341, +0.311, $V_{\rm rot}$ +0.027, +0.005). 타겟 잡음을 보정하면 고속 채널 증분과 $V_{\rm rot}$ 증분의 상관은 모든 시차(0–200 ms)와 윈도(10–200 ms)에서 95% 상한 $|r| \le 0.044$를 가지며, T_i는 50 ms 이하 윈도에서 하한 +0.127을 가진다. 이는 선형 연관의 상한이지 부재의 증명이 아니다(BES의 100–200 ms에서 $r \approx +0.01$이고 그 구간은 0을 제외한다). 공유 인코더로 고속 채널이 $V_{\rm rot}$에 닿게 한 모델은 네 분할 모두에서 $V_{\rm rot}$ skill을 잃는다(짝지은 -0.044, -0.072, -0.067, -0.023). 그래서 분기를 인코더에서 나눈다. T_i에서 고속 채널 응답은 CES 채널에서 1.5 cm 안에 있는 채널들의 동시각 공동움직임이다(§4.5). 그 기전은 여기서 규명하지 않는다. 방전별 표준화가 충돌 교환에 필요한 T_e와 n_e의 절댓값을 지우고, 파일에는 빔 파워나 D-alpha 신호가 없기 때문이다.

4.3. 시간 척도

격자 간격 $\Delta t = 10$ ms에서 $f_{\rm Nyq} = 1/(2\Delta t) = 50$ Hz다. 모드 회전은 kHz 대역에 있으므로(이 데이터셋의 가장자리 조화 진동은 약 4와 8 kHz), 반앨리어싱 없이 100 Hz로 데시메이트한 dB/dt는 그것을 담을 수 없다. Mirnov의 lag-1 자기상관 -0.009(BES +0.568)가 이를 확인한다. 자기상관 $1/e$ 시간은 T_i(159 ms), BES(161), ECEI(147)에서 일치하지만, $V_{\rm rot}$은 유지값을 빼면 16 ms, 넣으면 300 ms를 넘는다. $V_{\rm rot}$의 완화 시간은 이 데이터셋에서 측정할 수 없다.

4.4. 전체격자 시퀀스 백본

고속 진단에는 결측이 없으므로, `seq_v2`는 연속 세그먼트의 입력이 완전한 모든 행을 라벨 유무와 무관하게 맥락으로 유지한다(그림 2). 각 스텝은 22개 채널을 담는다. CES에서 나온 입력은 모두 t 이전 행만 쓰고, 고속 채널 15개는 그 방전 자신의 평균과 분산으로 표준화하는데, 이는 오프라인 단계다. CES에서 나온 채널은 $\log(1+\Delta t_{\rm prev})$, 그리고 타겟별로 t 이전 행에서 이월된 마지막 관측값, $\log(1+$경과시간$)$, 과거 관측 존재 플래그다. T_i 분기는 전부를 읽고, $V_{\rm rot}$ 분기는 고속이 아닌 7개 채널만 읽는다. 이것이 §4.2의 구현이다. 분기가 인코더에서 나뉘므로 고속 정보를 $V_{\rm rot}$ 헤드로 나르는 공유 순환 상태는 없다. 출력은 행별 정규화 $[T_i, V_{\rm rot}]$이며, 모든 라벨 행에 대해 식 (1)로 학습한다(AdamW, $\eta = 10^{-3}$, weight decay 10^{-4}, 배치 16 세그먼트, clipping 1.0, 최대 30 epoch의 조기 종료). 분할은 파일 단위이고 다른 모든 채널의 정규화는 학습 파일 전용이며, 타겟 행은 입력에 들어가지 않는다. 이 프로토콜에서 인과(학습 통계) 표준화의 비용은 측정하지 않았다. 피팅 실패 컷이 없던 이전 프로토콜에서 그 변형은 PCHIP 대비 T_i skill +0.22 ~ +0.30을 유지했고 4/4 분할에서 구간이 0을 제외했다. 백본 자신의 문맥을 자르면 20 ms에서 -0.066을 잃고 50 ms에서 포화한다. 과거는 이월된 CES 값과 약 50 ms의 고속 채널 문맥을 통해 T_i 출력에 닿는다.

윈도 대조군과 관문. 대조군(201,258 파라미터)은 방전별 표준화 없이 돌며, 각 모달리티를 직전 W=2 행 위의 전용 시간 인지 1-D CNN으로 인코딩하고, CES 이력을 양방향 GRU로 읽은 뒤 타겟마다 하나씩의 멀티헤드 어텐션 readout으로 풀링한다. 어텐션은 하드 마스킹되어 그 타겟이 실제로 측정된 행에만 질량을 둔다. 그 $V_{\rm rot}$ 헤드도 이력과 시간만 융합한다. 전체격자 프레이밍은 분할 × 초기화 시드의 4×4 격자에 대한 사전등록 4조건 관문으로 채택되었다. 짝지은 T_i skill은 16/16 실행에서 양수이고, 합산하면 +0.081 $[+0.067, +0.096]$이다. 대조군의 인과 GP 대비 skill은 +0.041이다(컷, 3/4 분할에서 구간이 0 포함).

크기와 비용. persistence에서 출발해 유계 tanh 잠재를 더하는 해석 가능한 칸(21,498 파라미터)의 백본 대비 짝지은 T_i skill은 컷에서 +0.002(모든 구간이 0 포함)이지만 포함 모집단에서 -0.194이므로, LSTM이 백본으로 남는다. 상태 유지 스텝 하나의 비용은 CPU에서 중앙값 0.97 ms, p99 1.49 ms이며, 배치에는 인과 표준화가 필요하다.

4.5. T_i 분기의 20-parameter 대리 식

동결된 `seq_v2` 체크포인트 30벌에 대한 사전등록 판독에서 가중치 크기는 안정된 정보를 주지 않았다(첫 층 열 노름은 고속 채널 15개에서 평평하고, 채널별 순위는 분할 간에 재현되지 않는다). 반면 입출력 응답은 정보를 준다. T_i 출력은 과거 관측 T_i의 지수가중 평균에 고속 채널에 대한 동시각 응답을 더한 것이고, forget 게이트의 기억은 격자 1.3 스텝이다. 판독은 등록된 네 단계로 진행했다. *(1) 동결 행:* 맞춤 파라미터가 없는 이동 평균 하나가 persistence 대비 백본 skill의 73–82%(컷)를 내고, 10 ms 증분 15개에 대한 ridge 선형 항을 더하면 77–85%가 된다(4/4 분할이 문턱 0.75 이상). *(2) 학습된 증분 형태:* 같은 식을 처음부터 학습하면 PCHIP 대비 skill의 50–66%만 유지해 문턱 0.70에 못 미치고, 교차항은 0.001 미만을 더한다. *(3) 야코비안:* 동결된 TEST 행 전부에서 백본의 고속 채널 응답은 ≈100 ms 고역 통과(현재값에서 직전 10스텝 평균을 뺀 것)이고, 이득은 2σ까지 평탄하다가 3σ 너머에서 꺼지며 직전 증분에 의존하지 않는다. 3단계는 4단계를 채점하는 같은 네 분할의 TEST 행에서 백본의 야코비안을 읽었으므로, 그 유지는 사후적이다. *(4) 교정된 형태*를 동일한 프로토콜로 처음부터 학습한다:

$$\hat{y}_t = m_t + \sum_{c=1}^{15} a_c \, d_{c,t} \, \sigma\!\left(\frac{\theta - |d_{c,t}|}{0.5}\right) + b_0, \tag{4}$$

$$d_{c,t} = x_{c,t} - \bar{x}_{c,\,t-10..t-1},$$

$$m_t = m_{t-1} + K(s)\,(y^{\rm obs} - m_{t-1}),$$

$$K(s) = K_\infty + (K_0 - K_\infty)\, e^{-s/s_K}. \tag{5}$$

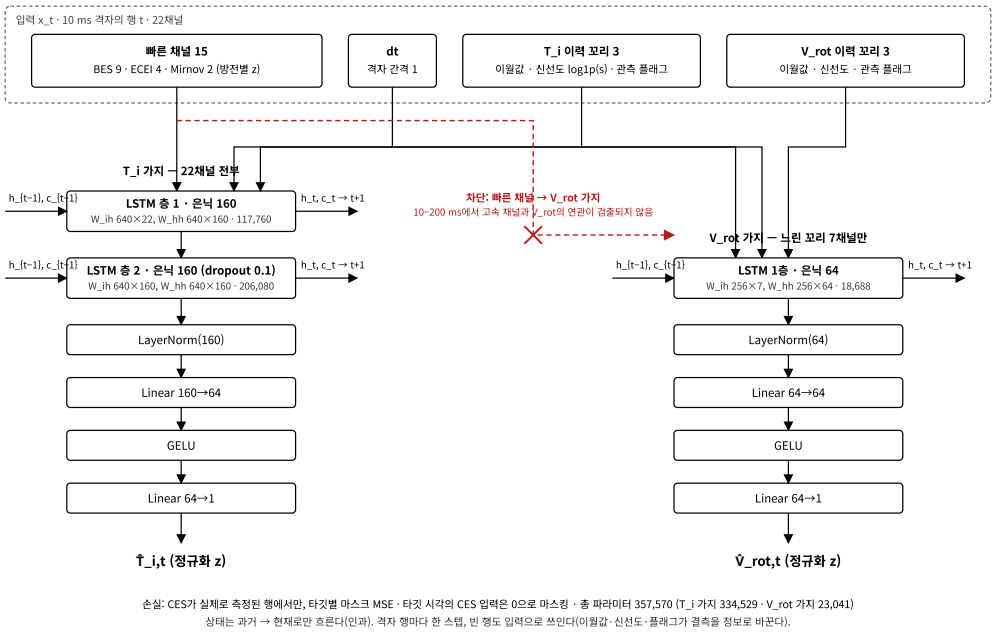


그림 2: 격자 행 t 하나에 대한 seq_v2. 입력 22채널(고속 15, 방전별 z(방전 전체 통계); Δt; 타겟별 이월값, 경과시간, 관측 플래그)이 시간 순방향으로 도는 두 LSTM으로 들어간다. T_i 분기는 22채널 전부를 읽고(2층, 160 유닛), $V_{\rm rot}$ 분기는 느린 7채널만 읽으며(1층, 64 유닛), 각각 LayerNorm과 Linear–GELU–Linear로 끝난다. 고속 채널에서 $V_{\rm rot}$으로 가는 붉은 점선 경로는 구조상 존재하지 않는다. 총 357,570 파라미터.

여기서 m_t는 T_i 측정이 새로 들어올 때만 갱신되고, s는 직전 측정 이후의 공백이며, $\sigma(\cdot)$는 로지스틱 함수이고, $d_{c,t}$와 θ는 방전별 표준편차 단위다(오프라인 정규화). 세 그먼트의 첫 관측은 그대로 받는다($K = 1$). 20개 파라미터는 이득 상수 셋, 고속 채널마다의 이득 a_c, 문턱 θ, 오프셋 b_0이다. 컷 네 분할에서 학습된 값은 새 측정 직후 $K_0 = 0.27$–0.30, 긴 공백 뒤 $K_\infty = 0.48$–0.53, 전이 $s_K = 39$–$47\,\text{ms}$, $\theta = 2.9$–3.0σ, $\sum a_{\rm BES} = +48 \sim +53$, $\sum a_{\rm ECEI} = +44 \sim +50\,\text{eV}/\sigma$다. 필터로 읽으면, 기다린 시간이 길수록 새 CES 표본을 더 믿는 칼만형 관측 갱신에, 각 고속 채널의 100 ms 기준선 대비 편차에 대한 선형 응답을 3σ 너머의 이상치에서 차단한 항을 더한 것이다. 이 식의 백본 skill 유지는 §6.4에 있다. 독립 estimator로서 그 skill(컷)은 PCHIP 대비 +0.13 ~ +0.21(4/4 분할), 인과 GP 대비 +0.02 ~ +0.07(2/4에서 구간이 0 제외)이고, 4/4에서 오프라인 GP보다 낮다. 이는 모델에 대한 측정이며, 헤드라인 수치는 여전히 백본의 것이다.

5. 평가 방법론

지표와 기준선. 오차는 물리 단위로 타겟별로 계산하며, 1차 점수는 $\text{skill}_{\rm PCHIP} = 1 - \text{MSE}_{\rm model}/\text{MSE}_{\rm PCHIP}$(0 = 오차가 같음)다. 모든 팔은 동일한 (파일, 행) 집합에서 채점된다. persistence, 이동 평균, 두 점 외삽은 과거만 읽고, 선형·PCHIP·오프라인 GP(Matérn-3/2 + 백색잡음, 최근접 16+16 이웃, 표본별 주변우도 선택)는 미래를 읽는다. 인과 GP는 같은 GP를 과거 이웃 16개로 제한한 것이다. 미래 이웃이 없는 곳에서는 보간이 persistence 값을 예측한다(채점된 T_i 행의 0.2%, 채점된 $V_{\rm rot}$ 행의 0.3–0.5%).

분할과 사전등록. 파일은 네 시드(42, 1, 7, 123)로 train/val/test에 분할된다. test 파일은 아키텍처 탐색보다 먼저 예약되었지만, 시퀀스 백본, 방전별 표준화, 대리 식 형태의 채택에는 같은 네 test 분할의 결과를 썼다. 반복 교차검증은 같은 639개 방전을 재분할한다. 표준 test 셋은 96개 shot의 T_i 32,589행과 60개 shot의 $V_{\rm rot}$ 10,463행이다(컷). "사전등록"은 한 배치의 가설, 판정 규칙, 수치 예측을 실행 전에 저장소에 커밋했다는 뜻이며, 제3자 등록소는 없다.

구간. 표본별 짝지은 제곱오차 차이를 shot 단위로 집계하고 shot 전체를 재표본한다 (10,000회). 결과는 95% 구간이 0을 제외하는지와 함께 보고한다. 분할이 넷뿐이므로 네 값의 평균 ± 표준편차 대신 분할별 값과 그 구간, 범위, 구간이 0을 제외한 분할 수를 적는다 [26, 27]. 네 분할은 학습 방전 대부분을 공유하므로, 백본을 639개 방전의 shot 단위 반복 5겹 교차검증으로 다시 돌렸다(반복 10회, 100회 실행, 반복마다 모든 방전을 한 번씩 시험). *겹 단위*: Nadeau–Bengio 구간 $\bar{S} \pm t_{0.975,n-1}\sqrt{(1/n + n_{\rm test}/n_{\rm train})\,s^2}$ [21]. *합산*: 한 반복의 test 다섯 겹을 이어 붙여 하나의 skill로 채점하고, 반복 하나를 먼저 뽑은 뒤 그 반복의 방전을 다시

표 1: RMSE. 시드 42 test 분할, 컷 모집단, 진짜 측정만 (n = 32,589 T_i, 10,463 $V_{\rm rot}$). 아래쪽 행은 미래를 읽는다. 포함 모집단: `seq_v2` 363.0 / 23.7, PCHIP 412.4 / 30.2, 인과 GP 394.6 / 28.8, persistence 478.0 / 33.4.

팔	정보	T_i (eV)	$V_{\rm rot}$ (km/s)
`seq_v2`	고속 + 과거 CES, 세그먼트	**157.8**	**23.6**
20-param. 대리 식	고속 + 과거 CES	162.3	–
윈도 대조군	고속 + 과거 CES 2행	169.2	26.1
인과 GP	과거 CES 16개	164.3	28.8
이동 평균	과거 CES	169.2	–
Persistence	마지막 관측 CES	197.2	33.4
두 점 외삽	과거 CES 2개	472.2	51.0
GP (오프라인)	과거 + 미래 CES	153.8	24.7
선형 보간	과거 + 미래 CES	169.8	29.0
PCHIP	과거 + 미래 CES	173.6	30.2

뽑는 두 단계 bootstrap을 쓴다. 반복 교차검증은 겹 단위 구간을 판정 판독으로 등록했으며, $V_{\rm rot}$의 PCHIP 대비 구간은 0을 포함했다. 그 뒤 합산 판독을 사후에 계산했고, 새 반복 8회를 실행하기 전에 합산 두 단계 판독을 판정 기준으로 하여 등록했다. 이 구간은 학습된 모델을 조건으로 하며 겹치는 학습 집합 사이의 상관을 담지 않는다. 겹 단위 구간은 그것을 담는다.

6. 결과

6.1. RMSE 사다리

표 1는 표준 test 분할의 물리 단위 RMSE다. 미래를 읽지 않는 방법 가운데 `seq_v2`의 RMSE가 가장 낮아 인과 GP보다 4%(T_i)와 18%($V_{\rm rot}$) 낮고, 선형·PCHIP 보간보다도 낮다. 잡음 낀 앵커를 평균하는 오프라인 GP가 T_i RMSE가 더 낮은 유일한 팔이다(153.8 대 157.8). 이 데이터에서 더 강한 오프라인 보간은 선형 보간이다. 분할별 T_i의 선형 보간 대비 skill은 +0.136 ~ +0.226(컷), +0.209 ~ +0.288(포함)로 두 모집단 모두 4/4 분할에서 구간이 0을 제외하며, PCHIP 대비 skill보다 0.01–0.05 낮다. $V_{\rm rot}$에서는 각 모집단 1/4 분할에서 구간이 0을 제외한다.

6.2. 헤드라인과 재현

T_i. 표 2에서 $\text{skill}_{\rm PCHIP}$는 +0.17 ~ +0.26(컷), +0.23 ~ +0.32(포함)이고, 네 분할 모두에서 shot 군집 구간이 0을 제외한다. 인과 GP 대비 +0.08 ~ +0.17, persistence 대비 +0.36 ~ +0.46이며, 둘 다 모집단–분할 8/8 셀에서 구간이 0을 제외한다. 오프라인 GP 대비 짝지은 skill은 −0.05 ~ +0.11로 8셀 중 7셀에서 구간이 0을 포함한다. 여유는 보간과 인과 평활기에 대한 것이지 모든 오프라인 평활기에 대한 것이 아니다. 재현은 모든 판정을 되풀이한다. PCHIP 대비 겹 단위 구간은 [+0.19, +0.25](컷), [+0.19, +0.31](포함)이다. skill은 인접 이력에 국한되지 않는다. 마지막 관측 이후 $\Delta t > 15$ ms에서 PCHIP 대비 skill은 +0.268(컷), +0.206(포함)이고 두 구간 모두 0을 제외한다.

$V_{\rm rot}$. 점추정은 모든 분할에서 양수이지만, PCHIP 대비 네 분할 구간이 0을 제외하는 것은 1/4(컷), 2/4(포함) 분할뿐이고 겹 단위 구간은 0을 포함한다([−0.02, +0.41], 컷). 같은 639개 방전의 재분할 8벌에 대한 합산 판독은 PCHIP, persistence, 인과 GP 대비 모두 0을 제외하지만(표 2), 그 PCHIP 대비 여유는 피팅 실패에 기댄다. 타겟, persistence 앵커, PCHIP 앵커 가운데 하나라도 $|V_{\rm rot}|$ = 1,000 km/s를 넘는 행을 모든 팔에서 빼는 규칙은 반복마다 약 71,700행 중 36–41행(0.05%)을 빼는데, 이 행들이 PCHIP 제곱오차의 63–78%를 담는다(컷). 이 규칙에서 PCHIP 대비 합산 skill은 +0.092 [+0.0003, +0.170](컷), +0.090 [−0.010, +0.177](포함)이고, 임계값 500과 2,000 km/s에서는 두 모집단 모두 0을 포함한다. persistence 대비로는 +0.265 [+0.198, +0.326](컷), +0.257 [+0.183, +0.323](포함), 인과 GP 대비로는 +0.151 [+0.038, +0.290], +0.132 [+0.026, +0.267]로 세 임계값 모두에서 0을 제외한다. 오프라인 GP 대비로는 이력만 쓰는 추정이 뒤진다. −0.073 [−0.162, +0.005](컷), −0.087 [−0.174, −0.008](포함)이다. 따라서 $V_{\rm rot}$ 주장은 인과 estimator에 대해서만 성립한다.

포함 모집단의 수치가 더 높은 이유. 컷이 없으면 모든 팔의 PCHIP 대비 점수가 오른다(백본 평균 +0.268 대 +0.236). 스파이크가 보간 앵커를 오염시키고 학습 모델은 그것을 할인할 수 있기 때문이다. 그래서 어느 모집단도 단독으로 인용하지 않는다.

두 스트레스 테스트. *MNAR:* 채점 행을 진짜 결측이면서 도메인 안에 있는 행(결측 T_i 행의 53.6–67.0%(컷), 54.1–67.7%(포함))의 공변량 분포($\Delta t \times$ 국소 활동도)로 재가중하면, T_i의 PCHIP 대비 skill은 +0.14 ~ +0.28로 컷 2/4·포함 4/4 분할에서 구간이 0을 제외하고, persistence 대비로는 +0.28 ~ +0.44로 8/8 셀에서 구간이 0을 제외한다(결측 $V_{\rm rot}$ 행은 4–6%만 도메인 안에 있어 아무것도 끌어내지 않는다). *캠페인 이동:* 엄격한 시간 분할(학습 416 shot, 검증 128, 시험은 가장 늦은 97)에서 `seq_v2`는 PCHIP 대비 +0.17 ~ +0.20, 인과 GP 대비 +0.11 ~ +0.16을 유지하며 두 모집단 4/4 초기화에서 구간이 0을 제외하고, 윈도 대조군은 −0.001 ~ +0.091(컷 2/4, 포함 0/4)이다. $V_{\rm rot}$의 skill은 PCHIP 대비 +0.19 ~ +0.23(4/4에서 구간이 0 포함), persistence 대비 +0.33(4/4, 컷)이다. 고속 진단은 두 기간 사이에 1.22σ(BES), 0.53σ(ECEI) 이동하고 타겟은 0.115σ 이동한다. 방전별 표준화는 윈도 대조군이 이 분할에서 실패한 뒤에 채택되었고 방전 전체 통계를 쓰므로, 이는 배치 가능한 estimator의 독립 검정이 아니다.

6.3. $T_i \leftrightarrow V_{\rm rot}$ 비대칭

윈도 대조군에서 평가 시점에 입력 그룹 하나를 0으로 만들면(표 3) 이력이 필수임이 드러난다. 컷 모집단의 T_i에서 고속 채널을 제거하면 그 모델의 skill이 보간 아래로 떨어진다

표 2: 비교 대상별 seq_v2의 skill. *네 분할*: 시드 42/1/7/123에 걸친 분할별 skill의 범위와, shot 군집 95% CI가 0을 제외하는 분할 수. *겹 단위*: 반복 5겹 CV의 50겹에 대한 Nadeau–Bengio 95% 구간과, 자체 CI가 0을 제외하는 겹 수. 처음 등록할 때의 판정 판독이다. *합산*: 같은 639개 방전의 재분할 8벌에 대한 중앙값과 두 단계 bootstrap 95% 구간으로, 그 반복들을 실행하기 전에 판정 기준으로 등록했다. 굵은 글씨 = 구간이 0을 제외. 네 분할의 오프라인 GP 칸은 두 모집단을 합친 것이다. V_{rot} 행은 §6.2의 피팅 실패 규칙을 적용하지 않은 등록 판독이다.

		네 분할		겹 단위 (반복 5겹)		합산 (두 단계)	
타겟	대비	컷	포함	컷	포함	컷	포함
T_i	PCHIP	+0.174 ~ +0.264 (**4/4**)	+0.225 ~ +0.316 (**4/4**)	[**+0.186**, **+0.253**] (50/50)	[**+0.188**, **+0.307**] (46/50)	+0.221 [**+0.188**, **+0.248**]	+0.248 [**+0.192**, **+0.294**]
	persistence	+0.360 ~ +0.415 (**4/4**)	+0.406 ~ +0.459 (**4/4**)	[**+0.368**, **+0.410**] (50/50)	[**+0.361**, **+0.445**] (50/50)	+0.391 [**+0.369**, **+0.408**]	+0.404 [**+0.364**, **+0.438**]
	인과 GP	+0.078 ~ +0.138 (**4/4**)	+0.123 ~ +0.169 (**4/4**)	[**+0.084**, **+0.138**] (47/50)	[**+0.067**, **+0.170**] (40/50)	+0.113 [**+0.085**, **+0.132**]	+0.118 [**+0.076**, **+0.157**]
	오프라인 GP	−0.05 ~ +0.11 (8셀 중 7셀에서 CI가 0 포함)		[−0.044, +0.020] (1/50)	[−0.026, +0.094] (12/50)	−0.010 [−0.043, +0.014]	+0.035 [−0.017, +0.075]
V_{rot}	PCHIP	+0.135 ~ +0.390 (1/4)	+0.132 ~ +0.384 (2/4)	[−0.021, +0.405] (15/50)	[−0.053, +0.391] (11/50)	+0.313 [**+0.072**, **+0.701**]	+0.319 [**+0.046**, **+0.683**]
	persistence	+0.30 ~ +0.50 (각각 3/4)		[**+0.190**, **+0.601**] (42/50)	[**+0.159**, **+0.587**] (38/50)	+0.451 [**+0.277**, **+0.763**]	+0.451 [**+0.139**, **+0.747**]
	인과 GP	+0.020 ~ +0.331 (2/4)	+0.018 ~ +0.324 (2/4)	[−0.060, +0.512] (11/50)	[−0.096, +0.502] (10/50)	+0.361 [**+0.045**, **+0.701**]	+0.357 [**+0.023**, **+0.683**]
	오프라인 GP	−0.07 ~ +0.09 (8셀 중 7셀에서 CI가 0 포함)		[−0.234, +0.312] (0/50)	[−0.268, +0.300] (0/50)	+0.262 [−0.119, +0.635]	+0.251 [−0.139, +0.609]

표 3: 윈도 대조군의 평가 시점 입력 민감도(재학습 없음): T_i의 $\mathrm{skill}_{\mathrm{PCHIP}}$(4분할 평균)와 전체 모델 대비 짝지은 변화(* = 유의한 분할).

입력	컷	포함
전체	+0.173	+0.238
고속 제거	−0.125; −0.25 ~ −0.42 (4/4*)	+0.201; −0.03 ~ −0.09 (2/4*)
이력 제거	−2.11	−1.16

(짝지은 −0.25 ~ −0.42, 4/4 유의). 이 검정은 백본과 다른 모델에 대한 것이며, 이력만 쓰도록 다시 학습한 백본은 돌리지 않았다. 백본의 PCHIP 대비 여유 가운데 절반가량은 과거 CES로 얻을 수 있는 잡음 제거다(이동 평균 +0.05 ~ +0.17). 나머지는 사건 행에 몰린다 (상위 10% $|d\mathrm{ECEI}|$ 행, 시드 42/1: 백본의 PCHIP 대비 +0.116/+0.269, 이동 평균에 선형 고속 채널 항을 더한 것은 −0.011/+0.088). 이동 평균 대비 백본 skill은 +0.113 ~ +0.137(컷)로 4/4 분할에서 구간이 0을 제외하고, +0.061 ~ +0.140(포함, 4/4)이다. 포함 모집단에서는 고속 채널 없는 윈도 대조군도 PCHIP 대비 +0.15 ~ +0.23을 유지하는데, 이는 스파이크 강건성 성분이다. V_{rot}에서 대조군의 출력은 고속 채널 없이도 비트 단위로 동일하며, 이는 라우팅의 귀결이다. 라우팅의 근거는 §4.2와 아래의 두 검정이다.

회전 정보로 가는 두 경로의 검정. *Mirnov:* 원시 2 MHz 스트림과 대조한 코일 24개 전부(방전 12개)에서 100 Hz 값은 격자 시각의 원시 표본 하나와 같다(시차 0). 평균도 필터도 거치지 않은 점 스냅숏이므로 kHz 모드 회전은 앨리어싱으로 사라진다. 원시 스트림의 인과 10 ms 특징을 V_{rot} 분기에 넣은 탐색적 검정(학습 방전 6개, 시험 방전 3개. 이 크기에서 15-특징 팔은 과적합이 예상된다)은 이득을 찾지 못했다. 코일 물리 자체는 온전하다(#32092의 가장자리 조화 진동이 4.39와 8.91 kHz에 나타난다). 방전 안에서 주 모드 주파수와 V_{rot}의 상관은 일곱 방전 중 여섯에서 $|\rho| \le 0.11$이다. *빔 토크:* 토크 채널이 없으므로 빔 토크는 여기서 검정하지 않았다. 이 진술은 $R = 2.198$ m 채널의 표준 CES 10 ms에 한정한다. ELM 주기 안의 가장자리 회전 [28]은 다른 측정이다.

6.4. 대리 식의 skill 유지

동일한 프로토콜로 처음부터 학습한 20-parameter 대리 필터 (4)–(5)은 컷 4/4 분할에서 백본의 PCHIP 대비 skill의 **72–78%**, persistence 대비 skill의 87–90%를 유지해 등록 문턱 0.70 위에 있고, 2단계의 증분 형태 식보다 짝지은 +0.034 ~ +0.042 위에 있다(4/4 분할에서 구간이 0 위). 3단계가 같은 TEST 행을 읽었으므로 이 유지는 사후적이다. 남은 22–28%는 신경망의 비선형 사건 처리로, 고속 채널 이력의 어떤 저차 함수로도 재현되지 않는다. 이 띠는 컷 모집단에서만 읽는다. 포함 모집단에서 대리 식은 PCHIP 대비 skill의 0.43–0.81을 유지하고, 그 BES 이득은 피팅 실패 스파이크 아래에서 부호를 바꾼다.

6.5. 평균과 중앙값: 이중 판독

MSE skill은 소수의 행이 정한다. 백본의 T_i 제곱오차 상위 1% 행이 전체의 48%(컷), 83%(포함)를 담는다. 전형적인 행에서 백본은 앵커를 그대로 옮긴다. 중앙값 T_i 절대오차 47.2 eV는 persistence의 46.1 eV, 타겟 자신의 10 ms 산포 46.4 eV와 같고, PCHIP은 미래 이웃과 평균해 39.4 eV에 이른다(중앙값 AE skill −0.198 [−0.259, −0.135], 승률 0.48). 모델/PCHIP 오차 비는 오차 상위 사분위에서만 1 아래로 내려간다. V_{rot}에서 백본의 중앙값 행은 persistence보다 나쁘다(4.3 대 3.7 km/s; PCHIP 대비 중앙값 AE skill 컷 −0.488, 포함 −0.518, 4/4 분할에서 구간이 0 아래). 그 집계 skill은 꼬리의 이득이 본류의 손실을 상쇄한 결과다. 그래서 중앙값은 별도의 사전등록 estimator에서 읽는다. 타겟별 스칼라 유지-또는-점프 필터로, CES 이력 위에서 인과적으로 돌며, 사전은 수준을 유지하되 점프를 허용하고 측정 잡음은 10 ms 본류 산포를 척도로 하는 Student-$t(\nu_0 = 3)$다. 그 중앙값 절대오차는 T_i에서 persistence의 0.911–0.920×(컷), 0.906–0.915×(포함)이고, persistence 대비 중앙값 skill은 +0.08 ~ +0.09로 두 모집단 4/4 분할에서 구간이 0을 제외한다(분할–모집단 8/8 셀). V_{rot}에서 필터의 비는 0.94–1.00×로 3/4 분할에서 구간이 1

을 포함하며, 필터를 TRAIN에서 맞춰도 그렇다. 반면 백본 대비 중앙값 skill은 +0.09 ~ +0.23(컷), +0.09 ~ +0.26(포함)으로 두 모집단 4/4다. 10 ms 산포는 서로 독립인 가우스 선 맞춤 오차와 맞는다. T_i 상대 산포와 V_{rot} 산포의 비는 8/8 셀에서 $\sqrt{2}$(1.395–1.532)이고, 광자 통계라면 기대되는 $\sqrt{T_i}$ 척도는 관측되지 않았다 (기울기 0.09–0.23, 기대값 0.5). 라벨 사이에서 중앙값 최적점은 마지막 값이다. 필터의 백본 대비 MSE skill은 −0.06 ~ −0.52인데, 사건 행에서 늦기 때문이다. 중앙값은 필터에서, 평균은 나우캐스터에서 읽는다. 백본에 Student-t 예측 head를 달면 보정된 불확도를 준다(컷: 50% / 90% 포함률 0.48–0.51 / 0.91–0.92. 포함 모집단에서는 두 성분 혼합 head만 guard를 통과하며, 포함률은 0.53–0.55 / 0.90–0.91).

7. 한계와 결론

한계. 집계 skill은 꼬리 통계이며, 중앙값은 그 옆의 유지-또는-점프 필터에서 읽는다. 고속 채널은 방전 전체 통계로 표준화하는데 이는 오프라인 단계이므로, 배치 가능한 변형은 이 프로토콜에서 검정되지 않았다. 대리 식의 유지는 컷 모집단에서만 성립하고(포함 0.43–0.81), 그 형태는 채점 분할에서 골랐다. 반복 단위는 shot이며, 재가중은 결측 V_{rot} 행의 4–6%에만 닿는다. 모든 것이 한 채널, 한 장치, 한 캠페인이다. NN-CES [11]가 줄 수 있는 노출별 피팅 메타데이터가 값 기준 컷을 대체할 것이다.

결론. 다음 CES 노출을 기다릴 수 없는 추정에서, 같은 위치의 BES와 ECEI는 과거 T_i에 동시각 과도 항을 더한다. 이는 인과 GP 대비로 측정했고 20-parameter 대리 필터로 요약된다. 오프라인에서는 양쪽 이웃을 읽는 잡음 인지 평활기가 같은 평균 오차에 이른다. 이 채널의 V_{rot}은 자기 이력에서 추정되며 persistence와 인과 GP보다 앞서고, 그 10 ms 산포는 피팅 잡음 바닥에 있다. 코드와 평가 산출물: https://github.com/iseungsang01/ml-intern-revision.

감사의 글과 데이터 사용. [저자가 채울 것: KSTAR 2022 CES, BES, ECEI, Mirnov 데이터의 제공처와 KFE 사용 허가.]

참고문헌

[1] W.H. Ko, Hyungho Lee, D. C. Seo, and Myeun Kwon. Charge exchange spectroscopy system calibration for ion temperature measurement in KSTAR. *Review of Scientific Instruments*, 81:10D740, 2010. doi: 10.1063/1.3496991.

[2] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley Series in Probability and Statistics. Wiley, 2nd edition, 2002. doi: 10.1002/9781119013563.

[3] F. N. Fritsch and R. E. Carlson. Monotone piecewise cubic interpolation. *SIAM Journal on Numerical Analysis*, 17(2): 238–246, 1980. doi: 10.1137/0717021.

[4] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. ISBN 0-262-18253-X.

[5] M. A. Chilenski, M. Greenwald, Y. Marzouk, N. T. Howard, A. E. White, J. E. Rice, and J. R. Walk. Improved profile fitting and quantification of uncertainty in experimental measurements of impurity transport coefficients using Gaussian process regression. *Nuclear Fusion*, 55(2):023012, 2015. doi: 10.1088/0029-5515/55/2/023012.

[6] C. Michoski, T. A. Oliver, D. R. Hatch, A. Diallo, M. Kotschenreuther, D. Eldon, M. Waller, R. Groebner, and A. O. Nelson. A Gaussian process guide for signal regression in magnetic fusion. *Nuclear Fusion*, 64(3):035001, 2024. doi: 10.1088/1741-4326/ad1af5.

[7] Minseok Kim, W.H. Ko, Sehyun Kwak, Semin Joung, Wonjun Lee, B. Kim, D. Kim, J.H. Lee, Choongki Sung, Yong-Su Na, and Y.-C. Ghim. Kinetic profile inference with outlier detection using support vector machine regression and Gaussian process regression. *Nuclear Fusion*, 64:106052, 2024. doi: 10.1088/1741-4326/ad7304.

[8] A. H. Murphy. Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12):2417–2424, 1988. doi: 10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2.

[9] Joseph Abbate, Emiliano Fable, Giovanni Tardini, Rainer Fischer, and Egemen Kolemen. Combining physics-based and data-driven models for quantitatively accurate plasma profile prediction. *Nuclear Fusion*, 65:056014, 2025. doi: 10.1088/1741-4326/adc283.

[10] M. J. Owens, R. Challen, J. Methven, E. Henley, and D. R. Jackson. A 27 day persistence model of near-Earth solar wind conditions: A long lead-time forecast and a benchmark for dynamical models. *Space Weather*, 11(5):225–236, 2013. doi: 10.1002/swe.20040.

[11] J.K. Lee, W.H. Ko, H.H. Lee, B. Kim, Y.H. Lee, G.W. Shin, J. Kim, and J.M. Lee. Neural network-based analysis of charge exchange spectra in KSTAR. *Fusion Engineering and Design*, 222:115518, 2026. doi: 10.1016/j.fusengdes.2025.115518.

[12] Zichao Lin, Hongming Zhang, Fudi Wang, Cheonho Bae, Jia Fu, Yongcai Shen, Shuyu Dai, Yifei Jin, Dian Lu, Shengyu Fu, Huajian Ji, and Bo Lyu. Prediction of plasma rotation velocity and ion temperature profiles in EAST Tokamak using artificial neural network models. *Nuclear Fusion*, 64:106061, 2024. doi: 10.1088/1741-4326/ad73e8.

[13] Ricardo Shousha, Jaemin Seo, Keith Erickson, Z. Xing, S.K. Kim, Joseph Abbate, and Egemen Kolemen. Machine learning-based real-time kinetic profile reconstruction in DIII-D. *Nuclear Fusion*, 64:026006, 2024. doi: 10.1088/1741-4326/ad142f.

[14] Azarakhsh Jalalvand, S.K. Kim, Jaemin Seo, Qiming Hu, M. Curie, Peter Steiner, A. Nelson, Yong-Su Na, and Egemen Kolemen. Multimodal super-resolution: discover-

ing hidden physics and its application to fusion plasmas. *Nature Communications*, 16:8506, 2025. doi: 10.1038/s41467-025-63492-1.

[15] M. Imríšek, J. Seidl, Michal Odložilík, M. Šos, P. Bílková, Petr Boehm, Haluk Sait Aksoy, Raul Scapini Weiand, Iván Alcaraz Aguado, Robin Mahieu, and D. Naydenkova. Temporal super-resolution of kinetic plasma profiles at COMPASS using neural networks. *Plasma Physics and Controlled Fusion*, 68:065049, 2026. doi: 10.1088/1361-6587/ae72c6.

[16] F. Pastore, F. Felici, T. O. S. J. Bosman, C. Galperti, O. Sauter, B. Vincent, and N. M. T. Vu. Model-based electron density estimation using multiple diagnostics on TCV. *Fusion Engineering and Design*, 192:113615, 2023. doi: 10.1016/j.fusengdes.2023.113615.

[17] M.R. Wang, Chenguang Wan, Jingjing Lu, Zhi Yu, Bingjia Xiao, Yanlong Li, X.X. He, Zhengping Luo, Qiping Yuan, Yemin Hu, and Jiangang Li. Time series extrinsic regression for reconstructing missing electron temperature in tokamak. *Nuclear Fusion*, 65:076008, 2025. doi: 10.1088/1741-4326/addb5f.

[18] K. Jia, Z. Xu, Z. Wu, W. Gao, M. Wang, A. Ti, et al. Time series regression network using exogenous variables for missing effective ion charge reconstruction in EAST tokamak. *Nuclear Fusion*, 67:016012, 2026. doi: 10.1088/1741-4326/aeb432.

[19] Zongyu Yang, Zhenghao Yang, Wenjing Tian, Jiyuan Li, Xiang Sun, Guohui Zheng, Songfen Liu, Niannian Wu, Rongpeng Li, Zhaohe Xu, Bo Li, Zhongbing Shi, Zhe Gao, Wei Chen, Xiaoquan Ji, Min Xu, and Wulyu Zhong. FusionMAE, a self-supervised pretrained model to optimize and simplify diagnostic and control of fusion plasma. *Communications Physics*, 2026. doi: 10.1038/s42005-026-02626-3.

[20] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8:6085, 2018. doi: 10.1038/s41598-018-24271-9.

[21] Claude Nadeau and Yoshua Bengio. Inference for the generalization error. *Machine Learning*, 52:239–281, 2003. doi: 10.1023/A:1024068626366.

[22] Varun Saravanan, Gordon J. Berman, and Samuel J. Sober. Application of the hierarchical bootstrap to multi-level data in neuroscience. *Neurons, Behavior, Data analysis, and Theory*, 3(5):1–25, 2020. doi: 10.1101/819334. Preprint: bioRxiv 819334.

[23] Niru Maheswaranathan and David Sussillo. How recurrent networks implement contextual processing in sentiment analysis. arXiv:2004.08013, 2020.

[24] Y. U. Nam, S. Zoletnik, M. Lampert, and Á. Kovácsik. Analysis of edge density fluctuation measured by trial KSTAR beam emission spectroscopy system. *Review of Scientific Instruments*, 83:10D531, 2012. doi: 10.1063/1.4739078.

[25] G.S. Yun, W. Lee, M. Choi, Joon Bum Kim, HK Park, C. W. Domier, Benjamin Tobias, T. Liang, Xiangyu Kong, N. C. Luhmann, and A. J. H. Donné. Development of KSTAR ECE imaging system for measurement of temperature fluctuations and edge density fluctuations. *Review of Scientific Instruments*, 81:10D930, 2010. doi: 10.1063/1.3483209.

[26] Tracey L. Weissgerber, Natasa M. Milic, Stacey J. Winham, and Vesna D. Garovic. Beyond bar and line graphs: Time for a new data presentation paradigm. *PLoS Biology*, 13(4): e1002128, 2015. doi: 10.1371/journal.pbio.1002128.

[27] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems*, volume 34, 2021.

[28] E. Viezzer, M. Cavedon, P. Cano-Megias, E. Fable, E. Wolfrum, D. J. Cruz-Zabala, et al. Dynamics of the pedestal transport during edge localized mode cycles at ASDEX Upgrade. *Plasma Physics and Controlled Fusion*, 62:024009, 2020. doi: 10.1088/1361-6587/ab5b1d.